

Predicció de Metàstasi en Càncer Colorectal

a partir de **Whole Slide Images**
usant **Graph Attention Networks**

David Morillo Massagué
TFG Enginyeria de Dades, UAB

Motivació: El Repte Clínic

Sobretractament en CCR pT1

Risc de metàstasi d'entre el 2% i el 23%.

Fins a un 80% de cirurgies innecessàries

Dades massives

Mida de WSI fins a 150.000 píxels de costat



Estat de l'Art

Guies Clínicas Actuals

JSCCR, NCCN i ESMO: alta sensibilitat però una especificitat baixa (19% - 52%).

IA en Histopatologia

Models actuals assoleixen especificitats altes:

- 85,8% fent servir variables clíniques
- 57,5% fent servir Whole Slide Images

Objectius de l'Estudi



Pipeline

Construir un sistema complet: des de característiques de la WSI fins al diagnosi N0/N1.



Comparativa GNN


Avaluar dues arquitectures: un model GAT de referència, davant d'un model GAT+DiffPool per a representacions multiescala.




Diagnòstic Clínic

Implementar tècniques (MIL, readout o cerca de llindar...) per a un diagnosi fiable, a partir de múltiples imatges per pacient

El Pipeline de Predicció



Construcció del Graf



Extracció: Patches de 2048x2048 px.




UNI2: Embeddings CLS [1, 1536]




Delaunay: Connexió i poda d'arestes.

Arquitectures proposades

Graph Attention Network (Baseline)



Graph Attention Network + Differentiable Pooling



Readout del Graf




Operacions Fixes

Mean / max pooling



Mecanisme d'Atenció

Pes après per node



Agregació a Nivell de Pacient (MIL)

 **El Repte:** Un pacient té varies seccions de teixit; no totes presenten senyals de metàstasi visible. L'etiqueta és del pacient.

 **Multiple Instance Learning:** El pacient es tracta com un 'bag' de seccions.

 **Estratègies implementades:**

Mean, Max, Noisy-OR: Agregació de probabilitats.

Attention MIL: Agregació d'embeddings, MLP final únic.

Jimmy's keychain



cannot open

John's keychain



can open

Brenda's keychain



can open

instance

Garantia Diagnòstica Operativa

100%


Objectiu Sensibilitat Clínica

Optimització del Llindar (t^*)

Un fals negatiu (no tractar metàstasi) és inacceptable.

Llindar de predicció per defecte = 0.5.


S'ha establert el criteri **T2**: Trobar el llindar màxim a la corba ROC de validació que manté **TPR=1** (zero falsos negatius), per tal de maximitzar l'especificitat sense risc.



Disseny Experimental i Avaluació

Avaluació estricta dissenyada per evitar biaixos i estimar el rendiment real.

-  **Test Aïllat (15%):** 56 pacients separats inicialment.
-  **Cerca Bayesiana (TPE):** Sobre el Pool (85%). Validació creuada 5-fold per trobar la millor configuració (max. especificitat penalitzant caiguda de sensibilitat).
-  **Retrain i Avaluació:** Reentrenament sobre el 90% del Pool i avaluació final al Test.



Resultats (Validació):

Arquitectura	Readout	MIL	h	H	dropout	AUC CV
Baseline	attention	mean	256	4	0,3	$0,862 \pm 0,038$
DiffPool	mean_max	mean	128	2	0,44	$0,847 \pm 0,048$

Configuracions Guanyadores

La cerca Optuna demostra la superioritat del model **GAT**

Baseline respecte a GAT+DiffPool.


El model Baseline seleccionat utilitza: 3 capes GAT, **Readout per**

Atenció, MIL Mean, dimensió oculta 256 i 4 caps d'atenció.

AUC Validació (Baseline): 0.862 ± 0.038

Resultats al Conjunt de Test i SOTA

Sistema	Tipus d'entrada	Sensibilitat	Especificitat	AUC	Bal.Acc.
<i>Guies i puntuació clínica</i>					
JSCCR [3]	Guia clínica	100%	19%	0,596	59,5%
NCCN	Guia clínica	98%	52%	0,749	75,0%
ESMO [9]	Guia clínica	98%	50%	0,743	74,0%
IBC Score [4]	Puntuació histopat.	90%	26%	0,68	58,0%
<i>Models d'IA</i>					
LightGBM [10]	Var. clinicopatol.	100%	85,8%	0,960	92,9%
Song et al. [27]	Imatge WSI	92,9%	57,6%	0,781	75,3%
<i>GAT Baseline (AUC = 0,875)</i>					
T1 ($t=0,5$)	Imatge WSI	56,2%	92,5%	0,875	74,4%
T2 ($t^*=0,133$, TPR= 1)[†]	Imatge WSI	100%	57,5%	0,875	78,8%
<i>GAT+DiffPool (AUC = 0,786)</i>					
T1 ($t=0,5$)	Imatge WSI	50,0%	82,5%	0,786	66,3%
T2 ($t^*=0,303$) [†]	Imatge WSI	62,5%	70,0%	0,786	66,3%



GAT Baseline (AUC 0.875) > GAT+DiffPool (AUC 0.786).

T2 Garanteix major sensibilitat

Model competitiu amb NCCN i ESMO

Discussió i Limitacions

Impacte Clínic: Filtre de Descartament

Amb Especificitat del 57.5% a Sensibilitat 100%:

Reducció del 47% de les cirurgies innecessàries respecte la guia JSCCR, sense posar en risc cap pacient N1.

Limitacions

-  **Mida del Test:** 56 pacients → intervals de confiança amplis.
-  **Validació Externa:** Caldria provar el model en més centres (internacionals).
-  **Biaix de Prevalença:** La prevalença N1 al test (28.6%) supera la realitat (~10%), afectant el Valor Predictiu Positiu.

Conclusions Principals



Arquitectura Òptima

El model GAT Baseline, amb Attention Pooling i MIL Mean, demostra ser la configuració superior per davant dels mètodes jeràrquics (DiffPool).



Diagnòstic viable

S'ha demostrat la capacitat de predir metàstasi utilitzant únicament la imatge (WSI), prescindint d'anotacions clíniques.



Eina Clínica Prometedora

Alt potencial de filtre de descartament i reduir el sobretractament en pacients.

Moltes Gràcies.

Preguntes?



David Morillo Massagué | UAB - Enginyeria de Dades

