

Predicció de Metàstasi en Càncer Colorectal

a partir de **Whole Slide Images**
usant **Graph Attention Networks**



David Morillo Massagué
TFG Enginyeria de Dades, UAB

Motivació: El Repte Clínic

Sobretractament en CCR pT1


Risc de metàstasi d'entre el 2% i el 23%.

Fins a un 80% de cirurgies innecessàries,
amb un 20% de falsos negatius

Dades massives

Entrada: "Imatge de portaobjectes sencer" (WSI)

Fins a 150.000 píxels de costat




Estat de l'Art

Guies Clínicas Actuals

JSCCR, NCCN i ESMO: alta sensibilitat però una especificitat baixa (19% - 52%).

IA en Histopatologia

57,6% d'especificitat i 92,9% sensibilitat fent servir Whole Slide Images



Objectius de l'Estudi



Objectiu principal

Construir un sistema complet: des de característiques d'imatges WSI en un **graf espacial**, fins al diagnosi N0/N1.



Comparativa GNN


Avaluar dues arquitectures: un model GAT de referència, davant d'un model GAT+DiffPool per a representacions multiescala.




Diagnòstic Clínic

Implementar tècniques (MIL, readout o cerca de llindar...) per a un diagnosi fiable, a partir de múltiples imatges per pacient

El Pipeline de Predicció



Construcció del Graf




Extracció: Patches de 2048x2048 px.



UNI2: Embeddings CLS [1, 1536]




Delaunay: Connexió i poda d'arestes.




GNNs proposats

Graph Attention Network (Baseline)



Graph Attention Network + Differentiable Pooling



Readout del Graf




Operacions Fixes

Mean / max pooling



Mecanisme d'Atenció

Pes après per node



Agregació a Nivell de Pacient (MIL)


 **El Repte:** Un pacient té varies seccions de teixit; no totes presenten senyals de metàstasi visible. L'etiqueta N0/N1 és del pacient.

 **Multiple Instance Learning:** Pacient = bag de làmines

 **Estratègies implementades:**

Mean, Max, Noisy-OR: Agregació de **probabilitats**.

Attention MIL: Agregació d'embeddings, MLP final únic.



Garantia Diagnòstica Operativa

100%


Objectiu Sensibilitat Clínica

Optimització del Llindar (t^*)

Un fals negatiu (no tractar metàstasi) és inacceptable.

Llindar de predicció per defecte = 0.5.


S'ha establert el criteri **T2**: Trobar el llindar màxim a la corba ROC de validació que manté **TPR=1** (zero falsos negatius), per tal de maximitzar l'especificitat sense risc.



Disseny Experimental i Avaluació

Avaluació estricta dissenyada per evitar biaixos i estimar el rendiment real.

- 🔒 **Test Aïllat (15%):** 56 pacients separats inicialment.
- 🔍 **Cerca Bayesiana (TPE):** Sobre el Pool (85%). Validació creuada 5-fold per trobar la millor configuració (max. especificitat penalitzant caiguda de sensibilitat).
- 🔄 **Retrain i Avaluació:** Reentrenament sobre el 90% del Pool i avaluació final al Test.
- 🎯 **Funció a maximitzar:** $\overline{\text{spec}}_{\text{CV}} - 10 \cdot \max(0, 1 - \overline{\text{sens}}_{\text{CV}})$



Resultats (Validació):

Arquitectura	Readout	MIL	h	H	dropout	AUC CV
Baseline	attention	mean	256	4	0,3	$0,862 \pm 0,038$
DiffPool	mean_max	mean	128	2	0,44	$0,847 \pm 0,048$

Configuracions Guanyadores

La cerca Optuna demostra la superioritat del model **GAT**

Baseline respecte a GAT+DiffPool.


El model Baseline seleccionat utilitza: 3 capes GAT, **Readout per**

Atenció, MIL Mean, dimensió oculta 256 i 4 caps d'atenció.

AUC Validació (Baseline): 0.862 ± 0.038

Resultats al Conjunt de Test i SOTA

Sistema	Tipus d'entrada	Sensibilitat	Especificitat	AUC	Bal.Acc.
<i>Guies i puntuació clínica</i>					
JSCCR [3]	Guia clínica	100%	19%	0,596	59,5%
NCCN	Guia clínica	98%	52%	0,749	75,0%
ESMO [9]	Guia clínica	98%	50%	0,743	74,0%
IBC Score [4]	Puntuació histopat.	90%	26%	0,68	58,0%
<i>Models d'IA</i>					
LightGBM [10]	Var. clinicopatol.	100%	85,8%	0,960	92,9%
Song et al. [27]	Imatge WSI	92,9%	57,6%	0,781	75,3%
<i>GAT Baseline (AUC = 0,875)</i>					
T1 ($t=0,5$)	Imatge WSI	56,2%	92,5%	0,875	74,4%
T2 ($t^*=0,133$, TPR= 1)[†]	Imatge WSI	100%	57,5%	0,875	78,8%
<i>GAT+DiffPool (AUC = 0,786)</i>					
T1 ($t=0,5$)	Imatge WSI	50,0%	82,5%	0,786	66,3%
T2 ($t^*=0,303$) [†]	Imatge WSI	62,5%	70,0%	0,786	66,3%



GAT Baseline (AUC 0.875) > GAT+DiffPool (AUC 0.786).

T2 Garanteix major sensibilitat

Model competitiu amb NCCN i ESMO

Discussió i Limitacions

Impacte Clínic: Filtre de Descartament

Amb Especificitat del 57.5% a Sensibilitat 100%:

Reducció del 47% de les cirurgies innecessàries respecte la guia JSCCR, sense posar en risc cap pacient N1.

$$\text{Reducció \%} = \frac{\text{espec}_A - \text{espec}_B}{1 - \text{espec}_B} \times 100$$

Limitacions



Mida del Test: 56 pacients → intervals de confiança amplis.



Validació Externa: Caldria provar el model en més centres (dades internacionals, diferents escàners...).

Conclusions Principals



Arquitectura Òptima

El model GAT Baseline, amb Attention Pooling i MIL Mean, demostra ser la configuració superior per davant dels mètodes jeràrquics (DiffPool).



Diagnòstic viable

S'ha demostrat la capacitat de predir metàstasi utilitzant únicament la imatge (WSI), prescindint d'anotacions clíniques.



Eina Clínica Prometedora


Alt potencial de filtre de descartament i reduir el sobretractament en pacients.

Moltes Gràcies.

Preguntes?



David Morillo Massagué | UAB - Enginyeria de Dades



TAULA 6: EIXOS DEL *sweep* BAYESIÀ (DOS ESTUDIS OPTUNA AÏLLATS, UN PER ARQUITECTURA).

Eix	Valors / rang	Tipus mostreig
<i>Arquitectura del model — Baseline</i>		
L (capes GAT)	2, 3, 4	enter
<i>Readout</i>	mean, max, mean_max, attention	categòric
h (dimensió oculta)	64, 128, 256	categòric
H (caps d'atenció)	2, 4	categòric
<i>Dropout</i>	[0,05, 0,5]	uniforme
<i>Arquitectura del model — DiffPool</i>		
L_{DP} (blocs DiffPool)	1, 2, 3	enter
K_{top} (super-nodes 1r nivell)	10, 25, 50	categòric
K_{bot} (super-nodes últim nivell)	3, 5, 10	categòric
(Intermedis: $K = \lfloor \sqrt{K_{top} \cdot K_{bot}} \rfloor$; clamp $K_{bot} < K_{top}$)		
λ_{aux} (pes aux.)	[0,1, 10]	log-uniforme
<i>Readout</i>	mean, max, mean_max, attention	categòric
h (dimensió oculta)	64, 128, 256	categòric
H (caps d'atenció)	2, 4	categòric
<i>Dropout</i>	[0,05, 0,5]	uniforme
<i>Agregació MIL — ambdues architectures (optimitzada independentment)</i>		
Agregació MIL	mean, max, noisy-OR, attention	categòric
<i>Optimitzador i regularització — ambdues (independentment)</i>		
<i>Optimizer</i>	Adam, AdamW	categòric
<i>Scheduler</i>	ReduceLROnPlateau, CosineAnnealingLR	categòric
Taxa aprenentatge	$[5 \cdot 10^{-5}, 5 \cdot 10^{-3}]$	log-uniforme
<i>Weight decay</i>	$[10^{-5}, 10^{-2}]$	log-uniforme
<i>Grad. clipping</i>	0, 1, 5	categòric
Pes classe N1 (w_+)	[1,5, 8,0]	uniforme

TAULA 5: CONFIGURACIÓ DEL GAT BASELINE I DEL GAT+DIFFPOOL.

Eix	Baseline	DiffPool
<i>Arquitectura — Baseline</i>		
L (capes GAT)	3	—
$h / H / \text{Dropout}$	256 / 4 / 0,3	—
<i>Readout</i>	<i>attention</i>	—
<i>Arquitectura — DiffPool</i>		
$L (= L_{\text{DP}} + 1)$	—	3
$L_{\text{DP}} / K_{\text{top}}, K_{\text{bot}}$	—	2 / 50, 3
$h / H / \text{Dropout}$	—	128 / 2 / 0,437
λ_{aux}	—	0,108
<i>Readout</i>	—	<i>mean_max</i>
<i>Entrenament i regularització</i>		
MIL	<i>mean</i>	<i>mean</i>
$\eta / \lambda_{\text{wd}} / w_{+}$	$3 \cdot 10^{-4} / 10^{-4} / 2,0$	$5,3 \cdot 10^{-4} / 5,5 \cdot 10^{-3} / 3,52$
<i>Optimizer / Scheduler</i>	<i>adam / plateau</i>	<i>adam / cosine</i>
<i>Mètriques re-avaluades al test</i>		
AUC CV ($\pm \text{std}$)	$0,862 \pm 0,038$	$0,847 \pm 0,048$
AUC test	0,875	0,786
Sens. / Espec. test @ t^*	1,000 / 0,575	0,625 / 0,700
t^*	0,133	0,303

TAULA 4: IMPORTÀNCIA FANOVA PER ARQUITECTURA. LES CEL·LES BUIDES INDIQUEN QUE L'EIX NO ÉS APLICABLE A LA BRANCA.

Eix	Baseline	DiffPool
<i>Eixos específics d'arquitectura</i>		
L (capes GAT)	0,017	—
L_{DP} (blocs DiffPool)	—	0,062
K_{top}	—	0,027
K_{bot}	—	0,021
λ_{aux}	—	0,141
<i>Eixos compartits (optimitzats independentment a cada study)</i>		
<i>Readout</i> (final del graf)	0,079	0,053
h (dim. oculta)	0,012	0,027
H (caps d'atenció)	0,024	0,066
<i>Dropout</i>	0,054	0,079
Agregació MIL	0,640	0,224
η (<i>learning rate</i>)	0,036	0,129
λ_{wd} (<i>weight decay</i>)	0,020	0,083
w_+ (<i>pos_weight</i>)	0,075	0,046
<i>Optimizer</i>	0,005	0,015
<i>Scheduler</i>	0,019	0,008
<i>Grad clipping</i>	0,017	0,019

A.2 Diagrama de flux detallat del *pipeline*

