

Predicció de Metàstasi en Càncer Colorectal

a partir de **Whole Slide Images**
usant **Graph Attention Networks**

David Morillo Massagué
TFG Enginyeria de Dades, UAB

Motivació: El Repte Clínic

Sobretractament en CCR pT1

El carcinoma pT1 ha envaït la submucosa, presentant un risc latent de metàstasi ganglionar (LNM) d'entre el 2% i el 23%. Aplicant els criteris de risc vigents, fins a un **80% de les cirurgies radicals addicionals resulten innecessàries**, penalitzant greument la qualitat de vida del pacient.



Estat de l'Art

Guies Clíiques Actuals

Protocols com JSCCR, NCCN i ESMO ofereixen una alta sensibilitat però una especificitat extremadament baixa (19% - 52%). L'avaluació visual humana mostra limitacions per discernir el risc real.

IA en Histopatologia

Les *Whole Slide Images* (WSI) són massives (150k px). L'estat de l'art usa *Vision Transformers* (com UNI2) per extreure característiques i aprenentatge múltiple (MIL) o *Grafs* (GNN) per entendre la topologia espacial.

Objectius de l'Estudi



Pipeline WSI

Construir un sistema complet: des de la imatge WSI fins a la generació de grafs espacials de Delaunay mitjançant embeddings CLS de UNI2.



Comparativa GNN


Avaluar dues arquitectures: un model GAT Baseline (plana) davant d'un model avançat GAT+DiffPool per a representacions multiescala.




Diagnòstic Clínic

Implementar agregació MIL per unificar prediccions de múltiples seccions en un diagnòstic fiable a nivell pacient.

El Pipeline de Predicció



Construcció del Graf Espacial



Extracció: Patches de 2048x2048 px.




UNI2: Embeddings CLS (1536 feat.).




Delaunay: Connexió i poda d'arestes.

Processing GNN: Baseline vs DiffPool


Graph Attention Network (Baseline)



Graph Attention Network + Differentiable Pooling



Variants d'Arquitectura (Detall)



Lectura Final del Graf



Operacions Fixes (Mean / Max)

Col·lapsa els centenars de nodes del graf (o super-nodes en DiffPool) en un únic vector representatiu calculant el promig o el valor màxim dels atributs de tota la secció de manera uniforme.



Mecanisme d'Atenció (Attention)

Una capa lineal aprèn a assignar un pes escalar a cada node segons la seva rellevància clínica. L'embedding de la secció s'obté per suma ponderada, sent molt més precís.

Agregació a Nivell de Pacient (MIL)



 **El Repte:** Un pacient té varies seccions de teixit; no totes presenten senyals de metàstasi visible. L'etiqueta és del pacient.

 **Multiple Instance Learning:** El pacient es tracta com un 'bag' de seccions.

 **Estratègies implementades:**

Mean, Max, Noisy-OR: Agregació de probabilitats.

Attention MIL: Agregació d'embeddings, MLP final únic.



Agregació a Nivell de Pacient (MIL)



El Repte: Un pacient té varies seccions de teixit; no totes presenten senyals de metàstasi visible. L'etiqueta és del pacient.



Multiple Instance Learning: El pacient es tracta com un 'bag' de seccions.



Estratègies implementades:

Mean, Max, Noisy-OR: Agregació de probabilitats.

Attention MIL: Agregació d'embeddings, MLP final únic.

Agregació a Nivell de Pacient (MIL)

 **El Repte:** Un pacient té varies seccions de teixit; no totes presenten senyals de metàstasi visible. L'etiqueta és del pacient.

 **Multiple Instance Learning:** El pacient es tracta com un 'bag' de seccions.

 **Estratègies implementades:**

Mean, Max, Noisy-OR: Agregació de probabilitats.

Attention MIL: Agregació d'embeddings, MLP final únic.

Jimmy's keychain



cannot open

John's keychain



can open

Brenda's keychain



can open

instance

Garantia Diagnòstica Operativa

100%

Sensibilitat Clínica Requerida

Optimització del Llindar (t^*)


Un fals negatiu (no tractar metàstasi) és inacceptable. El sistema rebutja el llindar per defecte ($t=0.5$).

S'ha establert el criteri **T2**: Trobar el llindar màxim a la corba ROC de validació que manté **TPR=1** (zero falsos negatius), per tal de maximitzar l'especificitat sense risc.


Disseny Experimental i Avaluació

Avaluació estricta dissenyada per evitar biaixos i estimar el rendiment real.

-  **Test Aïllat (15%):** 56 pacients separats inicialment.
-  **Cerca Bayesiana (TPE):** Sobre el Pool (85%). Validació creuada 5-fold per trobar la millor configuració (max. especificitat penalitzant caiguda de sensibilitat).
-  **Retrain i Avaluació:** Reentrenament sobre el 90% del Pool i avaluació final al Test.



Resultats: Corbes ROC (Validació)



Configuracions Guanyadores

La cerca Optuna demostra la superioritat del model **GAT**

Baseline respecte a GAT+DiffPool.

El model Baseline seleccionat utilitza: 3 capes GAT, **Readout per Atenció, MIL Mean**, dimensió oculta 256 i 4 caps d'atenció.


AUC Validació (Baseline): 0.862 ± 0.038

Resultats al Conjunt de Test i SOTA

Sistema	Tipus d'entrada	Sensibilitat	Especificitat	AUC	Bal.Acc.
<i>Guies i puntuació clínica</i>					
JSCCR [3]	Guia clínica	100%	19%	0,596	59,5%
NCCN	Guia clínica	98%	52%	0,749	75,0%
ESMO [9]	Guia clínica	98%	50%	0,743	74,0%
IBC Score [4]	Puntuació histopat.	90%	26%	0,68	58,0%
<i>Models d'IA</i>					
LightGBM [10]	Var. clinicopatol.	100%	85,8%	0,960	92,9%
Song et al. [27]	Imatge WSI	92,9%	57,6%	0,781	75,3%
<i>GAT Baseline (AUC = 0,875)</i>					
T1 ($t=0,5$)	Imatge WSI	56,2%	92,5%	0,875	74,4%
T2 ($t^*=0,133$, TPR= 1)[†]	Imatge WSI	100%	57,5%	0,875	78,8%
<i>GAT+DiffPool (AUC = 0,786)</i>					
T1 ($t=0,5$)	Imatge WSI	50,0%	82,5%	0,786	66,3%
T2 ($t^*=0,303$) [†]	Imatge WSI	62,5%	70,0%	0,786	66,3%

El model GAT Baseline (amb llindar clínic T2) assolix **Sensibilitat 100%** al test, **superant en especificitat (57.5%)** a guies com JSCCR (19%) i sent competitiu amb NCCN (52%) operant només a partir de la imatge WSI, sense variables clíniques.

Avaluació Final al Conjunt de Test



Superant el Repte DiffPool

L'arquitectura **GAT Baseline** (AUC 0.875) venç amb claredat a GAT+DiffPool (AUC 0.786).

Per què? En histopatologia pT1, les seccions contenen pocs centenars de patches. La compressió jeràrquica de DiffPool cap a 'super-nodes' elimina informació microscòpica vital (formes, textures) abans de poder aprofitar-la per a la classificació, mostrant que l'escala de resolució original és crítica.

Discussió i Limitacions

Impacte Clínic: Filtre de Descartament

Amb Especificitat del 57.5% a Sensibilitat 100%, l'ús d'aquesta IA permetria **reduir aproximadament un 47% les cirurgies innecessàries** respecte a aplicar estrictament la guia JSCCR, protegint pacients NO sense posar en risc cap pacient N1.

Limitacions



Mida del Test: 56 pacients generen intervals de confiança estadístics amplis.



Validació Externa: Cal provar el model en escàners i centres independents.



Biaix de Prevalença: La prevalença N1 al test (28.6%) supera la realitat clínica (~10%), afectant el Valor Predictiu Positiu.

Conclusions Principals



Arquitectura Òptima

El model GAT Baseline, amb Attention Pooling i MIL Mean, demostra ser la configuració superior per davant dels mètodes jeràrquics (DiffPool).



Diagnòstic Immersiu

S'ha demostrat la capacitat de predir metàstasi utilitzant únicament gigapíxels d'imatge (WSI) com a nodes d'un graf de Delaunay, prescindint d'anotacions clíniques estructurades.



Eina Clínica Prometedora

L'eina presenta un alt potencial pràctic per actuar com a filtre de descartament i reduir eficaçment el sobretractament en pacients amb CCR pT1.

Moltes Gràcies.

Preguntes?



David Morillo Massagué | UAB - Enginyeria de Dades