

Predicció de Metàstasis en Histopatologia en Càncer Colorrectal usant Graph Attention Networks

David Morillo Massagué

Resum— Es presenta un sistema de classificació N0/N1 per a la detecció de metàstasi en ganglis limfàtics en càncer colorrectal pT1 a partir de *Whole Slide Images*. El teixit es representa com un **graf espacial** construït per triangulació de Delaunay sobre les coordenades dels *patches*, de manera que es preserva la topologia real del teixit, a diferència d'enfocaments basats en similitud de característiques. Cada node és un *patch* de 2048×2048 px representat per l'embedding CLS (1.536 dim.) del model UNI2. Es comparen dues arquitectures: un GAT de referència amb *readout* pla i un GAT amb **DiffPool jeràrquic** intercalat ($N \rightarrow K_1 \rightarrow K_2$ super-nodes) per obtenir representacions a múltiples escales. El diagnòstic per pacient s'obté per agregació MIL sobre les seccions. El millor model obté un AUC de test de 0,925 amb sensibilitat i especificitat de 0,875 (validació creuada 5-fold; AUC CV = $0,860 \pm 0,061$; 367 pacients).

Paraules clau— Càncer colorrectal pT1, Histopatologia digital, Graph Attention Networks, DiffPool jeràrquic, Graf espacial de Delaunay, MIL, Desbalanceig de classes.

Abstract— We present an N0/N1 classification system for lymph node metastasis prediction in pT1 colorectal cancer from Whole Slide Images. Tissue is represented as a **spatial graph** built by Delaunay triangulation over patch coordinates, preserving the real spatial topology of the tissue, unlike feature-similarity graph approaches. Each node is a 2048×2048 px patch represented by a 1,536-dimensional CLS embedding from the UNI2 model. Two architectures are compared: a **GAT baseline** with flat readout (mean/max) and a **GAT+DiffPool** model with pooling layers interleaved between GAT layers ($N \rightarrow K_1 \rightarrow K_2$ super-nodes) for multi-scale representations. Patient-level diagnosis is obtained via MIL aggregation over histological sections. The best model achieves a test AUC of 0.925 with 0.875 sensitivity/specificity (5-fold cross-validation; CV AUC = 0.860 ± 0.061 ; 367 patients).

Keywords— pT1 colorectal cancer, Digital histopathology, Graph Attention Networks, Hierarchical DiffPool, Spatial Delaunay graph, Multiple Instance Learning, Class imbalance.

1 INTRODUCCIÓ

EL càncer colorrectal (CCR) és un dels reptes de salut pública més greus del nostre entorn. A Espanya, la SEOM preveu per al 2026 més de **44.132** nous casos anuals, fet que el converteix en el tumor més freqüent i en la segona causa de mort per càncer, amb 14.629 defuncions [1].

El carcinoma pT1 és especialment complex: el tumor ha envaït la submucosa però no la muscular pròpia, i el risc de metàstasi als ganglis limfàtics oscil·la entre el **2%** i el **23%** depenent de la profunditat d'invasió [2]. Quan hi ha criteris de mal pronòstic (**invasió submucosa $\geq 1000 \mu\text{m}$, invasió vascular o limfàtica, histologia indiferenciada, tumor budding de grau ≥ 2 o marge vertical positiu** [3, 4]), el risc puja al voltant del 10%, fet que porta les guies clíniques (JSCCR [3], NCCN i ESMO [5]) a recomanar cirurgia radical addicional. Com que la majoria de tumors pT1 no desenvolupa LNM real, s'estima que **més del 80%** d'aquestes cirurgies són innecessàries [6, 7].

La histopatologia digital, mitjançant les *Whole Slide Images* (WSI), permet aplicar tècniques avançades de visió per

• E-mail de contacte: David.MorilloMa@autonoma.cat
 • Treball tutoritzat per: Debora Gil Resina (DCC)
 • Curs 2025/26

computador. En concret, les *Graph Attention Networks* (GAT) [8] permeten modelar el teixit com una estructura espacial. Una decisió clau en la construcció del graf és el criteri de les arestes: alguns treballs les basen en la *similitud de característiques* entre *patches*; aquest treball opta per la **proximitat espacial** (triangulació de Delaunay sobre coordenades WSI), preservant la topologia real del teixit. El projecte, desenvolupat al grup IAM del CVC (iam.cvc.uab.es) sota la supervisió de la Dra. Debora Gil, compara un GAT de referència amb *readout* pla contra un model amb *pooling* jeràrquic (DiffPool) intercalat, i proposa diferents estratègies d'agregació MIL per al diagnòstic per pacient.

Dues raons justifiquen aquest treball. Des del punt de vista clínic, els sistemes d'IA poden detectar patrons morfològics subtils de manera consistent i ajudar a reduir cirurgies innecessàries. Des del punt de vista tècnic, combinar xarxes d'atenció sobre grafs amb aprenentatge profund sobre WSI és just la intersecció entre teoria de grafs i deep learning que vull explorar dins de l'Enginyeria de Dades.

2 OBJECTIUS

- Construir un *pipeline* complet de classificació N0/N1 sobre WSI reals a partir d'embeddings CLS del model UNI2, basat en **grafs espacials** (triangulació de Delaunay sobre coordenades del teixit).
- **Comparar un GAT de referència** amb *readout* pla contra un model amb **DiffPool jeràrquic** intercalat entre capes GAT, avaluant si la reducció progressiva del graf aporta millor representació multi-escala.
- Implementar i comparar estratègies d'agregació MIL a nivell de pacient per integrar les prediccions de múltiples seccions histològiques.

3 ESTAT DE L'ART

3.1 Classificació de WSI amb MIL

Les *Whole Slide Images* tenen resolucions de fins a $150\,000 \times 150\,000$ píxels i no es poden processar directament amb xarxes convencionals. L'enfocament habitual és dividir la làmina en *patches* petits i treballar amb *Multiple Instance Learning* (MIL), on el model ha d'inferir l'etiqueta global a partir de fragments sense etiqueta individual. Ilse et al. [9] van proposar l'agregació per atenció (*attention-based MIL*), que aprèn quins *patches* són més rellevants per al diagnòstic. Lu et al. [10] van aplicar aquest mètode a conjunts de dades clínics reals (CLAM), i Li et al. [11] van proposar DSMIL, que combina dues branques, a nivell de *patch* i de làmina, amb aprenentatge contrastiu. La predicció de metàstasi ganglionar a partir d'histopatologia s'ha estudiat en altres càncers: Muti et al. [12] mostren que és possible predir l'estat N0/N1 a partir de làmines de càncer gàstric, amb resultats prometedors.

3.2 Grafs i GNN en Patologia Digital

Les *Graph Neural Networks* permeten tractar el teixit com una estructura on les regions estan connectades segons la seva proximitat, capturant relacions espacials que les CNN no modelen directament. Jaume et al. [13] van presentar

HistoCartography, un entorn de treball per a l'anàlisi de grafs en patologia digital, amb resultats que mostren millores respecte de les CNN en classificació de biòpsies. Les GAT [8] afegeixen un mecanisme d'atenció que permet al model ponderar cada veí de manera diferent, cosa especialment útil en histopatologia on no totes les regions del teixit aporten la mateixa informació. Pel que fa al *pooling* en grafs, Grattarola et al. [14] revisen els principals mètodes existents, entre ells DiffPool [15], que agrupa nodes en super-nodes de manera progressiva.

3.3 Models de Fundació per a Histopatologia

En els darrers anys han aparegut *foundation models* preentrenats específicament sobre dades de patologia, que generen embeddings molt més informatius que les CNNs genèriques. UNI2 [16] és un *vision transformer* entrenat sobre més de 100 milions de *patches* de 20 tipus de teixit, amb bons resultats en nombroses tasques de classificació histopatològica. CONCH [17] és un model similar que incorpora a més alineament entre imatge i text. En aquest projecte s'utilitzen els embeddings de UNI2 com a vector de característiques de cada node, ja que estan preentrenats en el mateix domini i capturen informació morfològica rellevant.

3.4 Guies Clíniques i Models Predictius per a pT1 CRC

Les guies clíniques de referència (JSCCR [3], NCCN i ESMO [5]) recomanen cirurgia addicional quan el pacient presenta un o més dels criteris de risc histopatològics esmentats a la Introducció. Malgrat la seva sensibilitat elevada, la seva especificitat és baixa: en un estudi comparatiu sobre 560 pacients [18], les AUC reportades són 0,596 (JSCCR), 0,749 (NCCN) i 0,743 (ESMO), amb especificitats del 19%, 52% i 50% respectivament, la qual cosa implica que més del 80% dels pacients operats no tenien LNM real [18, 6].

Paral·lelament, Piao et al. [19] van proposar un model d'IA sobre variables clinicopatològiques ($n = 783$ entrenament, $n = 105$ test) basat en regressió logística regularitzada (LASSO), obtenint sensibilitat del 100%, especificitat del 85,8%, AUC de 0,960 i *balanced accuracy* del 92,9%; la taxa de pacients classificats com a alt risc es va reduir del 83,8% (JSCCR) al 20,9%. Dawson et al. [4] van proposar l'IBC Score, una puntuació ponderada sobre invasió limfovascular, grau de *tumor budding*, profunditat d'invasió i grau tumoral, que obté AUC de 0,68 sobre 565 pacients. A diferència d'aquests treballs, aquest TFG fa la predicció exclusivament a partir de la **imatge histopatològica** (WSI), sense variables clíniques estructurades ni puntuació manual d'un patòleg.

3.5 Treball Previ al CVC sobre pT1 CRC

Aquest treball s'integra dins una línia de recerca del grup IAM del CVC. Martí et al. [20] van comparar CNNs, ViTs i GNNs sobre el mateix conjunt pT1 CRC per a la classificació de *patches* individuals, amb millor AUC ($0,954 \pm 0,077$) per una arquitectura híbrida ViT+NN. Aquell treball, però, opera a nivell de *patch* i no té en compte la topologia espacial del teixit ni el diagnòstic per pacient. Aquest TFG parteix dels embeddings CLS del model UNI2 per construir

grafs espacials de les seccions i aborda el problema des d'una perspectiva MIL per pacient.

4 DADES I PREPROCESSAMENT

Aquest projecte es realitza en col·laboració amb un equip de la UAB que cobreix des de la recollida de dades fins a la creació d'autoencoders per a l'extracció de característiques.

4.1 Imatges de Gran Format (WSI)

Les dades originals consisteixen en imatges de làmines senceres (WSI) obtingudes amb escàners d'alta resolució i tintades amb hematoxilina-eosina, emmagatzemades en format MIRAX (.mrxs). Les dimensions oscil·len entre els 30.000 i els 150.000 píxels per costat, amb una quantitat significativa d'espai buit o artefactes que requereixen tractament previ.

El conjunt de dades efectiu comprèn **1.607 grafs** (un per secció histològica), provinents de **367 pacients** distribuïts de forma desequilibrada entre les dues classes (Taula 1). D'un total de 606 pacients a la base de dades clínica, 236 es descarten per diagnòstic indeterminat (NX), i dels 370 restants amb diagnòstic vàlid, 3 no disposen d'embeddings UNI2 generats, deixant 367 pacients usables. Les mostres es divideixen en conjunts d'entrenament (70%), validació (15%) i test (15%) estratificats a nivell de pacient.

4.2 Anotacions i Màscares de Segmentació

La Dra. Eva Musulén, patòloga especialitzada, ha realitzat les anotacions manualment amb el programari *Labelme*. Aquestes identifiquen tres categories d'afectació:

- **Infiltració:** teixit anormal que envaeix zones no corresponents.
- **Displàsia:** cèl·lules anormals que poden convertir-se en canceroses.
- **Infiltració + Displàsia:** usat en casos de dubte diagnòstic.

A partir d'aquestes s'obtenen màscares de segmentació codificades per color: vermell (infiltració), blau (displàsia) i verd clar (combinada).




Fig. 1: Exemple de WSI i la seva corresponent màscara de segmentació.

4.3 Extracció de Patches i Embeddings CLS

S'aplica una finestra lliscant (*sliding window*) sense solapament per dividir cada làmina en *patches* de 2048×2048 píxels a resolució completa (nivell 0). El model de fundació UNI2 [16] processa cada *patch* individualment i extreu el token *CLS* de la seva sortida, obtenint un vector de **1.536 dimensions** que condensa la informació morfològica i textural del patch. No s'aplica cap filtratge de qualitat previ (ni per borrositat ni per proporció de blanc): tots els *patches* d'una secció generen un node del graf.

5 CONSTRUCCIÓ DEL GRAF

5.1 Model de dades: dimensions i estructures

Formalment, cada secció histològica es representa com un graf $\mathcal{G} = (\mathbf{X}, \mathbf{A})$ on:

- $\mathbf{X} \in \mathbb{R}^{N \times 1536}$ és la matriu de característiques dels N nodes (*patches*).
- $\mathbf{A} \in \{0, 1\}^{N \times N}$ és la matriu d'adjacència construïda per triangulació de Delaunay i posterior poda d'arestes llargues.

Dues estratègies de *pooling* transformen la seqüència de grafs en un vector global que alimenta el capçal MLP per produir $P(N1)$:

- **Pla (readout).** *Mean* o *max* aplicats sobre les sortides de la darrera capa GAT, reduint directament de N nodes a d_h dimensions.
- **Jeràrquic (DiffPool intercalat).** Dues capes DiffPool s'insereixen entre les capes GAT: la primera colapsa el graf de N nodes a K_1 super-nodes, i la segona de K_1 a K_2 . Cada nivell aprèn una matriu d'assignació suau i produeix un nou graf de menor grandària sobre el qual opera la capa GAT següent.

Model 1 — Múltiples grafs + agregació MIL. Cada secció genera un graf independent; les S seccions d'un pacient es processen per separat i les probabilitats $\{P(N1_i)\}_{i=1}^S$ s'agreguen a posteriori (Secció 7.1).

Model 2 — Un sol graf per pacient. Com a alternativa, totes les seccions d'un pacient es concatenen en un únic mega-graf bloc-diagonal: les matrius de característiques s'apilen i les d'adjacència s'organitzen a la diagonal (sense arestes entre seccions). El GAT opera llavors sobre totes les seccions simultàniament i un únic *pooling* global produeix el diagnòstic sense etapa MIL separada.

5.2 Connectivitat per triangulació de Delaunay

Una connectivitat fixa de reixeta no és adequada perquè la màscara exclou regions de fons i trenca la simetria de la quadrícula. Per aquest motiu, s'aplica una **triangulació de Delaunay** sobre els nodes restants, que s'adapta a distribucions irregulars de forma natural. A continuació, s'eliminen les arestes que travessen píxels de valor zero a la màscara, evitant connexions entre regions separades per espai buit. Finalment, s'aplica un criteri de distància màxima: s'eliminen les arestes que superen el doble de la longitud mitjana

TAULA 1: COMPOSICIÓ DEL DATASET EFECTIU PER PARTICIÓ (26 HOSPITALS). ELS GRAFS CORRESPONEN A SECCIONS HISTOLÒGIQUES INDIVIDUALS (UN PER SECCIÓ).

Partició	Pacients			Grafs (seccions)		
	N0	N1	Total	N0	N1	Total
Train	184	72	256	897	185	1 082
Val	40	15	55	236	34	270
Test	40	16	56	212	43	255
Total	264	103	367	1 345	262	1 607


del conjunt. La figura 2 mostra el resultat del procés: les arestes eliminades pel filtre de màscara apareixen en vermell.

Cal notar que una secció histològica pot contenir múltiples regions de teixit físicament separades (per exemple, diverses illes de teixit sobre el porta). En aquest cas, la triangulació de Delaunay produeix un graf amb múltiples **components connexes**, sense arestes entre illes. El pipeline genera **un graf per secció** (no per component): tot el teixit de la secció s'inclou en un únic objecte *Data*, i el *pooling* global opera sobre tots els nodes conjuntament.

6 ARQUITECTURA DEL MODEL

6.1 GATClassifier

El model implementat, *GATClassifier*, és un classificador de grafs que alterna capes **Graph Attention Network** (GATConv [8, 21]) amb capes de *pooling* jeràrquic per a la classificació binària N0/N1. L'arquitectura proposa intercalar operacions de reducció del graf *entre* les capes de propagació de missatges, de manera que cada estadi treballa sobre una representació progressivament més compacta del teixit:



on $K_1 \ll N$ i $K_2 \ll K_1$ són el nombre de *super-nodes* de cada nivell jeràrquic.

Mecanisme d'atenció. A diferència de les xarxes convolucionals clàssiques sobre grafs que tracten tots els veïns d'un node de forma uniforme, GAT aprèn a assignar pesos d'importància diferenciats a cada veí. Donada la representació $\mathbf{h}_i \in \mathbb{R}^F$ del node i , per a cada parella de nodes veïns (i, j) es calcula un coeficient d'atenció no normalitzat:

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j])$$

on $\mathbf{W}$ és una transformació lineal aprenible, $\parallel$ la concatenació i $\mathbf{a}$ un vector d'atenció aprenible. Els coeficients es normalitzen amb *softmax* sobre tots els veïns del node i :

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$

i la nova representació del node s'obté com la suma ponderada dels veïns:

$$\mathbf{h}'_i = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W}\mathbf{h}_j \right)$$

Multi-cap. Per incrementar la capacitat expressiva, cada capa usa H caps d'atenció independents les sortides dels quals es concatenen (a les dues primeres capes) o es promitgen (tercera capa). D'aquesta manera el model pot capturar múltiples tipus de relació de veïnatge simultàniament. Cada capa va seguida de normalització per *batch*, activació ELU i *dropout*.

El capçal MLP (*Linear* $\rightarrow$ ReLU $\rightarrow$ Dropout $\rightarrow$ *Linear*) transforma la representació global del graf en els logits N0/N1.

6.2 Estratègies de Pooling Pla (Readout)

Quan no s'utilitza pooling jeràrquic, les representacions dels nodes de la darrera capa GAT s'agreguen directament amb operacions de *readout*: *mean*, *max* o la seva concatenació (*mean_max*). Tot i la seva eficiència computacional, aquestes estratègies ignoren la topologia del graf i col·lapsen tota la informació espacial en un sol pas.

6.3 Pooling Jeràrquic: DiffPool entre Capes GAT

Per superar les limitacions del *readout* pla, s'implementa **DiffPool** [15] com a operació intermèdia entre les capes de propagació. A diferència d'aplicar el *pooling* únicament al final, la proposta intercala dues capes DiffPool al llarg de la xarxa: una entre la primera i la segona capa GAT, i una altra entre la segona i la tercera. Cada capa DiffPool aprèn una matriu d'assignació suau (*soft assignment*) $\mathbf{S} \in \mathbb{R}^{N \times K}$ que agrupa els N nodes actuals en $K \ll N$ *super-nodes*:

$$\mathbf{X}^{(\ell+1)} = \mathbf{S}^\top \mathbf{X}^{(\ell)}, \quad \mathbf{A}^{(\ell+1)} = \mathbf{S}^\top \mathbf{A}^{(\ell)} \mathbf{S}$$

Amb aquesta arquitectura, la primera capa GAT opera sobre el graf original de nodes de teixit (N patches), la segona ho fa sobre un graf reduït de K_1 super-nodes que representen regions de teixit de nivell intermedi, i la tercera opera




Fig. 2: Etapes del preprocessament per a la construcció del graf. D'esquerra a dreta: WSI original → extracció de *patches* de 2048×2048 px per finestra lliscant + filtratge → extracció de l'embedding CLS de 1.536 dimensions per UNI2 (un vector per *patch*) → construcció del graf de Delaunay sobre la màscara anotada, on les arestes en vermell han estat eliminades pel filtre de màscara




Fig. 3: Il·lustració del mecanisme d'atenció en una capa GAT amb tres caps independents (verd, blau, lila). El node central $\vec{h}_1$ agrega les representacions dels seus veïns i la seva pròpia (α_{11} , *self-loop*) mitjançant coeficients d'atenció α_{1j} apresos per cada cap. Les sortides dels caps es combinen per concatenació o promig per obtenir la nova representació $\vec{h}'_1$.

sobre un graf molt compacte de K_2 super-nodes que codifiquen l'organització arquitectònica global de la secció. Finalment, un *readout* global (*mean* o *max*) sobre els K_2 nodes produeix l'embedding que entra al capçal MLP.

L'entrenament incorpora una pèrdua auxiliar (*link prediction* + entropia mínima) per regularitzar l'assignació i evitar degeneracions trivials.

A diferència dels mètodes clàssics (min-cut, clusterització espectral), DiffPool és completament diferenciable: la matriu S s'obté com la sortida d'una GNN auxiliar amb *softmax*, de manera que el gradient flueix de cap a cap i el *pooling* s'ajusta conjuntament amb la resta del model.

Com a alternativa, SAGPool [22] selecciona els K nodes més rellevants via puntuacions d'auto-atenció (selecció discreta, no assignació suau); s'ha preferit DiffPool per la seva expressivitat contínua i la pèrdua auxiliar de regularització.

7 METODOLOGIA

7.1 Agregació per Pacient (MIL)

El diagnòstic és per **pacient**, no per làmina. Una mateixa secció histològica pot no presentar senyals visibles de metàstasi si s'analitza aïlladament, mentre que en una altra secció del mateix pacient sí que és apreciable. Si s'entrena a nivell de làmina, les seccions N1 de pacients N1 que no mostren metàstasi visible reben un senyal de supervisió incorrecte (N0), contaminant l'entrenament.

Per evitar aquest problema, s'utilitza el paradigma d'**aprenentatge per múltiples instàncies** (*Multiple Instance Learning*, MIL): cada pacient es tracta com un *bag* i totes les seves làmines comparteixen la mateixa etiqueta. El model aprèn a classificar el pacient a partir de les seves seccions, sense necessitat d'etiquetes individuals per làmina.

Donades les probabilitats $\{p_i = P(N1_i)\}_{i=1}^S$ de les S làmines d'un pacient, s'implementen quatre estratègies d'agregació:

- **Mean:** $P(N1_p) = \frac{1}{S} \sum_i p_i$. Mitjana aritmètica; estratègia escollida per al model final.
- **Noisy-OR:** $P(N1_p) = 1 - \prod_{i=1}^S (1 - p_i)$. N'hi ha prou amb una làmina amb metàstasi per marcar el pacient com N1.
- **Max:** $P(N1_p) = \max_i p_i$. Conservadora, basada en l'evidència màxima.
- **Attention MIL:** pes d'atenció aprenent (*gated attention* d'Ilse et al. [9]) per a cada làmina a partir del seu embedding GAT, i suma ponderada dels embeddings per obtenir la representació del pacient.

7.2 Desbalanceig de Classes

El conjunt de dades presenta un fort desbalanceig: els casos N0 superen àmpliament els N1 (proporció aproximada




Fig. 4: Comparació visual de les dues arquitectures. **Dalt:** GAT Baseline, on les capes d'atenció operen sobre els N nodes originals al llarg de tota la xarxa i un *readout* global (mean, max) produeix l'embedding final de dimensió $1 \times F_2$. **Baix:** GAT+DiffPool, on cada capa d'atenció va seguida d'un DiffPool que col·lapsa progressivament el graf de N nodes a K_1 macro-nodes i finalment a un únic macro-node, capturant representacions multi-escala del teixit.

80/20). Per combatre-ho s'apliquen tres mesures complementàries.

(1) **Partició estratificada.** La divisió train/val/test es realitza amb estratificació a nivell de pacient, assegurant que la proporció N0/N1 sigui representativa en cada subconjunt (Taula 1). Sense estratificació, amb un conjunt petit i desequilibrat, alguns subconjunts podrien contenir per atzar una proporció de N1 molt diferent a la real, invalidant les mètriques.

(2) **Pesos de classe.** S'apliquen pesos balancejats $w_c = N/(C \cdot n_c)$, on n_c és el nombre de pacients de la classe c , incorporats directament a la funció de pèrdua BCE. Així, cada error sobre un cas N1 té més pes en el gradient que un error sobre N0, penalitzant més els falsos negatius.

(3) **Mostratge ponderat per batch.** Durant l'entrenament s'utilitza un *WeightedRandomSampler* que assigna a cada pacient una probabilitat de mostratge inversament proporcional a la freqüència de la seva classe. Això garanteix que cada *mini-batch* contingui una proporció equilibrada de casos N0 i N1, evitant que el model vegi gairebé exclusivament N0 durant molts *batches* consecutius.

7.3 Grid Search i Validació Creuada

Cada configuració s'avalua amb **Stratified K-Fold Cross-Validation** ($K = 5$) sobre el *pool* d'entrenament/validació, deixant el test aïllat des de la construcció dels grafs. Aquest esquema substitueix el *hold-out* simple per dues raons:

- **Estabilitat estadística.** Reportar $\mu \pm \sigma$ sobre $K = 5$ folds és més robust que un *hold-out* únic, sensible al

split concret quan el conjunt és petit (367 pacients).

- **Representativitat de classes.** L'estratificació per N0/N1 manté la proporció a cada fold. Amb una classe minoritària com N1 (28%), un *split* aleatori podria deixar-la mal representada i distorsionar la sensibilitat.

Per a cada combinació s'entrenen $K = 5$ models, un per fold, amb *early stopping* (patience=20) i reducció de la taxa d'aprenentatge en *plateau*. Les mètriques ($\mu \pm \sigma$ d'AUC, sensibilitat, F1-macro i *accuracy*) es calculen sobre els fold validation sets. Només el millor model per AUC CV s'avalua sobre el test, per mantenir-ne la independència.

Els grafs es divideixen físicament a nivell de pacient en tres particions (*train*, *val*, *test*); les dues primeres formen el *pool* de la CV. Pesos de classe i tota selecció d'hiperparàmetres s'ajusten exclusivament dins de cada fold, evitant filtracions de dades.

8 RESULTATS

Les mètriques principals són l'**AUC-ROC** (ordenació global independent del llindar) i les **mètriques clíniques: sensibilitat** ($VP/(VP + FN)$) i **especificitat** ($VN/(VN + FP)$). En detecció de metàstasi, la sensibilitat és la més rellevant: un fals negatiu (no tractar un N1) és més greu que un fals positiu.

La cerca d'hiperparàmetres s'ha fet amb validació creuada 5-fold sobre el *pool* d'entrenament/validació (Secció 7.3), variant arquitectura (GAT Baseline / GAT+DiffPool), tipus de graf (per secció / per pacient),

pooling, agregació MIL, *learning rate*, dimensió oculta h , nombre de caps H , *dropout* i regularització L2. En total s'han avaluat **255 configuracions**. La Taula 2 mostra les 5 millors per AUC CV, i el text justifica la selecció del model final.

Les 5 millors configuracions per CV mostren AUC molt similars (rang 0,860–0,881), indicant que diverses combinacions properes a l'òptim donen un rendiment comparable. Per al *reporting* final s'ha seleccionat el model #5 (GAT Baseline amb *attention pooling*, $H = 2$, $h = 256$, *dropout* 0,1 i $\lambda_{wd} = 10^{-4}$). Tot i ser el 5è per AUC CV, és l'únic dels cinc candidats que assoleix **Sens. = 100% al test** amb el llinard derivat del val set del seu fold (procediment sense *data leakage*, Secció 10.3); en els altres quatre, el llinard de val deixa Sens. residual entre 75% i 87,5% al test. El model #5 té, a més, l'AUC de test més alt (0,925).

Dels 16 casos N1 del test, el model en detecta 14 al llinard 0,5 (2 falsos negatius) i tots 16 al llinard $t^* = 0,261$ derivat del val set.

8.1 Anàlisi d'influència dels hiperparàmetres

Per identificar quins factors determinen el rendiment s'han calculat els **efectes principals** sobre l'AUC: per a cada nivell d'un factor, l'AUC mitjà sobre totes les configuracions que inclouen aquell nivell. El **rang d'influència** (diferència entre el millor i el pitjor nivell) mesura la importància relativa del factor. L'anàlisi cobreix nou factors: tres decisions arquitectòniques (arquitectura, tipus de graf, agregació MIL) i sis hiperparàmetres d'optimització i regularització. La taula completa es presenta a l'Apèndix (Taula 5); els resultats es resumeixen aquí.

Decisions arquitectòniques. Les tres tenen impacte de primer ordre:

- **L'agregació MIL** és el factor més influent (rang 0,206): *mean* i *attention* superen *noisy-OR*.
- El **tipus de graf** (rang 0,143): un graf per secció supera el mega-graf per pacient. Aquest darrer força una única passada de *pooling* sobre teixits físicament inconnexos, perdent l'estructura per secció.
- L'**arquitectura** (rang 0,097): GAT Baseline supera GAT+DiffPool. Amb seccions de pocs centenars de *patches*, la reducció a super-nodes elimina més informació útil que la que sintetitza.

Optimització i regularització. El nombre de caps d'**atenció** és el factor amb més pes (rang 0,253): $H = 8$ provoca un col·lapse del rendiment ($\sim 0,58$, proper a l'atzar), mentre que $H = 2$ i $H = 4$ són pràcticament equivalents (0,833 vs 0,830). Amb ~ 250 pacients d'entrenament, $H = 8$ té massa paràmetres per convergir amb estabilitat. La **regularització L2** alta ($\lambda_{wd} = 10^{-3}$) destaca per estabilitzar l'entrenament: redueix la desviació entre folds de 0,127 a 0,018. La resta de factors (*hidden*, tipus de *pooling*, *learning rate*, *dropout*) tenen efectes secundaris un cop els tres anteriors estan ben fixats.

La Taula 3 mostra la matriu de confusió del millor model sobre el test.

8.2 Comparació amb guies clíniques i SOTA

La Taula 4 situa el model davant de les guies clíniques de referència (Secció 3.4) i del model de IA de referència. Les xifres de les guies provenen de [18] ($n = 560$), i les del GAT s'han obtingut sobre el test d'aquest treball ($n = 56$; prevalença N1 28,6%, superior a la clínica real ~ 8 –15% [6]). Sensibilitat i especificitat són independents de la prevalença i són la base de la comparació; el VPP s'ha d'interpretar amb cautela (Secció 10.3).

En la detecció de metàstasi, un fals negatiu (no tractar un pacient N1) és un error inacceptable, mentre que un fals positiu (cirurgia innecessària) és recuperable. Per això, el punt operatiu desitjat sobre la corba ROC és el que toca la **part superior** (Sens. = 100%, cap N1 perdut) i alhora queda **tan a l'esquerra com sigui possible** (Espec. màxima). La Figura 5 superposa les corbes ROC dels cinc millors candidats amb els punts operatius de les guies clíniques i del model d'IA de referència. El model seleccionat és l'únic que assoleix Sens. = 100% al test amb el llinard determinat sobre el val set, i ho fa amb la menor fracció de falsos positius dels cinc.




Fig. 5: Corbes ROC al conjunt de test (56 pacients) dels cinc millors models per AUC CV. El model seleccionat (#5, magenta) és l'únic que assoleix Sens. = 100% al test amb el llinard $t^* = 0,261$ derivat exclusivament del val set (cercle gros, sense *data leakage*). Es marquen els punts operatius publicats de JSCCR, NCCN, ESMO (quadrats) i LASSO (diamant). La franja ressaltada al voltant de Sens. = 1 delimita el rang clínicament acceptable: el sistema busca el punt més a l'esquerra possible dins d'aquesta franja per minimitzar les cirurgies innecessàries.

L'**impacte clínic** d'aquesta especificitat es pot quantificar de manera directa. La literatura citada estima que entre el 80% i el 90% de les cirurgies actuals en pT1 amb criteris de risc són innecessàries [7], xifra coherent amb l'especificitat del 19% de JSCCR. Per cada 100 pacients N0:

- **JSCCR**: 81 cirurgies innecessàries.
- **NCCN/ESMO**: 48–50 cirurgies innecessàries.
- **GAT (llinard t^*)**: 22,5 cirurgies innecessàries.

Mantenint Sens. = 100%, el GAT redueix les cirurgies innecessàries en ~ 58 pacients per cada 100 N0 respecte de

TAULA 2: TOP-5 CONFIGURACIONS PER AUC CV MITJANA (255 CONFIGURACIONS AVALUADES AMB VALIDACIÓ CREUADA 5-FOLD; TEST DE 56 PACIENTS). **NEGRETA**: MODEL SELECCIONAT PER AL *reporting* FINAL, ESCOLLIT PER L'AUC ALT AL TEST (0,925) I PER MANTENIR SENS.= 100% AL TEST AMB UN LLINDAR DERIVAT DEL VAL SET (VEGEU SECCIÓ 10.3). TOTS ELS MODELS SÓN *GAT Baseline* AMB AGREGACIÓ MIL *mean*.

#	Pooling	LR	H	hidden	drop	λ_{wd}	AUC CV	AUC test
1	<i>attention</i>	$3 \cdot 10^{-4}$	4	256	0,3	10^{-4}	$0,881 \pm 0,034$	0,850
2	<i>attention</i>	$3 \cdot 10^{-4}$	2	256	0,1	0	$0,865 \pm 0,072$	0,884
3	<i>mean_max</i>	$1 \cdot 10^{-4}$	2	128	0,2	0	$0,862 \pm 0,038$	0,891
4	<i>attention</i>	$3 \cdot 10^{-4}$	4	128	0,3	10^{-3}	$0,861 \pm 0,058$	0,866
5	<i>attention</i>	$3 \cdot 10^{-4}$	2	256	0,1	10^{-4}	$0,860 \pm 0,061$	0,925

TAULA 3: MATRIU DE CONFUSIÓ DEL MILLOR MODEL (GAT BASELINE, *attention pooling*, AGREGACIÓ *mean*, LR = $3 \cdot 10^{-4}$, H = 2, dropout = 0,1, $\lambda_{WD} = 10^{-4}$; CONJUNT DE TEST, 56 PACIENTS). MÈTRIQES CLÍNiques: SENSIBILITAT = 0,875, ESPECIFICITAT = 0,875, VPP = 0,737, VPN = 0,946.

		Diagnòstic real	
		N0	N1
Predicció	N0	35	2
	N1	5	14

JSCCR ($\sim 72\%$ menys) i en ~ 26 respecte de NCCN/ESMO ($\sim 54\%$). Sobre els 40 N0 del test, això són 9 FP en lloc dels ~ 32 que aplicaria JSCCR sobre la mateixa població.

9 IMPLEMENTACIÓ

La implementació segueix un disseny modular: la construcció de grafs, el model, el codi d'entrenament i els *data loaders* estan desacoblats per facilitar l'experimentació independent. La configuració d'hiperparàmetres es gestiona via fitxer YAML, on qualsevol paràmetre pot ser una llista per activar el *grid search* automàtic. El repositori és accessible a [23].

S'ha implementat un *frontend* web per explorar els models entrenats, visualitzar els grafs de Delaunay amb pesos d'atenció per node i consultar corbes ROC/PR i matrius de confusió sobre el conjunt de test. El diagrama de flux complet del *pipeline* es presenta a l'Apèndix A (Figura 6).

10 CONCLUSIONS I TREBALL FUTUR

10.1 Conclusions

En aquest TFG s'ha construït un sistema complet de classificació N0/N1 per a càncer colorrectal pT1 a partir de WSI, que inclou la generació de grafs espacials de Delaunay, l'entrenament del model GAT amb una cerca d'hiperparàmetres avaluada per validació creuada 5-fold i l'avaluació final sobre un conjunt de test fix (56 pacients). El millor model assolix un AUC de **0,925** (CV: $0,860 \pm 0,061$) amb una sensibilitat i una especificitat de 0,875, detectant correctament 14 dels 16 casos N1 reals del conjunt de test. Se'n destaquen tres observacions:

- El mètode d'agregació MIL i el tipus de *pooling* del graf són factors amb influència de primer ordre sobre

el resultat. La combinació *attention pooling* + agregació *mean* (mitjana de probabilitats per pacient) és consistentment la millor.

- El GAT Baseline supera el GAT+DiffPool, cosa que suggereix que el *pooling* jeràrquic no aporta avantatge real amb el conjunt de dades actual: la dimensió de cada secció (N del centenar de *patches*) probablement és massa petita perquè la reducció a super-nodes preservi informació útil.
- La regularització L2 amb un *dropout* suau i un *learning rate* moderadament alt són la combinació que dona el millor rendiment, especialment en sensibilitat. Aquest és el guany clínicament més rellevant: cada N1 detectat de més és un pacient identificat per a tractament correcte.

10.2 Discussió Comparativa

L'AUC de test (0,925) supera la de JSCCR (0,596), NCCN (0,749) i ESMO (0,743) [18]. L'especificitat (87,5%) és molt superior a la de les tres guies, cosa que reduiria les cirurgies innecessàries si el model s'apliqués com a filtre previ a la decisió quirúrgica.

VPP i ajust per prevalença. El VPP de 73,7% s'ha calculat amb la prevalença del test (28,6% N1), molt superior a la clínica real ($\sim 8\text{--}15\%$) [6]. A una prevalença del 10%, el VPP baixa al 43,8% i el VPN puja al 98,4% (càlcul per Bayes amb les Sens./Espec. observades). El model és, doncs, especialment útil com a **filtre de descartament**: un resultat negatiu té molta probabilitat de ser correcte i podria evitar la cirurgia amb seguretat. Sensibilitat i especificitat, independents de la prevalença, segueixen sent les mètriques comparatives més robustes.

Sensibilitat ajustable per llindar. Al llindar per defecte (0,5), la sensibilitat del GAT (87,5%) és inferior a la de JSCCR/NCCN/ESMO (98–100%), però aquestes guies hi arriben amb especificitats del 19–52%. Ajustant el llindar a $t^* = 0,261$ (derivat del val set, Limitació 4) el GAT assolix sensibilitat del 100% amb especificitat del 77,5%: una millora de 58,5 punts sobre JSCCR al mateix nivell de sensibilitat.

Comparació amb IA SOTA. LASSO [19], entrenat amb $\sim 14\times$ més dades i amb accés a variables clinicopatològiques estructurades, obté Sens.= 100% amb Espec.= 85,8% i AUC 0,960. El GAT, al mateix punt operatiu, arriba a Espec.= 77,5% (uns 8 punts per sota), però amb la imatge WSI com a única entrada. Els dos models són complementaris: el GAT pot córrer just després d'escanejar la làmina,

TAULA 4: COMPARACIÓ DE RENDIMENT ENTRE EL MODEL PROPOSAT, LES GUIES CLÍNiques I L'ESTAT DE L'ART. **GUIES:** TANINO ET AL. [18] ($n=560$, HIROSHIMA). **IBC SCORE:** DAWSON ET AL. [4] ($n=565$, MULTICÈNTRIC). **LASSO:** PIAO ET AL. [19] ($n = 105$ TEST, VARIABLES CLINICOPAT.). **GAT:** AQUEST TREBALL ($n = 56$ TEST). ESTUDIS I POBLACIONS INDEPENDENTS; EL PPV NO ÉS DIRECTAMENT COMPARABLE (PREVALENÇA N1 DIFERENT ENTRE ESTUDIS). $BAL.ACC. = (S+E)/2$; CALCULADA PER A LES GUIES I L'IBC SCORE A PARTIR DE SENS./ESPEC. REPORTADES.

Sistema	Tipus d'entrada	Sens.	Espec.	AUC	Bal.Acc.
<i>Guies i puntuació clínica</i>					
JSCCR [3]	Guia clínica	100%	19%	0,596	59,5%
NCCN	Guia clínica	98%	52%	0,749	75,0%
ESMO [5]	Guia clínica	98%	50%	0,743	74,0%
IBC Score [4]	Puntuació histopat.	90%	26%	0,68	58,0%
<i>Models d'IA</i>					
LASSO [19]	Var. clinicopatol.	100%	85,8%	0,960	92,9%
GAT (aquest TFG, llindar 0,5)	Imatge WSI	87,5%	87,5%	0,925	87,5%
GAT (aquest TFG, llindar $t^*=0,261$)[†]	Imatge WSI	100%	77,5%	0,925	88,7%

[†] t^* s'ha determinat exclusivament sobre el val set del fold del model (sense *data leakage* del test).

sense esperar el report patològic, i LASSO requereix les variables ja anotades.

10.3 Limitacions

(1) **Mida del test.** Amb 56 pacients al test, els intervals de confiança al 95% de l'AUC són amplis; l'AUC CV $0,860 \pm 0,061$ sobre cinc *folds* és la xifra més honesta del rendiment esperat.

(2) **Absència de validació externa.** El dataset prové de 26 hospitals espanyols, però no s'ha provat sobre dades d'un centre independent. Campanella et al. [24] reporten, en models MIL de patologia, caigudes de 3–6 punts d'AUC en escàners externs i fins a 7 punts en canvis de domini institucional. L'aplicabilitat clínica requereix, per tant, validació externa.

(3) **Desbalanceig de prevalença.** La prevalença N1 al test (28,6%) supera la clínica real ($\sim 8\text{--}15\%$); el VPP s'ha d'interpretar amb cautela (Discussió Comparativa).

(4) **Selecció del llindar i biaix del val set.** Al llindar 0,5, dos N1 (de 16) queden sense detectar al test. Per maximitzar la sensibilitat, s'ha buscat el primer punt de la corba ROC del val set del fold del millor model en què $TPR=1,0$, obtenint $t^* = 0,261$. Aplicat al test (sense reajustar), dona $Sens.=100\%$ amb $Espec.=77,5\%$. El val set ja s'havia usat per a *early stopping* i selecció del checkpoint, per la qual cosa t^* pot tenir un biaix optimista lleuger; idealment, hauria de fixar-se sobre un val set extern.

10.4 Treball Futur

Optimització dirigida d'hiperparàmetres. La cerca actual ha cobert els eixos estructurals (arquitectura, *pooling*, MIL, h , H , *dropout*, λ_{wd} , *learning rate*) amb 255 configuracions de validació creuada 5-fold. Un pas natural seria explorar de manera més fina la regió òptima identificada (*attention pooling*, $H \in \{2,4\}$, $\lambda_{wd} = 10^{-3}$, $lr \in [10^{-4}, 3 \cdot 10^{-4}]$) per millorar la calibració del model i reduir la variabilitat entre folds.

Supervisió amb màscares d'anotació. Les màscares de displàsia i infiltració anotades per la Dra. Musulén podrien fer-se servir per guiar els pesos d'atenció del GAT: les

regions anotades haurien de rebre més atenció que les zones sanes. Tourniaire et al. [25] mostren que fins i tot amb un nombre limitat d'anotacions parcials es pot millorar la localització i la classificació del model.

Comparació de connectivitats. En el marc del mateix projecte, un altre estudiant treballa en paral·lel en un model on la matriu d'adjacència es construeix a partir de la **distància entre les característiques** dels *patches*, sense triangulació de Delaunay ni relacions espacials. Comparar els dos models sobre el mateix conjunt de dades permetrà valorar si la topologia espacial aporta avantatge real respecte d'una connectivitat basada en similitud de *features*.

REFERÈNCIES

[1] Sociedad Española de Oncología Médica (SEOM). *Las Cifras del Cáncer en España 2026*. Consultat el 6 de febrer de 2026. 2026. URL: <https://seom.org/prensa/el-cancer-en-cifras>.

[2] Unitat Funcional Càncer Colorectal. *Protocol de Pràctica Clínica del Càncer de Còlon i Recte*. Actualització de la 3^a edició. Parc de Salut MAR Barcelona - Hospital del Mar. Barcelona, juny de 2013. URL: https://www.hospitaldelmar.cat/media/upload/arxius/unitats/cancer_colorectal/protocols/practica_clinica.pdf.

[3] Yojiro Hashiguchi et al. "Japanese Society for Cancer of the Colon and Rectum (JSCCR) guidelines 2019 for the treatment of colorectal cancer". A: *International Journal of Clinical Oncology* 25.1 (2020), pàg. 1-42. DOI: 10.1007/s10147-019-01485-z. URL: <https://doi.org/10.1007/s10147-019-01485-z>.

[4] Heather Dawson et al. "Lymph node metastases and recurrence in pT1 colorectal cancer: Prediction with the International Budding Consortium Score — a retrospective, multi-centric study". A: *United European Gastroenterology Journal* 12.3 (2024), pàg. 299-308. DOI: 10.1002/ueg2.12521.

- URL: <https://doi.org/10.1002/ueg2.12521>.
- [5] Pedro Pimentel-Nunes et al. "Endoscopic submucosal dissection for superficial gastrointestinal lesions: European Society of Gastrointestinal Endoscopy (ESGE) Guideline – Update 2022". A: *Endoscopy* 54.6 (2022), pàg. 591-622. DOI: 10.1055/a-1811-7025. URL: <https://doi.org/10.1055/a-1811-7025>.
 - [6] Dario Zaffalon et al. "Dilemmas in the Clinical Management of pT1 Colorectal Cancer". A: *Cancers* 15.13 (2023), pàg. 3511. DOI: 10.3390/cancers15133511. URL: <https://doi.org/10.3390/cancers15133511>.
 - [7] Fernando Martínez de Juan, Samuel Navarro i Isidro Machado. "Refining Risk Criteria May Substantially Reduce Unnecessary Additional Surgeries after Local Resection of T1 Colorectal Cancer". A: *Cancers* 16.13 (2024), pàg. 2321. DOI: 10.3390/cancers16132321.
 - [8] Petar Veličković et al. *Graph Attention Networks*. 2018. arXiv: 1710.10903 [stat.ML]. URL: <https://arxiv.org/abs/1710.10903>.
 - [9] Maximilian Ilse, Jakub M. Tomczak i Max Welling. *Attention-based Deep Multiple Instance Learning*. 2018. arXiv: 1802.04712 [cs.LG]. URL: <https://arxiv.org/abs/1802.04712>.
 - [10] Ming Y. Lu et al. *Data Efficient and Weakly Supervised Computational Pathology on Whole Slide Images*. 2020. arXiv: 2004.09666 [eess.IV]. URL: <https://arxiv.org/abs/2004.09666>.
 - [11] Bin Li, Yin Li i Kevin W. Eliceiri. *Dual-stream Multiple Instance Learning Network for Whole Slide Image Classification with Self-supervised Contrastive Learning*. 2021. arXiv: 2011.08939 [cs.CV]. URL: <https://arxiv.org/abs/2011.08939>.
 - [12] Holger S. Muti, Christoph Röcken, Hans-Michael Behrens et al. "Deep learning trained on lymph node status predicts outcome from gastric cancer histopathology: a retrospective multicentric study". A: *European Journal of Cancer* 194 (2023), pàg. 113335. DOI: 10.1016/j.ejca.2023.113335.
 - [13] Guillaume Jaume et al. *HistoCartography: A Toolkit for Graph Analytics in Digital Pathology*. 2021. arXiv: 2107.10073 [eess.IV]. URL: <https://arxiv.org/abs/2107.10073>.
 - [14] Daniele Grattarola et al. "Understanding Pooling in Graph Neural Networks". A: *IEEE Transactions on Neural Networks and Learning Systems* 35.2 (febr. de 2024), pàg. 2708-2718. ISSN: 2162-2388. DOI: 10.1109/tnnls.2022.3190922.
 - [15] Rex Ying et al. *Hierarchical Graph Representation Learning with Differentiable Pooling*. 2019. arXiv: 1806.08804 [cs.LG]. URL: <https://arxiv.org/abs/1806.08804>.
 - [16] Richard J. Chen et al. "Towards a general-purpose foundation model for computational pathology". A: *Nature Medicine* 30.3 (març de 2024), pàg. 850-862. DOI: 10.1038/s41591-024-02857-3.
 - [17] Ming Y. Lu et al. "A visual-language foundation model for computational pathology". A: *Nature Medicine* 30.3 (març de 2024), pàg. 863-874. DOI: 10.1038/s41591-024-02856-4.
 - [18] Fumiaki Tanino et al. "Comparative prediction of lymph node metastasis in pT1 colorectal cancer among Western and Japanese guidelines". A: *Frontiers in Oncology* 14 (2024), pàg. 1475270. DOI: 10.3389/fonc.2024.1475270. URL: <https://www.frontiersin.org/journals/oncology/articles/10.3389/fonc.2024.1475270>.
 - [19] Zhenghu Piao, Ruiquan Ge i Ling Lu. "An artificial intelligence prediction model outperforms conventional guidelines in predicting lymph node metastasis of T1 colorectal cancer". A: *Frontiers in Oncology* 13 (2023), pàg. 1229998. DOI: 10.3389/fonc.2023.1229998. URL: <https://doi.org/10.3389/fonc.2023.1229998>.
 - [20] Pau Martí Escolà. "Anàlisi d'espais de representació profunds pel diagnòstic del carcinoma colorectal en histopatologia digital". Treb. fin. de màst. Universitat Autònoma de Barcelona, 2025. URL: <https://ddd.uab.cat/record/317556>.
 - [21] Matthias Fey i Jan Eric Lenssen. *Fast Graph Representation Learning with PyTorch Geometric*. 2019. arXiv: 1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.
 - [22] Junhyun Lee, Inyeop Lee i Jaewoo Kang. *Self-Attention Graph Pooling*. 2019. arXiv: 1904.08082 [cs.LG]. URL: <https://arxiv.org/abs/1904.08082>.
 - [23] David M. et al. *Implementació de Graph Attention Networks per a la detecció de metàstasi en pT1*. 2026. URL: <https://github.com/IAM-CVC/PT1Diagnosis> (cons. 03-05-2026).
 - [24] Gabriele Campanella et al. "Clinical-grade computational pathology using weakly supervised deep learning on whole slide images". A: *Nature Medicine* 25.8 (2019), pàg. 1301-1309. DOI: 10.1038/s41591-019-0508-1. URL: <https://doi.org/10.1038/s41591-019-0508-1>.
 - [25] Paul Tourniaire et al. "MS-CLAM: Mixed supervision for the classification and localization of tumors in Whole Slide Images". A: *Medical Image Analysis* 85 (2023), pàg. 102763. DOI: 10.1016/j.media.2023.102763.

A DIAGRAMA DE FLUX DEL *pipeline*




Fig. 6: Diagrama de flux del *pipeline* complet. *Blocs grisos*: etapes realitzades pels companys de l'equip i dades de referència. *Blocs blaus*: contribucions d'aquest TFG. La fletxa $\times S$ indica que les S seccions d'un pacient es processen com a grafs independents i les $P(N1)$ s'agreguen via MIL per obtenir el diagnòstic per pacient, que es compara amb el diagnòstic real de l'Excel.

B EFECTES PRINCIPALS DELS HIPERPARÀMETRES

La Taula 5 mostra l'efecte de cada factor sobre l'AUC, ordenat per rang d'influència. Les tres primeres files corresponen a decisions arquitectòniques avaluades sobre la cerca exploratòria inicial ($n = 48$ configuracions, AUC de validació), on aquests eixos sí que es van variar conjuntament. Les sis darreres corresponen al subgrup de configuracions amb la millor base (GAT Baseline + grafs per secció + agregació *mean*; $n = 248$), avaluat amb validació creuada 5-fold (AUC CV mitjana). El *rang* és la diferència entre el millor i el pitjor nivell de cada factor.

TAULA 5: EFECTES PRINCIPALS DE CADA HIPERPARÀMETRE SOBRE L'AUC. FILES SUPERIORS ($n = 48$, AUC VAL): DECISIONS ARQUITECTÒNIQUES DE LA CERCA INICIAL. FILES INFERIORS ($n = 248$, AUC CV DE 5-FOLD): HIPERPARÀMETRES DEL SUBGRUP AMB LA MILLOR BASE. RANGS ORDENATS PER MAGNITUD DECREIXENT DINS DE CADA BLOC.

Factor	Nivell	n	AUC (mitjana $\pm$ std)	Rang
Decisions arquitectòniques (n=48, AUC val)				
Agregació MIL	attention	12	0,834 $\pm$ 0,060	0,206
	mean	24	0,702 $\pm$ 0,177	
	noisy-OR	12	0,628 $\pm$ 0,142	
Tipus de graf	per secció	36	0,752 $\pm$ 0,147	0,143
	mega (per pacient)	12	0,609 $\pm$ 0,167	
Arquitectura	GAT Baseline	32	0,749 $\pm$ 0,158	0,097
	GAT+DiffPool	16	0,652 $\pm$ 0,158	
Hiperparàmetres d'optimització i regularització (n=248, AUC CV)				
Heads (H)	2	108	0,833 $\pm$ 0,015	0,253
	4	104	0,830 $\pm$ 0,019	
	8	36	0,580 $\pm$ 0,167	
Hidden (h)	128	106	0,830 $\pm$ 0,017	0,062
	256	142	0,768 $\pm$ 0,139	
λ_{wd}	10^{-3}	72	0,831 $\pm$ 0,018	0,052
	10^{-4}	90	0,781 $\pm$ 0,128	
	0	86	0,779 $\pm$ 0,127	
Pooling	attention	124	0,811 $\pm$ 0,035	0,033
	mean_max	124	0,779 $\pm$ 0,150	
Learning rate	$3 \cdot 10^{-4}$	84	0,801 $\pm$ 0,107	0,016
	10^{-4}	80	0,798 $\pm$ 0,108	
	$3 \cdot 10^{-5}$	84	0,785 $\pm$ 0,115	
Dropout	0,1	84	0,799 $\pm$ 0,101	0,007
	0,2	84	0,794 $\pm$ 0,106	
	0,3	80	0,791 $\pm$ 0,124	