

Predicció de Metàstasi en Histopatologia en Càncer Colorrectal usant Graph Attention Networks

David Morillo Massagué

Resum— Es presenta un sistema de classificació N0/N1 per a la detecció de metàstasi en ganglis limfàtics en càncer colorrectal pT1 a partir de *Whole Slide Images*. El teixit es representa com un **graf espacial** sobre les coordenades dels *patches*, de manera que es preserva la topologia real del teixit. Cada node és un *patch* de 2048×2048 px representat per l'embedding CLS (vector de forma $[1, 1536]$) del model UNI2. Es comparen dues arquitectures configurables: un GAT de referència amb *readout* pla (mean, max, mean_max o attention) i un GAT amb **DiffPool jeràrquic** intercalat ($N \rightarrow \dots \rightarrow K_{L_{DP}}$ super-nodes) per obtenir representacions a múltiples escales. El diagnòstic per pacient s'obté per agregació MIL sobre les seccions. La cerca d'hiperparàmetres combina dos estudis Optuna TPE aïllats per arquitectura (5-fold CV + retrain 90/10 de les millors configuracions obtingudes). El millor model és un **GAT Baseline**, que obté AUC test = 0,875, sensibilitat 100% i especificitat 57,5% al llindar derivat del val set, detectant els 16 casos N1 del conjunt de test ($n = 56$ pacients; 367 pacients efectius en total).

Paraules clau— Càncer colorrectal pT1, Histopatologia digital, Graph Attention Networks, DiffPool jeràrquic, Graf espacial de Delaunay, MIL, Desbalanceig de classes.

Abstract— We present an N0/N1 classification system for lymph node metastasis prediction in pT1 colorectal cancer from Whole Slide Images. Tissue is represented as a **spatial graph** over patch coordinates, preserving the real spatial topology of the tissue. Each node is a 2048×2048 px patch represented by a CLS embedding of shape $[1, 1536]$ from the UNI2 model. Two configurable architectures are compared: a **GAT baseline** with flat readout (mean, max, mean_max or attention) and a **GAT+DiffPool** model with L_{DP} DiffPool blocks interleaved between GAT layers ($N \rightarrow \dots \rightarrow K_{L_{DP}}$ super-nodes) for multi-scale representations. Patient-level diagnosis is obtained via MIL aggregation over histological sections. Hyperparameter search combines two isolated Optuna TPE studies (one per architecture) (5-fold CV + 90/10 retraining of the best configurations). The best model is a **GAT Baseline**, achieving test AUC = 0.875, sensitivity 100% and specificity 57.5% at the validation-derived threshold, detecting all 16 N1 cases of the test set ($n = 56$ patients; 367 effective patients overall).

Keywords— pT1 colorectal cancer, Digital histopathology, Graph Attention Networks, Hierarchical DiffPool, Spatial Delaunay graph, Multiple Instance Learning, Class imbalance.

1 INTRODUCCIÓ

EL càncer colorrectal (CCR) és un dels reptes de salut pública més greus del nostre entorn. A Espanya, la SEOM preveu per al 2026 uns **44.132** nous diagnòstics, fet que el converteix en el tumor més freqüent i

en la segona causa de mort per càncer, amb 14.629 defuncions [1].

El carcinoma pT1 és especialment complex: el tumor ha envaït la submucosa però no la muscular pròpia, i el risc de metàstasi als ganglis limfàtics (LNM, de l'anglès *lymph node metastasis*) oscil·la entre el **2%** i el **23%** depenent de la profunditat d'invasió [2]. Quan hi ha criteris de mal pronòstic (**invasió submucosa $\geq 1000 \mu\text{m}$, invasió vascular o limfàtica, histologia indiferenciada, tumor budding de grau ≥ 2 o marge vertical positiu** [3, 4]), el risc puja al voltant del 10%, fet que porta les guies clíniques (JSCCR

- E-mail de contacte: David.MorilloMa@autonoma.cat
- Treball tutoritzat per: Debora Gil Resina (DCC)
- Curs 2025/26

[3], NCCN i ESMO [5]) a recomanar cirurgia radical addicional. Com que la majoria de tumors pT1 no desenvolupa LNM real, s'estima que **fins un 80%** d'aquestes cirurgies són innecessàries [6, 7].

La histopatologia digital va néixer cap a finals dels anys 1990 amb els primers escàners de làmina sencera, i des de mitjans de la dècada de 2010 s'hi apliquen models d'aprenentatge profund per ajudar el patòleg [8]. Mitjançant les *Whole Slide Images* (WSI), aquesta disciplina permet aplicar tècniques avançades de visió per computador. En concret, les *Graph Neural Networks* (GNN) permeten modelar el teixit com una estructura espacial, i les *Graph Attention Networks* (GAT) [9] en són una evolució que afegeix un mecanisme d'atenció per ponderar de manera diferent cada veí. Una decisió clau en la construcció del graf és el criteri de les arestes: alguns treballs les basen en la *similitud de característiques* entre *patches*; aquest treball opta per la **proximitat espacial** (triangulació de Delaunay sobre coordenades WSI), preservant la topologia real del teixit. El projecte, desenvolupat al CVC [10] sota la supervisió de la Dra. Debora Gil, compara un GAT de referència amb *readout* pla contra un model amb *pooling* jeràrquic (DiffPool) intercalat, i proposa diferents estratègies d'agregació MIL (*Multiple Instance Learning*, aprenentatge per múltiples instàncies) per al diagnòstic per pacient.

Dues raons justifiquen aquest treball. Des del punt de vista clínic, els sistemes d'IA poden detectar patrons subtils de manera consistent (sovint superant a les guies clíniques) i ajudar a reduir cirurgies innecessàries. Des del punt de vista tècnic, combinar xarxes d'atenció sobre grafs amb aprenentatge profund en dades reals és la intersecció entre teoria de grafs i deep learning que vull explorar dins de l'Enginyeria de Dades.

2 OBJECTIUS

- Construir un *pipeline* complet de classificació N0/N1 sobre WSI reals a partir d'embeddings CLS del model UNI2, basat en **grafs espacials** (triangulació de Delaunay sobre coordenades del teixit).
- Comparar un GAT de referència amb *readout* pla contra un model amb **DiffPool jeràrquic** intercalat entre capes GAT, avaluant si la reducció progressiva del graf aporta millores de representació intra-secció.
- Implementar i comparar estratègies d'agregació MIL a nivell de pacient per integrar les prediccions de múltiples seccions histològiques.

3 ESTAT DE L'ART

3.1 Classificació de WSI amb MIL

Les *Whole Slide Images* tenen resolucions de fins a $150\,000 \times 150\,000$ píxels i no es poden processar directament amb xarxes convencionals. L'enfocament habitual és dividir la làmina en *patches* petits i treballar amb MIL, on el model ha d'inferir l'etiqueta global (N0/N1) a partir de fragments sense etiqueta individual. Ilse et al. [11] van proposar l'agregació per atenció (*attention-based MIL*), que aprèn quins *patches* són més rellevants per al diagnòstic. Lu

et al. [12] van aplicar aquest mètode a conjunts de dades clínics reals (CLAM), i Li et al. [13] van proposar DSMIL, que combina dues branques, a nivell de *patch* i de làmina, amb aprenentatge contrastiu. La predicció de metàstasi ganglionar a partir d'histopatologia s'ha estudiat en altres càncers: Muti et al. [14] mostren que és possible predir l'estat N0/N1 a partir de làmines de càncer gàstric, amb resultats prometedors.

3.2 Grafs i GNN en Patologia Digital

Les GNN permeten tractar el teixit com una estructura on les regions estan connectades segons la seva proximitat, capturant relacions espacials que les xarxes neuronals convolucionals (CNN) no modelen directament. Jaume et al. [15] van presentar HistoCartography, un entorn de treball per a l'anàlisi de grafs en patologia digital, amb resultats que mostren millores respecte de les CNN en classificació de biòpsies. Les GAT [9] afegeixen un mecanisme d'atenció que permet al model ponderar cada veí de manera diferent, cosa especialment útil en histopatologia on no totes les regions del teixit aporten la mateixa informació. Pel que fa al *pooling* en grafs, Grattarola et al. [16] revisen els principals mètodes existents, entre ells DiffPool [17], que agrupa nodes en super-nodes de manera progressiva.

3.3 Models de Fundació per a Histopatologia

En els darrers anys han aparegut *foundation models* preentrenats específicament sobre dades de patologia, que generen embeddings molt més informatius que les CNNs genèriques. UNI2 [18] és un *vision transformer* (ViT) entrenat sobre més de 100 milions de *patches* de 20 tipus de teixit, amb bons resultats en nombroses tasques de classificació histopatològica. CONCH [19] és un model similar que incorpora a més alineament entre imatge i text. En aquest projecte s'utilitzen els embeddings de UNI2 com a vector de característiques de cada node, ja que estan preentrenats en el mateix domini i capturen informació morfològica rellevant.

3.4 Guies Clíniques i Models Predictius per a pT1 CRC

Les guies clíniques de referència (JSCCR [3], NCCN i ESMO [5]) recomanen cirurgia addicional quan el pacient presenta un o més dels criteris de risc histopatològics esmentats a la Introducció. Malgrat la seva sensibilitat elevada, la seva especificitat és baixa: en un estudi comparatiu sobre 560 pacients [20], les AUC reportades són 0,596 (JSCCR), 0,749 (NCCN) i 0,743 (ESMO)¹, amb especificitats del 19%, 52% i 50% respectivament, la qual cosa implica que més del 80% dels pacients operats no tenien LNM real [20, 6].

Paral·lelament, Piao et al. [21] van proposar un model d'IA sobre variables clinicopatològiques ($n = 546$ entrenament, $n = 105$ test) basat en gradient boosting (*LightGBM*), obtenint sensibilitat del 100%, especificitat del 85,8%, AUC de 0,960 i *balanced accuracy* del 92,9%; la taxa de pacients classificats com a alt risc es va reduir del 83,8% (JSCCR) al 20,9%. Dawson et al. [4] van proposar l'IBC

¹En ser classificadors binaris, l'AUC d'una guia equival a (sens + espec)/2 (*balanced accuracy*).

Score, una puntuació ponderada sobre invasió limfovacular, grau de *tumor budding*, profunditat d'invasió i grau tumoral, que obté AUC de 0,68 sobre 565 pacients. A diferència d'aquests treballs, aquest TFG fa la predicció exclusivament a partir de la **imatge histopatològica** (WSI), sense variables clíniques estructurades ni puntuació manual d'un patòleg.

3.5 Treball Previ al CVC sobre pT1 CRC

Aquest treball s'integra dins una línia de recerca del grup IAM del CVC. Martí et al. [22] van comparar CNNs, ViTs i GNNs sobre el mateix conjunt pT1 CRC per a la classificació de *patches* individuals, amb millor AUC ($0,954 \pm 0,077$) per una arquitectura híbrida ViT+NN. El treball, però, opera a nivell de *patch* i no té en compte la topologia espacial del teixit ni el diagnòstic per pacient. Aquest TFG parteix dels embeddings CLS del model UNI2 per construir grafs espacials de les seccions i aborda el problema des d'una perspectiva MIL per pacient.

4 DADES I PREPROCESSAMENT

Aquest projecte es realitza en col·laboració amb un equip de la UAB que cobreix des del preprocessament de dades, o la creació d'autoencoders alternatius per a l'extracció de característiques, per una posterior classificació amb diversos models.

4.1 Imatges de Gran Format (WSI)

Les dades originals consisteixen en imatges de làmines senceres (WSI) obtingudes amb escàners d'alta resolució i tintades amb hematoxilina-eosina, emmagatzemades en format MIRAX (.mrxs). Les dimensions oscil·len entre els 30.000 i els 150.000 píxels per costat, amb una quantitat significativa d'espai buit o artefactes que requereixen tractament previ.

El conjunt de dades efectiu comprèn **1.607 grafs** (un per secció histològica), provinents de **367 pacients** distribuïts de forma desequilibrada entre les dues classes (Taula 1). D'un total de 606 pacients a la base de dades clínica, 236 es descarten per diagnòstic indeterminat (NX), i dels 370 restants amb diagnòstic vàlid, 3 no disposen d'embeddings UNI2 generats, deixant 367 pacients usables. Les mostres es divideixen en un pool d'entrenament+validació (85%) i un conjunt de test fix (15%), ambdós estratificats a nivell de pacient. Dins del pool s'aplica validació creuada 5-fold per a la cerca d'hiperparàmetres (Secció 7.3).

4.2 Anotacions i Màscara de Segmentació

La Dra. Eva Musulén, patòloga especialitzada, ha realitzat les anotacions manualment amb el programari *Labelme*. Aquestes identifiquen tres categories d'afectació:

- **Infiltració:** teixit anormal que envaeix zones no corresponents.
- **Displàsia:** cèl·lules anormals que poden convertir-se en canceroses.

- **Infiltració + Displàsia:** usat en casos de dubte diagnòstic.

A partir d'aquestes s'obtenen màscares de segmentació codificades per color: vermell (infiltració), blau (displàsia) i verd clar (combinada).




Fig. 1: Exemple de WSI i la seva corresponent màscara de segmentació.

4.3 Extracció de Patches i Embeddings CLS

S'aplica una finestra lliscant (*sliding window*) sense solapament per dividir cada làmina en *patches* de 2048×2048 píxels a resolució completa. Per cada finestra, es comprova el percentatge de teixit a la corresponent regió de la màscara binària anotada (§4.2); les finestres sense cap píxel de teixit (*tissue_percentage* = 0) es descarten.

El model UNI2 [18] processa cada *patch* individualment i extreu el token *CLS* de la seva sortida, obtenint un vector de forma $[1, 1536]$ que condensa la informació morfològica i textural del patch. Cada vector CLS resultant passarà a formar un node, conservant les coordenades del patch per a la posterior construcció del graf.

5 CONSTRUCCIÓ DEL GRAF

5.1 Model de dades: dimensions i estructures

Formalment, cada secció histològica es representa com un graf $\mathcal{G} = (\mathbf{X}, \mathbf{A})$ on:

- $\mathbf{X} \in \mathbb{R}^{N \times 1536}$ és la matriu de característiques dels N nodes (*patches*).
- $\mathbf{A} \in \{0, 1\}^{N \times N}$ és la matriu d'adjacència construïda per triangulació de Delaunay i posterior poda d'arestes llargues.

Estratègia adoptada: un graf per secció. Cada secció genera un graf independent; les S seccions d'un pacient es processen per separat i les probabilitats $\{P(N1_i)\}_{i=1}^S$ s'agreguen via MIL (Secció 7.1). Com a alternativa es va explorar un *mega-graf* per pacient (bloc-diagonal de totes les seccions, sense arestes entre elles), però va donar resultats inferiors, probablement per forçar un únic *pooling* global sobre teixits físicament inconnexos.

TAULA 1: COMPOSICIÓ DEL DATASET (26 HOSPITALS). ELS GRAFS CORRESPONEN A SECCIONS HISTOLÒGIQUES INDIVIDUALS. EL POOL (85%) S'UTILITZA PER A LA CERCA D'HIPERPARÀMETRES AMB VALIDACIÓ CREUADA 5-FOLD; EL TEST (15%) PER A L'AVALUACIÓ FINAL.

Partició	Pacients			Grafs (seccions)		
	N0	N1	Total	N0	N1	Total
Pool (train+val CV)	224	87	311	1 133	219	1 352
Test	40	16	56	212	43	255
Total	264	103	367	1 345	262	1 607

5.2 Connectivitat per triangulació de Delaunay

Els centres dels *patches* formen una quadrícula regular, però connectar-los amb una reixeta fixa no és suficient: la màscara deixa forats de teixit irregulars que en trenquen la simetria. Per això es connecten els nodes amb una **triangulació de Delaunay** sobre les seves coordenades, que s'adapta a qualsevol distribució. Després es poden les arestes en dos passos: s'eliminen les que travessen píxels de fons (màscara = 0), per no unir regions separades per espai buit, i les que superen el doble de la longitud mitjana, per evitar connexions massa llargues. El resultat (Figura 2, amb les arestes podades en vermell) és una malla local entre *patches* veïns.

6 ARQUITECTURA DEL MODEL

6.1 Visió general del pipeline

El sistema encadena set mòduls: (i) lectura del WSI, (ii) extracció de *patches* 2048×2048, (iii) càlcul de l'embedding CLS de forma [1, 1536] amb el model *foundation* UNI2, (iv) construcció del graf de Delaunay per secció amb poda d'arestes llargues, (v) propagació amb L capes GAT i *pooling* (pla o jeràrquic amb DiffPool), (vi) agregació MIL intersecció per pacient, i (vii) decisió mitjançant un llinar t^* derivat del *validation set*.

Les seccions següents descriuen el model (GAT, pooling pla i jeràrquic), l'agregació MIL i el procediment d'entrenament.

6.2 GATClassifier

El model implementat, *GATClassifier*, és un classificador de grafs que alterna capes **Graph Attention Network** (*GATConv* [9, 23]) amb capes de *pooling* jeràrquic per a la classificació binària N0/N1. L'arquitectura és completament parametrizable: el nombre de capes GAT, el nombre de blocs DiffPool intercalats i la dimensió oculta es trien com a hiperparàmetres. Quan s'utilitza DiffPool, cada bloc inserit entre capes GAT redueix el graf de N_ℓ nodes a K_ℓ super-nodes: $(\mathbf{X}^{(0)}, \mathbf{A}^{(0)}) \xrightarrow{\text{GAT+Pool}} \dots \xrightarrow{\text{GAT+readout}} \mathbf{h}_s$. Tot el model s'entrena de forma **end-to-end**: un únic pas de retropropagació propaga els gradients des del capçal MLP fins a les primeres capes GAT. La Figura 3 mostra la comparació visual de les dues arquitectures.

Mecanisme d'atenció. A diferència de les xarxes convolucionals clàssiques sobre grafs que tracten tots els veïns d'un node de forma uniforme, GAT aprèn a assignar pesos d'importància diferenciats a cada veí. Donada la representació $\mathbf{h}_i$ del node i , per a cada parella de nodes veïns (i, j)

es calcula un coeficient d'atenció:

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j])$$

on $\mathbf{W}$ és una transformació lineal aprenible, $\parallel$ la concatenació i $\mathbf{a}$ un vector aprenible. Els coeficients es normalitzen amb *softmax* sobre tots els veïns:

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$

i la nova representació del node s'obté com la suma ponderada:

$$\mathbf{h}'_i = \sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W}\mathbf{h}_j$$

Multi-cap i no-linealitat. Per incrementar la capacitat expressiva, cada capa usa H caps d'atenció independents (*heads*), parametritzats per $\mathbf{W}^{(h)}$ i $\mathbf{a}^{(h)}$. Les sortides es concatenen a les capes intermèdies i es promitgen a la darrera. La capa *GATConv* no aplica activació final dins de la pròpia capa; la no-linealitat es fa per fora com *Batch-Norm* $\rightarrow$ *ELU* $\rightarrow$ *Dropout*. L'única no-linealitat interna és la *LeakyReLU* del càlcul de e_{ij} .

Profunditat de la xarxa. El nombre de capes GAT, L , és un eix d'optimització: $L \in \{2, 3, 4\}$ per al model *baseline*; per a la variant amb DiffPool, L ve determinat per $L = L_{\text{DP}} + 1$, intercalant cada GAT amb un pas de *pooling* (vegeu §6.3).

El capçal MLP (*Linear* $\rightarrow$ *ReLU* $\rightarrow$ *Dropout* $\rightarrow$ *Linear*) transforma la representació global del graf en els logits N0/N1.

Per obtenir aquesta representació global s'implementen dues estratègies de *pooling* configurables: una de **plana** (*readout*), que agrega tots els nodes de la darrera capa GAT sense reduir el graf, i una de **jeràrquica** (DiffPool intercalat), que col·lapsa progressivament el graf en super-nodes abans del *readout*. Les dues subseccions següents les detallen.

6.3 Estratègies de Pooling Pla (Readout)

Quan no s'utilitza pooling jeràrquic, les representacions dels nodes de la darrera capa GAT s'agreguen directament amb una operació de *readout* global, sense reduir el graf: *mean*, *max* o *mean_max*; i *attention*, que aprèn un pes escalar per node via una capa lineal seguida de *softmax* i agrega per suma ponderada. Tot i la seva eficiència, aquestes estratègies ignoren la topologia del graf i col·lapsen tota la informació espacial en un sol pas.




Fig. 2: Etapes del preprocessament per a la construcció del graf. D'esquerra a dreta: WSI original → extracció de *patches* de 2048×2048 px per finestra lliscant + filtratge → extracció de l'embedding CLS de forma $[1, 1536]$ per UNI2 (un vector per *patch*) → construcció del graf de Delaunay sobre la màscara anotada, on les arestes en vermell han estat eliminades pel filtre de màscara

6.4 Pooling Jeràrquic: DiffPool entre Capes GAT

Per superar les limitacions del *readout* pla, s'implementa **DiffPool** [17] com a operació intermèdia entre les capes GAT. La idea és **agrupar els nodes en super-nodes** i substituir el graf per un de més petit; repetint-ho diverses vegades s'obté una representació del teixit a múltiples escales.

Cada bloc DiffPool aprèn, per a cada node, una **assignació suau** (*soft assignment*) als K super-nodes del nivell següent: en comptes d'enviar cada node a un sol grup, en reparteix la pertinença entre tots els grups amb pesos que sumen 1 (la sortida d'un petit MLP per node seguida de *softmax*). A partir d'aquesta assignació, les *features* dels nodes s'agreguen com a mitjana ponderada per formar les dels super-nodes, i les arestes originals es projecten al nou graf. Així el graf passa de N a $K \ll N$ nodes conservant una versió comprimida de la seva estructura.

Profunditat configurable. El nombre de blocs DiffPool intercalats és un eix d'optimització, $L_{DP} \in \{1, 2, 3\}$, amb una capa GAT abans, entre i després de cada un (total $L_{DP} + 1$ capes GAT). El nombre de super-nodes es fixa per nivell; el *readout* final sobre els $K_{L_{DP}}$ super-nodes és també configurable (mean, max, mean_max o attention), de manera anàloga al model *baseline*.

Pèrdua auxiliar. Per cada bloc s'afegeixen dos termes de regularització sobre l'assignació apresca: un que empeny a agrupar junts els nodes veïns i un altre (d'entropia) que fa que cada node s'assigni de manera neta a pocs grups. La pèrdua total és la *cross-entropy* de classificació més λ_{aux} vegades aquests termes, amb λ_{aux} com a eix d'optimització.

Com a alternativa, SAGPool [24] selecciona els K nodes més rellevants via puntuacions d'auto-atenció (selecció discreta, no assignació suau); s'ha preferit DiffPool per la seva expressivitat contínua i la pèrdua auxiliar de regularització.

7 METODOLOGIA

7.1 Agregació per Pacient (MIL)

El diagnòstic és per **pacient**, no per làmina. Una mateixa secció histològica pot no presentar senyals visibles de metàstasi si s'analitza aïlladament, mentre que en una altra

secció del mateix pacient sí que és apreciable. Si s'entrena a nivell de làmina, les seccions N1 de pacients N1 que no mostren metàstasi visible reben un senyal de supervisió incorrecte (N0), contaminant l'entrenament.

Per evitar aquest problema, s'utilitza el paradigma d'**aprenentatge per múltiples instàncies** (*Multiple Instance Learning*, MIL): cada pacient es tracta com un *bag* i totes les seves làmines comparteixen la mateixa etiqueta. El model aprèn a classificar el pacient a partir de les seves seccions, sense necessitat d'etiquetes individuals per làmina.

Donades les probabilitats $\{p_i = P(N1_i)\}_{i=1}^S$ de les S làmines d'un pacient, s'implementen quatre estratègies d'agregació:

- **Mean:** $P(N1_p) = \frac{1}{S} \sum_i p_i$. Mitjana aritmètica.
- **Noisy-OR:** $P(N1_p) = 1 - \prod_{i=1}^S (1 - p_i)$. N'hi ha prou amb una làmina amb metàstasi per marcar el pacient com N1.
- **Max:** $P(N1_p) = \max_i p_i$. Conservadora, basada en l'evidència màxima.
- **Attention MIL:** pes d'atenció aprenent (*gated attention* d'Ilse et al. [11]) per a cada làmina a partir del seu embedding GAT, i suma ponderada dels embeddings per obtenir la representació del pacient.

7.2 Desbalanceig de Classes i Llindar Operatiu

El conjunt presenta un fort desbalanceig ($N0/N1 \approx 72/28$). En detecció de metàstasi, un fals negatiu és més greu que un fals positiu: l'objectiu clínic és maximitzar l'especificitat mantenint sensibilitat $\approx 100\%$, per reduir les cirurgies innecessàries sense perdre cap N1. S'apliquen tres mecanismes complementaris:

- **Partició estratificada** per pacient (manté la proporció $N0/N1$ a cada subconjunt).
- **Pesos a la cross-entropy** amb pes positiu w_+ (multiplicador del gradient per a la classe N1) com a eix d'optimització, $w_+ \in [1, 5, 8]$.




Fig. 3: Comparació visual de les dues arquitectures configurables (una instància de cada branca amb dues capes de processament). **Dalt:** GAT Baseline, on dues capes d'atenció operen sobre els N nodes originals i un *readout* global produeix l'embedding final. **Baix:** GAT+DiffPool amb dos blocs DiffPool ($L_{DP} = 2$, és a dir tres capes GAT intercalades), que col·lapsen progressivament el graf fins al dos super-nodes finals, en aquest cas.

- **Llindar operatiu derivat del val (t^*):** es selecciona el llindar més alt sobre la corba ROC del *validation set* de cada *fold* que manté TPR= 1; la mediana entre *folds* és el llindar final aplicat al test.

7.3 Esquema d'entrenament i avaluació

L'avaluació segueix un esquema en tres etapes que aïlla completament el conjunt de test:

1. **Test (15%):** es separa des de la construcció dels grafs i **mai s'usa** per a selecció d'hiperparàmetres ni *early stopping*.
2. **Cerca bayesiana + CV 5-fold** sobre el 85% restant: cada configuració s'avalua amb *Stratified K-Fold* per pacient i *early stopping* (*patience*= 20). L'objectiu maximitzat és $\overline{\text{spec}}_{CV} - 10 \cdot \max(0, 1 - \overline{\text{sens}}_{CV})$: especificitat mitjana penalitzant fortament caigudes de sensibilitat (vegeu Annex A.5).
3. **Entrenament final i avaluació al test:** amb els millors hiperparàmetres, el 85% es torna a dividir 90/10 per fer *early stopping* intern, i el model final s'avalua una sola vegada al test (15%) amb el llindar t^* mediana de les 5 t^* obtingudes als folds CV.

Cerca bayesiana. S'utilitza el *Tree-structured Parzen Estimator* (TPE) sobre ~ 15 eixos. Els **200 primers trials** ($\sim 10 \times$ dimensions) són mostreig uniforme aleatori (exploració); després el TPE explota l'historial. Tots els mostratges, *folds* CV i inicialització de pesos usen *seed* fixa. L'estudi és persistent (SQLite) i reproducible; l'espai complet es recull a l'Annex A.5.

8 RESULTATS

Les mètriques principals són l'**AUC-ROC** (ordenació global independent del llindar) i les **mètriques clíniques**: **sensibilitat** ($VP/(VP + FN)$), **especificitat** ($VN/(VN + FP)$), el **valor predictiu positiu** ($VPP, VP/(VP + FP)$) i el **valor predictiu negatiu** ($VPN, VN/(VN + FN)$), on VP, VN, FP i FN són els vertaders/falsos positius i negatius. En detecció de metàstasi, la sensibilitat és la més rellevant: un fals negatiu (no tractar un N1) és més greu que un fals positiu.

Interpretació clínica. Si la sortida del model s'usés per decidir la necessitat de cirurgia (operar els casos predits com a N1), la **sensibilitat** equival al *percentatge de pacients N1 que rebrien tractament* (els que realment tenen metàstasi i, per tant, necessiten cirurgia); una sensibilitat del 100% vol dir que cap pacient amb metàstasi quedaria sense tractar. L'**especificitat** equival a 1 menys el *percentatge de pacients N0 operats innecessàriament*: una especificitat del 57,5% implica que el 42,5% dels pacients sense metàstasi serien sotmesos a una cirurgia que no necessiten. Maximitzar l'especificitat mantenint la sensibilitat a 100% és, doncs, reduir les cirurgies innecessàries sense deixar cap N1 sense tractar.

Pregunta central. Aquest TFG vol respondre, sobre les dades disponibles, si el **GAT Baseline** (*readout* global pla després de les capes GAT) o el **GAT+DiffPool** (reducció jeràrquica del graf abans del *readout*) és preferible per al diagnòstic N0/N1, i quina configuració d'hiperparàmetres maximitza el rendiment al test. Per arribar-hi s'han combinat dues estratègies: (i) dos estudis Optuna TPE aïllats per arquitectura (Annex A.5, eixos compartits i específics per branca) i (ii) una exploració per graella exhaustiva més acotada sobre GAT Baseline (255 configuracions, només eixos arquitectònics i de regularització).

Volum d'experiments. El sweep TPE va avaluar $N_{\text{base}} = 350$ trials GAT Baseline i $N_{\text{diff}} = 231$

GAT+DiffPool (581 totals; 499 complets, 82 *pruned*, 1 fallit). El grid va avaluar 255 configuracions de GAT Baseline. Per a la comparació final, s'han re-avaluat les millors configuracions de cada estratègia amb el **procediment estricte sense data leakage** (5-fold StratifiedKFold sobre el pool + retrain final 90/10 + avaluació única al test). La Taula 2 resumeix les configuracions més rellevants.

Lectura dels resultats. El sweep TPE no supera el grid recuperat tot i avaluar $2,3\times$ més configuracions (581 vs 255 trials): el millor del sweep (DiffPool #199, AUC test 0,786) queda 9 punts per sota del Grid #1 (0,875). Amb dataset petit ($n_{\text{pool}} = 311$), la cerca bayesiana és més vulnerable a sobreajustar el val set; el TPE pot triar configuracions "afortunades" al CV que no es transfereixen al test. Dues configuracions del grid (#1 i #5) mantenen $\text{sens.} = 100\%$ al test amb el llindar t^* , cosa que cap del sweep aconsegueix. Finalment, el GAT Baseline supera GAT+DiffPool en aquest dataset: les seccions tenen pocs centenars de *patches* i la reducció jeràrquica a super-nodes elimina més informació que la que sintetitza (la variant $\lambda_{\text{aux}} = 0,01$ tot just arriba a AUC test 0,805).

Model seleccionat. Es tria **Grid #1** per al *reporting* final: GAT Baseline amb pooling *attention*, MIL *mean*, $h = 256$, $H = 4$, *dropout* 0,3, $\lambda_{\text{wd}} = 10^{-4}$, $\eta = 3 \cdot 10^{-4}$ i optimitzador Adam amb *ReduceLROnPlateau*. AUC CV $0,862 \pm 0,038$, AUC test 0,875, sensibilitat 100% al test (els 16 casos N1 detectats), especificitat 57,5%.

8.1 Importància dels hiperparàmetres per arquitectura

Cada estudi Optuna calcula automàticament la **importància de cada eix d'optimització** amb *fANOVA*, una descomposició funcional de la variància de l'objectiu CV explicada per cada hiperparàmetre. L'Annex A.3 presenta la taula completa (columnes **Baseline** i **DiffPool** costat a costat). Aquí destaquem els eixos amb importància $> 10\%$ en almenys una arquitectura.

GAT Baseline. L'agregació MIL domina l'objectiu de manera molt clara ($I = 0,64$): cap altre eix supera el 10%. Curiosament, el sweep TPE prefereix *attention* MIL (90% del top 10%), mentre que el **model que millor generalitza al test** (Grid #1) usa *mean* MIL: una mostra més que l'objectiu CV no prediu bé el test amb aquesta mida de dades.

GAT+DiffPool. La importància es distribueix molt més: MIL és encara el primer (0,22), seguit del pes del penalty auxiliar λ_{aux} (0,14), η (0,13), λ_{wd} (0,08) i *dropout* (0,08). El sweep convergeix a $\lambda_{\text{aux}} \approx 0,1$ (límit inferior del rang), suggerint que un rang més ampli ($[10^{-3}, 10]$) podria explorar zones encara millors. Una variant amb $\lambda_{\text{aux}} = 0,01$ (fora del rang del sweep) ja millora lleugerament l'AUC test del millor DiffPool del sweep (de 0,786 a 0,805; vegeu Taula 2).

8.2 Comparació amb guies clíniques i SOTA

La Taula 4 situa el **model seleccionat** (Grid #1, vegeu Taula 2) davant de les guies clíniques de referència (Secció 3.4) i de dos models d'IA de referència (un sobre variables clíniques i un altre sobre imatge WSI). Les xifres de les guies provenen de [20] ($n = 560$), i les del GAT s'han obtingut sobre el test d'aquest treball ($n = 56$; prevalença N1 28,6%,

superior a la clínica real $\sim 8\text{--}15\%$ [6]). Sensibilitat i especificitat són independents de la prevalença i són la base de la comparació; el VPP s'ha d'interpretar amb cautela (Secció 10.3).

En la detecció de metàstasi, un fals negatiu (no tractar un pacient N1) és un error inacceptable, mentre que un fals positiu (cirurgia innecessària) és recuperable. Per això el punt operatiu desitjat és el que toca **la part superior** ($\text{sens.} = 100\%$) i alhora queda **tan a l'esquerra com sigui possible** (espec. màxima). La Figura 4 superposa les corbes ROC dels models més rellevants amb els punts operatius de les guies clíniques.




Fig. 4: Corbes ROC al conjunt de test (56 pacients) dels models comparats: **Grid #1** (GAT Baseline; model seleccionat; AUC = 0,875), Grid #5 (AUC = 0,892), sweep Baseline #303 (AUC = 0,816) i sweep DiffPool #199 (AUC = 0,786). El cercle gros marca el llindar $t^* = 0,133$ del model seleccionat (Grid #1), que assoleix $\text{sens.} = 100\%$ i $\text{espec.} = 57,5\%$ al test. t^* s'ha derivat exclusivament del val set sense *data leakage*. Es marquen els punts operatius publicats de JSCCR, NCCN, ESMO (quadrats) i LightGBM (diamant).

Impacte clínic. El llindar t^* manté $\text{sens.} = 100\%$ al test (16/16 N1 detectats, VPN = 1,000), amb $\text{espec.} = 57,5\%$. La literatura estima que el 80–90% de les cirurgies actuals en pT1 són innecessàries [7], coherent amb les especificitats del 19–52% de les guies. Mantenint $\text{sens.} = 100\%$, el GAT redueix les cirurgies innecessàries de ~ 81 (JSCCR) o ~ 49 (NCCN/ESMO) a $\sim 42,5$ per cada 100 pacients N0. Sobre els 40 N0 del test, són 17 FP en lloc dels ~ 32 de JSCCR. Al llindar 0,5 la sensibilitat és inferior (56,2%); t^* és el que fa el model clínicament útil.

9 IMPLEMENTACIÓ I EINES

La implementació segueix un disseny modular: la construcció de grafs, el model, el codi d'entrenament i el *sweep* bayesià estan desacoblats. La configuració es gestiona via YAML i, per a la cerca, via Optuna amb *storage* SQLite repreneble. Codi accessible a [26].

TAULA 2: COMPARACIÓ DE CONFIGURACIONS RE-AVALUADES AMB EL PROCEDIMENT ESTRICTE DE LA SECCIÓ 7.3 (5-FOLD CV + RETRAIN 90/10 + TEST ÚNIC). **FILES RESSALTADES:** MODEL SELECCIONAT (*grid1*) PER MÀXIMA AUC CV I MANTENIR SENS. = 100% AL TEST AMB MILLOR ESPECIFICITAT. GRID #1/#5 CORRESPONEN A CONFIGS DEL GRID ANTIC (255 CONFIGS), *sweep* A LES MILLORS DEL TPE BAYESIÀ.

Config	Arq.	Pooling/MIL	$h/H/\text{drop}$	AUC CV	AUC test	Sens/Espec @ t^*	Sens/Espec @0,5
Grid #1 (sel.)	Base.	att/mean	256/4/0,3	0,862±0,038	0,875	1,00 / 0,575	0,562 / 0,925
Grid #5	Baseline	att/mean	256/2/0,1	0,836±0,050	0,892	1,00 / 0,375	0,688 / 0,900
Sweep Baseline #303	Baseline	mm/att	128/4/0,36	0,843±0,026	0,816	0,69 / 0,825	0,438 / 0,900
Sweep DiffPool #199	DiffPool	diff/mean	128/2/0,44	0,847±0,048	0,786	0,63 / 0,700	0,500 / 0,825
DiffPool aux=0,01	DiffPool	diff/mean	128/2/0,40	0,844±0,035	0,805	0,81 / 0,725	0,562 / 0,900

Pooling: att = attention, mm = mean_max, diff = DiffPool jeràrquic. MIL: mean = mitjana, att = attention MIL. Llíndar t^* derivat com a mediana dels 5 líndars del val set (sens=100% a cada fold), aplicat al test sense reajustar.

TAULA 3: MATRIU DE CONFUSIÓ DEL **MODEL SELECCIONAT** (GRID #1) AL CONJUNT DE TEST ($n = 56$) AMB EL LLINDAR $t^* = 0,133$. MÈTRIQUES CLÍNQUES: SENSIBILITAT = 1,000 (16/16 N1 DETECTATS), ESPECIFICITAT = 0,575, VPP = 0,485, VPN = 1,000.

		Diagnòstic real	
		N0	N1
Predicció	N0	23	0
	N1	17	16

Frontend web. S'ha desenvolupat una interfície (FastAPI + JS sense *build step*) que ofereix: (a) **visualització del WSI** amb superposició dels *patches* i la màscara anotada; (b) **visualització dels grafs** de Delaunay sobre la imatge, amb pesos d'atenció per node (mitjana sobre els H caps de l'última capa GAT, $\in [0, 1]$ ja que GAT fa *softmax* sobre veïns); (c) **selector de model** que carrega qualsevol *checkpoint* dels *trials* del sweep i n'infereix automàticament l'arquitectura des dels pesos; (d) **mode d'inferència** amb desglossament de la propagació capa a capa (mode depuració); i (e) **pestanya d'estadístiques** amb corbes ROC/PR, matriu de confusió i mètriques per classe al test, generades sense *data leakage*. El diagrama de blocs detallat del pipeline és la Figura 5 de l'Annex A.1.

10 CONCLUSIONS

10.1 Conclusions

En aquest TFG s'ha construït un sistema complet de classificació N0/N1 per a càncer colorrectal pT1 a partir de WSI, que inclou la generació de grafs espacials de Delaunay, l'entrenament del model GAT amb dues estratègies de cerca d'hiperparàmetres (graella exhaustiva acotada + sweep bayesià TPE), i l'avaluació final sobre un conjunt de test fix (56 pacients). La pregunta central «**GAT Baseline o GAT+DiffPool, i amb quina configuració?**» es respon a partir de la Taula 2: **el GAT Baseline amb la configuració Grid #1** (*attention pooling*, MIL *mean*, $h = 256$, $H = 4$, dropout 0,3, $\lambda_{wd} = 10^{-4}$) obté el millor balanç: AUC test = 0,875, sensibilitat 100% (els 16 N1 detectats) i especificitat 57,5% al líndar $t^* = 0,133$ derivat del val set. Se'n destaquen tres observacions:

- **El sweep TPE no supera el grid recuperat.** Tot i avaluar $2,3 \times$ més configuracions (581 vs 255 tri-

als) i cobrir més eixos, el millor model del sweep (DiffPool #199) queda 9 punts d'AUC test per sota del Grid #1 (0,786 vs 0,875). Amb un dataset petit ($n_{\text{pool}} = 311$), la cerca bayesiana és més vulnerable a sobreajustar el val set, especialment quan l'objectiu ($\text{spec} - 10 \cdot \max(0, 1 - \text{sens})$) prioritza un punt operatiu concret que pot no transferir-se al test.

- **El GAT Baseline supera el GAT+DiffPool** amb aquest dataset. Les seccions contenen pocs centenars de *patches*; la reducció jeràrquica a super-nodes ($K_{\text{top}} = 50$, $K_{\text{bot}} = 3$) elimina més informació que la que sintetitza. Una variant amb $\lambda_{\text{aux}} = 0,01$ (fora del rang del sweep) millora lleugerament el DiffPool (0,805 AUC) però no arriba al nivell del Baseline.
- **Robustesa del líndar.** El Grid #1 i altres dues configuracions del grid (#5 i #5+AdamW) mantenen sens. = 100% al test amb el líndar t^* del val set, cosa que cap configuració del sweep aconsegueix. Aquesta propietat és la que fa el sistema clínicament útil com a filtre de descartament: amb VPN = 1,000 al test, un resultat negatiu del model permet evitar la cirurgia amb seguretat sobre la mostra avaluada.

10.2 Discussió Comparativa

L'AUC de test del model seleccionat (0,875) supera la de JSCCR (0,596), NCCN (0,749) i ESMO (0,743) [20]. L'especificitat al líndar t^* (57,5%) és superior a la de JSCCR (19%) i comparable a NCCN/ESMO (50–52%) mantenint la sensibilitat al 100%.

VPP i ajust per prevalença. El VPP de 48,5% s'ha calculat amb la prevalença del test (28,6% N1), superior a la clínica real (~ 8 –15%) [6]. A una prevalença del 10%, el VPP baixa a $\sim 21\%$ i el VPN es manté al 100% (càlcul per Bayes amb Sens./Espec. observades: 1,000/0,575). El model és, doncs, especialment útil com a **filtre de descartament**: un resultat negatiu té probabilitat 1 de ser correcte sobre aquesta mostra, i podria evitar la cirurgia amb seguretat. Sensibilitat i especificitat, independents de la prevalença, segueixen sent les mètriques comparatives més robustes.

Sensibilitat ajustable per líndar. Al líndar per defecte (0,5) la sensibilitat al test és inferior (56,2%) però l'especificitat puja al 92,5%. Ajustant el líndar a $t^* = 0,133$ (derivat exclusivament del val set, vegeu Limitació 4), el GAT assoleix sensibilitat 100% i especificitat 57,5%, una millora de 38,5 punts sobre JSCCR al mateix nivell de sensibilitat.

TAULA 4: COMPARACIÓ DE RENDIMENT ENTRE EL MODEL PROPOSAT, LES GUIES CLÍNiques I L'ESTAT DE L'ART. **GUIES:** TANINO ET AL. [20] ($n=560$, HIROSHIMA). **IBC SCORE:** DAWSON ET AL. [4] ($n=565$, MULTICÈNTRIC). **LIGHTGBM:** PIAO ET AL. [21] ($n=105$ TEST, VARIABLES CLINICOPAT.). **SONG ET AL.:** MODEL MIL D'ATENCIÓ SOBRE WSI H&E [25] ($n=1281$, 2604 WSIs). **GAT:** AQUEST TREBALL ($n=56$ TEST). ESTUDIS I POBLACIONS INDEPENDENTS; EL PPV NO ÉS DIRECTAMENT COMPARABLE (PREVALENCIA N1 DIFERENT ENTRE ESTUDIS). $BAL.ACC. = (S+E)/2$; CALCULADA PER A LES GUIES I L'IBC SCORE A PARTIR DE SENS./ESPEC. REPORTADES.

Sistema	Tipus d'entrada	Sens.	Espec.	AUC	Bal.Acc.
<i>Guies i puntuació clínica</i>					
JSCCR [3]	Guia clínica	100%	19%	0,596	59,5%
NCCN	Guia clínica	98%	52%	0,749	75,0%
ESMO [5]	Guia clínica	98%	50%	0,743	74,0%
IBC Score [4]	Puntuació histopat.	90%	26%	0,68	58,0%
<i>Models d'IA</i>					
LightGBM [21]	Var. clinicopatol.	100%	85,8%	0,960	92,9%
Song et al. [25]	Imatge WSI	92,9%	57,6%	0,781	75,3%
GAT (aquest TFG, llindar 0,5)	Imatge WSI	56,2%	92,5%	0,875	74,4%
GAT (aquest TFG, llindar $t^*=0,133$)[†]	Imatge WSI	100%	57,5%	0,875	78,8%

[†] t^* s'ha determinat com a mediana dels 5 llindars dels *val sets* dels folds CV (sens=100% en cada fold), aplicat al test sense reajustar. Model: Grid #1 (vegeu Taula 2).

Comparació amb IA SOTA. El model de gradient boosting (*LightGBM*) de Piao et al. [21], entrenat amb $\sim 10\times$ més dades i amb accés a variables clinicopatològiques estructurades, obté Sens.=100% amb Espec.=85,8% i AUC 0,960. El GAT, al mateix punt operatiu de sensibilitat, arriba a Espec. 57,5% (28 punts per sota), però amb la imatge WSI com a única entrada. Els dos models són complementaris: el GAT pot córrer just després d'escanejar la làmina, sense esperar el report patològic; el model basat en *LightGBM* requereix les variables clinicopatològiques ja anotades.

Una comparació més justa, a la **mateixa modalitat**, és la de Song et al. [25], un model MIL d'atenció sobre WSI H&E (sense variables clíniques), del mateix paradigma que el GAT però amb un extractor CNN per *patch* en lloc d'un graf. Sobre 1281 pacients obté AUC 0,781, sens. 92,9% i espec. 57,6%. A una especificitat pràcticament idèntica (57,5% vs 57,6%), el GAT assoleix sens. 100% (vs 92,9%) i un AUC superior (0,875 vs 0,781); cal matisar, però, que la seva avaluació és molt més robusta estadísticament (1281 pacients vs els 56 del nostre test). Aquest resultat suggereix que representar la secció com a graf espacial és, com a mínim, competitiu amb l'agregació MIL plana sobre *patches*.

Cerca bayesiana vs graella en datasets petits. Una observació metodològica rellevant: en aquest treball, el sweep TPE bayesià (581 trials, 17 eixos) **no ha trobat un model millor** que la graella exhaustiva acotada (255 configs, 6 eixos). Una hipòtesi: amb dataset petit ($n_{\text{pool}}=311$), la variància entre splits CV ($\sigma_{\text{spec}} \approx 0,10-0,20$) domina sobre el guany d'una exploració més fina, i el TPE pot triar configuracions "afortunades" al val set que no es transfereixen. La graella, en canvi, va explorar un nombre menor de configuracions "robustes" que generalitzen millor.

10.3 Limitacions

(1) Mida del test. Amb 56 pacients al test (només 16 N1), els intervals de confiança al 95% de l'AUC són amplis ($\pm 0,07-0,10$). L'AUC CV del model seleccionat (0,862 $\pm$ 0,038) i l'AUC test (0,875) són consistents, però la variàn-

cia de l'especificitat al CV és alta (mitjana $0,369 \pm 0,198$ amb el llindar t^*), reflectint la inestabilitat entre folds. Caldria un test més gran per a conclusions clíniques robustes.

(2) Absència de validació externa. El dataset prové de 26 hospitals espanyols, però no s'ha provat sobre dades d'un centre independent. Campanella et al. [27] reporten, en models MIL de patologia, caigudes de 3–6 punts d'AUC en escàners externs i fins a 7 punts en canvis de domini institucional. L'aplicabilitat clínica requereix, per tant, validació externa.

(3) Desbalanceig de prevalença. La prevalença N1 al test (28,6%) supera la clínica real ($\sim 8-15\%$); el VPP s'ha d'interpretar amb cautela (Discussió Comparativa).

(4) Selecció del llindar i biaix del val set. Per maximitzar la sensibilitat, s'ha buscat el primer punt de la corba ROC del val set de cada fold del model seleccionat (Grid #1) en què TPR=1,0, i s'ha pres la mediana sobre els 5 folds com a $t^*=0,133$. Aplicat al test, manté sens. =100% amb espec. = 57,5%. El val set ja s'havia usat per a *early stopping*, per la qual cosa t^* pot tenir un biaix lleugerament optimista; idealment, hauria de fixar-se sobre un val set extern. La variància del llindar entre folds també és alta ($\sigma_{t^*} \approx 0,08$), reflectint la sensibilitat del procediment a la divisió de dades.

REFERÈNCIES

- [1] Sociedad Española de Oncología Médica (SEOM). *Las Cifras del Cáncer en España 2026*. Consultat el 6 de febrer de 2026. 2026. URL: <https://seom.org/prensa/el-cancer-en-cifras>.
- [2] Unitat Funcional Càncer Colorectal. *Protocol de Pràctica Clínica del Càncer de Còlon i Recte*. Actualització de la 3^a edició. Parc de Salut MAR Barcelona - Hospital del Mar. Barcelona, juny de 2013. URL: https://www.hospitaldelmar.cat/media/upload/arxius/unitats/cancer_colorectal/protocols/practica_clinica.pdf.

- [3] Yojiro Hashiguchi et al. “Japanese Society for Cancer of the Colon and Rectum (JSCCR) guidelines 2019 for the treatment of colorectal cancer”. A: *International Journal of Clinical Oncology* 25.1 (2020), pàg. 1-42. DOI: 10.1007/s10147-019-01485-z. URL: <https://doi.org/10.1007/s10147-019-01485-z>.
- [4] Heather Dawson et al. “Lymph node metastases and recurrence in pT1 colorectal cancer: Prediction with the International Budding Consortium Score — a retrospective, multi-centric study”. A: *United European Gastroenterology Journal* 12.3 (2024), pàg. 299-308. DOI: 10.1002/ueg2.12521. URL: <https://doi.org/10.1002/ueg2.12521>.
- [5] Pedro Pimentel-Nunes et al. “Endoscopic submucosal dissection for superficial gastrointestinal lesions: European Society of Gastrointestinal Endoscopy (ESGE) Guideline – Update 2022”. A: *Endoscopy* 54.6 (2022), pàg. 591-622. DOI: 10.1055/a-1811-7025. URL: <https://doi.org/10.1055/a-1811-7025>.
- [6] Dario Zaffalon et al. “Dilemmas in the Clinical Management of pT1 Colorectal Cancer”. A: *Cancers* 15.13 (2023), pàg. 3511. DOI: 10.3390/cancers15133511. URL: <https://doi.org/10.3390/cancers15133511>.
- [7] Fernando Martínez de Juan, Samuel Navarro i Isidro Machado. “Refining Risk Criteria May Substantially Reduce Unnecessary Additional Surgeries after Local Resection of T1 Colorectal Cancer”. A: *Cancers* 16.13 (2024), pàg. 2321. DOI: 10.3390/cancers16132321.
- [8] Babak Ehteshami Bejnordi et al. “Diagnostic Assessment of Deep Learning Algorithms for Detection of Lymph Node Metastases in Women With Breast Cancer”. A: *JAMA* 318.22 (2017), pàg. 2199-2210. DOI: 10.1001/jama.2017.14585. URL: <https://doi.org/10.1001/jama.2017.14585>.
- [9] Petar Veličković et al. *Graph Attention Networks*. 2018. arXiv: 1710.10903 [stat.ML]. URL: <https://arxiv.org/abs/1710.10903>.
- [10] Centre de Visió per Computador (CVC). *Centre de Visió per Computador (CVC), UAB*. URL: <https://www.cvc.uab.es> (cons. 14-06-2026).
- [11] Maximilian Ilse, Jakub M. Tomczak i Max Welling. *Attention-based Deep Multiple Instance Learning*. 2018. arXiv: 1802.04712 [cs.LG]. URL: <https://arxiv.org/abs/1802.04712>.
- [12] Ming Y. Lu et al. *Data Efficient and Weakly Supervised Computational Pathology on Whole Slide Images*. 2020. arXiv: 2004.09666 [eess.IV]. URL: <https://arxiv.org/abs/2004.09666>.
- [13] Bin Li, Yin Li i Kevin W. Eliceiri. *Dual-stream Multiple Instance Learning Network for Whole Slide Image Classification with Self-supervised Contrastive Learning*. 2021. arXiv: 2011.08939 [cs.CV]. URL: <https://arxiv.org/abs/2011.08939>.
- [14] Holger S. Muti, Christoph Röcken, Hans-Michael Behrens et al. “Deep learning trained on lymph node status predicts outcome from gastric cancer histopathology: a retrospective multicentric study”. A: *European Journal of Cancer* 194 (2023), pàg. 113335. DOI: 10.1016/j.ejca.2023.113335.
- [15] Guillaume Jaume et al. *HistoCartography: A Toolkit for Graph Analytics in Digital Pathology*. 2021. arXiv: 2107.10073 [eess.IV]. URL: <https://arxiv.org/abs/2107.10073>.
- [16] Daniele Grattarola et al. “Understanding Pooling in Graph Neural Networks”. A: *IEEE Transactions on Neural Networks and Learning Systems* 35.2 (febr. de 2024), pàg. 2708-2718. ISSN: 2162-2388. DOI: 10.1109/tnnls.2022.3190922.
- [17] Rex Ying et al. *Hierarchical Graph Representation Learning with Differentiable Pooling*. 2019. arXiv: 1806.08804 [cs.LG]. URL: <https://arxiv.org/abs/1806.08804>.
- [18] Richard J. Chen et al. “Towards a general-purpose foundation model for computational pathology”. A: *Nature Medicine* 30.3 (març de 2024), pàg. 850-862. DOI: 10.1038/s41591-024-02857-3.
- [19] Ming Y. Lu et al. “A visual-language foundation model for computational pathology”. A: *Nature Medicine* 30.3 (març de 2024), pàg. 863-874. DOI: 10.1038/s41591-024-02856-4.
- [20] Fumiaki Tanino et al. “Comparative prediction of lymph node metastasis in pT1 colorectal cancer among Western and Japanese guidelines”. A: *Frontiers in Oncology* 14 (2024), pàg. 1475270. DOI: 10.3389/fonc.2024.1475270. URL: <https://www.frontiersin.org/journals/oncology/articles/10.3389/fonc.2024.1475270>.
- [21] Zhenghu Piao, Ruiquan Ge i Ling Lu. “An artificial intelligence prediction model outperforms conventional guidelines in predicting lymph node metastasis of T1 colorectal cancer”. A: *Frontiers in Oncology* 13 (2023), pàg. 1229998. DOI: 10.3389/fonc.2023.1229998. URL: <https://doi.org/10.3389/fonc.2023.1229998>.
- [22] Pau Martí Escolà. “Anàlisi d’espais de representació profunds pel diagnòstic del carcinoma colorectal en histopatologia digital”. Treb. fin. de màst. Universitat Autònoma de Barcelona, 2025. URL: <https://ddd.uab.cat/record/317556>.
- [23] Matthias Fey i Jan Eric Lenssen. *Fast Graph Representation Learning with PyTorch Geometric*. 2019. arXiv: 1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.

- [24] Junhyun Lee, Inyeop Lee i Jaewoo Kang. *Self-Attention Graph Pooling*. 2019. arXiv: 1904.08082 [cs.LG]. URL: <https://arxiv.org/abs/1904.08082>.
- [25] Joo Hye Song et al. "Prediction of Lymph Node Metastasis in T1 Colorectal Cancer Using Artificial Intelligence with Hematoxylin and Eosin-Stained Whole-Slide-Images of Endoscopic and Surgical Resection Specimens". A: *Cancers* 16.10 (2024), pàg. 1900. DOI: 10.3390/cancers16101900. URL: <https://doi.org/10.3390/cancers16101900>.
- [26] David M. et al. *Implementació de Graph Attention Networks per a la detecció de metàstasi en pT1*. 2026. URL: <https://github.com/IAM-CVC/PT1Diagnosis> (cons. 03-05-2026).
- [27] Gabriele Campanella et al. "Clinical-grade computational pathology using weakly supervised deep learning on whole slide images". A: *Nature Medicine* 25.8 (2019), pàg. 1301 - 1309. DOI: 10.1038/s41591-019-0508-1. URL: <https://doi.org/10.1038/s41591-019-0508-1>.

APÈNDIX

A.1 Diagrama de flux detallat del *pipeline*




Fig. 5: Diagrama de flux del *pipeline* complet amb hiperparàmetres optimitzats per la cerca bayesiana (columna dreta, caixes vermelles discontinües). *Blocs grisos*: etapes realitzades pels companys de l'equip i dades de referència. *Blocs blaus*: contribucions d'aquest TFG. La fletxa $\times S$ indica que les S seccions d'un pacient es processen com a grafs independents i les $P(N1)$ s'agreguen via MIL per obtenir el diagnòstic per pacient, que es compara amb el diagnòstic real de l'Excel. L : capes GAT; h : dim. oculta; H : caps d'atenció; L_{DP} : blocs DiffPool; K_{ℓ} : super-nodes per nivell; λ_{aux} : pes del penalty DiffPool; t^* : llindar de decisió derivat del val set.

A.2 Variants d'arquitectura del *GATClassifier*

El diagrama 6 mostra com un **mateix graf d'entrada** pot ser processat de maneres molt diverses depenent de la configuració: les caixes blaves representen capes apreses i les taronges discontinües els eixos d'optimització configurables.




Fig. 6: Variants d'arquitectura del *GATClassifier*: el mateix graf $\mathcal{G}$ es pot processar per dues branques configurables (BASELINE o DIFFPOOL), cadascuna amb la seva pròpia estratègia de *readout* intra-secció (caixes taronges discontinües). Totes dues convergeixen en un embedding $\mathbf{h}_s$ per secció. L'agregació MIL bifurca de nou: **mean/max/noisy-OR** apliquen el MLP per secció per obtenir $P(\mathbf{N1})_s$ i n'agreguen els *escalars*; **attention (gated)** agrega primer els *vectors* $\mathbf{h}_s$ (amb pesos d'atenció apresos) i aplica el MLP *una sola vegada*. L : capes GAT; h : dim. oculta; H : caps d'atenció; L_{DP} : blocs DiffPool; K_ℓ : super-nodes per nivell; λ_{aux} : pes de la pèrdua auxiliar de DiffPool; t^* : llindar derivat del val set (Secció 7.3).

A.3 Importància dels hiperparàmetres per arquitectura

La Taula 5 mostra la **importància fANOVA** de cada eix d'optimització, calculada de manera independent per a cada estudi Optuna (Baseline i DiffPool). La importància és una descomposició funcional de la variància de l'objectiu CV explicada per cada hiperparàmetre, en el rang $[0, 1]$. Eixos específics d'una branca apareixen com a -- a l'altra columna. Tots els valors provenen de l'anàlisi fANOVA calculada per Optuna sobre els *trials* complets de cada estudi.

TAULA 5: IMPORTÀNCIA fANOVA PER ARQUITECTURA. **BASILINE**: 304 *trials* COMPLETS. **DIFFPOOL**: 195 *trials* COMPLETS. VALORS ENTRE 0 (CAP INFLUÈNCIA) I 1 (L'EIX EXPLICA TOTA LA VARIÀNCIA). --: EIX NO APLICABLE A AQUELLA BRANCA.

Eix	Baseline	DiffPool
<i>Eixos específics d'arquitectura</i>		
<i>Pooling</i>	0,079	--
<i>L</i> (capes GAT)	0,017	--
<i>L_{DP}</i> (blocs DiffPool)	--	0,062
<i>K_{top}</i>	--	0,027
<i>K_{bot}</i>	--	0,021
<i>λ_{aux}</i>	--	0,141
<i>Diff. readout</i>	--	0,053
<i>Eixos compartits (optimitzats independentment a cada study)</i>		
<i>h</i> (dim. oculta)	0,012	0,027
<i>H</i> (caps d'atenció)	0,024	0,066
<i>Dropout</i>	0,054	0,079
Agregació MIL	0,640	0,224
<i>η</i> (<i>learning rate</i>)	0,036	0,129
<i>λ_{wd}</i> (<i>weight decay</i>)	0,020	0,083
<i>w₊</i> (<i>pos_weight</i>)	0,075	0,046
<i>Optimizer</i>	0,005	0,015
<i>Scheduler</i>	0,019	0,008
<i>Grad clipping</i>	0,017	0,019

A.4 Hiperparàmetres del model seleccionat i alternatives properes

La Taula 6 resumeix la configuració del model seleccionat (Grid #1) juntament amb els bests dels dos estudis Optuna, ja avaluats amb el procediment estricte de la Taula 2.

TAULA 6: CONFIGURACIÓ DEL MODEL SELECCIONAT (GRID #1) I BESTS DEL SWEEP TPE PER ARQUITECTURA.

Eix	Grid #1 (sel.)	Sweep Base. (#303)	Sweep DiffP. (#199)
<i>Arquitectura</i>			
<i>Pooling</i>	<i>attention</i>	<i>mean_max</i>	<i>diff</i> (fix)
<i>L</i> (capes GAT)	3	3	3 ($= L_{DP} + 1$)
$L_{DP} / K_{top}, K_{bot}$	—/—	—/—	2 / 50, 3
$\lambda_{aux} / \text{Diff. readout}$	—/—	—/—	0,108 / <i>mean_max</i>
<i>Compartits</i>			
<i>h</i> / <i>H</i> / <i>Dropout</i>	256 / 4 / 0,3	128 / 4 / 0,355	128 / 2 / 0,437
MIL	<i>mean</i>	<i>attention</i>	<i>mean</i>
$\eta / \lambda_{wd} / w_{+}$	$3 \cdot 10^{-4} / 10^{-4} / 2,0$	$1,1 \cdot 10^{-3} / 6,6 \cdot 10^{-3} / 6,77$	$5,3 \cdot 10^{-4} / 5,5 \cdot 10^{-3} / 3,52$
<i>Optimizer</i> / <i>Scheduler</i>	<i>adam</i> / <i>plateau</i>	<i>adam</i> / <i>cosine</i>	<i>adam</i> / <i>cosine</i>
<i>Mètriques re-avaluades (proc. estricte)</i>			
AUC CV ($\pm$ std)	$0,862 \pm 0,038$	$0,843 \pm 0,026$	$0,847 \pm 0,048$
AUC test	0,875	0,816	0,786
Sens. / Espec. test @ t^*	1,000 / 0,575	0,688 / 0,825	0,625 / 0,700
t^*	0,133	0,330	0,303

A.5 Espai de cerca de la cerca bayesiana

La Taula 7 llista els eixos d'optimització, els seus rangs i la branca d'arquitectura on s'apliquen. La cerca es fa amb *TPE* (Optuna); cada *trial* avalua una configuració amb 5-fold CV sobre el *pool* train+val. Les dues arquitectures s'optimitzen en **estudis Optuna aïllats** (SQLite separats): els eixos específics de cada arquitectura no es barregen, i els eixos comuns s'optimitzen de forma independent per a cada branca. La millor configuració trobada es marcaria en negreta al final de la cerca.

TAULA 7: EIXOS DEL *sweep* BAYESIÀ (DOS ESTUDIS OPTUNA AÏLLATS, UN PER ARQUITECTURA). ESTIMACIÓ DE TEMPS EN UNA NVIDIA L40S: 60–150 H PER 1000 *trials* TOTALS.

Eix	Branca	Valors / rang	Tipus mostreig
<i>Arquitectura del model</i>			
<i>Pooling</i>	només baseline	mean, max, mean_max, attention	categòric
<i>L</i> (capes GAT)	només baseline	2, 3, 4	enter
<i>L_{DP}</i> (blocs DiffPool)	només DiffPool	1, 2, 3	enter
<i>K_{top}</i> (super-nodes 1r nivell)	només DiffPool	10, 25, 50	categòric
<i>K_{bot}</i> (super-nodes últim nivell)	només DiffPool	3, 5, 10	categòric
(Nivells intermedis: $K = \lfloor \sqrt{K_{top} \cdot K_{bot}} \rfloor$; amb clamp $K_{bot} < K_{top}$)			
λ_{aux} (pes aux. DiffPool)	només DiffPool	[0,1, 10]	log-uniforme
<i>Diff. readout</i>	només DiffPool	mean, max, mean_max, attention	categòric
<i>h</i> (dimensió oculta)	ambdues (indep.)	64, 128, 256	categòric
<i>H</i> (caps d'atenció)	ambdues (indep.)	2, 4	categòric
<i>Dropout</i>	ambdues (indep.)	[0,05, 0,5]	uniforme
<i>Agregació a nivell de pacient (MIL)</i>			
Agregació MIL	ambdues (indep.)	mean, max, noisy-OR, attention	categòric
<i>Optimitzador i regularització</i>			
<i>Optimizer</i>	ambdues (indep.)	Adam, AdamW	categòric
<i>Scheduler</i>	ambdues (indep.)	ReduceLROnPlateau, CosineAnnealingLR	categòric
Taxa aprenentatge	ambdues (indep.)	$[5 \cdot 10^{-5}, 5 \cdot 10^{-3}]$	log-uniforme
<i>Weight decay</i>	ambdues (indep.)	$[10^{-5}, 10^{-2}]$	log-uniforme
<i>Grad. clipping</i>	ambdues (indep.)	0, 1, 5	categòric
<i>Tractament del desbalanceig</i>			
Pes de la classe N1 (w_+)	ambdues (indep.)	[1,5, 8]	uniforme
Llindar t^*	post-CV	sobre la corba ROC del val, condició TPR=1	determinista

Objectiu del sweep: $\text{objective} = \overline{\text{spec}}_{CV} - 10 \cdot \max(0, 1 - \overline{\text{sens}}_{CV})$, on $\overline{\text{spec}}_{CV}$ i $\overline{\text{sens}}_{CV}$ són les mitjanes sobre els 5 *val sets*, calculades amb el llindar t^* derivat de cada *fold* (llindar més alt amb TPR= 1). Aquesta és l'**única** mètrica que el TPE veu per decidir els paràmetres del següent *trial*. La penalització $\times 10$ fa que el TPE prioritzi sensibilitat $\approx 100\%$, però accepta una pèrdua moderada (sens $\geq 95\%$) si s'aconsegueix un guany substancial d'especificitat (> 5 punts).