

Predicció de Metàstasi en Histopatologia en Càncer Colorrectal usant Graph Attention Networks

David Morillo Massagué

Resum— Es proposa un *pipeline* de classificació N0/N1 per a la predicció de metàstasi en ganglis limfàtics en càncer colorrectal pT1 a partir de *Whole Slide Images*. El teixit es representa com un **graf espacial** construït per triangulació de Delaunay sobre les coordenades dels *bags*, preservant l'arquitectura topològica del teixit —a diferència d'enfocaments basats en similitud de característiques. Cada node és un *bag* de 256 *patches* caracteritzat per l'embedding CLS (1.536 dim.) del model de fundació UNI2. Es comparen dues arquitectures: un GAT de referència amb *readout* pla i un GAT amb **DiffPool jeràrquic** intercalat ($N \rightarrow K_1 \rightarrow K_2$ super-nodes), que captura representació multi-escala del teixit. El diagnòstic per pacient s'obté per agregació MIL sobre les seccions. El millor model assoleix un AUC de $0,817 \pm 0,073$ (5-fold CV, 230 pacients).

Paraules clau— Càncer colorrectal pT1, Histopatologia digital, Graph Attention Networks, Diff-Pool jeràrquic, Graf espacial de Delaunay, MIL, Desbalanceig de classes.

Abstract— We propose an N0/N1 classification pipeline for lymph node metastasis prediction in pT1 colorectal cancer from Whole Slide Images. Tissue is represented as a **spatial graph** built by Delaunay triangulation over bag coordinates, preserving the topological architecture of tissue —unlike feature-similarity graph approaches. Each node is a bag of 256 patches characterised by a 1,536-dimensional CLS embedding from the UNI2 foundation model. Two architectures are compared: a **GAT baseline** with flat readout (mean/max) and a **hierarchical GAT+DiffPool** model with pooling layers interleaved between GAT layers ($N \rightarrow K_1 \rightarrow K_2$ super-nodes), enabling multi-scale tissue representations. Patient-level diagnosis is obtained via MIL aggregation over histological sections. The best model achieves an AUC of 0.817 ± 0.073 (5-fold CV, 230 patients).

Keywords— pT1 colorectal cancer, Digital histopathology, Graph Attention Networks, Hierarchical DiffPool, Spatial Delaunay graph, Multiple Instance Learning, Class imbalance.

1 INTRODUCCIÓ

EL càncer colorrectal (CCR) representa un dels reptes de salut pública més greus del nostre entorn. A Espanya, la SEOM preveu per al 2026 més de **44.132** nous casos anuals, convertint-lo en el tumor més freqüentment diagnosticat i en la segona causa de mort per càncer amb 14.629 defuncions [1].

El carcinoma pT1 és especialment complex: el tumor ha envaït la submucosa però no la muscular pròpia, i el risc de

metàstasi als ganglis limfàtics oscil·la entre el **2%** i el **23%** depenent de la profunditat d'invasió [2]. Quan hi ha criteris de mal pronòstic, el risc s'estima al voltant del 10%, la qual cosa obliga a considerar una cirurgia radical. Tanmateix, s'estima que **entre el 80% i el 90%** d'aquestes cirurgies resulten innecessàries [3].

La histopatologia digital, a través de les *Whole Slide Images* (WSI), obre la porta a tècniques avançades de visió per computador. En concret, les *Graph Attention Networks* (GAT) [4] permeten modelar l'arquitectura espacial del teixit de forma relacional. Una decisió clau en la construcció del graf és la definició de les arestes: mentre que alguns treballs les basen en la *similitud de característiques* entre *bags*, aquest projecte opta per la **proximitat espacial** (triangulació de Delaunay sobre coordenades WSI), preservant la topologia real del teixit. Aquest projecte, desenvolupat al

• E-mail de contacte: David.MorilloMa@autonoma.cat
• Treball tutoritzat per: Debora Gil Resina (DCC)
• Curs 2025/26

grup IAM del CVC (iam.cvc.uab.es) sota la supervisió de la Dra. Debora Gil, compara un GAT de referència amb *readout* pla contra un model amb *pooling* jeràrquic (DiffPool) intercalat, i proposa estratègies d'agregació MIL per al diagnòstic a nivell de pacient.

Dues raons complementàries justifiquen la tria d'aquest projecte. Des del punt de vista clínic, els sistemes d'IA demostren una capacitat creixent per identificar patrons morfològics subtils de manera consistent, amb el potencial real de reduir cirurgies innecessàries. Des del punt de vista tècnic, la combinació de xarxes d'atenció sobre grafs i aprenentatge profund sobre imatges histopatològiques d'alta resolució és exactament la intersecció entre la teoria de grafs i les xarxes neuronals profundes que vull explorar dins de l'Enginyeria de Dades.

2 OBJECTIUS

- Construir un *pipeline* complet de classificació N0/N1 sobre WSI reals a partir d'embeddings CLS del model UNI2, basat en **grafs espacials** (triangulació de Delaunay sobre coordenades del teixit).
- **Comparar un GAT de referència** amb *readout* pla contra un model amb **DiffPool jeràrquic** intercalat entre les capes GAT, avaluant si la reducció progressiva del graf aporta millor representació multi-escala.
- Implementar i comparar estratègies d'agregació MIL a nivell de pacient per integrar les prediccions de múltiples seccions histològiques.
- Avaluar la robustesa dels models mitjançant validació creuada estratificada (*k*-fold).
- Proporcionar una eina interactiva de visualització i inferència en temps real.

3 ESTAT DE L'ART

3.1 Classificació de WSI amb MIL

El processament de *Whole Slide Images* comporta un repte computacional fonamental: les imatges, amb resolucions de fins a $150\,000 \times 150\,000$ píxels, no poden processar-se directament amb arquitectures convencionals. L'enfocament dominant és el *Multiple Instance Learning* (MIL) sobre *bags* de *patches*. Ilse et al. [5] van introduir l'agregació per atenció (*attention-based MIL*), que aprèn pesos d'importància per a cada instància i n'obté una representació global ponderada. Lu et al. [6] van escalar aquest paradigma a grans conjunts de dades clínics (CLAM), afegint guia d'instàncies per millorar la interpretabilitat. Li et al. [7] van proposar DSMIL, que combina una branca a nivell de *patch* i una a nivell de làmina amb aprenentatge contrastiu auto-supervisat. La predicció de l'estat ganglionar a partir d'histopatologia s'ha abordat en altres tipus de càncer: Muti et al. [8] demostren que models de *deep learning* entrenats sobre làmines de càncer gàstric poden predir l'estat N0/N1 amb resultats clínicament rellevants.

3.2 Grafs i GNN en Patologia Digital

Les *Graph Neural Networks* permeten representar el teixit com una estructura relacional, capturant la topologia espacial entre regions de manera explícita. Jaume et al. [9] van presentar HistoCartography, un marc de treball per a l'anàlisi de grafs en patologia digital que demostra la superioritat dels grafs sobre les CNN en tasques de classificació de biòpsies. El mecanisme d'atenció de les GAT [4] és especialment adequat per a aquest domini, on no tots els veïns d'una regió contribueixen igualment al diagnòstic. Les estratègies de *pooling* jeràrquic com DiffPool [10] han demostrat la seva utilitat per capturar representacions multi-escala en grafs de propietats moleculars i estructures biològiques; Grattarola et al. [11] ofereixen una revisió sistemàtica de les fortaleses i limitacions de les diverses estratègies de *pooling*.

3.3 Models de Fundació per a Histopatologia

L'extracció de característiques de *patches* histopatològics ha experimentat una evolució accelerada amb l'aparició de *foundation models* preentrenats a gran escala. UNI2 [12] és un *vision transformer* entrenat sobre més de 100 milions de *patches* de 20 tipus de teixit, assolint l'estat de l'art en nombroses tasques *downstream*. CONCH [13] estén aquest paradigma amb alineament text-imatge, permetent la cerca semàntica sobre representacions histopatològiques. La qualitat dels embeddings generats per aquests models és determinant per a la representació dels nodes en el graf, substituint avantajosament les tècniques d'extracció tradicionals basades en CNNs genèriques.

3.4 Treball Previ al CVC sobre pT1 CRC

El present projecte s'emmarca en una línia de recerca del grup IAM del CVC. Martí et al. [14] van analitzar el mateix conjunt de dades pT1 CRC comparant CNNs, ViTs i GNNs per a la classificació de *patches* individuals, obtenint la millor AUC ($0,954 \pm 0,077$) amb una arquitectura híbrida ViT+NN. Tanmateix, aquell enfocament opera a nivell de *patch* i no modela explícitament la topologia espacial del teixit ni el diagnòstic a nivell de pacient. El present treball construeix sobre els embeddings CLS del model UNI2 i proposa una arquitectura específicament dissenyada per explorar les relacions espacials entre regions histològiques i per al diagnòstic a nivell de pacient via MIL.

4 DADES I PREPROCESSAMENT

Aquest projecte es realitza en col·laboració amb un equip de la UAB que cobreix des de la recollida de dades fins a la creació d'autoencoders per a l'extracció de característiques.

4.1 Imatges de Gran Format (WSI)

Les dades originals consisteixen en imatges de làmines senceres (WSI) obtingudes amb escàners d'alta resolució i tintades amb hematoxilina-eosina, emmagatzemades en format MIRAX (*.mrxs*). Les dimensions oscil·len entre els 30.000 i els 150.000 píxels per costat, amb una quantitat significativa d'espai buit o artefactes que requereixen tractament previ.

El conjunt de dades efectiu comprèn **963 grafs** (un per secció histològica), provinents de **230 pacients** distribuïts de forma desequilibrada entre les dues classes (Taula 1). D'un total de 606 pacients a la base de dades clínica, 236 es descarten per diagnòstic indeterminat (NX), i dels 370 restants amb diagnòstic vàlid, 140 no disposen encara d'embeddings UNI2 generats, deixant 230 pacients usables. L'avaluació es realitza amb validació creuada estratificada de 5 particions a nivell de pacient.

TAULA 1: COMPOSICIÓ DEL DATASET EFECTIU (26 HOSPITALS).

	N0	N1	Total
Pacients	160	70	230
Slides úniques	—	—	448
Seccions (grafs)	—	—	963
Bags (nodes)	—	—	89 637

Bags per secció: mín. 3 / mitjana 93 / màx. 619

4.2 Anotacions i Màscare de Segmentació

La Dra. Eva Musulén, patòloga especialitzada, ha realitzat les anotacions manualment amb el programari *Labelme*. Aquestes identifiquen tres categories d'afectació:

- **Infiltració:** teixit anormal que envaeix zones no corresponents.
- **Displàsia:** cèl·lules anormals que poden esdevenir canceroses.
- **Infiltració + Displàsia:** emprat en casos de dubte diagnòstic.

A partir d'aquestes s'obtenen màscare de segmentació codificades per color: vermell (infiltració), blau (displàsia) i verd clar (combinada).




Fig. 1: Exemple de WSI i la seva corresponent màscara de segmentació.

4.3 Extracció de Patches i Embeddings CLS

S'aplica una finestra lliscant (*sliding window*) sense solapament per dividir cada làmina en *patches* de 256×256 píxels. Aquests s'agrupen en **bags** de 16×16 *patches* (256 *patches* per *bag*), cadascun cobrint una regió de $\approx 4096 \times 4096$ píxels del WSI a resolució completa (nivell 0). El model de fundació UNI2 [12] processa cada *bag* i extreu el token CLS de la seva sortida, obtenint un vector de **1.536 dimensions** que condensa la informació morfològica i textural de

la regió. No s'aplica cap filtratge de qualitat previ (ni per borrositat ni per proporció de blanc): tots els *bags* d'una secció generen un node del graf.

5 CONSTRUCCIÓ DEL GRAF

5.1 Nodes i característiques

Cada *bag* (conjunt de 256 *patches* de 256×256 px que cobreix $\approx 4096 \times 4096$ px al WSI) constitueix un **node** del graf. El vector de característiques de cada node és l'embedding CLS de **1.536 dimensions** obtingut per UNI2. La posició del node al pla WSI és el centroid de les coordenades dels seus 256 *patches*. A la subfigura 2a es pot observar la distribució esparsa dels *bags* extrets sobre una làmina real.

5.2 Model de dades: dimensions i estructures

Formalment, cada secció histològica es representa com un graf $\mathcal{G} = (\mathbf{X}, \mathbf{A})$ on:

- $\mathbf{X} \in \mathbb{R}^{N \times 1536}$ és la matriu de característiques dels N nodes (*bags*).
- $\mathbf{A} \in \{0, 1\}^{N \times N}$ és la matriu d'adjacència construïda per triangulació de Delaunay i posterior poda d'arestes llargues.

Dues estratègies de *pooling* transformen la seqüència de grafs en un vector global que alimenta el capçal MLP per produir $P(N1)$:

- **Pla (*readout*).** *Mean* o *max* aplicats sobre les sortides de la darrera capa GAT, reduint directament de N nodes a d_h dimensions.
- **Jeràrquic (DiffPool intercalat).** Dues capes DiffPool s'insereixen entre les capes GAT: la primera colapsa el graf de N nodes a K_1 super-nodes, i la segona de K_1 a K_2 . Cada nivell aprèn una matriu d'assignació suau i produeix un nou graf de menor grandària sobre el qual opera la capa GAT següent.

Model 1 — Múltiples grafs + agregació MIL. Cada secció genera un graf independent; les S seccions d'un pacient es processen per separat i les probabilitats $\{P(N1_i)\}_{i=1}^S$ s'agreguen a posteriori (Secció 7.1).

Model 2 — Mega-graf pacient (un sol graf). Com a alternativa, es pot construir un únic graf per pacient concatenant verticalment les matrius de característiques i col·locant les matrius d'adjacència en la diagonal d'una mega-matriu per blocs:

$$\mathbf{X}_{\text{pac}} = \begin{pmatrix} \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_S \end{pmatrix} \in \mathbb{R}^{(\sum_i N_i) \times 1536} \quad (1)$$

$$\mathbf{A}_{\text{pac}} = \begin{pmatrix} \mathbf{A}_1 & \mathbf{0} & \cdots \\ \mathbf{0} & \ddots & \mathbf{0} \\ \cdots & \mathbf{0} & \mathbf{A}_S \end{pmatrix} \quad (2)$$

Els triangles fora de la diagonal queden a zero, és a dir, no hi ha arestes entre seccions diferents. D'aquesta manera el mecanisme d'atenció del GAT opera sobre totes les

seccions simultàniament, i un únic *pooling* global produeix directament el diagnòstic del pacient sense necessitat d'una etapa d'agregació de probabilitats. Tots dos models estan implementats: el Model 1 és el mode per defecte de la *pipeline*, i el Model 2 s'activa amb l'argument `--mega` de `scripts/build_dataset.py`, que genera un fitxer `.pt` per pacient en lloc d'un per secció.


5.3 Connectivitat per triangulació de Delaunay

Una connectivitat fixa de reixeta no és adequada perquè la màscara exclou regions de fons, trencant la simetria de la quadrícula inicial. Per aquest motiu, s'aplica una **triangulació de Delaunay** sobre els nodes restants, que s'adapta orgànicament a distribucions irregulars. A continuació, s'eliminen les arestes que creuen píxels de valor zero en la màscara, evitant connexions entre regions separades per espai buit. Finalment, s'aplica un criteri de distància màxima: s'eliminen les arestes que superen el doble de la longitud mitjana del conjunt (`DISTANCE_FACTOR = 2,0`). La subfigura 2b mostra el resultat sobre la mateixa làmina: les arestes eliminades pel filtre de màscara apareixen en vermell.

6 ARQUITECTURA DEL MODEL

6.1 GATClassifier

El model implementat, `GATClassifier`, és un classificador de grafs que alterna capes **Graph Attention Network** (GATConv [4, 15]) amb capes de *pooling* jeràrquic per a la classificació binària N0/N1. L'arquitectura proposa intercalar operacions de reducció del graf *entre* les capes de propagació de missatges, de manera que cada estadi treballa sobre una representació progressivament més compacta del teixit:



on $K_1 \ll N$ i $K_2 \ll K_1$ són el nombre de *super-nodes* de cada nivell jeràrquic.

Mecanisme d'atenció. A diferència de les xarxes convolucionals clàssiques sobre grafs que tracten tots els veïns d'un node de forma uniforme, GAT aprèn a assignar pesos d'importància diferenciats a cada veí. Donada la representació $\mathbf{h}_i \in \mathbb{R}^F$ del node i , per a cada parella de nodes veïns

(i, j) es calcula un coeficient d'atenció no normalitzat:

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j])$$

on $\mathbf{W}$ és una transformació lineal aprenible, $\parallel$ la concatenació i $\mathbf{a}$ un vector d'atenció aprenible. Els coeficients es normalitzen amb *softmax* sobre tots els veïns del node i :

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$

i la nova representació del node s'obté com la suma ponderada dels veïns:

$$\mathbf{h}'_i = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W}\mathbf{h}_j \right)$$

Multi-cap. Per incrementar la capacitat expressiva, cada capa usa H caps d'atenció independents les sortides dels quals es concatenen (a les dues primeres capes) o es promitgen (tercera capa). D'aquesta manera el model pot capturar múltiples tipus de relació de veïnatge simultàniament. Cada capa va seguida de normalització per *batch*, activació ELU i *dropout*.

El capçal MLP (*Linear* $\rightarrow$ ReLU $\rightarrow$ Dropout $\rightarrow$ *Linear*) transforma la representació global del graf en els logits N0/N1.

6.2 Estratègies de Pooling Pla (Readout)

Quan no s'utilitza pooling jeràrquic, les representacions dels nodes de la darrera capa GAT s'agreguen directament amb operacions de *readout*: *mean*, *max* o la seva concatenació (*mean_max*). Tot i la seva eficiència computacional, aquestes estratègies ignoren la topologia del graf i col·lapsen tota la informació espacial en un sol pas.


6.3 Pooling Jeràrquic: DiffPool entre Capes GAT

Per superar les limitacions del *readout* pla, s'implementa **DiffPool** [10] com a operació intermèdia entre les capes de propagació. A diferència d'aplicar el *pooling* únicament al final, la proposta intercala dues capes DiffPool al llarg de la xarxa: una entre la primera i la segona capa GAT, i una altra entre la segona i la tercera. Cada capa DiffPool aprèn una matriu d'assignació suau (*soft assignment*) $\mathbf{S} \in \mathbb{R}^{N \times K}$ que agrupa els N nodes actuals en $K \ll N$ *super-nodes*:


$$\mathbf{X}^{(\ell+1)} = \mathbf{S}^\top \mathbf{X}^{(\ell)}, \quad \mathbf{A}^{(\ell+1)} = \mathbf{S}^\top \mathbf{A}^{(\ell)} \mathbf{S}$$

Amb aquesta arquitectura, la primera capa GAT opera sobre el graf original de nodes de teixit (N bags), la segona ho fa sobre un graf reduït de K_1 *super-nodes* que representen regions de teixit de nivell intermediari, i la tercera opera sobre un graf molt compacte de K_2 *super-nodes* que codifiquen l'organització arquitectònica global de la secció. Finalment, un *readout* global (*mean* o *max*) sobre els K_2 nodes produeix l'embedding que entra al capçal MLP.

L'entrenament incorpora una pèrdua auxiliar (*link prediction* + entropia mínima) per regularitzar l'assignació i evitar degeneracions trivials.



(a) Posicions dels *patches* dels quals se n'extreuen les característiques, superposades sobre la imatge original.



(b) Graf de Delaunay sobre la imatge anotada. Les zones verdes indiquen àrees afectades anotades per la patòloga; les arestes en vermell han estat eliminades pel filtratge de màscara.

Fig. 2: Visualització del procés de construcció del graf sobre una làmina real. Les dues imatges corresponen a la mateixa secció histològica i il·lustren com la topologia del graf s'adapta a la distribució irregular del teixit.




Fig. 3: Il·lustració del mecanisme d'atenció en una capa GAT amb tres caps independents (verd, blau, lila). El node central $\vec{h}_1$ agrega les representacions dels seus veïns i la seva pròpia (α_{11} , *self-loop*) mitjançant coeficients d'atenció α_{1j} apresos per cada cap. Les sortides dels caps es combinen per concatenació o promig per obtenir la nova representació $\vec{h}'_1$.

Com a alternativa, **SAGPool** [16] proposa un enfocament esparç que selecciona els K nodes més rellevants via puntuacions d'auto-atenció, descartant la resta i preservant l'estructura topològica original. A diferència de DiffPool, SAGPool no aprèn assignacions suaus sinó seleccions discretes, amb un cost computacional menor però sense la capacitat de capturar representacions jeràrquiques contínues. En aquest projecte s'utilitza DiffPool per la seva major expressivitat i la possibilitat d'integrar la pèrdua auxiliar de regularització.

7 METODOLOGIA

7.1 Agregació per Pacient (MIL)

El diagnòstic és per **pacient**, no per làmina. Una mateixa secció histològica pot no presentar senyals visibles de metàstasi si s'analitza aïlladament, mentre que en una altra secció del mateix pacient sí que és apreciable. Si s'entrena a nivell de làmina, les seccions N1 de pacients N1 que no mostren metàstasi visible reben un senyal de supervisió incorrecte (N0), contaminant l'entrenament.

Per solucionar-ho, s'adopta un paradigma d'**aprenentatge per múltiples instàncies** (*Multiple Instance Learning*, MIL): cada pacient és un *bag* i les seves làmines (instàncies) comparteixen l'etiqueta del *bag*. El model aprèn a classificar el *bag* a partir de les instàncies.

Donades les probabilitats $\{p_i = P(N1_i)\}_{i=1}^S$ de les S làmines d'un pacient, s'implementen les estratègies d'agregació següents:

- **Noisy-OR** (per defecte): $P(N1_p) = 1 - \prod_{i=1}^S (1 - p_i)$. Modela la hipòtesi que n'hi ha prou que una làmina presenti metàstasi per classificar el pacient com N1.
- **Max**: $P(N1_p) = \max_i p_i$. Predicció conservadora basada en l'evidència màxima.
- **Mean / LSE**: mitjana aritmètica o *log-sum-exp* per als casos intermedis.
- **Attention MIL**: PatientAggregator basat en l'atenció *gated* de Ilse et al. [5]. Aprèn un pes d'atenció per a cada làmina a partir del seu embedding (produït per l'encoder del GAT sense el capçal MLP), i la representació del pacient s'obté com la suma ponderada dels embeddings de les seves làmines.

Formalment, per a l'agregació per atenció, donat l'embedding $\mathbf{h}_i \in \mathbb{R}^d$ de la làmina i produït per l'encoder GAT,




Fig. 4: Agrupació jeràrquica de nodes per *DiffPool*: l'assignació suau colapsa progressivament el graf en super-nodes de major abstracció. En el model proposat, dos nivells *DiffPool* s'intercalen entre les capes GAT. Font: [10].

els pesos d'atenció i la representació del pacient s'obtenen com:

$$a_i = \frac{\exp(\mathbf{w}^\top (\tanh(\mathbf{V}\mathbf{h}_i) \odot \sigma(\mathbf{U}\mathbf{h}_i)))}{\sum_{j=1}^S \exp(\mathbf{w}^\top (\tanh(\mathbf{V}\mathbf{h}_j) \odot \sigma(\mathbf{U}\mathbf{h}_j)))}$$

$$\mathbf{z}_p = \sum_{i=1}^S a_i \mathbf{h}_i$$

on $\mathbf{w}$, $\mathbf{V}$, $\mathbf{U}$ són paràmetres aprenibles, $\odot$ és la multiplicació element a element i $\mathbf{z}_p$ és l'embedding del pacient que entra al capçal MLP per a la predicció final N0/N1.

7.2 Desbalanceig de Classes

El conjunt de dades presenta un fort desbalanceig: els casos N0 superen àmpliament els N1 (proporció aproximada 80/20). Per combatre-ho s'apliquen tres mesures complementàries.

(1) **Validació creuada estratificada.** S'utilitza una validació creuada de $k = 5$ particions estratificades a nivell de pacient, assegurant que la proporció N0/N1 sigui representativa en cada partició. Sense estratificació, amb un conjunt petit i desequilibrat, algunes particions podrien contenir per atzar una proporció de N1 molt diferent a la real, invalidant les mètriques.

(2) **Pesos de classe.** S'apliquen pesos balancejats $w_c = N/(C \cdot n_c)$, on n_c és el nombre de pacients de la classe c , incorporats directament a la funció de pèrdua BCE. Així, cada error sobre un cas N1 té més pes en el gradient que un error sobre N0, penalitzant més els falsos negatius.

(3) **Mostratge ponderat per batch.** Durant l'entrenament s'utilitza un *WeightedRandomSampler* que assigna a cada pacient una probabilitat de mostratge inversament proporcional a la freqüència de la seva classe. Això garanteix que cada *mini-batch* contingui una proporció equilibrada de casos N0 i N1, evitant que el model vegi gairebé exclusivament N0 durant molts *batches* consecutius.

7.3 Grid Search, K-Fold i Configuració d'Entrenament

S'ha dut a terme un *grid search* amb múltiples hiperparàmetres variables: *hidden units*, nombre de caps d'atenció, tipus de *pooling*, mètode d'agregació MIL, nombre de clústers *DiffPool*, *dropout* i *weight decay*. Cada combinació

d'hiperparàmetres genera una *run* independent amb mètriques registrades a *Weights & Biases*. El millor model per AUC de validació es desa com a *checkpoint*. L'entrenament inclou *early stopping* amb 15 epochs de *warm-up* i *patience* de 10, basant el criteri d'aturada en la pèrdua de validació.

Per a una avaluació estadísticament més robusta, s'implementa una validació creuada estratificada de k particions ($k = 5$ per defecte) a nivell de pacient, activable amb l'argument `--kfold 5` de *train.py*. En mode *k-fold*, tots els grafs (particions *train* i *val* predefinides) es reunifiquen i es reparteixen de nou en k folds estratificats per la proporció N0/N1, garantint representativitat en cada partició. Cada *fold* entrena un model independent (amb la seva pròpia *run* a W&B), i al final es reporta la mitjana $\pm$ desviació estàndard de les mètriques clau (AUC, F1-macro, F1-N1, *recall*-N1). Aquesta modalitat és compatible amb el *grid search*: si es combinen totes dues opcions, s'executen $n_{\text{combos}} \times k$ runs.

8 RESULTATS PRELIMINARS

El *grid search* amb validació creuada de 5 *folds* estratificada per pacient ha avaluat 4 configuracions: els dos tipus de *pooling* (GAT Baseline *mean_max* i GAT+*DiffPool diff*) creuats amb els dos mètodes d'agregació MIL (*noisy-OR* i *attention*). Per a cada combinació es va seleccionar el millor *learning rate* entre $\{10^{-4}, 10^{-5}\}$. Les mètriques de validació a nivell de pacient (mitjana $\pm$ desviació estàndard dels 5 *folds*) es presenten a la Taula 2.

El model GAT Baseline amb agregació *attention* assoleix el millor AUC ($0,817 \pm 0,073$). El model GAT+*DiffPool* amb *attention* obté un AUC comparable ($0,801 \pm 0,042$) amb la menor variabilitat entre *folds* i el millor F1-N1 ($0,679 \pm 0,058$), indicant una detecció de casos positius més estable. En contrast, l'agregació *noisy-OR* sense *attention* presenta resultats clarament inferiors, especialment per al GAT Baseline ($0,581 \pm 0,142$), confirmant la importància de l'agregació per atenció en el paradigma MIL per a aquest conjunt de dades desbalancejat.

Cal remarcar que aquests resultats són **preliminars**: corresponen a la segona entrega del TFG, en un moment en què l'arquitectura del model i les estratègies d'entrenament encara s'estan definint. No és possible extreure conclusions definitives sobre la superioritat d'un model respecte de l'altre; les diferències observades entre configuracions podrien variar significativament amb un espai de cerca d'hiperparàmetres més ampli, més dades o ajustaments al preprocés. En fases posteriors del projecte es duran a terme experi-


(a) GAT Baseline — readout pla sobre els N nodes originals.(b) GAT+DiffPool — DiffPool intercalat entre capes GAT; $K_1 \ll N$, $K_2 \ll K_1$ (p. ex. $N \approx 250$, $K_1 = 25$, $K_2 = 8$).

Fig. 5: Comparació de les dues arquitectures GATClassifier. **Esquerra:** model de referència amb readout pla (mean || max global); **Dreta:** model jeràrquic on DiffPool redueix progressivament $N \rightarrow K_1 \rightarrow K_2$ super-nodes. Les dimensions del tensor de sortida s'indiquen a la dreta de cada bloc ($h = 128$, $H = 4$, per tant $h \cdot H = 512$).

ments més exhaustius i una avaluació final consolidada.

9 IMPLEMENTACIÓ I FRONTEND

La implementació segueix un disseny modular: la construcció de grafs, el model, el codi d'entrenament i els *data loaders* estan desacoblats per facilitar l'experimentació independent. La configuració d'hiperparàmetres es gestiona via fitxer YAML, on qualsevol paràmetre pot ser una llista per activar el *grid search* automàtic. El repositori és accessible a [17] i el desplegament al servidor CVC es gestiona via GitHub Actions amb un *runner self-hosted*.

9.1 Frontend Web Interactiu

S'ha desenvolupat un *frontend* web (FastAPI + JavaScript pur, sense *build step*) per facilitar l'exploració dels models entrenats. Les funcionalitats principals inclouen:

- **Inferència en temps real:** selecció de pacient o làmina, *forward pass* al model actiu i visualització del resultat N0/N1 amb la descomposició per làmina.
- **Visualització de l'atenció:** representació del graf de Delaunay sobre la làmina, amb nodes colorejats per pes d'atenció (capes GATConv) i visualització dels *patches* RGB originals.

- **Estadístiques:** corbes ROC i PR, matriu de confusió i mètriques per classe sobre el conjunt de validació.
- **Selecció de checkpoint:** comparació entre múltiples models entrenats.

La figura 6 mostra el diagrama de flux complet del sistema.

10 CONCLUSIONS I TREBALL FUTUR

10.1 Conclusions Parcial

S'ha dissenyat i implementat un *pipeline* complet de classificació N0/N1 per a la predicció de metàstasi ganglionar en càncer colorectal pT1, des de la construcció de grafs espacials de Delaunay sobre embeddings UNI2 fins a l'entrenament amb validació creuada de 5 particions. Els resultats preliminars (millor AUC $0,817 \pm 0,073$) validen la viabilitat de l'enfocament. Se'n destaquen tres observacions:

- L'agregació per atenció MIL (PatientAggregator) és determinant: la mateixa arquitectura GAT Baseline passa d'AUC 0,581 amb *noisy-OR* a 0,817 amb *attention*, confirmant que el paradigma MIL requereix un mecanisme d'agregació expressiu per a un conjunt de dades desbalancejat.

TAULA 2: RESULTATS DEL *grid search* (5-fold CV, NIVELL DE PACIENT). PER A CADA COMBINACIÓ ES MOSTRA EL *learning rate* ÒPTIM. **NEGRETA**: MILLOR VALOR PER COLUMNA. MÈTRIQUES REPORTADES COM A MITJANA $\pm$ DESVIACIÓ ESTÀNDAR.

Model	Pooling	Agregació MIL	AUC	F1-macro	F1-N1
GAT Baseline	<i>mean_max</i>	<i>noisy-OR</i>	$0,581 \pm 0,142$	$0,498 \pm 0,123$	$0,499 \pm 0,070$
GAT Baseline	<i>mean_max</i>	<i>attention</i>	$0,817 \pm 0,073$	$0,751 \pm 0,083$	$0,641 \pm 0,126$
GAT+DiffPool	<i>diff</i>	<i>noisy-OR</i>	$0,754 \pm 0,059$	$0,653 \pm 0,046$	$0,568 \pm 0,052$
GAT+DiffPool	<i>diff</i>	<i>attention</i>	$0,801 \pm 0,042$	$0,749 \pm 0,061$	$0,679 \pm 0,058$

- GAT+DiffPool amb *attention* obté la menor variabilitat entre *folds* ($\sigma = 0,042$) i el millor F1-N1 ($0,679 \pm 0,058$), indicant que el *pooling* jeràrquic pot aportar una representació més estable tot i no superar clarament el model de referència en AUC.
- L'espai d'hiperparàmetres explorat és reduït i el dataset és limitat; no és possible extreure conclusions definitives en aquesta fase del projecte.

10.2 Treball Futur

Cerca d'hiperparàmetres exhaustiva. L'exploració actual cobreix 4 combinacions. S'implementarà un *random search* o cerca bayesiana (Optuna) sobre un espai més ampli que inclogui h_{hidden} , K_1/K_2 per a DiffPool, profunditat del MLP, *dropout*, *weight decay* i estratègia d'optimitzador.

Supervisió amb màscares d'anotació. S'explorà l'ús de les màscares binàries (displàsia, infiltració) anotades per la Dra. Musulén per guiar els pesos d'atenció del GAT, seguint l'enfocament de Tourniaire et al. [18] (MS-CLAM), on entre el 12 % i el 62 % de les anotacions parcials és suficient per millorar la localització i la classificació. Això permetria aprofitar les anotacions disponibles com a supervisió feble espacialment informada, afegint un senyal de regularització al model.

Ampliació del dataset. Dels 370 pacients amb diagnòstic vàlid, 140 (el 38 %) no disposen d'embeddings UNI2 perquè el *pipeline* d'extracció no s'ha executat sobre les seves làmines (notablement tot l'H. 12 de Octubre amb 48 pacients). Generar aquests embeddings podria pràcticament doblar el dataset efectiu i millorar substancialment la capacitat de generalització.

Comparació amb baselines MIL sense graf. Per quantificar l'aportació real de la informació topològica, es comparà el model GAT contra ABMIL/CLAM [6] aplicat sobre els mateixos embeddings UNI2 però sense estructura de graf, permetent aïllar la contribució de les arestes de Delaunay.

Ablació de la connectivitat. Es compararan els grafs de Delaunay amb alternatives (k -NN, radi fix, graf completament connectat) per verificar si la topologia espacial real del teixit aporta avantatge respecte de connexions menys informades.

REFERÈNCIES

- [1] Sociedad Española de Oncología Médica (SEOM). *Las Cifras del Cáncer en España 2026*. Consultat el 6 de febrer de 2026. 2026. URL: <https://seom.org/prensa/el-cancer-en-cifras>.
- [2] Unitat Funcional Càncer Colorectal. *Protocol de Pràctica Clínica del Càncer de Còlon i Recte*. Actualització de la 3^a edició. Parc de Salut MAR Barcelona - Hospital del Mar. Barcelona, juny de 2013. URL: https://www.hospitaldelmar.cat/media/upload/arxius/unitats/cancer_colorectal/protocols/practica_clinica.pdf.
- [3] Fernando Martínez de Juan, Samuel Navarro i Isidro Machado. "Refining Risk Criteria May Substantially Reduce Unnecessary Additional Surgeries after Local Resection of T1 Colorectal Cancer". A: *Cancers* 16.13 (2024), pàg. 2321. DOI: 10.3390/cancers16132321.
- [4] Petar Veličković et al. *Graph Attention Networks*. 2018. arXiv: 1710.10903 [stat.ML]. URL: <https://arxiv.org/abs/1710.10903>.
- [5] Maximilian Ilse, Jakub M. Tomczak i Max Welling. *Attention-based Deep Multiple Instance Learning*. 2018. arXiv: 1802.04712 [cs.LG]. URL: <https://arxiv.org/abs/1802.04712>.
- [6] Ming Y. Lu et al. *Data Efficient and Weakly Supervised Computational Pathology on Whole Slide Images*. 2020. arXiv: 2004.09666 [eess.IV]. URL: <https://arxiv.org/abs/2004.09666>.
- [7] Bin Li, Yin Li i Kevin W. Eliceiri. *Dual-stream Multiple Instance Learning Network for Whole Slide Image Classification with Self-supervised Contrastive Learning*. 2021. arXiv: 2011.08939 [cs.CV]. URL: <https://arxiv.org/abs/2011.08939>.
- [8] Holger S. Muti, Christoph Röcken, Hans-Michael Behrens et al. "Deep learning trained on lymph node status predicts outcome from gastric cancer histopathology: a retrospective multicentric study". A: *European Journal of Cancer* 194 (2023), pàg. 113335. DOI: 10.1016/j.ejca.2023.113335.
- [9] Guillaume Jaume et al. *HistoCartography: A Toolkit for Graph Analytics in Digital Pathology*. 2021. arXiv: 2107.10073 [eess.IV]. URL: <https://arxiv.org/abs/2107.10073>.
- [10] Rex Ying et al. *Hierarchical Graph Representation Learning with Differentiable Pooling*. 2019. arXiv: 1806.08804 [cs.LG]. URL: <https://arxiv.org/abs/1806.08804>.




Fig. 6: Diagrama de flux del *pipeline* complet. *Blocs grisos*: etapes realitzades pels companys de l'equip (extracció de *patches* i obtenció de l'embedding CLS via UNI2). *Blocs blaus (vora gruixuda)*: contribucions d'aquest TFG. La fletxa $\times S$ indica que les S seccions d'un pacient es processen com a grafs independents i les probabilitats $P(N1)$ s'agreguen via MIL per obtenir el diagnòstic final a nivell de pacient.

- [11] Daniele Grattarola et al. "Understanding Pooling in Graph Neural Networks". A: *IEEE Transactions on Neural Networks and Learning Systems* 35.2 (febr. de 2024), pàg. 2708 - 2718. ISSN: 2162-2388. DOI: 10.1109/tnnls.2022.3190922.
- [12] Richard J. Chen et al. "Towards a general-purpose foundation model for computational pathology". A: *Nature Medicine* 30.3 (març de 2024), pàg. 850 - 862. DOI: 10.1038/s41591-024-02857-3.
- [13] Ming Y. Lu et al. "A visual-language foundation model for computational pathology". A: *Nature Medicine* 30.3 (març de 2024), pàg. 863 - 874. DOI: 10.1038/s41591-024-02856-4.
- [14] Pau Martí Escolà. "Anàlisi d'espais de representació profunds pel diagnòstic del carcinoma colorectal en histopatologia digital". Treb. fin. de màst. Universitat Autònoma de Barcelona, 2025. URL: <https://ddd.uab.cat/record/317556>.
- [15] Matthias Fey i Jan Eric Lenssen. *Fast Graph Representation Learning with PyTorch Geometric*. 2019. arXiv: 1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.
- [16] Junhyun Lee, Inyeop Lee i Jaewoo Kang. *Self-Attention Graph Pooling*. 2019. arXiv: 1904.08082 [cs.LG]. URL: <https://arxiv.org/abs/1904.08082>.
- [17] David M. et al. *Implementació de Graph Attention Networks per a la detecció de metàstasi en pT1*. 2026. URL: <https://github.com/IAM-CVC/PT1Diagnosis> (cons. 03-05-2026).
- [18] Paul Tourniaire et al. "MS-CLAM: Mixed supervision for the classification and localization of tumors in Whole Slide Images". A: *Medical Image Analysis* 85 (2023), pàg. 102763. DOI: 10.1016/j.media.2023.102763.