

Predicció de Metàstasi en Histopatologia en Càncer Colorrectal usant Graph Attention Networks

David Morillo Massagué

Resum— Es proposa un *pipeline* de classificació N0/N1 per a la predicció de metàstasi en ganglis limfàtics en càncer colorrectal pT1 a partir de *Whole Slide Images*. El teixit es representa com un **graf espacial** construït per triangulació de Delaunay sobre les coordenades dels *bags*, preservant l'arquitectura topològica del teixit —a diferència d'enfocaments basats en similitud de característiques. Cada node és un *bag* de 256 *patches* caracteritzat per l'embedding CLS (1.536 dim.) del model de fundació UNI2. Es comparen dues arquitectures: un GAT de referència amb *readout* pla i un GAT amb **DiffPool jeràrquic** intercalat ($N \rightarrow K_1 \rightarrow K_2$ super-nodes), que captura representació multi-escala del teixit. El diagnòstic per pacient s'obté per agregació MIL sobre les seccions. El millor model assoleix un AUC de $0,817 \pm 0,073$ (5-fold CV, 230 pacients).

Paraules clau— Càncer colorrectal pT1, Histopatologia digital, Graph Attention Networks, Diff-Pool jeràrquic, Graf espacial de Delaunay, MIL, Desbalanceig de classes.

Abstract— We propose an N0/N1 classification pipeline for lymph node metastasis prediction in pT1 colorectal cancer from Whole Slide Images. Tissue is represented as a **spatial graph** built by Delaunay triangulation over bag coordinates, preserving the topological architecture of tissue —unlike feature-similarity graph approaches. Each node is a bag of 256 patches characterised by a 1,536-dimensional CLS embedding from the UNI2 foundation model. Two architectures are compared: a **GAT baseline** with flat readout (mean/max) and a **hierarchical GAT+DiffPool** model with pooling layers interleaved between GAT layers ($N \rightarrow K_1 \rightarrow K_2$ super-nodes), enabling multi-scale tissue representations. Patient-level diagnosis is obtained via MIL aggregation over histological sections. The best model achieves an AUC of 0.817 ± 0.073 (5-fold CV, 230 patients).

Keywords— pT1 colorectal cancer, Digital histopathology, Graph Attention Networks, Hierarchical DiffPool, Spatial Delaunay graph, Multiple Instance Learning, Class imbalance.

1 INTRODUCCIÓ

EL càncer colorrectal (CCR) representa un dels reptes de salut pública més greus del nostre entorn. A Espanya, la SEOM preveu per al 2026 més de **44.132** nous casos anuals, convertint-lo en el tumor més freqüentment diagnosticat i en la segona causa de mort per càncer amb 14.629 defuncions [1].

El carcinoma pT1 és especialment complex: el tumor ha envaït la submucosa però no la muscular pròpia, i el risc de

metàstasi als ganglis limfàtics oscil·la entre el **2%** i el **23%** depenent de la profunditat d'invasió [2]. Quan hi ha criteris de mal pronòstic, el risc s'estima al voltant del 10%, la qual cosa obliga a considerar una cirurgia radical. Tanmateix, s'estima que **entre el 80% i el 90%** d'aquestes cirurgies resulten innecessàries [3].

La histopatologia digital, a través de les *Whole Slide Images* (WSI), obre la porta a tècniques avançades de visió per computador. En concret, les *Graph Attention Networks* (GAT) [4] permeten modelar l'arquitectura espacial del teixit de forma relacional. Una decisió clau en la construcció del graf és la definició de les arestes: mentre que alguns treballs les basen en la *similitud de característiques* entre *bags*, aquest projecte opta per la **proximitat espacial** (triangulació de Delaunay sobre coordenades WSI), preservant la topologia real del teixit. Aquest projecte, desenvolupat al

• E-mail de contacte: David.MorilloMa@autonoma.cat
• Treball tutoritzat per: Debora Gil Resina (DCC)
• Curs 2025/26

grup IAM del CVC (iam.cvc.uab.es) sota la supervisió de la Dra. Debora Gil, compara un GAT de referència amb *readout* pla contra un model amb *pooling* jeràrquic (DiffPool) intercalat, i proposa estratègies d'agregació MIL per al diagnòstic a nivell de pacient.

2 MOTIVACIÓ

Dues raons complementàries justifiquen la tria d'aquest projecte. Des del punt de vista clínic, els sistemes d'IA demostren una capacitat creixent per identificar patrons morfològics subtils de manera consistent, amb el potencial real de reduir cirurgies innecessàries. Des del punt de vista tècnic, la combinació de xarxes d'atenció sobre grafs i aprenentatge profund sobre imatges histopatològiques d'alta resolució és exactament la intersecció entre la teoria de grafs i les xarxes neuronals profundes que vull explorar dins de l'Enginyeria de Dades.

3 OBJECTIUS

- Construir un *pipeline* complet de classificació N0/N1 sobre WSI reals a partir d'embeddings CLS del model UNI2, basat en **grafs espacials** (triangulació de Delaunay sobre coordenades del teixit).
- **Comparar un GAT de referència** amb *readout* pla contra un model amb **DiffPool jeràrquic** intercalat entre les capes GAT, avaluant si la reducció progressiva del graf aporta millor representació multi-escala.
- Implementar i comparar estratègies d'agregació MIL a nivell de pacient per integrar les prediccions de múltiples seccions histològiques.
- Avaluar la robustesa dels models mitjançant validació creuada estratificada (*k*-fold).
- Proporcionar una eina interactiva de visualització i inferència en temps real.

4 DADES I PREPROCESSAMENT

Aquest projecte es realitza en col·laboració amb un equip de la UAB que cobreix des de la recollida de dades fins a la creació d'autoencoders per a l'extracció de característiques.

4.1 Imatges de Gran Format (WSI)

Les dades originals consisteixen en imatges de làmines senceres (WSI) obtingudes amb escàners d'alta resolució i tintades amb hematoxilina-eosina, emmagatzemades en format MIRAX (.mrxs). Les dimensions oscil·len entre els 30.000 i els 150.000 píxels per costat, amb una quantitat significativa d'espai buit o artefactes que requereixen tractament previ.

El conjunt de dades comprèn **963 grafs**, un per secció histològica (cadascun amb una o diverses components connexes), provinents de **230 pacients** en total. S'aplica una divisió estratificada 80/20 a nivell de pacient per evitar la filtració d'informació entre entrenament i validació.

4.2 Anotacions i Màscares de Segmentació

La Dra. Eva Musulén, patòloga especialitzada, ha realitzat les anotacions manualment amb el programari *Labelme*. Aquestes identifiquen tres categories d'afectació:

- **Infiltració:** teixit anormal que envaeix zones no corresponents.
- **Displàsia:** cèl·lules anormals que poden esdevenir canceroses.
- **Infiltració + Displàsia:** emprat en casos de dubte diagnòstic.

A partir d'aquestes s'obtenen màscares de segmentació codificades per color: vermell (infiltració), blau (displàsia) i verd clar (combinada).




Fig. 1: Exemple de WSI i la seva corresponent màscara de segmentació.

4.3 Extracció de Patches i Embeddings CLS

S'aplica una finestra lliscant (*sliding window*) sense solapament per dividir cada làmina en *patches* de 256×256 píxels. Aquests s'agrupen en **bags** de 16×16 *patches* (256 *patches* per *bag*), cadascun cobrint una regió de $\approx 4096 \times 4096$ píxels del WSI a resolució completa (nivell 0). El model de fundació UNI2 [5] processa cada *bag* i extreu el token CLS de la seva sortida, obtenint un vector de **1.536 dimensions** que condensa la informació morfològica i textural de la regió. No s'aplica cap filtratge de qualitat previ (ni per borrositat ni per proporció de blanc): tots els *bags* d'una secció generen un node del graf.

5 CONSTRUCCIÓ DEL GRAF

5.1 Nodes i característiques

Cada *bag* (conjunt de 256 *patches* de 256×256 px que cobreix $\approx 4096 \times 4096$ px al WSI) constitueix un **node** del graf. El vector de característiques de cada node és l'embedding CLS de **1.536 dimensions** obtingut per UNI2. La posició del node al pla WSI és el centroid de les coordenades dels seus 256 *patches*. A la subfigura 2a es pot observar la distribució esparsa dels *bags* extrets sobre una làmina real.

5.2 Model de dades: dimensions i estructures

Formalment, cada secció histològica es representa com un graf $\mathcal{G} = (\mathbf{X}, \mathbf{A})$ on:

- $\mathbf{X} \in \mathbb{R}^{N \times 1536}$ és la matriu de característiques dels N nodes (*bags*).

- $\mathbf{A} \in \{0, 1\}^{N \times N}$ és la matriu d'adjacència construïda per triangulació de Delaunay i posterior poda d'arestes llargues.

Dues estratègies de *pooling* transformen la seqüència de grafs en un vector global que alimenta el capçal MLP per produir $P(N1)$:

- **Pla (readout).** *Mean* o *max* aplicats sobre les sortides de la darrera capa GAT, reduint directament de N nodes a d_h dimensions.
- **Jeràrquic (DiffPool intercalat).** Dues capes DiffPool s'insereixen entre les capes GAT: la primera colapsa el graf de N nodes a K_1 super-nodes, i la segona de K_1 a K_2 . Cada nivell aprèn una matriu d'assignació suau i produeix un nou graf de menor grandària sobre el qual opera la capa GAT següent.

Model 1 — Múltiples grafs + agregació MIL. Cada secció genera un graf independent; les S seccions d'un pacient es processen per separat i les probabilitats $\{P(N1_i)\}_{i=1}^S$ s'agreguen a posteriori (Secció 7.1).

Model 2 — Mega-graf pacient (un sol graf). Com a alternativa, es pot construir un únic graf per pacient concatenant verticalment les matrius de característiques i col·locant les matrius d'adjacència en la diagonal d'una mega-matriu per blocs:

$$\mathbf{X}_{\text{pac}} = \begin{pmatrix} \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_S \end{pmatrix} \in \mathbb{R}^{(\sum_i N_i) \times 1536} \quad (1)$$

$$\mathbf{A}_{\text{pac}} = \begin{pmatrix} \mathbf{A}_1 & \mathbf{0} & \cdots \\ \mathbf{0} & \ddots & \mathbf{0} \\ \cdots & \mathbf{0} & \mathbf{A}_S \end{pmatrix} \quad (2)$$

Els triangles fora de la diagonal queden a zero, és a dir, no hi ha arestes entre seccions diferents. D'aquesta manera el mecanisme d'atenció del GAT opera sobre totes les seccions simultàniament, i un únic *pooling* global produeix directament el diagnòstic del pacient sense necessitat d'una etapa d'agregació de probabilitats. Tots dos models estan implementats: el Model 1 és el mode per defecte del *pipeline*, i el Model 2 s'activa amb l'argument `--mega` de `scripts/build_dataset.py`, que genera un fitxer `.pt` per pacient en lloc d'un per secció.

5.3 Connectivitat per triangulació de Delaunay


Una connectivitat fixa de reixeta no és adequada perquè la màscara exclou regions de fons, trencant la simetria de la quadrícula inicial. Per aquest motiu, s'aplica una **triangulació de Delaunay** sobre els nodes restants, que s'adapta orgànicament a distribucions irregulars. A continuació, s'eliminen les arestes que creuen píxels de valor zero en la màscara, evitant connexions entre regions separades per espai buit. Finalment, s'aplica un criteri de distància màxima: s'eliminen les arestes que superen el doble de la longitud mitjana del conjunt (`DISTANCE_FACTOR = 2,0`). La subfigura 2b mostra el resultat sobre la mateixa làmina: les

arestes eliminades pel filtre de màscara apareixen en vermell.

6 ARQUITECTURA DEL MODEL

6.1 GATClassifier

El model implementat, `GATClassifier`, és un classificador de grafs que alterna capes **Graph Attention Network** (`GATConv` [4, 6]) amb capes de *pooling* jeràrquic per a la classificació binària N0/N1. L'arquitectura proposa intercalar operacions de reducció del graf *entre* les capes de propagació de missatges, de manera que cada estadi treballa sobre una representació progressivament més compacta del teixit:



on $K_1 \ll N$ i $K_2 \ll K_1$ són el nombre de *super-nodes* de cada nivell jeràrquic.

Mecanisme d'atenció. A diferència de les xarxes convolucionals clàssiques sobre grafs que tracten tots els veïns d'un node de forma uniforme, GAT aprèn a assignar pesos d'importància diferenciats a cada veí. Donada la representació $\mathbf{h}_i \in \mathbb{R}^F$ del node i , per a cada parella de nodes veïns (i, j) es calcula un coeficient d'atenció no normalitzat:

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j])$$


on $\mathbf{W}$ és una transformació lineal aprenible, $\parallel$ la concatenació i $\mathbf{a}$ un vector d'atenció aprenible. Els coeficients es normalitzen amb *softmax* sobre tots els veïns del node i :

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$


i la nova representació del node s'obté com la suma ponderada dels veïns:

$$\mathbf{h}'_i = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W}\mathbf{h}_j \right)$$

Multi-cap. Per incrementar la capacitat expressiva, cada capa usa H caps d'atenció independents les sortides dels quals es concatenen (a les dues primeres capes) o es promitgen (tercera capa). D'aquesta manera el model pot capturar múltiples tipus de relació de veïnatge simultàniament. Cada



(a) Posicions dels *patches* dels quals se n'extreuen les característiques, superposades sobre la imatge original.



(b) Graf de Delaunay sobre la imatge anotada. Les zones verdes indiquen àrees afectades anotades per la patòlogia; les arestes en vermell han estat eliminades pel filtratge de màscara.

Fig. 2: Visualització del procés de construcció del graf sobre una làmina real. Les dues imatges corresponen a la mateixa secció histològica i il·lustren com la topologia del graf s'adapta a la distribució irregular del teixit.




Fig. 3: Il·lustració del mecanisme d'atenció en una capa GAT amb tres caps independents (verd, blau, lila). El node central $\vec{h}_1$ agrega les representacions dels seus veïns i la seva pròpia (α_{11} , *self-loop*) mitjançant coeficients d'atenció α_{1j} apresos per cada cap. Les sortides dels caps es combinen per concatenació o promig per obtenir la nova representació $\vec{h}'_1$.

capa va seguida de normalització per *batch*, activació ELU i *dropout*.

El capçal MLP (*Linear* $\rightarrow$ *ReLU* $\rightarrow$ *Dropout* $\rightarrow$ *Linear*) transforma la representació global del graf en els logits N0/N1.

6.2 Estratègies de Pooling Pla (*Readout*)

Quan no s'utilitza pooling jeràrquic, les representacions dels nodes de la darrera capa GAT s'agreguen directament amb operacions de *readout*: *mean*, *max* o la seva concatenació (*mean_max*). Tot i la seva eficiència computacional, aquestes estratègies ignoren la topologia del graf i col·lapsen tota la informació espacial en un sol pas.

6.3 Pooling Jeràrquic: DiffPool entre Capes GAT

Per superar les limitacions del *readout* pla, s'implementa **DiffPool** [7] com a operació intermèdia entre les capes de propagació. A diferència d'aplicar el *pooling* únicament al final, la proposta intercala dues capes DiffPool al llarg de la xarxa: una entre la primera i la segona capa GAT, i una altra entre la segona i la tercera. Cada capa DiffPool aprèn una matriu d'assignació suau (*soft assignment*) $\mathbf{S} \in \mathbb{R}^{N \times K}$ que agrupa els N nodes actuals en $K \ll N$ *super-nodes*:

$$\mathbf{X}^{(\ell+1)} = \mathbf{S}^\top \mathbf{X}^{(\ell)}, \quad \mathbf{A}^{(\ell+1)} = \mathbf{S}^\top \mathbf{A}^{(\ell)} \mathbf{S}$$

Amb aquesta arquitectura, la primera capa GAT opera sobre el graf original de nodes de teixit (N bags), la segona ho fa sobre un graf reduït de K_1 super-nodes que representen regions de teixit de nivell intermedi, i la tercera opera sobre un graf molt compacte de K_2 super-nodes que codifiquen l'organització arquitectònica global de la secció. Finalment, un *readout* global (*mean* o *max*) sobre els K_2 nodes produeix l'embedding que entra al capçal MLP.

L'entrenament incorpora una pèrdua auxiliar (*link prediction* + entropia mínima) per regularitzar l'assignació i evitar degeneracions trivials.

Com a alternativa, **SAGPool** [8] proposa un enfocament esparç que selecciona els K nodes més rellevants via puntuacions d'auto-atenció, descartant la resta i preservant l'estructura topològica original. A diferència de DiffPool, SAGPool no aprèn assignacions suaus sinó seleccions discretes, amb un cost computacional menor però sense la capacitat de capturar representacions jeràrquiques contínues. En aquest projecte s'utilitza DiffPool per la seva major expressivitat i la possibilitat d'integrar la pèrdua auxiliar de regularització.




Fig. 4: Agrupació jeràrquica de nodes per *DiffPool*: l'assignació suau colapsa progressivament el graf en super-nodes de major abstracció. En el model proposat, dos nivells *DiffPool* s'intercalen entre les capes GAT. Font: [7].

7 METODOLOGIA

7.1 Agregació per Pacient (MIL)

El diagnòstic és per **pacient**, no per làmina. Una mateixa secció histològica pot no presentar senyals visibles de metàstasi si s'analitza aïlladament, mentre que en una altra secció del mateix pacient sí que és apreciable. Si s'entrena a nivell de làmina, les seccions N1 de pacients N1 que no mostren metàstasi visible reben un senyal de supervisió incorrecte (N0), contaminant l'entrenament.

Per solucionar-ho, s'adopta un paradigma d'**aprenentatge per múltiples instàncies** (*Multiple Instance Learning*, MIL) [9]: cada pacient és un *bag* i les seves làmines (instàncies) comparteixen l'etiqueta del *bag*. El model aprèn a classificar el *bag* a partir de les instàncies.

Donades les probabilitats $\{p_i = P(N1_i)\}_{i=1}^S$ de les S làmines d'un pacient, s'implementen les estratègies d'agregació següents:

- **Noisy-OR** (per defecte): $P(N1_p) = 1 - \prod_{i=1}^S (1 - p_i)$. Modela la hipòtesi que n'hi ha prou que una làmina presenti metàstasi per classificar el pacient com N1.
- **Max**: $P(N1_p) = \max_i p_i$. Predicció conservadora basada en l'evidència màxima.
- **Mean / LSE**: mitjana aritmètica o *log-sum-exp* per als casos intermedis.
- **Attention MIL**: *PatientAggregator* basat en l'atenció *gated* de Ilse et al. [9]. Aprèn un pes d'atenció per a cada làmina a partir del seu embedding (produït per l'encoder del GAT sense el capçal MLP), i la representació del pacient s'obté com la suma ponderada dels embeddings de les seves làmines.

7.2 Desbalanceig de Classes

El conjunt de dades presenta un fort desbalanceig: els casos N0 superen àmpliament els N1 (proporció aproximada 80/20). Per combatre-ho s'apliquen tres mesures complementàries.

(1) **Divisió estratificada**. La partició entrenament/validació (80/20) es realitza de forma estratificada a nivell de pacient: s'assegura que la proporció N0/N1 sigui equivalent en ambdós subconjunts. Sense estratificació, amb un conjunt petit i desbalancejat, el conjunt de validació podria contenir per atzar una proporció de N1 molt diferent a la real, invalidant les mètriques.

(2) **Pesos de classe**. S'apliquen pesos balancejats $w_c = N/(C \cdot n_c)$, on n_c és el nombre de pacients de la classe c , incorporats directament a la funció de pèrdua BCE. Així, cada error sobre un cas N1 té més pes en el gradient que un error sobre N0, penalitzant més els falsos negatius.

(3) **Mostratge ponderat per batch**. Durant l'entrenament s'utilitza un *WeightedRandomSampler* que assigna a cada pacient una probabilitat de mostratge inversament proporcional a la freqüència de la seva classe. Això garanteix que cada *mini-batch* contingui una proporció equilibrada de casos N0 i N1, evitant que el model vegi gairebé exclusivament N0 durant molts *batches* consecutius.

7.3 Grid Search, K-Fold i Configuració d'Entrenament

S'ha dut a terme un *grid search* amb múltiples hiperparàmetres variables: *hidden units*, nombre de caps d'atenció, tipus de *pooling*, mètode d'agregació MIL, nombre de clústers *DiffPool*, *dropout* i *weight decay*. Cada combinació d'hiperparàmetres genera una *run* independent amb mètriques registrades a *Weights & Biases*. El millor model per AUC de validació es desa com a *checkpoint*. L'entrenament inclou *early stopping* amb 15 epochs de *warm-up* i *patience* de 10, basant el criteri d'aturada en la pèrdua de validació.

Per a una avaluació estadísticament més robusta, s'implementa una validació creuada estratificada de k particions ($k = 5$ per defecte) a nivell de pacient, activable amb l'argument `--kfold 5` de *train.py*. En mode *k-fold*, tots els grafs (particions *train* i *val* predefinides) es reunifiquen i es reparteixen de nou en k folds estratificats per la proporció N0/N1, garantint representativitat en cada partició. Cada *fold* entrena un model independent (amb la seva pròpia *run* a W&B), i al final es reporta la mitjana $\pm$ desviació estàndard de les mètriques clau (AUC, F1-macro, F1-N1, *recall*-N1). Aquesta modalitat és compatible amb el *grid search*: si es combinen totes dues opcions, s'executen $n_{\text{combos}} \times k$ runs.

7.4 Atenció Supervisada amb Màscare

Una línia d'investigació planificada és l'ús de les màscares binàries d'anotació expert (displàsia, infiltració) per supervisar els pesos d'atenció del model GAT. L'objectiu és que les regions anotades amb patologia actuïn com a guia de supervisió feble, forçant el model a focalitzar l'atenció sobre les àrees d'interès clínic independentment de l'etiqueta N0/N1 final. Això permetria aprofitar les anotacions dispo-


(a) GAT Baseline — readout pla sobre els N nodes originals.(b) GAT+DiffPool — DiffPool intercalat entre capes GAT; $K_1 \ll N$, $K_2 \ll K_1$ (p. ex. $N \approx 250$, $K_1 = 25$, $K_2 = 5$).

Fig. 5: Comparació de les dues arquitectures GATClassifier. **Esquerra:** model de referència amb readout pla (mean || max global); **Dreta:** model jeràrquic on DiffPool redueix progressivament $N \rightarrow K_1 \rightarrow K_2$ super-nodes, emetent a cada nivell una pèrdua auxiliar $\mathcal{L}_{aux} = \mathcal{L}_{link} + \mathcal{L}_{ent}$ que es suma a la BCE principal. Les dimensions del tensor de sortida s'indiquen a la dreta de cada bloc ($h = 128$, $H = 4$, per tant $h \cdot H = 512$).

nibles més enllà del diagnòstic binari, afegint un senyal de regularització espacialment informat.

8 RESULTATS PRELIMINARS

El *grid search* amb validació creuada de 5 *folds* estratificada per pacient ha avaluat 4 configuracions: els dos tipus de *pooling* (GAT Baseline *mean_max* i GAT+DiffPool *diff*) creuats amb els dos mètodes d'agregació MIL (*noisy-OR* i *attention*). Per a cada combinació es va seleccionar el millor *learning rate* entre $\{10^{-4}, 10^{-5}\}$. Les mètriques de validació a nivell de pacient (mitjana $\pm$ desviació estàndard dels 5 *folds*) es presenten a la Taula 1.

El model GAT Baseline amb agregació *attention* assoleix el millor AUC ($0,817 \pm 0,073$). El model GAT+DiffPool amb *attention* obté un AUC comparable ($0,801 \pm 0,042$) amb la menor variabilitat entre *folds* i el millor F1-N1 ($0,679 \pm 0,058$), indicant una detecció de casos positius més estable. En contrast, l'agregació *noisy-OR* sense *attention* presenta resultats clarament inferiors, especialment per al GAT Baseline ($0,581 \pm 0,142$), confirmant la importància de l'agregació per atenció en el paradigma MIL per a aquest conjunt de dades desbalancejat.

9 IMPLEMENTACIÓ I FRONTEND

La implementació segueix un disseny modular: la construcció de grafs, el model, el codi d'entrenament i els *data loaders* estan desacoblats per facilitar l'experimentació independent. La configuració d'hiperparàmetres es gestiona via fitxer YAML, on qualsevol paràmetre pot ser una llista per activar el *grid search* automàtic. El repositori és accessible a [10] i el desplegament al servidor CVC es gestiona via GitHub Actions amb un *runner self-hosted*.

9.1 Frontend Web Interactiu

S'ha desenvolupat un *frontend* web (FastAPI + JavaScript pur, sense *build step*) per facilitar l'exploració dels models entrenats. Les funcionalitats principals inclouen:

- **Inferència en temps real:** selecció de pacient o làmina, *forward pass* al model actiu i visualització del resultat N0/N1 amb la descomposició per làmina.
- **Visualització de l'atenció:** representació del graf de Delaunay sobre la làmina, amb nodes colorejats per pes d'atenció (capes GATConv) i visualització dels *patches* RGB originals.

TAULA 1: RESULTATS DEL *grid search* (5-fold CV, NIVELL DE PACIENT). PER A CADA COMBINACIÓ ES MOSTRA EL *learning rate* ÒPTIM. **NEGRETA**: MILLOR VALOR PER COLUMNA. MÈTRIQUES REPORTADES COM A MITJANA ± DESVIACIÓ ESTÀNDAR.

Model	Pooling	Agregació MIL	AUC	F1-macro	F1-N1
GAT Baseline	<i>mean_max</i>	<i>noisy-OR</i>	0,581 ± 0,142	0,498 ± 0,123	0,499 ± 0,070
GAT Baseline	<i>mean_max</i>	<i>attention</i>	0,817 ± 0,073	0,751 ± 0,083	0,641 ± 0,126
GAT+DiffPool	<i>diff</i>	<i>noisy-OR</i>	0,754 ± 0,059	0,653 ± 0,046	0,568 ± 0,052
GAT+DiffPool	<i>diff</i>	<i>attention</i>	0,801 ± 0,042	0,749 ± 0,061	0,679 ± 0,058

- **Estadístiques:** corbes ROC i PR, matriu de confusió i mètriques per classe sobre el conjunt de validació.
- **Selecció de checkpoint:** comparació entre múltiples models entrenats.

La figura 6 mostra el diagrama de flux complet del sistema.

[9] Maximilian Ilse, Jakub M. Tomczak i Max Welling. *Attention-based Deep Multiple Instance Learning*. 2018. arXiv: 1802.04712 [cs.LG]. URL: <https://arxiv.org/abs/1802.04712>.

[10] David M. et al. *Implementació de Graph Attention Networks per a la detecció de metàstasi en pT1*. 2026. URL: <https://github.com/IAM-CVC/PT1Diagnosis> (cons. 03-05-2026).

REFERÈNCIES

[1] Sociedad Española de Oncología Médica (SEOM). *Las Cifras del Cáncer en España 2026*. Consultat el 6 de febrer de 2026. 2026. URL: <https://seom.org/prensa/el-cancer-en-cifras>.

[2] Unitat Funcional Càncer Colorectal. *Protocol de Pràctica Clínica del Càncer de Còlon i Recte*. Actualització de la 3ª edició. Parc de Salut MAR Barcelona - Hospital del Mar. Barcelona, juny de 2013. URL: https://www.hospitaldelmar.cat/media/upload/arxius/unitats/cancer_colorectal/protocols/practica_clinica.pdf.

[3] Fernando Martínez de Juan, Samuel Navarro i Isidro Machado. “Refining Risk Criteria May Substantially Reduce Unnecessary Additional Surgeries after Local Resection of T1 Colorectal Cancer”. A: *Cancers* 16.13 (2024), pàg. 2321. DOI: 10.3390/cancers16132321. URL: <https://doi.org/10.3390/cancers16132321>.

[4] Petar Veličković et al. *Graph Attention Networks*. 2018. arXiv: 1710.10903 [stat.ML]. URL: <https://arxiv.org/abs/1710.10903>.

[5] Richard J. Chen et al. “Towards a general-purpose foundation model for computational pathology”. A: *Nature Medicine* 30.3 (març de 2024), pàg. 850 - 862. DOI: 10.1038/s41591-024-02857-3.

[6] Matthias Fey i Jan Eric Lenssen. *Fast Graph Representation Learning with PyTorch Geometric*. 2019. arXiv: 1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.

[7] Rex Ying et al. *Hierarchical Graph Representation Learning with Differentiable Pooling*. 2019. arXiv: 1806.08804 [cs.LG]. URL: <https://arxiv.org/abs/1806.08804>.

[8] Junhyun Lee, Inyeop Lee i Jaewoo Kang. *Self-Attention Graph Pooling*. 2019. arXiv: 1904.08082 [cs.LG]. URL: <https://arxiv.org/abs/1904.08082>.




Fig. 6: Diagrama de flux del *pipeline* complet. *Blocs grisos*: etapes realitzades pels companys de l'equip (extracció de *patches* i obtenció de l'embedding CLS via UNI2). *Blocs blaus (vora gruixuda)*: contribucions d'aquest TFG. La fletxa $\times S$ indica que les S seccions d'un pacient es processen com a grafs independents i les probabilitats $P(N1)$ s'agreguen via MIL per obtenir el diagnòstic final a nivell de pacient.