

Predicció de Metàstasi en Histopatologia en Càncer Colorrectal usant Graph Attention Networks

David Morillo Massagué

Resum— Es presenta un sistema de classificació N0/N1 per a la detecció de metàstasi en ganglis limfàtics en càncer colorrectal pT1 a partir de *Whole Slide Images*. El teixit es representa com un **graf espacial** construït per triangulació de Delaunay sobre les coordenades dels *patches*, de manera que es preserva la topologia real del teixit, a diferència d'enfocaments basats en similitud de característiques. Cada node és un *patch* de 2048×2048 px representat per l'embedding CLS (1.536 dim.) del model UNI2. Es comparen dues arquitectures configurables: un GAT de referència amb *readout* pla (mean, max, mean_max o attention) i un GAT amb **DiffPool jeràrquic** intercalat ($N \rightarrow \dots \rightarrow K_L$ super-nodes, nombre de blocs L_{DP} optimitzat) per obtenir representacions a múltiples escales. El diagnòstic per pacient s'obté per agregació MIL sobre les seccions. Cada arquitectura s'optimitza amb un estudi Optuna TPE aïllat (304 *trials* per Baseline + 195 per Diff-Pool); el GAT+DiffPool guanya al test amb AUC = 0,862 (vs 0,755 del Baseline), sensibilitat 0,625 i especificitat 0,850 al llindar derivat del val set ($n = 56$ pacients de test; 367 pacients efectius en total).

Paraules clau— Càncer colorrectal pT1, Histopatologia digital, Graph Attention Networks, DiffPool jeràrquic, Graf espacial de Delaunay, MIL, Desbalanceig de classes.

Abstract— We present an N0/N1 classification system for lymph node metastasis prediction in pT1 colorectal cancer from Whole Slide Images. Tissue is represented as a **spatial graph** built by Delaunay triangulation over patch coordinates, preserving the real spatial topology of the tissue, unlike feature-similarity graph approaches. Each node is a 2048×2048 px patch represented by a 1,536-dimensional CLS embedding from the UNI2 model. Two configurable architectures are compared: a **GAT baseline** with flat readout (mean, max, mean_max or attention) and a **GAT+DiffPool** model with L_{DP} DiffPool blocks interleaved between GAT layers ($N \rightarrow \dots \rightarrow K_L$ super-nodes) for multi-scale representations. Patient-level diagnosis is obtained via MIL aggregation over histological sections. Each architecture is tuned with an isolated Optuna TPE study (304 trials for Baseline + 195 for DiffPool); GAT+DiffPool wins on the test set with AUC = 0.862 (vs 0.755 for Baseline), sensitivity 0.625 and specificity 0.850 at the validation-derived threshold ($n = 56$ test patients; 367 effective patients overall).

Keywords— pT1 colorectal cancer, Digital histopathology, Graph Attention Networks, Hierarchical DiffPool, Spatial Delaunay graph, Multiple Instance Learning, Class imbalance.



1 INTRODUCCIÓ

EL càncer colorrectal (CCR) és un dels reptes de salut pública més greus del nostre entorn. A Espanya, la

- E-mail de contacte: David.MorilloMa@autonoma.cat
- Treball tutoritzat per: Debora Gil Resina (DCC)
- Curs 2025/26

SEOM preveu per al 2026 més de **44.132** nous casos anuals, fet que el converteix en el tumor més freqüent i en la segona causa de mort per càncer, amb 14.629 defuncions [1].

El carcinoma pT1 és especialment complex: el tumor ha envaït la submucosa però no la muscular pròpia, i el risc de metàstasi als ganglis limfàtics oscil·la entre el **2%** i el **23%** depenent de la profunditat d'invasió [2]. Quan hi ha criteris de mal pronòstic (**invasió submucosa $\geq 1000 \mu\text{m}$, invasió vascular o limfàtica, histologia indiferenciada, tumor**

budding de grau ≥ 2 o marge vertical positiu [3, 4]), el risc puja al voltant del 10%, fet que porta les guies clíniques (JSCCR [3], NCCN i ESMO [5]) a recomanar cirurgia radical addicional. Com que la majoria de tumors pT1 no desenvolupa LNM real, s'estima que **més del 80%** d'aquestes cirurgies són innecessàries [6, 7].

La histopatologia digital, mitjançant les *Whole Slide Images* (WSI), permet aplicar tècniques avançades de visió per computador. En concret, les *Graph Attention Networks* (GAT) [8] permeten modelar el teixit com una estructura espacial. Una decisió clau en la construcció del graf és el criteri de les arestes: alguns treballs les basen en la *similitud de característiques* entre *patches*; aquest treball opta per la **proximitat espacial** (triangulació de Delaunay sobre coordenades WSI), preservant la topologia real del teixit. El projecte, desenvolupat al grup IAM del CVC (iam.cvc.uab.es) sota la supervisió de la Dra. Debora Gil, compara un GAT de referència amb *readout* pla contra un model amb *pooling* jeràrquic (DiffPool) intercalat, i proposa diferents estratègies d'agregació MIL per al diagnòstic per pacient.

Dues raons justifiquen aquest treball. Des del punt de vista clínic, els sistemes d'IA poden detectar patrons morfològics subtils de manera consistent i ajudar a reduir cirurgies innecessàries. Des del punt de vista tècnic, combinar xarxes d'atenció sobre grafs amb aprenentatge profund sobre WSI és just la intersecció entre teoria de grafs i deep learning que vull explorar dins de l'Enginyeria de Dades.

2 OBJECTIUS

- Construir un *pipeline* complet de classificació N0/N1 sobre WSI reals a partir d'embeddings CLS del model UNI2, basat en **grafs espacials** (triangulació de Delaunay sobre coordenades del teixit).
- Comparar un GAT de referència amb *readout* pla contra un model amb **DiffPool jeràrquic** intercalat entre capes GAT, avaluant si la reducció progressiva del graf aporta millor representació multi-escala.
- Implementar i comparar estratègies d'agregació MIL a nivell de pacient per integrar les prediccions de múltiples seccions histològiques.

3 ESTAT DE L'ART

3.1 Classificació de WSI amb MIL

Les *Whole Slide Images* tenen resolucions de fins a $150\,000 \times 150\,000$ píxels i no es poden processar directament amb xarxes convencionals. L'enfocament habitual és dividir la làmina en *patches* petits i treballar amb *Multiple Instance Learning* (MIL), on el model ha d'inferir l'etiqueta global a partir de fragments sense etiqueta individual. Ilse et al. [9] van proposar l'agregació per atenció (*attention-based MIL*), que aprèn quins *patches* són més rellevants per al diagnòstic. Lu et al. [10] van aplicar aquest mètode a conjunts de dades clínics reals (CLAM), i Li et al. [11] van proposar DSMIL, que combina dues branques, a nivell de *patch* i de làmina, amb aprenentatge contrastiu. La predicció de metàstasi ganglionar a partir d'histopatologia s'ha estudiat en altres càncers: Muti et al. [12] mostren que és possible

predir l'estat N0/N1 a partir de làmines de càncer gàstric, amb resultats prometedors.

3.2 Grafs i GNN en Patologia Digital

Les *Graph Neural Networks* permeten tractar el teixit com una estructura on les regions estan connectades segons la seva proximitat, capturant relacions espacials que les CNN no modelen directament. Jaume et al. [13] van presentar HistoCartography, un entorn de treball per a l'anàlisi de grafs en patologia digital, amb resultats que mostren millores respecte de les CNN en classificació de biòpsies. Les GAT [8] afegeixen un mecanisme d'atenció que permet al model ponderar cada veí de manera diferent, cosa especialment útil en histopatologia on no totes les regions del teixit aporten la mateixa informació. Pel que fa al *pooling* en grafs, Grattarola et al. [14] revisen els principals mètodes existents, entre ells DiffPool [15], que agrupa nodes en super-nodes de manera progressiva.

3.3 Models de Fundació per a Histopatologia

En els darrers anys han aparegut *foundation models* preentrenats específicament sobre dades de patologia, que generen embeddings molt més informatius que les CNNs genèriques. UNI2 [16] és un *vision transformer* entrenat sobre més de 100 milions de *patches* de 20 tipus de teixit, amb bons resultats en nombroses tasques de classificació histopatològica. CONCH [17] és un model similar que incorpora a més alineament entre imatge i text. En aquest projecte s'utilitzen els embeddings de UNI2 com a vector de característiques de cada node, ja que estan preentrenats en el mateix domini i capturen informació morfològica rellevant.

3.4 Guies Clíniques i Models Predictius per a pT1 CRC

Les guies clíniques de referència (JSCCR [3], NCCN i ESMO [5]) recomanen cirurgia addicional quan el pacient presenta un o més dels criteris de risc histopatològics esmentats a la Introducció. Malgrat la seva sensibilitat elevada, la seva especificitat és baixa: en un estudi comparatiu sobre 560 pacients [18], les AUC reportades són 0,596 (JSCCR), 0,749 (NCCN) i 0,743 (ESMO), amb especificitats del 19%, 52% i 50% respectivament, la qual cosa implica que més del 80% dels pacients operats no tenien LNM real [18, 6].

Paral·lelament, Piao et al. [19] van proposar un model d'IA sobre variables clinicopatològiques ($n = 546$ entrenament, $n = 105$ test) basat en gradient boosting (*LightGBM*), obtenint sensibilitat del 100%, especificitat del 85,8%, AUC de 0,960 i *balanced accuracy* del 92,9%; la taxa de pacients classificats com a alt risc es va reduir del 83,8% (JSCCR) al 20,9%. Dawson et al. [4] van proposar l'IBC Score, una puntuació ponderada sobre invasió limfovascular, grau de *tumor budding*, profunditat d'invasió i grau tumoral, que obté AUC de 0,68 sobre 565 pacients. A diferència d'aquests treballs, aquest TFG fa la predicció exclusivament a partir de la **imatge histopatològica** (WSI), sense variables clíniques estructurades ni puntuació manual d'un patòleg.

3.5 Treball Previ al CVC sobre pT1 CRC

Aquest treball s'integra dins una línia de recerca del grup IAM del CVC. Martí et al. [20] van comparar CNNs, ViTs i GNNs sobre el mateix conjunt pT1 CRC per a la classificació de *patches* individuals, amb millor AUC ($0,954 \pm 0,077$) per una arquitectura híbrida ViT+NN. Aquell treball, però, opera a nivell de *patch* i no té en compte la topologia espacial del teixit ni el diagnòstic per pacient. Aquest TFG parteix dels embeddings CLS del model UNI2 per construir grafs espacials de les seccions i aborda el problema des d'una perspectiva MIL per pacient.

4 DADES I PREPROCESSAMENT

Aquest projecte es realitza en col·laboració amb un equip de la UAB que cobreix des de la recollida de dades fins a la creació d'autoencoders per a l'extracció de característiques.

4.1 Imatges de Gran Format (WSI)

Les dades originals consisteixen en imatges de làmines senceres (WSI) obtingudes amb escàners d'alta resolució i tintades amb hematoxilina-eosina, emmagatzemades en format MIRAX (.mrxs). Les dimensions oscil·len entre els 30.000 i els 150.000 píxels per costat, amb una quantitat significativa d'espai buit o artefactes que requereixen tractament previ.

El conjunt de dades efectiu comprèn **1.607 grafs** (un per secció histològica), provinents de **367 pacients** distribuïts de forma desequilibrada entre les dues classes (Taula 1). D'un total de 606 pacients a la base de dades clínica, 236 es descarten per diagnòstic indeterminat (NX), i dels 370 restants amb diagnòstic vàlid, 3 no disposen d'embeddings UNI2 generats, deixant 367 pacients usables. Les mostres es divideixen en un **pool d'entrenament+validació (85%)** i un **conjunt de test fix (15%)**, ambdós estratificats a nivell de pacient. Dins del pool s'aplica validació creuada 5-fold per a la cerca d'hiperparàmetres (Secció 7.3).

4.2 Anotacions i Màscara de Segmentació

La Dra. Eva Musulén, patòloga especialitzada, ha realitzat les anotacions manualment amb el programari *Labelme*. Aquestes identifiquen tres categories d'afectació:

- **Infiltració:** teixit anormal que envaeix zones no corresponents.
- **Displàsia:** cèl·lules anormals que poden convertir-se en canceroses.
- **Infiltració + Displàsia:** usat en casos de dubte diagnòstic.

A partir d'aquestes s'obtenen màscares de segmentació codificades per color: vermell (infiltració), blau (displàsia) i verd clar (combinada).

4.3 Extracció de Patches i Embeddings CLS

S'aplica una finestra lliscant (*sliding window*) sense solapament per dividir cada làmina en *patches* de 2048×2048




Fig. 1: Exemple de WSI i la seva corresponent màscara de segmentació.

píxels a resolució completa (nivell 0). El model de fundació **UNI2** [16] processa cada *patch* individualment i extreu el token *CLS* de la seva sortida, obtenint un vector de **1.536 dimensions** que condensa la informació morfològica i textual del *patch*.

Filtratge dels *patches*. L'única selecció es fa **abans del càlcul de l'embedding**, durant la pròpia extracció des del WSI: per cada finestra, es comprova el **percentatge de teixit** a la corresponent regió de la **màscara binària anotada** (§4.2); les finestres sense cap píxel de teixit (*tissue_percentage* = 0) o que cauen fora d'una component connexa anotada vàlida es descarten i **no s'extreuen ni passen per UNI2**. La resta sí es guarden al disc i generen un node del graf. Estadístiques de qualitat com la *borrositat*, la *proporció de píxels blancs* o la *desviació estàndard* de cada *patch* es calculen i s'emmagatzemen com a metadades, però **no s'usen** per filtrar.

5 CONSTRUCCIÓ DEL GRAF

5.1 Model de dades: dimensions i estructures

Formalment, cada secció histològica es representa com un graf $\mathcal{G} = (\mathbf{X}, \mathbf{A})$ on:

- $\mathbf{X} \in \mathbb{R}^{N \times 1536}$ és la matriu de característiques dels N nodes (*patches*).
- $\mathbf{A} \in \{0, 1\}^{N \times N}$ és la matriu d'adjacència construïda per triangulació de Delaunay i posterior poda d'arestes llargues.

Dues estratègies de *pooling* transformen la seqüència de grafs en un vector global que alimenta el capçal MLP per produir $P(N1)$:

- **Pla (*readout*).** Operació global sobre les sortides de la darrera capa GAT, sense reduir el graf: *mean*, *max*, *sum*, *mean_max* (concatenació de mean i max) o *attention* (pes escalar aprenible per node). Estratègia configurable.
- **Jeràrquic (DiffPool intercalat).** Un nombre configurable $L_{DP} \in \{1, 2, 3\}$ de blocs DiffPool s'intercalen entre capes GAT, col·lapsant progressivament el graf de N nodes fins a $K_{L_{DP}}$ super-nodes. Cada nivell aprèn una matriu d'assignació suau i produeix un nou graf de menor grandària.

TAULA 1: COMPOSICIÓ DEL DATASET EFECTIU PER PARTICIÓ (26 HOSPITALS). ELS GRAFS CORRESPONEN A SECCIONS HISTOLÒGIQUES INDIVIDUALS (UN PER SECCIÓ). EL POOL (85%) S'UTILITZA PER A LA CERCA D'HIPERPARÀMETRES AMB VALIDACIÓ CREUADA 5-FOLD; EL TEST (15%) ES RESERVA PER A L'AVALUACIÓ FINAL.

Partició	Pacients			Grafes (seccions)		
	N0	N1	Total	N0	N1	Total
Pool (train+val CV)	224	87	311	1 133	219	1 352
Test	40	16	56	212	43	255
Total	264	103	367	1 345	262	1 607

Estratègia adoptada: un graf per secció. Cada secció genera un graf independent; les S seccions d'un pacient es processen per separat i les probabilitats $\{P(N1_i)\}_{i=1}^S$ s'agreguen via MIL (Secció 7.1). Com a alternativa es va explorar un *mega-graf* per pacient (bloc-diagonal de totes les seccions sense arestes entre elles), però va donar resultats inferiors (veure Secció 8.1), probablement per forçar un únic *pooling* global sobre teixits físicament inconnexos.

5.2 Connectivitat per triangulació de Delaunay

Una connectivitat fixa de reixeta no és adequada perquè la màscara exclou regions de fons i trenca la simetria de la quadrícula. Per aquest motiu, s'aplica una **triangulació de Delaunay** sobre els nodes restants, que s'adapta a distribucions irregulars de forma natural. A continuació, s'eliminen les arestes que travessen píxels de valor zero a la màscara, evitant connexions entre regions separades per espai buit. Finalment, s'aplica un criteri de distància màxima: s'eliminen les arestes que superen el doble de la longitud mitjana del conjunt. La figura 2 mostra el resultat del procés: les arestes eliminades pel filtre de màscara apareixen en vermell.

Secció $\equiv$ component connexa. La definició de *secció* prové del pipeline d'extracció de patches, que aplica `cv2.connectedComponentsWithStats` sobre la màscara binària de teixit. Per construcció, una secció correspon a una **component connexa de la màscara**: les illes de teixit no adjacents són tractades com a seccions independents (un graf per illa). Empíricament, sobre les 1.607 seccions del dataset, el 100% generen un graf Delaunay d'una sola component, fet coherent amb aquesta definició.

6 ARQUITECTURA DEL MODEL

6.1 Visió general del pipeline

El sistema encadena set mòduls: (i) lectura del WSI, (ii) extracció de *patches* 2048×2048 , (iii) càlcul de l'embedding CLS de 1.536 dimensions amb el model *foundation* UNI2, (iv) construcció del graf de Delaunay per secció amb poda d'arestes llargues, (v) propagació amb L capes GAT i *pooling* (pla o jeràrquic amb DiffPool), (vi) agregació MIL inter-secció per pacient, i (vii) decisió mitjançant un llinar t^* derivat del *validation set*. Cada mòdul configurable té eixos optimitzats per la cerca bayesiana (vegeu Annex A.1 per al diagrama detallat amb hiperparàmetres associats a cada bloc).

Les seccions següents descriuen el model (GAT, pooling

pla i jeràrquic), l'agregació MIL i el procediment d'entrenament.

6.2 GATClassifier

El model implementat, `GATClassifier`, és un classificador de grafs que alterna capes **Graph Attention Network** (`GATConv` [8, 21]) amb capes de *pooling* jeràrquic per a la classificació binària N0/N1. L'arquitectura és completament parametrizable: el nombre de capes GAT, el nombre de blocs DiffPool intercalats i la dimensió oculta es trien com a hiperparàmetres. Quan s'utilitza DiffPool, cada bloc inserit entre capes GAT redueix el graf de N_ℓ nodes a K_ℓ super-nodes: $(\mathbf{X}^{(0)}, \mathbf{A}^{(0)}) \xrightarrow{\text{GAT+Pool}} \dots \xrightarrow{\text{GAT+readout}} \mathbf{z}$. Tot el model s'entrena de forma **end-to-end**: un únic pas de retropropagació propaga els gradients des del capçal MLP fins a les primeres capes GAT. La Figura 3 mostra la comparació visual de les dues arquitectures.

Mecanisme d'atenció. A diferència de les xarxes convolucionals clàssiques sobre grafs que tracten tots els veïns d'un node de forma uniforme, GAT aprèn a assignar pesos d'importància diferenciats a cada veí. Donada la representació $\mathbf{h}_i$ del node i , per a cada parella de nodes veïns (i, j) es calcula un coeficient d'atenció:

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j])$$

on $\mathbf{W}$ és una transformació lineal aprenible, $\parallel$ la concatenació i $\mathbf{a}$ un vector aprenible. Els coeficients es normalitzen amb *softmax* sobre tots els veïns:

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$

i la nova representació del node s'obté com la suma ponderada:

$$\mathbf{h}'_i = \sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W}\mathbf{h}_j$$

Multi-cap i no-linealitat. Per incrementar la capacitat expressiva, cada capa usa H caps d'atenció independents (*heads*), parametritzats per $\mathbf{W}^{(h)}$ i $\mathbf{a}^{(h)}$. Les sortides es concatenen a les capes intermèdies i es promiguen a la darrera. La capa `GATConv` no aplica activació final dins de la pròpia capa; la no-linealitat es fa per fora com *Batch-Norm* $\rightarrow$ *ELU* $\rightarrow$ *Dropout*. L'única no-linealitat interna és la *LeakyReLU* del càlcul de e_{ij} .

Profunditat de la xarxa. El nombre de capes GAT, L , és un eix d'optimització: $L \in \{2, 3, 4\}$ per al model *baseline*; per a la variant amb DiffPool, L ve determinat per $L = L_{\text{DP}} + 1$, intercalant cada GAT amb un pas de *pooling* (vegeu §6.3).




Fig. 2: Etapes del preprocessament per a la construcció del graf. D'esquerra a dreta: WSI original → extracció de *patches* de 2048×2048 px per finestra lliscant + filtratge → extracció de l'embedding CLS de 1.536 dimensions per UNI2 (un vector per *patch*) → construcció del graf de Delaunay sobre la màscara anotada, on les arestes en vermell han estat eliminades pel filtre de màscara

El capçal MLP (*Linear* → *ReLU* → *Dropout* → *Linear*) transforma la representació global del graf en els logits N0/N1.

6.3 Estratègies de Pooling Pla (*Readout*)

Quan no s'utilitza pooling jeràrquic, les representacions dels nodes de la darrera capa GAT s'agreguen directament amb una operació de *readout* global, sense reduir el graf: *mean*, *max* o *sum* sobre els N embeddings; *mean_max* en concatena els dos primers; i *attention* aprèn un pes escalar per node via una capa lineal seguida de *softmax*, i agrega per suma ponderada. Tot i la seva eficiència, aquestes estratègies ignoren la topologia del graf i col·lapsen tota la informació espacial en un sol pas.

6.4 Pooling Jeràrquic: DiffPool entre Capes GAT

Per superar les limitacions del *readout* pla, s'implementa **DiffPool** [15] com a operació intermèdia entre les capes de propagació. Cada bloc DiffPool aprèn una matriu d'assignació suau (*soft assignment*) $\mathbf{S}^{(\ell)} \in \mathbb{R}^{N_\ell \times K_\ell}$ que agrupa els N_ℓ nodes actuals en $K_\ell \ll N_\ell$ *super-nodes*, així com una projecció intermèdia $\mathbf{Z}^{(\ell)} = \text{MLP}_{\text{embed}}(\mathbf{X}^{(\ell)})$ que es propaga al nivell superior:

$$\mathbf{X}^{(\ell+1)} = \mathbf{S}^{(\ell)\top} \mathbf{Z}^{(\ell)}, \quad \mathbf{A}^{(\ell+1)} = \mathbf{S}^{(\ell)\top} \mathbf{A}^{(\ell)} \mathbf{S}^{(\ell)}$$

on $\mathbf{X}^{(\ell)} \in \mathbb{R}^{N_\ell \times F}$ són les *features* dels nodes, $\mathbf{A}^{(\ell)} \in \mathbb{R}^{N_\ell \times N_\ell}$ la matriu d'adjacència del nivell, i $\mathbf{S}^{(\ell)}$ s'obté com la sortida d'un MLP per nodes amb *softmax* per files (cada node distribueix la seva massa entre els K_ℓ clusters).

Profunditat configurable. El nombre de blocs DiffPool intercalats és un eix d'optimització, $L_{\text{DP}} \in \{1, 2, 3\}$, amb una capa GAT abans, entre i després de cada un (total $L_{\text{DP}} + 1$ capes GAT). Els K_ℓ es defineixen per nivell; el *readout* final sobre els $K_{L_{\text{DP}}}$ *super-nodes* és també configurable (mean, max, sum, mean_max o attention), de manera anàloga al model *baseline*.

Pèrdua auxiliar. Per cada bloc DiffPool s'afegeixen dos termes de regularització sobre $\mathbf{S}^{(\ell)}$: un terme de *link prediction* (empeny a col·lapsar veïns junts) i un terme d'entropia (prioritza assignacions precises). La pèrdua total és

la *cross-entropy* de classificació més λ_{aux} vegades la suma d'aquests termes sobre tots els blocs, amb λ_{aux} com a eix d'optimització.

Detall d'implementació. Com que $\mathbf{S}^{(\ell)\top} \mathbf{A}^{(\ell)} \mathbf{S}^{(\ell)}$ és densa i amb pesos continus, a la pràctica la connectivitat entre super-nodes es fixa com un graf complet $K_\ell \times K_\ell$ (sense *self-loops*): és barat ($K_\ell \leq 50$) i la GAT posterior aprèn les atencions rellevants.

Com a alternativa, SAGPool [22] selecciona els K nodes més rellevants via puntuacions d'auto-atenció (selecció discreta, no assignació suau); s'ha preferit DiffPool per la seva expressivitat contínua i la pèrdua auxiliar de regularització.

7 METODOLOGIA

7.1 Agregació per Pacient (MIL)

El diagnòstic és per **pacient**, no per làmina. Una mateixa secció histològica pot no presentar senyals visibles de metàstasi si s'analitza aïlladament, mentre que en una altra secció del mateix pacient sí que és apreciable. Si s'entrena a nivell de làmina, les seccions N1 de pacients N1 que no mostren metàstasi visible reben un senyal de supervisió incorrecte (N0), contaminant l'entrenament.

Per evitar aquest problema, s'utilitza el paradigma d'**aprenentatge per múltiples instàncies** (*Multiple Instance Learning*, MIL): cada pacient es tracta com un *bag* i totes les seves làmines comparteixen la mateixa etiqueta. El model aprèn a classificar el pacient a partir de les seves seccions, sense necessitat d'etiquetes individuals per làmina.

Donades les probabilitats $\{p_i = P(N1_i)\}_{i=1}^S$ de les S làmines d'un pacient, s'implementen quatre estratègies d'agregació:

- **Mean:** $P(N1_p) = \frac{1}{S} \sum_i p_i$. Mitjana aritmètica; estratègia escollida per al model final.
- **Noisy-OR:** $P(N1_p) = 1 - \prod_{i=1}^S (1 - p_i)$. N'hi ha prou amb una làmina amb metàstasi per marcar el pacient com N1.
- **Max:** $P(N1_p) = \max_i p_i$. Conservadora, basada en l'evidència màxima.




Fig. 3: Comparació visual de les dues arquitectures configurables. **Dalt:** GAT Baseline, on $L \in \{2, 3, 4\}$ capes d'atenció operen sobre els N nodes originals i un *readout* global (mean, max, mean_max o attention) produeix l'embedding final. **Baix:** GAT+DiffPool, on cada capa GAT va seguida d'un bloc DiffPool ($L_{DP} \in \{1, 2, 3\}$ blocs) que col·lapsa progressivament el graf fins als $K_{L_{DP}}$ super-nodes finals.

- **Attention MIL:** pes d'atenció aprenent (*gated attention* d'Ilse et al. [9]) per a cada làmina a partir del seu embedding GAT, i suma ponderada dels embeddings per obtenir la representació del pacient.

7.2 Desbalanceig de Classes i Llindar Operatiu

El conjunt presenta un fort desbalanceig ($N0/N1 \approx 72/28$). En detecció de metàstasi, un fals negatiu és més greu que un fals positiu: l'objectiu clínic és **maximitzar l'especificitat mantenint sensibilitat $\approx 100\%$** , per reduir les cirurgies innecessàries sense perdre cap N1. S'apliquen tres mecanismes complementaris:

- **Partició estratificada** per pacient (manté la proporció N0/N1 a cada subconjunt).
- **Pesos a la cross-entropy** amb pes positiu w_+ (multiplicador del gradient per a la classe N1) com a eix d'optimització, $w_+ \in [1, 5, 8]$.
- **Llindar operatiu derivat del val (t^*):** es selecciona el llindar més alt sobre la corba ROC del *validation set* de cada *fold* que manté $TPR = 1$; la mediana entre *folds* és el llindar final aplicat al test.

7.3 Esquema d'entrenament i avaluació

L'avaluació segueix un esquema en tres etapes que aïlla completament el conjunt de test:

1. **Test (15%):** es separa des de la construcció dels grafs i **mai s'usa** per a selecció d'hiperparàmetres ni *early stopping*.
2. **Cerca bayesiana + CV 5-fold** sobre el 85% restant: cada configuració s'avalua amb *Stratified K-Fold* per

pacient i *early stopping* (*patience* = 20). L'objectiu maximitzat és $\text{spec}_{CV} - 10 \cdot \max(0, 1 - \text{sens}_{CV})$: especificitat mitjana penalitzant fortament caigudes de sensibilitat (vegeu Annex A.4).

3. **Entrenament final i avaluació al test:** amb els millors hiperparàmetres, el 85% es torna a dividir 90/10 per fer *early stopping* intern, i el model final s'avalua una sola vegada al test (15%) amb el llindar t^* mediana de les 5 t^* obtingudes als folds CV.

Cerca bayesiana. S'utilitza el *Tree-structured Parzen Estimator* (TPE) sobre ~ 15 eixos. Els **200 primers trials** ($\sim 10 \times$ dimensions) són mostreig uniforme aleatori (exploració); després el TPE explota l'historial. Tots els mostratges, *folds* CV i inicialització de pesos usen *seed* fixa. L'estudi és persistent (SQLite) i reprenible; l'espai complet es recull a l'Annex A.4. **El conjunt de test (15%) no es toca en cap pas del sweep;** només es carrega al pas de finalització, una sola vegada.

8 RESULTATS

Les mètriques principals són l'**AUC-ROC** (ordenació global independent del llindar) i les **mètriques clíniques: sensibilitat** ($VP/(VP + FN)$) i **especificitat** ($VN/(VN + FP)$). En detecció de metàstasi, la sensibilitat és la més rellevant: un fals negatiu (no tractar un N1) és més greu que un fals positiu.

Pregunta central. Aquest TFG vol respondre, sobre les dades disponibles, si el **GAT Baseline** (*readout* global pla després de les capes GAT) o el **GAT+DiffPool** (reducció jeràrquica del graf abans del *readout*) és preferible per al diagnòstic N0/N1. Per arribar-hi s'ha definit l'espai d'hiperparàmetres de l'Annex A.4 (eixos compartits i específics per branca) i s'han llançat **dos estudis Optuna separats** per

arquitectura, perquè la informació acumulada en una branca no influeixi la cerca de l'altra. Cada estudi combina una fase inicial de mostreig aleatori (~ 100 *trials* per arquitectura) seguida de cerca bayesiana (TPE) sobre els *trials* acumulats. Cada *trial* avalua una configuració amb validació creuada 5-fold sobre el *pool* train+val.

Volum d'experiments. En conjunt s'han avaluat $N_{\text{base}} = 350$ *trials* per a GAT Baseline (304 complets, 46 *pruned*) i $N_{\text{diff}} = 231$ per a GAT+DiffPool (195 complets, 36 *pruned*); en total $N_{\text{tot}} = 581$ *trials*, 499 amb mètriques completes. La Taula 2 resumeix el millor de cada arquitectura segons el sweep i, després d'aplicar el procediment de finalització (Secció 7.3, 3a etapa), les mètriques al conjunt de test.

Comparació arquitectures. La Taula 2 mostra un resultat interessant: tot i que el **GAT Baseline** surt millor a la CV (0,530 vs 0,477 d'objectiu), al **conjunt de test** és el **GAT+DiffPool** qui obté el millor AUC (0,862 vs 0,755, una diferència d'11 punts). Això suggereix que el GAT Baseline ha sobreajustat el *val set* durant la cerca bayesiana, mentre que el GAT+DiffPool—amb la reducció jeràrquica del graf actuant com a regularitzador estructural—generalitza millor al test. Els hiperparàmetres òptims trobats per cada branca apareixen a l'Annex A.3: les dues convergeixen a $h = 128$ però difereixen substancialment en MIL (*attention* vs *mean*), H (4 vs 2), η ($1,1 \cdot 10^{-3}$ vs $5,3 \cdot 10^{-4}$) i w_+ (6,77 vs 3,52). Els eixos compartits no es barregen entre estudis perquè cada TPE veu només els seus *trials*.

Matriu de confusió. La Taula 3 mostra la matriu de confusió del model seleccionat (GAT+DiffPool) sobre el test ($n = 56$, 16 N1 + 40 N0).

8.1 Importància dels hiperparàmetres per arquitectura

Cada estudi Optuna calcula automàticament la **importància de cada eix d'optimització** amb *fANOVA*, una descomposició funcional de la variància de l'objectiu CV explicada per cada hiperparàmetre. L'Annex A.2 presenta la taula completa (columnes **Baseline** i **DiffPool** costat a costat). Aquí destaquem els eixos amb importància $> 10\%$ en almenys una arquitectura.

GAT Baseline. L'agregació MIL domina l'objectiu de manera molt clara ($I = 0,64$): *attention* és la millor i els altres modes (*mean*, *noisy-OR*, *max*) queden força per sota. Cap altre eix supera el 10%; els segons són *pooling* (0,08), w_+ (0,07) i *dropout* (0,05).

GAT+DiffPool. La importància es distribueix molt més: MIL és encara el primer (0,22), seguit del pes del penalty auxiliar λ_{aux} (0,14), η (0,13), λ_{wd} (0,08) i *dropout* (0,08). Els eixos específics de DiffPool (L_{DP} , $K_{\text{top}}/K_{\text{bot}}$, *diff readout*) tenen importància moderada però conjunta significativa ($> 0,15$).

8.2 Comparació amb guies clíniques i SOTA

La Taula 4 situa el **model seleccionat** (la branca guanyadora de la Taula 2) davant de les guies clíniques de referència (Secció 3.4) i del model de IA de referència. Les xifres de les guies provenen de [18] ($n = 560$), i les del GAT s'han obtingut sobre el test d'aquest treball ($n = 56$; prevalença

N1 28,6%, superior a la clínica real $\sim 8\text{--}15\%$ [6]). Sensibilitat i especificitat són independents de la prevalença i són la base de la comparació; el VPP s'ha d'interpretar amb cautela (Secció 10.3).

En la detecció de metàstasi, un fals negatiu (no tractar un pacient N1) és un error inacceptable, mentre que un fals positiu (cirurgia innecessària) és recuperable. La Figura 4 superposa les corbes ROC dels millors candidats de cada arquitectura amb els punts operatius de les guies clíniques i del model d'IA de referència.




Fig. 4: Corbes ROC al conjunt de test (56 pacients) dels millors models de cada arquitectura (GAT Baseline, AUC = 0,755; GAT+DiffPool, AUC = 0,862). El cercle gros marca el llindar $t^* = 0,299$ del model seleccionat (DiffPool), derivat exclusivament del *val set* (sens=100% a cada fold CV) i sense *data leakage* del test. Es marquen els punts operatius publicats de JSCCR, NCCN, ESMO (quadrats) i LightGBM (diamant).

Impacte clínic. El llindar t^* deriva del *val set* amb sens=100% a cada fold, però **al test la sensibilitat cau al 62,5%** (6 N1 no detectats sobre 16, matriu confusió de la Taula 3). En aquest punt operatiu, l'especificitat (85,0%) és molt millor que la de les guies clíniques, però el cost humà d'un fals negatiu fa que la comparació justa sigui per AUC i no per un punt operatiu mantenint sens=100% (que cap dels models GAT aconsegueix al test). Vegeu §10.3 (punt 4) per a la discussió detallada de la caiguda de sensibilitat.

Si s'apliqués el llindar baix (0,5), l'especificitat puja al 95,0% però la sensibilitat queda al 56,2%. Per a una eina de cribratge clínic, el rendiment actual no és suficient: caldria una sensibilitat $\geq 95\%$ que el GAT a aquesta mida de dades no aconsegueix sense una caiguda dràstica de l'especificitat.

9 IMPLEMENTACIÓ I EINES

La implementació segueix un disseny modular: la construcció de grafs, el model, el codi d'entrenament i el *sweep* bayesià estan desacoblats. La configuració es gestiona via YAML i, per a la cerca, via Optuna amb *storage* SQLite repreneble. Codi accessible a [23].

TAULA 2: MILLOR CONFIGURACIÓ PER ARQUITECTURA SEGONS EL SWEEP BAYESIÀ, I MÈTRIQES DE VALIDACIÓ CREUADA (CV) I AL CONJUNT DE TEST DESPRÉS DEL RETRAIN FINAL. **GAT+DIFFPOOL ÉS EL MODEL SELECCIONAT PER A LA COMPARACIÓ AMB LES GUIES CLÍNQUES (MAJOR AUC AL TEST). EL LLINDAR t^* ÉS LA MEDIANA DELS 5 LLINDARS OBTINGUTS EN CADA *fold* CV; EL TEST NOMÉS ES TOCA AL FINAL. CAP DELS DOS MODELS MANTÉ SENS. = 100% AL TEST, CONTRÀRIAMENT AL QUE S'OBSERVA A LA CV (VEGEU §10.3).**

Arquitectura	N_{trials}	Pooling	MIL	Obj. CV	AUC CV	AUC test	Sens. / Espec. test
GAT Baseline	350	<i>mean_max</i>	<i>attention</i>	0,530	0,867	0,755	0,562/0,825
GAT+DiffPool	231	<i>diff</i>	<i>mean</i>	0,477	0,855	0,862	0,625/0,850

Objectiu del sweep: $\overline{\text{spec}}_{\text{CV}} - 10 \cdot \max(0, 1 - \overline{\text{sens}}_{\text{CV}})$. Vegeu Annex A.4.

TAULA 3: MATRIU DE CONFUSIÓ DEL **GAT+DIFFPOOL** (MODEL SELECCIONAT) SOBRE EL CONJUNT DE TEST ($n = 56$) AL LLINDAR $t^* = 0,299$. MÈTRIQES CLÍNQUES: SENSIBILITAT = 0,625, ESPECIFICITAT = 0,850, VPP = 0,625, VPN = 0,850.

		Diagnòstic real	
		N0	N1
Predicció	N0	34	6
	N1	6	10

Frontend web. S'ha desenvolupat una interfície (FastAPI + JS sense *build step*) que ofereix: (a) **visualització del WSI** amb superposició dels *patches* i la màscara anotada; (b) **visualització dels grafs** de Delaunay sobre la imatge, amb pesos d'atenció per node (mitjana sobre els H caps de l'última capa GAT, $\in [0, 1]$ ja que GAT fa *softmax* sobre veïns); (c) **selector de model** que carrega qualsevol *checkpoint* dels *trials* del sweep i n'infereix automàticament l'arquitectura des dels pesos; (d) **mode d'inferència** amb desglossament de la propagació capa a capa (mode depuració); i (e) **pestanya d'estadístiques** amb corbes ROC/PR, matriu de confusió i mètriques per classe al test, generades sense *data leakage*. El diagrama de blocs detallat del pipeline és la Figura 5 de l'Annex A.1.

10 CONCLUSIONS

10.1 Conclusions

En aquest TFG s'ha construït un sistema complet de classificació N0/N1 per a càncer colorrectal pT1 a partir de WSI, que inclou la generació de grafs espacials de Delaunay, l'entrenament del model GAT amb dos estudis Optuna aïllats (un per arquitectura) i l'avaluació final sobre un conjunt de test fix (56 pacients). La pregunta central «**GAT Baseline o GAT+DiffPool?**» es respon a partir de la Taula 2: **el GAT+DiffPool obté el millor rendiment al test** (AUC 0,862, Sens. 62,5%, Espec. 85,0%), 11 punts d'AUC per sobre del GAT Baseline (0,755). Se'n destaquen tres observacions:

- **Resultat sorprenent del CV vs test:** el GAT Baseline és millor a la CV (objectiu 0,530 vs 0,477), però el GAT+DiffPool guanya al test. Això suggereix que el Baseline ha sobreajustat el *val set* durant la cerca bayesiana, mentre que el DiffPool generalitza millor al test (la reducció jeràrquica a super-nodes actua com a regularitzador estructural). Aquest mecanisme—pèrdua

auxiliar $\mathcal{L}_{\text{LP}} + \mathcal{L}_{\text{E}}$, més la compressió del graf—té l'efecte de *limitar la capacitat de memoritzar* el *val set*, i el premi és una millor projecció al test.

- **Aïllament dels estudis:** cada TPE veu només els seus propis *trials*, evitant que els hiperparàmetres compartits (η , h , H , *dropout*, etc.) es barregin entre branques. L'Annex A.3 mostra que les dues branques convergeixen a hidden $h = 128$ però difereixen substancialment en MIL (*attention* vs *mean*), heads i *learning rate*.
- **Factors d'influència:** l'agregació MIL és el factor més influent a totes dues branques (importància fANOVA 0,64 a Baseline, 0,22 a DiffPool). A DiffPool, el pes auxiliar λ_{aux} i el *learning rate* prenen un paper central ($\sim 0,13$ – $0,14$ cadascun).

10.2 Discussió Comparativa

L'AUC de test del GAT+DiffPool (0,862) supera la de JSCCR (0,596), NCCN (0,749) i ESMO (0,743) [18]. Tanmateix, la comparació amb les guies en els punts operatius respectius no és tan favorable: les guies mantenen sens=98–100% mentre que el GAT+DiffPool només arriba a sens=62,5% (t^*) o 56,2% (0,5).

VPP i ajust per prevalença. El VPP de 62,5% s'ha calculat amb la prevalença del test (28,6% N1), superior a la clínica real (~ 8 –15%) [6]. A una prevalença del 10%, el VPP baixa a $\sim 32\%$ i el VPN puja a $\sim 95\%$ (càlcul per Bayes amb les Sens./Espec. observades: 0,625/0,850). Sensibilitat i especificitat, independents de la prevalença, segueixen sent les mètriques comparatives més robustes.

Sensibilitat insuficient per a ús clínic. Al llindar derivat del *val set* ($t^* = 0,299$), la sensibilitat al test és del 62,5% (10/16 N1 detectats; 6 falsos negatius). Això està molt per sota del rang clínicament acceptable ($\geq 95\%$ per a una eina de cribratge). El llindar del *val set* garanteix sens=100% al *val* de cada *fold*, però aquesta condició no es manté al test, probablement per la combinació de mida petita del dataset ($n = 56$ al test, només 16 N1) i la variància entre splits.

Comparació amb IA SOTA. El model de gradient boosting (*LightGBM*) de Piao et al. [19], entrenat amb $\sim 10\times$ més dades i amb accés a variables clinicopatològiques estructurades, obté Sens.=100% amb Espec.=85,8% i AUC 0,960. El GAT queda 10 punts per sota en AUC (0,862) i, més importantment, molt per sota en sensibilitat al test. Els dos models són complementaris en termes d'entrada: el GAT podria córrer just després d'escanejar la làmina, sense esperar el report patològic; *LightGBM* requereix les variables ja anotades. Però amb les dades actuals, el GAT no ha demostrat ser una alternativa viable per a ús clínic autònom.

TAULA 4: COMPARACIÓ DE RENDIMENT ENTRE EL MODEL PROPOSAT, LES GUIES CLÍNiques I L'ESTAT DE L'ART. **GUIES:** TANINO ET AL. [18] ($n=560$, HIROSHIMA). **IBC SCORE:** DAWSON ET AL. [4] ($n=565$, MULTICÈNTRIC). **LIGHTGBM:** PIAO ET AL. [19] ($n=105$ TEST, VARIABLES CLINICOPAT.). **GAT:** AQUEST TREBALL ($n=56$ TEST). ESTUDIS I POBLACIONS INDEPENDENTS; EL PPV NO ÉS DIRECTAMENT COMPARABLE (PREVALENÇA N1 DIFERENT ENTRE ESTUDIS). $BAL.ACC. = (S+E)/2$; CALCULADA PER A LES GUIES I L'IBC SCORE A PARTIR DE SENS./ESPEC. REPORTADES.

Sistema	Tipus d'entrada	Sens.	Espec.	AUC	Bal.Acc.
<i>Guies i puntuació clínica</i>					
JSCCR [3]	Guia clínica	100%	19%	0,596	59,5%
NCCN	Guia clínica	98%	52%	0,749	75,0%
ESMO [5]	Guia clínica	98%	50%	0,743	74,0%
IBC Score [4]	Puntuació histopat.	90%	26%	0,68	58,0%
<i>Models d'IA</i>					
LightGBM [19]	Var. clinicopatol.	100%	85,8%	0,960	92,9%
GAT+DiffPool (aquest TFG, llindar 0,5)	Imatge WSI	56,2%	95,0%	0,862	75,6%
GAT+DiffPool (aquest TFG, llindar $t^*=0,299$)[†]	Imatge WSI	62,5%	85,0%	0,862	73,8%

[†] t^* s'ha determinat com a mediana dels 5 llindars dels *val sets* dels folds CV (sens=100% en cada fold), sense *data leakage* del test. Vegeu §10.3 sobre la caiguda de la sensibilitat al test.

10.3 Limitacions

(1) **Mida del test.** Amb 56 pacients al test (només 16 N1), els intervals de confiança al 95% de l'AUC són amplis. L'AUC CV del millor DiffPool és 0,855, propera a l'AUC test (0,862), però la variància CV de l'especificitat és alta (mitjana $0,477 \pm 0,110$), reflectint la inestabilitat entre folds. Caldria un test més gran per a conclusions clíniques robustes.

(2) **Absència de validació externa.** El dataset prové de 26 hospitals espanyols, però no s'ha provat sobre dades d'un centre independent. Campanella et al. [24] reporten, en models MIL de patologia, caigudes de 3–6 punts d'AUC en escàners externs i fins a 7 punts en canvis de domini institucional. L'aplicabilitat clínica requereix, per tant, validació externa.

(3) **Desbalanceig de prevalença.** La prevalença N1 al test (28,6%) supera la clínica real (~ 8 –15%); el VPP s'ha d'interpretar amb cautela (Discussió Comparativa).

(4) **Selecció del llindar i caiguda de la sensibilitat al test.** Per maximitzar la sensibilitat, s'ha buscat el primer punt de la corba ROC del val set de cada fold del millor model en què $TPR=1,0$, i s'ha pres la mediana sobre els 5 folds com a $t^*=0,299$ per al DiffPool. Aplicat al test, dona Sens. 62,5% i Espec. 85,0%—lluny del 100% de sensibilitat que es garantia per construcció a cada val set. Tres causes possibles, no excloents: (a) el val set ja s'usa per a *early stopping*, donant un biaix lleugerament optimista al threshold; (b) la variància entre folds ($\sigma_{t^*}=0,17$, rang $[0,03, 0,49]$) indica que la distribució de probabilitats N1 canvia significativament entre splits; (c) la mida del test (16 N1) amplifica l'error per a qualsevol llindar fix. Per a un sistema clínicament útil cal validació externa i, probablement, una estratègia de calibració de llindar més robusta (e.g., *conformal prediction* o *ensemble* de top-K trials).

REFERÈNCIES

- [1] Sociedad Española de Oncología Médica (SEOM). *Las Cifras del Cáncer en España 2026*. Consultat el

6 de febrer de 2026. 2026. URL: <https://seom.org/prensa/el-cancer-en-cifras>.

- [2] Unitat Funcional Càncer Colorectal. *Protocol de Pràctica Clínica del Càncer de Còlon i Recte*. Actualització de la 3^a edició. Parc de Salut MAR Barcelona - Hospital del Mar. Barcelona, juny de 2013. URL: https://www.hospitaldelmar.cat/media/upload/arxius/unitats/cancer_colorectal/protocols/practica_clinica.pdf.
- [3] Yojiro Hashiguchi et al. “Japanese Society for Cancer of the Colon and Rectum (JSCCR) guidelines 2019 for the treatment of colorectal cancer”. A: *International Journal of Clinical Oncology* 25.1 (2020), pàg. 1–42. DOI: 10.1007/s10147-019-01485-z. URL: <https://doi.org/10.1007/s10147-019-01485-z>.
- [4] Heather Dawson et al. “Lymph node metastases and recurrence in pT1 colorectal cancer: Prediction with the International Budding Consortium Score — a retrospective, multi-centric study”. A: *United European Gastroenterology Journal* 12.3 (2024), pàg. 299–308. DOI: 10.1002/ueg2.12521. URL: <https://doi.org/10.1002/ueg2.12521>.
- [5] Pedro Pimentel-Nunes et al. “Endoscopic submucosal dissection for superficial gastrointestinal lesions: European Society of Gastrointestinal Endoscopy (ESGE) Guideline – Update 2022”. A: *Endoscopy* 54.6 (2022), pàg. 591–622. DOI: 10.1055/a-1811-7025. URL: <https://doi.org/10.1055/a-1811-7025>.
- [6] Dario Zaffalon et al. “Dilemmas in the Clinical Management of pT1 Colorectal Cancer”. A: *Cancers* 15.13 (2023), pàg. 3511. DOI: 10.3390/cancers15133511. URL: <https://doi.org/10.3390/cancers15133511>.

- [7] Fernando Martínez de Juan, Samuel Navarro i Isidro Machado. “Refining Risk Criteria May Substantially Reduce Unnecessary Additional Surgeries after Local Resection of T1 Colorectal Cancer”. A: *Cancers* 16.13 (2024), pàg. 2321. DOI: 10.3390/cancers16132321.
- [8] Petar Veličković et al. *Graph Attention Networks*. 2018. arXiv: 1710.10903 [stat.ML]. URL: <https://arxiv.org/abs/1710.10903>.
- [9] Maximilian Ilse, Jakub M. Tomczak i Max Welling. *Attention-based Deep Multiple Instance Learning*. 2018. arXiv: 1802.04712 [cs.LG]. URL: <https://arxiv.org/abs/1802.04712>.
- [10] Ming Y. Lu et al. *Data Efficient and Weakly Supervised Computational Pathology on Whole Slide Images*. 2020. arXiv: 2004.09666 [eess.IV]. URL: <https://arxiv.org/abs/2004.09666>.
- [11] Bin Li, Yin Li i Kevin W. Eliceiri. *Dual-stream Multiple Instance Learning Network for Whole Slide Image Classification with Self-supervised Contrastive Learning*. 2021. arXiv: 2011.08939 [cs.CV]. URL: <https://arxiv.org/abs/2011.08939>.
- [12] Holger S. Muti, Christoph Röcken, Hans-Michael Behrens et al. “Deep learning trained on lymph node status predicts outcome from gastric cancer histopathology: a retrospective multicentric study”. A: *European Journal of Cancer* 194 (2023), pàg. 113335. DOI: 10.1016/j.ejca.2023.113335.
- [13] Guillaume Jaume et al. *HistoCartography: A Toolkit for Graph Analytics in Digital Pathology*. 2021. arXiv: 2107.10073 [eess.IV]. URL: <https://arxiv.org/abs/2107.10073>.
- [14] Daniele Grattarola et al. “Understanding Pooling in Graph Neural Networks”. A: *IEEE Transactions on Neural Networks and Learning Systems* 35.2 (febr. de 2024), pàg. 2708 - 2718. ISSN: 2162-2388. DOI: 10.1109/tnnls.2022.3190922.
- [15] Rex Ying et al. *Hierarchical Graph Representation Learning with Differentiable Pooling*. 2019. arXiv: 1806.08804 [cs.LG]. URL: <https://arxiv.org/abs/1806.08804>.
- [16] Richard J. Chen et al. “Towards a general-purpose foundation model for computational pathology”. A: *Nature Medicine* 30.3 (març de 2024), pàg. 850 - 862. DOI: 10.1038/s41591-024-02857-3.
- [17] Ming Y. Lu et al. “A visual-language foundation model for computational pathology”. A: *Nature Medicine* 30.3 (març de 2024), pàg. 863 - 874. DOI: 10.1038/s41591-024-02856-4.
- [18] Fumiaki Tanino et al. “Comparative prediction of lymph node metastasis in pT1 colorectal cancer among Western and Japanese guidelines”. A: *Frontiers in Oncology* 14 (2024), pàg. 1475270. DOI: 10.3389/fonc.2024.1475270. URL: <https://www.frontiersin.org/journals/oncology/articles/10.3389/fonc.2024.1475270>.
- [19] Zhenghu Piao, Ruiquan Ge i Ling Lu. “An artificial intelligence prediction model outperforms conventional guidelines in predicting lymph node metastasis of T1 colorectal cancer”. A: *Frontiers in Oncology* 13 (2023), pàg. 1229998. DOI: 10.3389/fonc.2023.1229998. URL: <https://doi.org/10.3389/fonc.2023.1229998>.
- [20] Pau Martí Escolà. “Anàlisi d’espais de representació profunds pel diagnòstic del carcinoma colorectal en histopatologia digital”. Treb. fin. de màst. Universitat Autònoma de Barcelona, 2025. URL: <https://ddd.uab.cat/record/317556>.
- [21] Matthias Fey i Jan Eric Lenssen. *Fast Graph Representation Learning with PyTorch Geometric*. 2019. arXiv: 1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.
- [22] Junhyun Lee, Inyeop Lee i Jaewoo Kang. *Self-Attention Graph Pooling*. 2019. arXiv: 1904.08082 [cs.LG]. URL: <https://arxiv.org/abs/1904.08082>.
- [23] David M. et al. *Implementació de Graph Attention Networks per a la detecció de metàstasi en pT1*. 2026. URL: <https://github.com/IAM-CVC/PT1Diagnosis> (cons. 03-05-2026).
- [24] Gabriele Campanella et al. “Clinical-grade computational pathology using weakly supervised deep learning on whole slide images”. A: *Nature Medicine* 25.8 (2019), pàg. 1301 - 1309. DOI: 10.1038/s41591-019-0508-1. URL: <https://doi.org/10.1038/s41591-019-0508-1>.

APÈNDIX

A.1 Diagrama de flux detallat del *pipeline*




Fig. 5: Diagrama de flux del *pipeline* complet amb hiperparàmetres optimitzats per la cerca bayesiana (columna dreta, caixes vermelles discontinuïes). *Blocs grisos*: etapes realitzades pels companys de l'equip i dades de referència. *Blocs blaus*: contribucions d'aquest TFG. La fletxa $\times S$ indica que les S seccions d'un pacient es processen com a grafs independents i les $P(N1)$ s'agreguen via MIL per obtenir el diagnòstic per pacient, que es compara amb el diagnòstic real de l'Excel. L : capes GAT; h : dim. oculta; H : caps d'atenció; L_{DP} : blocs DiffPool; K_L : super-nodes per nivell; λ_{aux} : pes del penalty DiffPool; t^* : líndar de decisió derivat del val set.

A.2 Importància dels hiperparàmetres per arquitectura

La Taula 5 mostra la **importància fANOVA** de cada eix d'optimització, calculada de manera independent per a cada estudi Optuna (Baseline i DiffPool). La importància és una descomposició funcional de la variància de l'objectiu CV explicada per cada hiperparàmetre, en el rang $[0, 1]$. Eixos específics d'una branca apareixen com a -- a l'altra columna. Tots els valors s'omplen a partir del `report.md` generat per `python -m sweep -report` després del sweep.

TAULA 5: IMPORTÀNCIA fANOVA PER ARQUITECTURA. **BASILINE**: 304 *trials* COMPLETS. **DIFFPOOL**: 195 *trials* COMPLETS. VALORS ENTRE 0 (CAP INFLUÈNCIA) I 1 (L'EIX EXPLICA TOTA LA VARIÀNCIA). --: EIX NO APLICABLE A AQUELLA BRANCA.

Eix	Baseline	DiffPool
<i>Eixos específics d'arquitectura</i>		
<i>Pooling</i>	0,079	—
<i>L</i> (capes GAT)	0,017	—
<i>L_{DP}</i> (blocs DiffPool)	—	0,062
<i>K_{top}</i>	—	0,027
<i>K_{bot}</i>	—	0,021
<i>λ_{aux}</i>	—	0,141
<i>Diff. readout</i>	—	0,053
<i>Eixos compartits (optimitzats independentment a cada study)</i>		
<i>h</i> (dim. oculta)	0,012	0,027
<i>H</i> (caps d'atenció)	0,024	0,066
<i>Dropout</i>	0,054	0,079
Agregació MIL	0,640	0,224
<i>η</i> (<i>learning rate</i>)	0,036	0,129
<i>λ_{wd}</i> (<i>weight decay</i>)	0,020	0,083
<i>w₊</i> (<i>pos_weight</i>)	0,075	0,046
<i>Optimizer</i>	0,005	0,015
<i>Scheduler</i>	0,019	0,008
<i>Grad clipping</i>	0,017	0,019

A.3 Millors hiperparàmetres per arquitectura

La Taula 6 mostra la configuració amb millor objectiu CV per a cada estudi (Baseline i DiffPool). Els eixos compartits s'optimitzen per separat per cada branca, per la qual cosa poden convergir a valors diferents. Aquests són els hiperparàmetres usats al `-finalize` per generar els resultats al test (Taula 2).

TAULA 6: MILLOR CONFIGURACIÓ PER ARQUITECTURA SEGONS EL SWEEP BAYESIÀ.

Eix	Baseline (#303)	DiffPool (#199)
<i>Arquitectura</i>		
<i>Pooling</i>	<i>mean_max</i>	<i>diff</i> (fix)
<i>L</i> (capes GAT)	3	3 ($= L_{DP} + 1$)
L_{DP}	—	2
K_{top}, K_{bot}	—	50, 3
λ_{aux}	—	0,108
<i>Diff. readout</i>	—	<i>mean_max</i>
<i>Compartits</i>		
<i>h / H / Dropout</i>	128 / 4 / 0,355	128 / 2 / 0,437
MIL	<i>attention</i>	<i>mean</i>
$\eta / \lambda_{wd} / w_+$	$1,1 \cdot 10^{-3} / 6,6 \cdot 10^{-3} / 6,77$	$5,3 \cdot 10^{-4} / 5,5 \cdot 10^{-3} / 3,52$
<i>Optimizer / Scheduler</i>	<i>adam / cosine</i>	<i>adam / cosine</i>
<i>Mètriques CV</i>		
Objectiu / AUC CV / Sens / Spec	0,530 / 0,867 / 1,00 / 0,530	0,477 / 0,855 / 1,00 / 0,477

A.4 Espai de cerca de la cerca bayesiana

La Taula 7 llista els eixos d'optimització, els seus rangs i la branca d'arquitectura on s'apliquen. La cerca es fa amb *TPE* (Optuna); cada *trial* avalua una configuració amb 5-fold CV sobre el *pool* train+val. Les dues arquitectures s'optimitzen en **estudis Optuna aïllats** (SQLite separats): els eixos específics de cada arquitectura no es barregen, i els eixos comuns s'optimitzen de forma independent per a cada branca. La millor configuració trobada es marcaria en negreta al final de la cerca.

TAULA 7: EIXOS DEL *sweep* BAYESIÀ (DOS ESTUDIS OPTUNA AÏLLATS, UN PER ARQUITECTURA). ESTIMACIÓ DE TEMPS EN UNA NVIDIA L40S: 60–150 H PER 1000 *trials* TOTALS.

Eix	Branca	Valors / rang	Tipus mostreig
<i>Arquitectura del model</i>			
<i>Pooling</i>	només baseline	mean, max, mean_max, attention	categòric
<i>L</i> (capes GAT)	només baseline	2, 3, 4	enter
<i>L_{DP}</i> (blocs DiffPool)	només DiffPool	1, 2, 3	enter
<i>K_{top}</i> (super-nodes 1r nivell)	només DiffPool	10, 25, 50	categòric
<i>K_{bot}</i> (super-nodes últim nivell)	només DiffPool	3, 5, 10	categòric
(Nivells intermedis: $K = \lfloor \sqrt{K_{\text{top}} \cdot K_{\text{bot}}} \rfloor$; amb clamp $K_{\text{bot}} < K_{\text{top}}$)			
λ_{aux} (pes aux. DiffPool)	només DiffPool	[0,1, 10]	log-uniforme
<i>Diff. readout</i>	només DiffPool	mean, max, mean_max, attention	categòric
<i>h</i> (dimensió oculta)	ambdues (indep.)	64, 128, 256	categòric
<i>H</i> (caps d'atenció)	ambdues (indep.)	2, 4	categòric
<i>Dropout</i>	ambdues (indep.)	[0,05, 0,5]	uniforme
<i>Agregació a nivell de pacient (MIL)</i>			
Agregació MIL	ambdues (indep.)	mean, max, noisy-OR, attention	categòric
<i>Optimitzador i regularització</i>			
<i>Optimizer</i>	ambdues (indep.)	Adam, AdamW	categòric
<i>Scheduler</i>	ambdues (indep.)	ReduceLROnPlateau, CosineAnnealingLR	categòric
Taxa aprenentatge	ambdues (indep.)	$[5 \cdot 10^{-5}, 5 \cdot 10^{-3}]$	log-uniforme
<i>Weight decay</i>	ambdues (indep.)	$[10^{-5}, 10^{-2}]$	log-uniforme
<i>Grad. clipping</i>	ambdues (indep.)	0, 1, 5	categòric
<i>Tractament del desbalanceig</i>			
Pes de la classe N1 (w_+)	ambdues (indep.)	[1,5, 8]	uniforme
Llindar t^*	post-CV	sobre la corba ROC del val, condició TPR=1	determinista

Objectiu del sweep: $\text{objective} = \overline{\text{spec}}_{\text{CV}} - 10 \cdot \max(0, 1 - \overline{\text{sens}}_{\text{CV}})$, on $\overline{\text{spec}}_{\text{CV}}$ i $\overline{\text{sens}}_{\text{CV}}$ són les mitjanes sobre els 5 *val sets*, calculades amb el llindar t^* derivat de cada *fold* (llindar més alt amb TPR= 1). Aquesta és l'**única** mètrica que el TPE veu per decidir els paràmetres del següent *trial*. La penalització $\times 10$ fa que el TPE prioritzi sensibilitat $\approx 100\%$, però accepta una pèrdua moderada (sens $\geq 95\%$) si s'aconsegueix un guany substancial d'especificitat (> 5 punts).