

Predicció de Metàstasi en Histopatologia en Càncer Colorrectal usant Graph Attention Networks

David Morillo Massagué

Resum— Es presenta un sistema de classificació N0/N1 per a la detecció de metàstasi en ganglis limfàtics en càncer colorrectal pT1 a partir de *Whole Slide Images*. El teixit es representa com un **graf espacial** sobre les coordenades dels *patches*, de manera que es preserva la topologia real del teixit. Cada node és un *patch* de 2048×2048 px representat per l'embedding CLS (vector de forma $[1, 1536]$) del model UNI2. Es comparen dues arquitectures configurables: un GAT de referència amb *readout* pla (mean, max, mean_max o attention) i un GAT amb **DiffPool jeràrquic** intercalat per obtenir representacions a múltiples escales. El diagnòstic per pacient s'obté per agregació MIL sobre les seccions histològiques. La cerca d'hiperparàmetres combina dos estudis Optuna (5-fold CV + retrain 90/10 de les millors configuracions obtingudes). El millor model és el **GAT de referència**, que obté AUC test = 0,875, sensibilitat 100% i especificitat 57,5%.

Paraules clau— Càncer colorrectal pT1, Histopatologia digital, Graph Attention Networks, DiffPool jeràrquic, Graf espacial de Delaunay, MIL, Desbalanceig de classes.

Abstract— We present an N0/N1 classification system for lymph node metastasis prediction in pT1 colorectal cancer from Whole Slide Images. Tissue is represented as a **spatial graph** over patch coordinates, preserving the real spatial topology of the tissue. Each node is a 2048×2048 px patch represented by a CLS embedding of shape $[1, 1536]$ from the UNI2 model. Two configurable architectures are compared: a **GAT baseline** with flat readout (mean, max, mean_max or attention) and a **GAT+DiffPool** model with L_{DP} DiffPool blocks interleaved between GAT layers for multi-scale representations. Patient-level diagnosis is obtained via MIL aggregation over histological sections. Hyperparameter search combines two Optuna studies (5-fold CV + 90/10 retraining of the best configurations). The best model is the **GAT baseline**, achieving test AUC = 0.875, sensitivity 100% and specificity 57.5%.

Keywords— pT1 colorectal cancer, Digital histopathology, Graph Attention Networks, Hierarchical DiffPool, Spatial Delaunay graph, Multiple Instance Learning, Class imbalance.

1 INTRODUCCIÓ

EL càncer colorrectal (CCR) és un dels reptes de salut pública més greus del nostre entorn. A Espanya, la SEOM preveu per al 2026 uns 44.132 nous diagnòstics, fet que el converteix en el tumor més freqüent i en la segona causa de mort per càncer, amb 14.629 defuncions [1].

El carcinoma pT1 és especialment complex: el tumor ha envaït la submucosa però no la muscular pròpia, i el risc de metàstasi als ganglis limfàtics (LNM, de l'anglès *lymph node metastasis*) oscil·la entre el 2% i el 23% depenent de la profunditat d'invasió [2]. Quan hi ha criteris de mal pronòstic (invasió submucosa $\geq 1000 \mu\text{m}$, invasió vascular o limfàtica, histologia indiferenciada, *tumor budding* de grau ≥ 2 o marge vertical positiu [3, 4]), el risc puja al voltant del 10%, fet que porta les guies clíniques (JSCCR [3], NCCN i ESMO [5]) a recomanar cirurgia radical addicional. Com que la majoria de tumors pT1 no desenvolupa LNM real, s'estima que fins un 80% d'aquestes cirurgies són innecessàries [6, 7].

La histopatologia digital va néixer cap a finals dels anys

• E-mail de contacte: David.MorilloMa@autonoma.cat
• Treball tutoritzat per: Debora Gil Resina (DCC)
• Curs 2025/26

1990 amb els primers escàners de làmina sencera, i des de mitjans de la dècada de 2010 s'hi apliquen models d'aprenentatge profund per ajudar el patòleg [8]. Aquest treball, desenvolupat al CVC [9] sota la supervisió de la Dra. Debora Gil, aborda la classificació N0/N1 a partir de les *Whole Slide Images* (WSI) modelant cada secció de teixit com un **graf espacial**. Es compara un GAT de referència amb *readout* pla contra un model amb *pooling* jeràrquic (Diff-Pool) intercalat, i es proposen diferents estratègies d'agregació MIL (*Multiple Instance Learning*, aprenentatge per múltiples instàncies) per al diagnòstic per pacient.

Dues raons justifiquen aquest treball. Des del punt de vista clínic, els sistemes d'IA poden detectar patrons subtils de manera consistent (sovint superant a les guies clíniques) i ajudar a reduir cirurgies innecessàries. Des del punt de vista tècnic, combinar xarxes d'atenció sobre grafs amb aprenentatge profund en dades reals és la intersecció entre teoria de grafs i deep learning que vull explorar dins de l'Enginyeria de Dades.

2 ESTAT DE L'ART

2.1 Guies Clíniques i Models Predictius per a pT1 CRC

Les guies clíniques de referència (JSCCR [3], NCCN i ESMO [5]) recomanen cirurgia addicional quan el pacient presenta un o més dels criteris de risc histopatològics esmentats a la Introducció. Malgrat la seva sensibilitat elevada, la seva especificitat és baixa: en un estudi comparatiu sobre 560 pacients [10], les AUC reportades són 0,596 (JSCCR), 0,749 (NCCN) i 0,743 (ESMO)¹, amb especificitats del 19%, 52% i 50% respectivament, la qual cosa implica que més del 80% dels pacients operats no tenien LNM real [10, 6].

Paral·lelament, Piao et al. [11] van proposar un model d'IA sobre variables clinicopatològiques ($n = 546$ entrenament, $n = 105$ test) basat en gradient boosting (*LightGBM*), obtenint sensibilitat del 100%, especificitat del 85,8%, AUC de 0,960 i *balanced accuracy* del 92,9%; la taxa de pacients classificats com a alt risc es va reduir del 83,8% (JSCCR) al 20,9%. Dawson et al. [4] van proposar l'IBC Score, una puntuació ponderada sobre invasió limfovacular, grau de *tumor budding*, profunditat d'invasió i grau tumoral, que obté AUC de 0,68 sobre 565 pacients. A diferència d'aquests treballs, aquest TFG fa la predicció exclusivament a partir de la imatge histopatològica (WSI), sense variables clíniques estructurades ni puntuació manual d'un patòleg.

2.2 Classificació de WSI amb MIL

Les *Whole Slide Images* tenen resolucions de fins a $150\,000 \times 150\,000$ píxels i no es poden processar directament amb xarxes convencionals. L'enfocament habitual és dividir la làmina en *patches* petits i treballar amb MIL, on el model ha d'inferir l'etiqueta global (N0/N1) a partir de fragments sense etiqueta individual. Ilse et al. [12] van proposar l'agregació per atenció (*attention-based MIL*), que aprèn quins *patches* són més rellevants per al diagnòstic. Lu

et al. [13] van aplicar aquest mètode a conjunts de dades clínics reals (CLAM), i Li et al. [14] van proposar DSMIL, que combina dues branques, a nivell de *patch* i de làmina, amb aprenentatge contrastiu. La predicció de metàstasi ganglionar a partir d'histopatologia s'ha estudiat en altres càncers: Muti et al. [15] mostren que és possible predir l'estat N0/N1 a partir de làmines de càncer gàstric, amb resultats prometedors.

2.3 Grafs i GNN en Patologia Digital

Les GNN permeten tractar el teixit com una estructura on les regions estan connectades segons la seva proximitat, capturant relacions espacials que les xarxes neuronals convolucionals (CNN) no modelen directament. Jaume et al. [16] van presentar HistoCartography, un entorn de treball per a l'anàlisi de grafs en patologia digital, amb resultats que mostren millores respecte de les CNN en classificació de biòpsies. Aquest entorn distingeix entre *cell-graphs* (nodes = cèl·lules individuals) i *tissue-graphs* (nodes = regions de teixit); aquest treball s'acosta al segon tipus, amb nodes que representen *patches* de teixit en lloc de cèl·lules. Pel que fa a l'arquitectura, HistoCartography classifica aquests grafs amb xarxes GIN (*Graph Isomorphism Networks*), mentre que aquest treball opta per GAT [17], que afegeixen un mecanisme d'atenció que permet al model ponderar cada veí de manera diferent, cosa especialment útil en histopatologia on no totes les regions del teixit aporten la mateixa informació. Pel que fa al *pooling* en grafs, Grattarola et al. [18] revisen els principals mètodes existents, entre ells DiffPool [19], que agrupa nodes en super-nodes de manera progressiva.

Una decisió clau en la construcció d'aquests grafs és el criteri de les arestes: alguns treballs les basen en la *similitud de característiques* entre *patches*, mentre que d'altres opten per la **proximitat espacial** entre regions del teixit. Aquest treball segueix la segona via i connecta els *patches* mitjançant una triangulació sobre les coordenades del teixit, de manera que nodes i arestes preserven la topologia real en lloc de relacions purament semàntiques.

2.4 Models de Fundació per a Histopatologia

En els darrers anys han aparegut *foundation models* preentrenats específicament sobre dades de patologia, que generen embeddings molt més informatius que les CNNs genèriques. UNI2 [20] és un *vision transformer* (ViT) entrenat sobre més de 100 milions de *patches* de 20 tipus de teixit, amb bons resultats en nombroses tasques de classificació histopatològica. CONCH [21] és un model similar que incorpora a més alineament entre imatge i text. En aquest projecte s'utilitzen els embeddings de UNI2 com a vector de característiques de cada node, ja que estan preentrenats en el mateix domini i capturen informació morfològica rellevant.

2.5 Treball Previ al CVC sobre pT1 CRC

Aquest treball s'integra dins una línia de recerca del grup IAM del CVC. Martí et al. [22] van comparar CNNs, ViTs i GNNs sobre el mateix conjunt pT1 CRC per a la classificació de *patches* individuals, amb millor AUC ($0,954 \pm 0,077$)

¹En ser classificadors binaris, l'AUC d'una guia equival a (sens + espec)/2 (*balanced accuracy*).

per una arquitectura híbrida ViT+NN. El treball, però, opera a nivell de *patch* i no té en compte la topologia espacial del teixit ni el diagnòstic per pacient. Aquest TFG parteix dels embeddings CLS del model UNI2 per construir grafs espacials de les seccions i aborda el problema des d'una perspectiva MIL per pacient.

3 OBJECTIUS

L'objectiu general d'aquest treball és **classificar l'estat ganglionar N0/N1** en càncer colorrectal pT1 a partir de WSI reals, utilitzant els embeddings CLS del model UNI2 i representant cada secció de teixit com un **graf espacial** (triangulació de Delaunay sobre les coordenades del teixit).

A partir d'aquest objectiu general se'n deriven els objectius específics següents:

- Construir un *pipeline* complet, des de la generació dels grafs espacials a partir dels embeddings CLS fins a l'entrenament i avaluació del model.
- **Comparar un GAT de referència** amb *readout* pla contra un model amb **DiffPool jeràrquic** intercalat entre capes GAT, avaluant si la reducció progressiva del graf aporta millores de representació intra-secció.
- Implementar i comparar estratègies d'agregació MIL a nivell de pacient per integrar les prediccions de múltiples seccions histològiques.

4 DADES I PREPROCESSAMENT

Aquest projecte es realitza en col·laboració amb un equip de la UAB que cobreix des del preprocessament de dades, o la creació d'autoencoders alternatius per a l'extracció de característiques, per una posterior classificació amb diversos models.

4.1 Dades d'entrada

Imatges WSI. Les dades originals consisteixen en imatges de làmines senceres (WSI) obtingudes amb escàners d'alta resolució i tintades amb hematoxilina-eosina, emmagatzemades en format MIRAX (.mrxs). Les dimensions oscil·len entre els 30.000 i els 150.000 píxels per costat, amb una quantitat significativa d'espai buit o artefactes que requereixen tractament previ.

El conjunt de dades efectiu comprèn **1.607 grafs** (un per secció histològica), provinents de **367 pacients** distribuïts de forma desequilibrada entre les dues classes (Taula 1). D'un total de 606 pacients a la base de dades clínica, 236 es descarten per diagnòstic indeterminat (NX), i dels 370 restants amb diagnòstic vàlid, 3 no disposen d'embeddings UNI2 generats, deixant 367 pacients usables. Les mostres es divideixen en un pool d'entrenament+validació (85%) i un conjunt de test fix (15%), ambdós estratificats a nivell de pacient. Dins del pool s'aplica validació creuada 5-fold per a la cerca d'hiperparàmetres (Secció 6.1).

Anotacions i màscares. La Dra. Eva Musulén, patòloga especialitzada, ha realitzat les anotacions manualment amb

el programari *Labelme*, identificant tres categories d'afectació: *infiltració* (teixit anormal que envaeix zones no corresponents), *displàsia* (cèl·lules anormals que poden convertir-se en canceroses) i *combinació* d'ambdues (usada en casos de dubte diagnòstic). A partir d'aquestes s'obtenen màscares de segmentació codificades per color: vermell (infiltració), blau (displàsia) i verd clar (combinada); la Figura 7 (Annex A.1) en mostra un exemple.

4.2 Construcció del graf

De patch a node. S'aplica una finestra lliscant (*sliding window*) sense solapament per dividir cada làmina en *patches* de 2048×2048 píxels a resolució completa. Per cada finestra, es comprova el percentatge de teixit a la corresponent regió de la màscara binària anotada (§4.1); les finestres sense cap píxel de teixit (*tissue_percentage* = 0) es descarten. El model UNI2 [20] processa cada *patch* individualment i extreu el token *CLS* de la seva sortida, obtenint un vector de forma $[1, 1536]$ que condensa la informació morfològica i textural del patch. Cada vector CLS esdevé un node del graf, conservant les coordenades del patch per a la construcció de les arestes.

El graf de la secció. Formalment, cada secció histològica es representa com un graf $\mathcal{G} = (\mathbf{X}, \mathbf{A})$, on $\mathbf{X} \in \mathbb{R}^{N \times 1536}$ és la matriu de característiques dels N nodes (*patches*) i $\mathbf{A} \in \{0, 1\}^{N \times N}$ la matriu d'adjacència construïda per triangulació de Delaunay i posterior poda d'arestes llargues. Cada secció genera un graf independent; les S seccions d'un pacient es processen per separat i les probabilitats $\{P(N_i)\}_{i=1}^S$ s'agreguen via MIL (Secció 5.5). Com a alternativa es va explorar un *mega-graf* per pacient (bloc-diagonal de totes les seccions, sense arestes entre elles), però va donar resultats inferiors, probablement per forçar un únic *pooling* global sobre teixits físicament inconnexos.

Connectivitat de Delaunay. Els centres dels *patches* formen una quadrícula regular, però connectar-los amb una reixeta fixa no és suficient: la màscara deixa forats de teixit irregulars que en trenquen la simetria. Per això es connecten els nodes amb una **triangulació de Delaunay** sobre les seves coordenades, que s'adapta a qualsevol distribució. Després es poden les arestes en dos passos: s'eliminen les que travessen píxels de fons (màscara = 0), per no unir regions separades per espai buit, i les que superen el doble de la longitud mitjana, per evitar connexions massa llargues. El resultat (Figura 1, amb les arestes podades en vermell) és una malla local entre *patches* veïns.

5 ARQUITECTURA DEL MODEL

5.1 Visió general del pipeline

A alt nivell, el sistema es pot resumir en cinc blocs encadenats (Figura 2): **(1) Preprocessament**, que converteix cada WSI en un graf espacial (extracció de *patches* 2048×2048 , embedding CLS $[1, 1536]$ amb el model *foundation* UNI2 i construcció del graf de Delaunay amb poda d'arestes); **(2) Arquitectura**, on les capes GAT propaguen la informació pel graf segons una de les dues variants comparades (*baseline* plana o amb DiffPool jeràrquic); **(3) Readout**, la lectura final que col·lapsa el graf en un únic embedding (mean, max, mean_max o attention), idèntica per a totes dues

TAULA 1: COMPOSICIÓ DEL DATASET (26 HOSPITALS). CADA GRAF CORRESPON A UNA SECCIÓ HISTOLÒGICA.

Partició	Pacients			Grafs (seccions)		
	N0	N1	Total	N0	N1	Total
Pool (train+val CV)	224	87	311	1 133	219	1 352
Test	40	16	56	212	43	255
Total	264	103	367	1 345	262	1 607




Fig. 1: Etapes del preprocessament per a la construcció del graf. D'esquerra a dreta: WSI original → extracció de *patches* de 2048×2048 px per finestra lliscant + filtratge → extracció de l'embedding CLS de forma $[1, 1536]$ per UNI2 (un vector per *patch*) → construcció del graf de Delaunay sobre la màscara anotada, on les arestes en vermell han estat eliminades pel filtre de màscara

arquitectures; (4) **MIL**, que agrega les prediccions de les seccions d'un pacient (mean, max, noisy-OR o attention); i (5) **Decisió**, on s'aplica el llindar t^* derivat del *validation set* per obtenir la classificació binària N0/N1.




Fig. 2: Visió general del *pipeline* en cinc blocs.

Les seccions següents detallen cada bloc: l'arquitectura GAT i les dues variants, el *readout* unificat, l'agregació MIL

i el procediment d'entrenament.

5.2 GATClassifier

El model implementat, *GATClassifier*, és un classificador de grafs basat en capes **Graph Attention Network** (GAT-Conv [17, 23]) per a la classificació binària N0/N1. L'arquitectura és completament parametrizable: el nombre de capes GAT, la dimensió oculta i el nombre de caps d'atenció es trien com a hiperparàmetres, i tot el model s'entrena de forma *end-to-end* (un únic pas de retropropagació propaga els gradients des del capçal MLP final fins a les primeres capes GAT). Sobre aquesta base comuna es comparen dues variants d'arquitectura, descrites a la Secció 5.3: una de *baseline* i una amb DiffPool jeràrquic.

Mecanisme d'atenció. A diferència de les xarxes convolucionals clàssiques sobre grafs que tracten tots els veïns d'un node de forma uniforme, GAT aprèn a assignar pesos d'importància diferenciats a cada veí. Donada la representació $\mathbf{h}_i$ del node i , per a cada parella de nodes veïns (i, j) es calcula un coeficient d'atenció:

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j])$$

on $\mathbf{W}$ és una transformació lineal aprenible, $\parallel$ la concatenació i $\mathbf{a}$ un vector aprenible. Els coeficients es normalitzen amb *softmax* sobre tots els veïns:

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$

i la nova representació del node s'obté com la suma ponderada:

$$\mathbf{h}'_i = \sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W}\mathbf{h}_j$$

Multi-cap i no-linealitat. Per incrementar la capacitat expressiva, cada capa usa H caps d'atenció independents (*heads*), parametritzats per $\mathbf{W}^{(h)}$ i $\mathbf{a}^{(h)}$. Les sortides es concatenen a les capes intermèdies i es promitgen a la darrera. La capa *GATConv* no aplica activació final dins de la pròpia capa; la no-linealitat es fa per fora com *Batch-Norm* $\rightarrow$ *ELU* $\rightarrow$ *Dropout*. L'única no-linealitat interna és la *LeakyReLU* del càlcul de e_{ij} .

5.3 Les dues arquitectures: Baseline i DiffPool

Sobre la base de capes GAT descrita abans es comparen dues arquitectures que es diferencien en com processen el graf abans del *readout* final. La Figura 3 en mostra una instància de cadascuna, i l'Annex A.3 en presenta un diagrama detallat amb tots els eixos configurables.

GAT Baseline (plana). Apila L capes GAT consecutives (L optimitzable) que operen sempre sobre els N nodes originals del graf, sense reduir-lo. Tota la informació espacial es manté fins al *readout* final.

GAT+DiffPool (jeràrquica). Intercala blocs **DiffPool** [19] entre les capes GAT. La idea és agrupar els nodes en *super-nodes* i substituir el graf per un de més petit; repetint-ho diverses vegades s'obté una representació del teixit a múltiples escales. Cada bloc aprèn, per a cada node, una **assignació suau** (*soft assignment*) als K super-nodes del nivell següent: en comptes d'enviar cada node a un sol grup, en reparteix la pertinença entre tots els grups amb pesos que sumen 1 (la sortida d'un petit MLP per node seguida de *softmax*). A partir d'aquesta assignació, les *features* dels nodes s'agreguen com a mitjana ponderada per formar les dels super-nodes, i les arestes originals es projecten al nou graf, de manera que el graf passa de N a $K \ll N$ nodes conservant una versió comprimida de la seva estructura. El nombre de blocs intercalats és un eix d'optimització, L_{DP} , amb una capa GAT abans, entre i després de cada un (total $L_{DP} + 1$ capes GAT).

Pèrdua auxiliar de DiffPool. Per cada bloc s'afegeixen dos termes de regularització sobre l'assignació apresada: un que empeny a agrupar junts els nodes veïns i un altre (d'entropia) que fa que cada node s'assigni de manera neta a pocs grups. La pèrdua total és la *cross-entropy* de classificació més λ_{aux} vegades aquests termes, amb λ_{aux} com a eix d'optimització. Com a alternativa, SAGPool [24] selecciona els K nodes més rellevants via puntuacions d'auto-atenció (selecció discreta, no assignació suau); s'ha preferit DiffPool per la seva expressivitat contínua i la pèrdua auxiliar de regularització.

5.4 Readout: lectura final del graf

Sigui quina sigui l'arquitectura, l'últim pas abans de la classificació és el mateix: un **readout global** que col·lapsa el conjunt final de nodes en un únic vector $\mathbf{h}_s$ que representa tota la secció. L'única diferència és sobre quins nodes s'aplica: en el Baseline són els N nodes de la darrera capa GAT, i en DiffPool són els $K_{L_{DP}}$ super-nodes finals. L'operació de *readout* és, doncs, un eix compartit per les dues branques, amb quatre opcions configurables: *mean*, *max* o *mean_max* (agregacions fixes), i *attention*, que aprèn un

pes escalar per node via una capa lineal seguida de *softmax* i agrega per suma ponderada.

Finalment, el capçal MLP (*Linear* $\rightarrow$ *ReLU* $\rightarrow$ *Dropout* $\rightarrow$ *Linear*) transforma aquesta representació global $\mathbf{h}_s$ en els logits N0/N1 de la secció.

5.5 Agregació per Pacient (MIL)

El diagnòstic és per **pacient**, no per làmina. Una mateixa secció histològica pot no presentar senyals visibles de metàstasi si s'analitza aïlladament, mentre que en una altra secció del mateix pacient sí que és apreciable. Si s'entrena a nivell de làmina, les seccions N1 de pacients N1 que no mostren metàstasi visible reben un senyal de supervisió incorrecte (N0), contaminant l'entrenament.

Per evitar aquest problema, s'utilitza el paradigma d'**aprenentatge per múltiples instàncies** (*Multiple Instance Learning*, MIL): cada pacient es tracta com un *bag* i totes les seves làmines comparteixen la mateixa etiqueta. El model aprèn a classificar el pacient a partir de les seves seccions, sense necessitat d'etiquetes individuals per làmina.

En tots els casos, el capçal MLP té la mateixa estructura: *Linear(h)* $\rightarrow$ *ReLU* $\rightarrow$ *Dropout* $\rightarrow$ *Linear(2)*, on h és la dimensió oculta (hiperparàmetre del sweep) i la sortida és un parell de logits (N0/N1); els pesos s'aprenen per retropropagació. La diferència entre estratègies és *quan* s'aplica:

- **Mean, Max, Noisy-OR:** el MLP s'aplica **per secció**, produint $P(N1)_s$ per a cada una de les S seccions del pacient; les probabilitats s'agreguen com a escalars:
 - **Mean:** $P(N1_p) = \frac{1}{S} \sum_i p_i$.
 - **Max:** $P(N1_p) = \max_i p_i$.
 - **Noisy-OR:** $P(N1_p) = 1 - \prod_i (1 - p_i)$.
- **Attention MIL** (*gated attention*, Ilse et al. [12]): els embeddings de les S seccions ($\mathbb{R}^h$ cadascun) s'agreguen primer en un únic vector de pacient mitjançant pesos d'atenció apresos (suma ponderada dels embeddings); el MLP s'aplica **una sola vegada** sobre aquest vector per obtenir els logits N0/N1.

6 DISSENY EXPERIMENTAL

6.1 Esquema de dades i avaluació

El dataset es divideix en un **pool del 85%** i un **test del 15%**, estratificats a nivell de pacient (Figura 4). Tota la cerca (selecció d'hiperparàmetres i lliurar) es fa només sobre el pool, de manera que el test no intervé en cap decisió i n'obté una estimació no esbiaixada del rendiment (sense *data leakage*). El procediment té tres etapes:

1. **Test (15%, 56 pacients):** es separa des de la construcció dels grafs i **mai s'usa** per a selecció d'hiperparàmetres ni *early stopping*.
2. **Cerca bayesiana + CV 5-fold sobre el pool (85%, 311 pacients):** cada configuració s'avalua amb *Stratified K-Fold* per pacient i *early stopping* (*patience*=20), de forma independent per a cada arquitectura. La cerca usa el *Tree-structured Parzen Estimator* (TPE) sobre ~ 15 eixos: els 200 primers *trials* ($\sim 10 \times$ dimensions) són mostreig uniforme aleatori (exploració)




Fig. 3: Comparació visual de les dues arquitectures configurables (una instància de cada branca amb dues capes de processament). **Dalt:** GAT Baseline, on dues capes d'atenció operen sobre els N nodes originals i un *readout* global produeix l'embedding final. **Baix:** GAT+DiffPool amb dos blocs DiffPool ($L_{DP} = 2$, és a dir tres capes GAT intercalades), que col·lapsen progressivament el graf fins a, en aquest cas, dos super-nodes finals.

i després el TPE explota l'historial. L'objectiu maximitzat és $\text{spec}_{CV} - 10 \cdot \max(0, 1 - \text{sens}_{CV})$: especificitat mitjana penalitzant fortament les caigudes de sensibilitat (Annex A.6).

3. **Retrain final i avaluació al test:** amb els millors hiperparàmetres de cada arquitectura, el pool es torna a dividir 90/10 (train/val intern per a *early stopping*) i el model final s'avalua **una sola vegada** al test (15%) amb el llindar t^* , mediana de les 5 t^* obtingudes als *folds* de CV.




Fig. 4: Esquema de partició i avaluació. El test (15%) s'aïlla des del principi i només s'usa al final (fletxa discontinua).

6.2 Desbalanceig de classes i llindar operatiu

El conjunt presenta un fort desbalanceig ($N0/N1 \approx 72/28$). En detecció de metàstasi, un fals negatiu és més greu que

un fals positiu: l'objectiu clínic és maximitzar l'especificitat mantenint sensibilitat $\approx 100\%$, per reduir les cirurgies innecessàries sense perdre cap N1. S'apliquen tres mecanismes complementaris:

- **Partició estratificada** per pacient (manté la proporció N0/N1 a cada subconjunt).
- **Pesos a la *cross-entropy*** amb pes positiu w_+ (multiplicador del gradient per a la classe N1) com a eix d'optimització, $w_+ \in [1, 5, 8]$.
- **Llindar operatiu derivat del val (t^*):** s'han comparat dos criteris: (T1) llindar fix $t = 0,5$; i (T2) llindar màxim de la corba ROC del val que manté $\text{TPR} = 1$ (zero falsos negatius en validació). Per a T2, es calcula el llindar a cada *fold* i se n'aplica la mediana al test.

6.3 Mètriques d'avaluació

Les mètriques principals són l'**AUC-ROC** (ordenació global independent del llindar) i les mètriques clíniques al llindar operatiu: sensibilitat ($\text{VP}/(\text{VP} + \text{FN})$), especificitat ($\text{VN}/(\text{VN} + \text{FP})$), valor predictiu positiu (VPP , $\text{VP}/(\text{VP} + \text{FP})$) i valor predictiu negatiu (VPN , $\text{VN}/(\text{VN} + \text{FN})$), on VP, VN, FP i FN són els veritables/falsos positius i negatius.

Interpretació clínica. Si la sortida del model s'usés per decidir la cirurgia (operar els casos predits com a N1), la **sensibilitat** és el percentatge de pacients N1 que rebrien tractament (una sensibilitat del 100% vol dir que cap pacient amb metàstasi quedaria sense tractar), i l'**especificitat** és 1 menys el percentatge de pacients N0 operats innecessàriament. Per això, en aquest context un fals negatiu (no tractar un N1) és més greu que un fals positiu, i l'objectiu és maximitzar l'especificitat mantenint la sensibilitat propera al 100%.

6.4 Eines i reproductibilitat

La implementació segueix un disseny modular: la construcció de grafs, el model, el codi d'entrenament i el *sweep* bayesià estan desacoblats, i la configuració es gestiona via fitxers YAML. La cerca s'orquestra amb *Optuna*, amb *storage SQLite* persistent i reprenible (cap *trial* es perd si el procés s'interromp). Per garantir la **reproductibilitat**, tots els mostratges del *sampler*, els *folds* de CV i la inicialització de pesos usen una *seed* fixa. El codi és accessible a [25].

7 RESULTATS

S'han optimitzat dos estudis Optuna TPE aïllats per arquitectura, i les millors configuracions de cada branca (GAT Baseline i GAT+DiffPool) s'han re-avaluat segons el procediment de la Secció 6.1 (5-fold CV + retrain 90/10 + avaluació al test). La Taula 2 en resumeix les més rellevants.

Lectura dels resultats. El **GAT Baseline supera clarament el GAT+DiffPool** en aquest dataset: el millor DiffPool arriba a AUC test 0,786, 9 punts per sota del Baseline seleccionat (0,875). Les seccions tenen pocs centenars de *patches* i la reducció jeràrquica a super-nodes elimina més informació de la que sintetitza. A més, només el Baseline manté sens. = 100% al test amb el llindar t^* derivat del val.

Model seleccionat. El model definitiu és un **GAT Baseline** amb *readout attention*, MIL *mean*, $h = 256$, $H = 4$, *dropout* 0,3, $\lambda_{wd} = 10^{-4}$, $\eta = 3 \cdot 10^{-4}$ i Adam amb *ReduceLROnPlateau*. Obté AUC CV $0,862 \pm 0,038$, AUC test 0,875, sensibilitat 100% (16/16 N1) i especificitat 57,5% al llindar $t^* = 0,133$.

7.1 Importància dels hiperparàmetres

L'anàlisi d'importància *fANOVA* de cada estudi (taula completa a l'Annex A.4) mostra que l'**agregació MIL** és l'eix més determinant del rendiment al Baseline ($I = 0,64$; cap altre supera el 10%), mentre que al DiffPool la importància es reparteix entre MIL (0,22), el pes auxiliar λ_{aux} (0,14) i el *learning rate* (0,13).

7.2 Comparació amb guies clíniques i SOTA

La Taula 3 situa el **model seleccionat** davant de les guies clíniques de referència (Secció 2.1) i de dos models d'IA (un sobre variables clíniques i un altre sobre imatge WSI). Les xifres de les guies provenen de [10] ($n = 560$), i les del GAT s'han obtingut sobre el test d'aquest treball ($n = 56$; prevalença N1 28,6%, superior a la clínica real ~ 8 –15% [6]). Sensibilitat i especificitat són independents de la prevalença i són la base de la comparació; el VPP s'ha d'interpretar amb cautela (Secció 8.2).

En detecció de metàstasi, un fals negatiu (no tractar un N1) és inacceptable, mentre que un fals positiu (cirurgia innecessària) és recuperable. Per això **T2 és l'única opció clínicament acceptable**: T1 ($t = 0,5$) deixa 7 de 16 pacients N1 sense detectar (**FN** = 7), mentre que T2 ($t^* = 0,133$, TPR = 1) garanteix zero falsos negatius (**sens.** = 100%, **VPN** = 1,000). L'especificitat resultant (57,5%) supera la guia JSCCR (19%) i l'IBC Score (26%), i és comparable a NCCN (52%) i ESMO (50%). La Figura 5 mostra les corbes ROC dels 5 *val sets* del CV i els punts operatius indivi-

duals; la mediana dels 5 llindars és $t^* = 0,133$. La Figura 6 superposa les corbes ROC del test amb les guies clíniques.




Fig. 5: Corbes ROC dels 5 *folds* de validació creuada (GAT Baseline). Cada cercle marca el llindar màxim amb TPR = 1 del seu *fold*; la mediana dels 5 llindars ($t^* = 0,133$, encuadrat groc) s'aplica al test.

Impacte clínic. El llindar t^* manté sens. = 100% al test (16/16 N1 detectats, VPN = 1,000), amb espec. 57,5%. La literatura estima que el 80–90% de les cirurgies actuals en pT1 són innecessàries [7], coherent amb les especificitats del 19–52% de les guies. Mantenint sens. = 100%, el GAT redueix les cirurgies innecessàries de ~ 81 (JSCCR) o ~ 49 (NCCN/ESMO) a $\sim 42,5$ per cada 100 pacients N0. En concret, si s'apliqués aquest model per decidir la cirurgia sobre els 40 pacients N0 del test, se n'operarien innecessàriament 17 enlloc dels ~ 32 que indicaria JSCCR: és a dir, **un $\sim 47\%$ menys de cirurgies innecessàries** respecte a JSCCR (i un $\sim 13\%$ menys respecte a NCCN/ESMO), **sense deixar cap pacient N1 sense tractar** (sens. = 100%). Al llindar 0,5 la sensibilitat és inferior (56,2%); t^* és el que fa el model clínicament útil.

8 DISCUSSIÓ I CONCLUSIONS

8.1 Discussió

L'AUC de test del model (0,875) supera la de JSCCR (0,596), NCCN (0,749) i ESMO (0,743) [10]. Al llindar $t^* = 0,133$ assoleix sensibilitat 100% amb especificitat 57,5% (una millora de 38,5 punts d'especificitat sobre JSCCR al mateix nivell de sensibilitat); al llindar per defecte (0,5) la sensibilitat baixa a 56,2% però l'especificitat puja al 92,5%.

VPP i prevalença. El VPP de 48,5% s'ha calculat amb la prevalença del test (28,6% N1), superior a la clínica real (~ 8 –15%) [6]. A una prevalença del 10% el VPP baixa a $\sim 21\%$ però el VPN es manté al 100%. El model és, doncs, útil sobretot com a **filtre de descartament**: un resultat negatiu permetria evitar la cirurgia amb seguretat. Sensibilitat i especificitat, independents de la prevalença, són les mètriques comparatives més robustes.

TAULA 2: MILLORS CONFIGURACIONS PER ARQUITECTURA, COMPARADES PER AUC EN VALIDACIÓ CREUADA 5-fold. **FILA RESSALTADA:** MODEL SELECCIONAT.

Arquitectura	Readout/MIL	$h/H/\text{drop}$	AUC CV
Baseline	att/mean	256/4/0,3	0,862±0,038
DiffPool	mean_max/mean	128/2/0,44	0,847±0,048

Readout: att = attention; mean_max = mitjana+màxim. MIL: mean = mitjana.

TAULA 3: COMPARACIÓ DE RENDIMENT ENTRE EL MODEL PROPOSAT, LES GUIES CLÍNQUES I L'ESTAT DE L'ART. **GUIES:** TANINO ET AL. [10] ($n=560$, HIROSHIMA). **IBC SCORE:** DAWSON ET AL. [4] ($n=565$, MULTICÈNTRIC). **LIGHTGBM:** PIAO ET AL. [11] ($n=105$ TEST, VARIABLES CLINICOPAT.). **SONG ET AL.:** MODEL MIL D'ATENCIÓ SOBRE WSI H&E [26] ($n=1281$, 2604 WSIs). **GAT:** AQUEST TREBALL ($n=56$ TEST). ESTUDIS I POBLACIONS INDEPENDENTS; EL PPV NO ÉS DIRECTAMENT COMPARABLE (PREVALENCIA N1 DIFERENT ENTRE ESTUDIS). $\text{BAL.ACC.} = (S+E)/2$; CALCULADA PER A LES GUIES I L'IBC SCORE A PARTIR DE SENS./ESPEC. REPORTADES.

Sistema	Tipus d'entrada	Sens.	Espec.	AUC	Bal.Acc.
<i>Guies i puntuació clínica</i>					
JSCCR [3]	Guia clínica	100%	19%	0,596	59,5%
NCCN	Guia clínica	98%	52%	0,749	75,0%
ESMO [5]	Guia clínica	98%	50%	0,743	74,0%
IBC Score [4]	Puntuació histopat.	90%	26%	0,68	58,0%
<i>Models d'IA</i>					
LightGBM [11]	Var. clinicopatol.	100%	85,8%	0,960	92,9%
Song et al. [26]	Imatge WSI	92,9%	57,6%	0,781	75,3%
<i>GAT Baseline (AUC = 0,875)</i>					
T1 ($t=0,5$)	Imatge WSI	56,2%	92,5%	0,875	74,4%
T2 ($t^*=0,133$, TPR= 1)[†]	Imatge WSI	100%	57,5%	0,875	78,8%
<i>GAT+DiffPool (AUC = 0,786)</i>					
T1 ($t=0,5$)	Imatge WSI	50,0%	82,5%	0,786	66,3%
T2 ($t^*=0,303$) [†]	Imatge WSI	62,5%	70,0%	0,786	66,3%

[†] t^* és la mediana dels llindars màxims amb TPR= 1 als 5 val sets, aplicat al test sense reajustar.

Comparació amb altres models d'IA. El model de *gradient boosting* de Piao et al. [11] obté millors xifres (Espec. 85,8%, AUC 0,960), però amb $\sim 10\times$ més dades i, sobretot, a partir de **variables clinicopatològiques ja anotades per un patòleg**; el nostre GAT usa només la imatge WSI i pot córrer just després de l'escaneig. La comparació més justa, a la mateixa modalitat (WSI sense variables clíniques), és la de Song et al. [26] (MIL d'atenció sobre WSI, sense variables clíniques): sobre 1281 pacients obté AUC 0,781 i, a una especificitat pràcticament idèntica (57,6% vs 57,5%), sens. 92,9%, per sota del 100% del nostre model, tot i que la seva avaluació és molt més robusta (1281 vs 56 pacients). Representar la secció com a graf espacial és, doncs, com a mínim competitiu amb l'MIL pla sobre *patches*.

8.2 Limitacions

(1) Mida del test. Amb 56 pacients al test (només 16 N1), els intervals de confiança al 95% de l'AUC són amplis ($\pm 0,07-0,10$). L'AUC CV del model seleccionat (0,862±0,038) i l'AUC test (0,875) són consistents, però la variància de l'especificitat al CV és alta (mitjana $0,369 \pm 0,198$ amb el llindar t^*), reflectint la inestabilitat entre folds. Caldrà un test més gran per a conclusions clíniques robustes.

(2) Absència de validació externa. El dataset prové de 26 hospitals espanyols, però no s'ha provat sobre dades d'un centre independent. Campanella et al. [27] reporten, en models MIL de patologia, caigudes de 3–6 punts d'AUC

en escàners externs i fins a 7 punts en canvis de domini institucional. L'aplicabilitat clínica requereix, per tant, validació externa.

(3) Desbalanceig de prevalença. La prevalença N1 al test (28,6%) supera la clínica real ($\sim 8-15\%$); el VPP s'ha d'interpretar amb cautela (vegeu la Discussió).

(4) Selecció del llindar i biaix del val set. S'han comparat dos criteris: llindar fix $t=0,5$ (T1) i llindar màxim amb TPR= 1 al val (T2, $t^*=0,133$). T1 deixa FN= 7; T2 garanteix sens. = 100%. El val set ja s'havia usat per a *early stopping*, per la qual cosa t^* pot tenir un biaix lleugerament optimista; idealment, hauria de fixar-se sobre un val set extern. La variància del llindar entre folds és alta ($\sigma_{t^*} \approx 0,08$, folds: 0,03–0,29), reflectint la sensibilitat del procediment a la divisió de dades.

8.3 Conclusions

En aquest TFG s'ha construït un sistema complet de classificació N0/N1 per a càncer colorrectal pT1 a partir de WSI: generació de grafs espacials de Delaunay, optimització del model GAT amb cerca bayesiana TPE, i avaluació final sobre un test fix (56 pacients). La pregunta central «**GAT Baseline o GAT+DiffPool?**» es respon clarament: **el GAT Baseline** (*attention pooling*, MIL *mean*, $h=256$, $H=4$, dropout 0,3) obté el millor balanç: AUC test = 0,875, sensibilitat 100% (els 16 N1 detectats) i especificitat 57,5% al llindar $t^*=0,133$ derivat del val set. Se'n destaquen tres




Fig. 6: Corbes ROC al conjunt de test ($n = 56$) del **GAT Baseline** (model seleccionat; AUC = 0,875) i del **GAT+DiffPool** (millor configuració; AUC = 0,786). Els cercles marquen els llindars t^* de cada model (derivats del val set): $t^* = 0,133$ per al Baseline (sens. = 100%, espec. = 57,5%) i $t^* = 0,303$ per al DiffPool (sens. = 62,5%, espec. = 70,0%). Es superposen els punts operatius de JSCCR, NCCN i ESMO (quadrats), *LightGBM* [11] (diamant) i Song et al. [26] (triangle).

observacions:

- **El GAT Baseline supera el GAT+DiffPool** amb aquest dataset. Les seccions contenen pocs centenars de *patches*; la reducció jeràrquica a super-nodes elimina més informació de la que sintetitza, i el millor DiffPool es queda en 0,786 AUC test, lluny del Baseline.
- **Predicció només a partir de la imatge.** El model diagnòstic N0/N1 exclusivament des del WSI, sense cap variable clinicopatològica anotada (a diferència de models com el de Piao et al.); pot, doncs, executar-se just després d'escanejar la làmina, sense esperar el report del patòleg.
- **Utilitat com a filtre de descartament.** Al llindar t^* el model manté sens. = 100% al test (VPN=1,000): un resultat negatiu permetria evitar la cirurgia amb seguretat sobre la mostra avaluada.

9 AGRAÏMENTS

A la meua tutora Debora, per donar-me l'oportunitat de treballar en un projecte tan interessant, i per contagiar-me la seva passió per la recerca i la salut. A la resta de companys del CVC, per compartir el seu coneixement i opinions, fent-me sentir part d'aquest lloc. A la meua família i amics, per mostrar interès i donar-me suport durant tot el procés. A l'Adrià, l'Albert i la Lucia, per acompanyar-me i ajudar-me, des del primer dia d'universitat fins al darrer.

REFERÈNCIES

- [1] Sociedad Española de Oncología Médica (SEOM). *Las Cifras del Cáncer en España 2026*. Consultat el 6 de febrer de 2026. URL: <https://seom.org/prensa/el-cancer-en-cifras>.
- [2] Unitat Funcional Càncer Colorectal. *Protocol de Pràctica Clínica del Càncer de Còlon i Recte*. Actualització de la 3^a edició. Parc de Salut MAR Barcelona - Hospital del Mar. Barcelona, juny de 2013. URL: https://www.hospitaldelmar.cat/media/upload/arxius/unitats/cancer_colorectal/protocols/practica_clinica.pdf.
- [3] Yojiro Hashiguchi et al. "Japanese Society for Cancer of the Colon and Rectum (JSCCR) guidelines 2019 for the treatment of colorectal cancer". A: *International Journal of Clinical Oncology* 25.1 (2020), pàg. 1-42. DOI: 10.1007/s10147-019-01485-z. URL: <https://doi.org/10.1007/s10147-019-01485-z>.
- [4] Heather Dawson et al. "Lymph node metastases and recurrence in pT1 colorectal cancer: Prediction with the International Budding Consortium Score — a retrospective, multi-centric study". A: *United European Gastroenterology Journal* 12.3 (2024), pàg. 299-308. DOI: 10.1002/ueg2.12521. URL: <https://doi.org/10.1002/ueg2.12521>.
- [5] Pedro Pimentel-Nunes et al. "Endoscopic submucosal dissection for superficial gastrointestinal lesions: European Society of Gastrointestinal Endoscopy (ESGE) Guideline – Update 2022". A: *Endoscopy* 54.6 (2022), pàg. 591-622. DOI: 10.1055/a-1811-7025. URL: <https://doi.org/10.1055/a-1811-7025>.
- [6] Dario Zaffalon et al. "Dilemmas in the Clinical Management of pT1 Colorectal Cancer". A: *Cancers* 15.13 (2023), pàg. 3511. DOI: 10.3390/cancers15133511. URL: <https://doi.org/10.3390/cancers15133511>.
- [7] Fernando Martínez de Juan, Samuel Navarro i Isidro Machado. "Refining Risk Criteria May Substantially Reduce Unnecessary Additional Surgeries after Local Resection of T1 Colorectal Cancer". A: *Cancers* 16.13 (2024), pàg. 2321. DOI: 10.3390/cancers16132321.
- [8] Babak Ehteshami Bejnordi et al. "Diagnostic Assessment of Deep Learning Algorithms for Detection of Lymph Node Metastases in Women With Breast Cancer". A: *JAMA* 318.22 (2017), pàg. 2199-2210. DOI: 10.1001/jama.2017.14585. URL: <https://doi.org/10.1001/jama.2017.14585>.
- [9] Centre de Visió per Computador (CVC). *Centre de Visió per Computador (CVC), UAB*. URL: <https://www.cvc.uab.es> (cons. 14-06-2026).

- [10] Fumiaki Tanino et al. “Comparative prediction of lymph node metastasis in pT1 colorectal cancer among Western and Japanese guidelines”. A: *Frontiers in Oncology* 14 (2024), pàg. 1475270. DOI: 10.3389/fonc.2024.1475270. URL: <https://www.frontiersin.org/journals/oncology/articles/10.3389/fonc.2024.1475270>.
- [11] Zhenghu Piao, Ruiquan Ge i Ling Lu. “An artificial intelligence prediction model outperforms conventional guidelines in predicting lymph node metastasis of T1 colorectal cancer”. A: *Frontiers in Oncology* 13 (2023), pàg. 1229998. DOI: 10.3389/fonc.2023.1229998. URL: <https://doi.org/10.3389/fonc.2023.1229998>.
- [12] Maximilian Ilse, Jakub M. Tomczak i Max Welling. *Attention-based Deep Multiple Instance Learning*. 2018. arXiv: 1802.04712 [cs.LG]. URL: <https://arxiv.org/abs/1802.04712>.
- [13] Ming Y. Lu et al. *Data Efficient and Weakly Supervised Computational Pathology on Whole Slide Images*. 2020. arXiv: 2004.09666 [eess.IV]. URL: <https://arxiv.org/abs/2004.09666>.
- [14] Bin Li, Yin Li i Kevin W. Eliceiri. *Dual-stream Multiple Instance Learning Network for Whole Slide Image Classification with Self-supervised Contrastive Learning*. 2021. arXiv: 2011.08939 [cs.CV]. URL: <https://arxiv.org/abs/2011.08939>.
- [15] Holger S. Muti, Christoph Röcken, Hans-Michael Behrens et al. “Deep learning trained on lymph node status predicts outcome from gastric cancer histopathology: a retrospective multicentric study”. A: *European Journal of Cancer* 194 (2023), pàg. 113335. DOI: 10.1016/j.ejca.2023.113335.
- [16] Guillaume Jaume et al. *HistoCartography: A Toolkit for Graph Analytics in Digital Pathology*. 2021. arXiv: 2107.10073 [eess.IV]. URL: <https://arxiv.org/abs/2107.10073>.
- [17] Petar Veličković et al. *Graph Attention Networks*. 2018. arXiv: 1710.10903 [stat.ML]. URL: <https://arxiv.org/abs/1710.10903>.
- [18] Daniele Grattarola et al. “Understanding Pooling in Graph Neural Networks”. A: *IEEE Transactions on Neural Networks and Learning Systems* 35.2 (febr. de 2024), pàg. 2708-2718. ISSN: 2162-2388. DOI: 10.1109/tnnls.2022.3190922.
- [19] Rex Ying et al. *Hierarchical Graph Representation Learning with Differentiable Pooling*. 2019. arXiv: 1806.08804 [cs.LG]. URL: <https://arxiv.org/abs/1806.08804>.
- [20] Richard J. Chen et al. “Towards a general-purpose foundation model for computational pathology”. A: *Nature Medicine* 30.3 (març de 2024), pàg. 850-862. DOI: 10.1038/s41591-024-02857-3.
- [21] Ming Y. Lu et al. “A visual-language foundation model for computational pathology”. A: *Nature Medicine* 30.3 (març de 2024), pàg. 863-874. DOI: 10.1038/s41591-024-02856-4.
- [22] Pau Martí Escolà. “Anàlisi d’espais de representació profunds pel diagnòstic del carcinoma colorectal en histopatologia digital”. Treb. fin. de màst. Universitat Autònoma de Barcelona, 2025. URL: <https://ddd.uab.cat/record/317556>.
- [23] Matthias Fey i Jan Eric Lenssen. *Fast Graph Representation Learning with PyTorch Geometric*. 2019. arXiv: 1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.
- [24] Junhyun Lee, Inyeop Lee i Jaewoo Kang. *Self-Attention Graph Pooling*. 2019. arXiv: 1904.08082 [cs.LG]. URL: <https://arxiv.org/abs/1904.08082>.
- [25] David M. et al. *Implementació de Graph Attention Networks per a la detecció de metàstasi en pT1*. 2026. URL: <https://github.com/IAM-CVC/PT1Diagnosis> (cons. 03-05-2026).
- [26] Joo Hye Song et al. “Prediction of Lymph Node Metastasis in T1 Colorectal Cancer Using Artificial Intelligence with Hematoxylin and Eosin-Stained Whole-Slide-Images of Endoscopic and Surgical Resection Specimens”. A: *Cancers* 16.10 (2024), pàg. 1900. DOI: 10.3390/cancers16101900. URL: <https://doi.org/10.3390/cancers16101900>.
- [27] Gabriele Campanella et al. “Clinical-grade computational pathology using weakly supervised deep learning on whole slide images”. A: *Nature Medicine* 25.8 (2019), pàg. 1301-1309. DOI: 10.1038/s41591-019-0508-1. URL: <https://doi.org/10.1038/s41591-019-0508-1>.

APÈNDIX

A.1 Exemple d'imatge WSI i màscara de segmentació




Fig. 7: Exemple de WSI i la seva corresponent màscara de segmentació, amb les regions anotades per la patòloga codificades per color (vermell: infiltració, blau: displàsia, verd clar: combinada).

A.2 Diagrama de flux detallat del *pipeline*




Fig. 8: Diagrama de flux del *pipeline* complet. Cada bloc és una etapa del procés: (1) preprocessament i construcció del graf a partir de la WSI; (2) processament del graf amb la GNN (dues arquitectures configurables); (3) *readout* que comprimeix el graf en un vector $\mathbf{h}_s$ per secció; (4) agregació MIL de les S seccions d'un pacient fins a obtenir $P(\text{N1})$; (5) decisió binària via el llindar operatiu t^* derivat del *val set*.

A.3 Variants d'arquitectura del *GATClassifier*

El diagrama 9 mostra com un **mateix graf d'entrada** pot ser processat de maneres molt diverses depenent de la configuració: les caixes blaves representen capes apreses i les taronges discontinües els eixos d'optimització configurables.




Fig. 9: Variants d'arquitectura del *GATClassifier*: el mateix graf $\mathcal{G}$ es pot processar per dues branques configurables (BASELINE o DIFFPOOL). Totes dues convergeixen en un *readout* unificat que produeix l'embedding $\mathbf{h}_s \in \mathbb{R}^h$ per secció; l'opció de *readout* s'optimitza de forma independent per a cada branca. L'agregació MIL bifurca de nou: **mean/max/noisy-OR** apliquen el MLP per secció i n'agreguen els *escalars*; **attention (gated)** agrega primer els *vectors* $\mathbf{h}_s$ amb pesos d'atenció **apresos** i aplica el MLP *una sola vegada* sobre l'embedding agregat. L : capes GAT; h : dim. oculta; H : caps d'atenció; L_{DP} : blocs DiffPool; K_ℓ : super-nodes per nivell; λ_{aux} : pes pèrdua auxiliar DiffPool; t^* : llindar derivat del val set (Secció 6.1).

A.4 Importància dels hiperparàmetres per arquitectura

La Taula 4 mostra la **importància fANOVA** de cada eix d'optimització, calculada de manera independent per a cada estudi Optuna (Baseline i DiffPool). La importància és una descomposició funcional de la variància de l'objectiu CV explicada per cada hiperparàmetre, en el rang $[0, 1]$. Els eixos específics d'una branca apareixen buits a l'altra columna. Tots els valors provenen de l'anàlisi fANOVA calculada per Optuna sobre els *trials* complets de cada estudi.

TAULA 4: IMPORTÀNCIA fANOVA PER ARQUITECTURA. **BASILINE**: 304 *trials* COMPLETS. **DIFFPOOL**: 195 *trials* COMPLETS. VALORS ENTRE 0 (CAP INFLUÈNCIA) I 1 (L'EIX EXPLICA TOTA LA VARIÀNCIA). LES CEL·LES BUIDES INDIQUEN QUE L'EIX NO ÉS APLICABLE A AQUELLA BRANCA.

Eix	Baseline	DiffPool
<i>Eixos específics d'arquitectura</i>		
L (capes GAT)	0,017	—
L_{DP} (blocs DiffPool)	—	0,062
K_{top}	—	0,027
K_{bot}	—	0,021
λ_{aux}	—	0,141
<i>Eixos compartits (optimitzats independentment a cada study)</i>		
Readout (final del graf)	0,079	0,053
h (dim. oculta)	0,012	0,027
H (caps d'atenció)	0,024	0,066
Dropout	0,054	0,079
Agregació MIL	0,640	0,224
η (learning rate)	0,036	0,129
λ_{wd} (weight decay)	0,020	0,083
w_+ (pos_weight)	0,075	0,046
Optimizer	0,005	0,015
Scheduler	0,019	0,008
Grad clipping	0,017	0,019

A.5 Hiperparàmetres del model seleccionat i del millor DiffPool

La Taula 5 resumeix la configuració del GAT Baseline i del GAT+DiffPool, ja avaluats segons el procediment de la Taula 2.

TAULA 5: CONFIGURACIÓ DEL GAT BASELINE I DEL GAT+DIFFPOOL.

Eix	Baseline	DiffPool
<i>Arquitectura — Baseline</i>		
L (capes GAT)	3	—
h / H / Dropout	256 / 4 / 0,3	—
Readout	attention	—
<i>Arquitectura — DiffPool</i>		
L ($= L_{DP} + 1$)	—	3
L_{DP} / K_{top} , K_{bot}	—	2 / 50, 3
h / H / Dropout	—	128 / 2 / 0,437
λ_{aux}	—	0,108
Readout	—	mean_max
<i>Entrenament i regularització</i>		
MIL	mean	mean
η / λ_{wd} / w_+	$3 \cdot 10^{-4}$ / 10^{-4} / 2,0	$5,3 \cdot 10^{-4}$ / $5,5 \cdot 10^{-3}$ / 3,52
Optimizer / Scheduler	adam / plateau	adam / cosine
<i>Mètriques re-avaluades al test</i>		
AUC CV ($\pm$ std)	$0,862 \pm 0,038$	$0,847 \pm 0,048$
AUC test	0,875	0,786
Sens. / Espec. test @ t^*	1,000 / 0,575	$0,625$ / $0,700$
t^*	0,133	0,303

A.6 Espai de cerca de la cerca bayesiana

La Taula 6 llista els eixos d'optimització, els seus rangs i la branca d'arquitectura on s'apliquen. La cerca es fa amb *TPE* (Optuna); cada *trial* avalua una configuració amb 5-fold CV sobre el *pool* train+val. Les dues arquitectures s'optimitzen en **estudis Optuna aïllats** (SQLite separats): els eixos específics de cada arquitectura no es barregen, i els eixos comuns s'optimitzen de forma independent per a cada branca.

TAULA 6: EIXOS DEL *sweep* BAYESIÀ (DOS ESTUDIS OPTUNA AÏLLATS, UN PER ARQUITECTURA). ESTIMACIÓ DE TEMPS EN UNA NVIDIA L40S: 60–150 H PER 1000 *trials* TOTALS.

Eix	Valors / rang	Tipus mostreig
<i>Arquitectura del model — Baseline</i>		
L (capes GAT)	2, 3, 4	enter
<i>Readout</i>	mean, max, mean_max, attention	categòric
h (dimensió oculta)	64, 128, 256	categòric
H (caps d'atenció)	2, 4	categòric
<i>Dropout</i>	[0,05, 0,5]	uniforme
<i>Arquitectura del model — DiffPool</i>		
L_{DP} (blocs DiffPool)	1, 2, 3	enter
K_{top} (super-nodes 1r nivell)	10, 25, 50	categòric
K_{bot} (super-nodes últim nivell)	3, 5, 10	categòric
(Intermedis: $K = \lfloor \sqrt{K_{top} \cdot K_{bot}} \rfloor$; clamp $K_{bot} < K_{top}$)		
λ_{aux} (pes aux.)	[0,1, 10]	log-uniforme
<i>Readout</i>	mean, max, mean_max, attention	categòric
h (dimensió oculta)	64, 128, 256	categòric
H (caps d'atenció)	2, 4	categòric
<i>Dropout</i>	[0,05, 0,5]	uniforme
<i>Agregació MIL — ambdues arquitectures (optimitzada independentment)</i>		
Agregació MIL	mean, max, noisy-OR, attention	categòric
<i>Optimitzador i regularització — ambdues (independentment)</i>		
<i>Optimizer</i>	Adam, AdamW	categòric
<i>Scheduler</i>	ReduceLROnPlateau, CosineAnnealingLR	categòric
Taxa aprenentatge	$[5 \cdot 10^{-5}, 5 \cdot 10^{-3}]$	log-uniforme
<i>Weight decay</i>	$[10^{-5}, 10^{-2}]$	log-uniforme
<i>Grad. clipping</i>	0, 1, 5	categòric
Pes classe N1 (w_+)	[1,5, 8,0]	uniforme

Objectiu del sweep: $\text{objective} = \overline{\text{spec}}_{CV} - 10 \cdot \max(0, 1 - \overline{\text{sens}}_{CV})$, on $\overline{\text{spec}}_{CV}$ i $\overline{\text{sens}}_{CV}$ són les mitjanes sobre els 5 *val sets*, calculades amb el llindar t^* derivat de cada *fold* (llindar més alt amb TPR= 1). Aquesta és l'**única** mètrica que el TPE veu per decidir els paràmetres del següent *trial*. La penalització $\times 10$ fa que el TPE prioritzi sensibilitat del 100%; qualsevol pèrdua de sensibilitat s'ha de compensar amb un guany d'especificitat molt superior (10 punts per cada punt de sensibilitat perdut).