

Predicció de Metàstasis en Histopatologia en Càncer Colorrectal usant Graph Attention Networks

David Morillo Massagué

Resum— Es presenta un sistema de classificació N0/N1 per a la detecció de metàstasi en ganglis limfàtics en càncer colorrectal pT1 a partir de *Whole Slide Images*. El teixit es representa com un **graf espacial** construït per triangulació de Delaunay sobre les coordenades dels *patches*, de manera que es preserva la topologia real del teixit —a diferència d'enfocaments basats en similitud de característiques. Cada node és un *patch* de 2048×2048 px representat per l'embedding CLS (1.536 dim.) del model UNI2. Es comparen dues arquitectures: un GAT de referència amb *readout* pla i un GAT amb **DiffPool jeràrquic** intercalat ($N \rightarrow K_1 \rightarrow K_2$ super-nodes) per obtenir representacions a múltiples escales. El diagnòstic per pacient s'obté per agregació MIL sobre les seccions. El millor model obté un AUC de 0,917 (Selecció d'hiperparàmetres, 367 pacients).

Paraules clau— Càncer colorrectal pT1, Histopatologia digital, Graph Attention Networks, DiffPool jeràrquic, Graf espacial de Delaunay, MIL, Desbalanceig de classes.

Abstract— We present an N0/N1 classification system for lymph node metastasis prediction in pT1 colorectal cancer from Whole Slide Images. Tissue is represented as a **spatial graph** built by Delaunay triangulation over patch coordinates, preserving the real spatial topology of the tissue —unlike feature-similarity graph approaches. Each node is a 2048×2048 px patch represented by a 1,536-dimensional CLS embedding from the UNI2 model. Two architectures are compared: a **GAT baseline** with flat readout (mean/max) and a **GAT+DiffPool** model with pooling layers interleaved between GAT layers ($N \rightarrow K_1 \rightarrow K_2$ super-nodes) for multi-scale representations. Patient-level diagnosis is obtained via MIL aggregation over histological sections. The best model achieves an AUC of 0.817 (Hyperparameter selection, 367 patients).

Keywords— pT1 colorectal cancer, Digital histopathology, Graph Attention Networks, Hierarchical DiffPool, Spatial Delaunay graph, Multiple Instance Learning, Class imbalance.



1 INTRODUCCIÓ

EL càncer colorrectal (CCR) representa un dels reptes de salut pública més greus del nostre entorn. A Espanya, la SEOM preveu per al 2026 més de **44.132** nous casos anuals, convertint-lo en el tumor més freqüentment diagnosticat i en la segona causa de mort per càncer amb 14.629 defuncions [1].

El carcinoma pT1 és especialment complex: el tumor ha envaït la submucosa però no la muscular pròpia, i el risc de

metàstasi als ganglis limfàtics oscil·la entre el **2%** i el **23%** depenent de la profunditat d'invasió [2]. Quan hi ha criteris de mal pronòstic, el risc s'estima al voltant del 10%, la qual cosa obliga a considerar una cirurgia radical. Tanmateix, s'estima que **entre el 80% i el 90%** d'aquestes cirurgies resulten innecessàries [3].

La histopatologia digital, a través de les *Whole Slide Images* (WSI), obre la porta a tècniques avançades de visió per computador. En concret, les *Graph Attention Networks* (GAT) [4] permeten modelar l'arquitectura espacial del teixit de forma relacional. Una decisió clau en la construcció del graf és la definició de les arestes: mentre que alguns treballs les basen en la *similitud de característiques* entre *patches*, aquest projecte opta per la **proximitat espacial** (triangulació de Delaunay sobre coordenades WSI), preservant la topologia real del teixit. Aquest projecte, desenvolupat

- E-mail de contacte: David.MorilloMa@autonoma.cat
- Treball tutoritzat per: Debora Gil Resina (DCC)
- Curs 2025/26

al grup IAM del CVC (iam.cvc.uab.es) sota la supervisió de la Dra. Debora Gil, compara un GAT de referència amb *readout* pla contra un model amb *pooling* jeràrquic (Diff-Pool) intercalat, i proposa estratègies d'agregació MIL per al diagnòstic a nivell de pacient.

Dues raons complementàries justifiquen la tria d'aquest projecte. Des del punt de vista clínic, els sistemes d'IA demostren una capacitat creixent per identificar patrons morfològics subtils de manera consistent, amb el potencial real de reduir cirurgies innecessàries. Des del punt de vista tècnic, la combinació de xarxes d'atenció sobre grafs i aprenentatge profund sobre imatges histopatològiques d'alta resolució és exactament la intersecció entre la teoria de grafs i les xarxes neuronals profundes que vull explorar dins de l'Enginyeria de Dades.

2 OBJECTIUS

- Construir un *pipeline* complet de classificació N0/N1 sobre WSI reals a partir d'embeddings CLS del model UNI2, basat en **grafs espacials** (triangulació de Delaunay sobre coordenades del teixit).
- **Comparar un GAT de referència** amb *readout* pla contra un model amb **DiffPool jeràrquic** intercalat entre capes GAT, avaluant si la reducció progressiva del graf aporta millor representació multi-escala.
- Implementar i comparar estratègies d'agregació MIL a nivell de pacient per integrar les prediccions de múltiples seccions histològiques.

3 ESTAT DE L'ART

3.1 Classificació de WSI amb MIL

Les *Whole Slide Images* tenen resolucions de fins a $150\,000 \times 150\,000$ píxels i no es poden processar directament amb xarxes convencionals. L'enfocament habitual és dividir la làmina en *patches* petits i treballar amb *Multiple Instance Learning* (MIL), on el model ha d'inferir l'etiqueta global a partir de fragments sense etiqueta individual. Ilse et al. [5] van proposar l'agregació per atenció (*attention-based MIL*), que aprèn quins *patches* són més rellevants per al diagnòstic. Lu et al. [6] van aplicar aquest mètode a conjunts de dades clínics reals (CLAM), i Li et al. [7] van proposar DSMIL, que combina dues branques —a nivell de *patch* i de làmina— amb aprenentatge contrastiu. La predicció de metàstasi ganglionar a partir d'histopatologia s'ha estudiat en altres càncers: Muti et al. [8] mostren que és possible predir l'estat N0/N1 a partir de làmines de càncer gàstric, amb resultats prometedors.

3.2 Grafs i GNN en Patologia Digital

Les *Graph Neural Networks* permeten tractar el teixit com una estructura on les regions estan connectades segons la seva proximitat, capturant relacions espacials que les CNN no modelen directament. Jaume et al. [9] van presentar HistoCartography, un entorn de treball per a l'anàlisi de grafs en patologia digital, amb resultats que mostren millores respecte de les CNN en classificació de biòpsies. Les GAT [4] afegeixen un mecanisme d'atenció que permet al

model ponderar cada veí de manera diferent, cosa especialment útil en histopatologia on no totes les regions del teixit aporten la mateixa informació. Pel que fa al *pooling* en grafs, Grattarola et al. [10] revisen els principals mètodes existents, entre ells DiffPool [11], que agrupa nodes en super-nodes de manera progressiva.

3.3 Models de Fundació per a Histopatologia

En els darrers anys han aparegut *foundation models* preentrenats específicament sobre dades de patologia, que generen embeddings molt més informatius que les CNNs genèriques. UNI2 [12] és un *vision transformer* entrenat sobre més de 100 milions de *patches* de 20 tipus de teixit, amb bons resultats en nombroses tasques de classificació histopatològica. CONCH [13] és un model similar que incorpora a més alineament entre imatge i text. En aquest projecte s'utilitzen els embeddings de UNI2 com a vector de característiques de cada node, ja que estan preentrenats en el mateix domini i capturen informació morfològica rellevant.

3.4 Treball Previ al CVC sobre pT1 CRC

Aquest treball s'integra dins una línia de recerca del grup IAM del CVC. Martí et al. [14] van treballar sobre el mateix conjunt de dades pT1 CRC comparant CNNs, ViTs i GNNs per a la classificació de *patches* individuals, obtenint la millor AUC ($0,954 \pm 0,077$) amb una arquitectura híbrida ViT+NN. Aquell treball, però, opera a nivell de *patch* i no considera la topologia espacial del teixit ni el diagnòstic a nivell de pacient. El present TFG parteix dels embeddings CLS del model UNI2 per construir grafs espacials de les seccions i aborda el problema des d'una perspectiva de MIL a nivell de pacient.

4 DADES I PREPROCESSAMENT

Aquest projecte es realitza en col·laboració amb un equip de la UAB que cobreix des de la recollida de dades fins a la creació d'autoencoders per a l'extracció de característiques.

4.1 Imatges de Gran Format (WSI)

Les dades originals consisteixen en imatges de làmines senceres (WSI) obtingudes amb escàners d'alta resolució i tintades amb hematoxilina-eosina, emmagatzemades en format MIRAX (.mrxs). Les dimensions oscil·len entre els 30.000 i els 150.000 píxels per costat, amb una quantitat significativa d'espai buit o artefactes que requereixen tractament previ.

El conjunt de dades efectiu comprèn **1.607 grafs** (un per secció histològica), provinents de **367 pacients** distribuïts de forma desequilibrada entre les dues classes (Taula 1). D'un total de 606 pacients a la base de dades clínica, 236 es descarten per diagnòstic indeterminat (NX), i dels 370 restants amb diagnòstic vàlid, 3 no disposen d'embeddings UNI2 generats, deixant 367 pacients usables. Les mostres es divideixen en conjunts d'entrenament (70%), validació (15%) i test (15%) estratificats a nivell de pacient, amb llavor fixa (`random_state=42`).

TAULA 1: COMPOSICIÓ DEL DATASET EFECTIU PER PARTICIÓ (26 HOSPITALS, `RANDOM_STATE=42`).

Partició	Pacients	N0	N1	Grafs
Train	256	184	72	1 082
Val	55	40	15	270
Test	56	40	16	255
Total	367	264	103	1 607

4.2 Anotacions i Màscares de Segmentació

La Dra. Eva Musulén, patòloga especialitzada, ha realitzat les anotacions manualment amb el programari *Labelme*. Aquestes identifiquen tres categories d'afectació:

- **Infiltració:** teixit anormal que envaeix zones no corresponents.
- **Displàsia:** cèl·lules anormals que poden esdevenir canceroses.
- **Infiltració + Displàsia:** emprat en casos de dubte diagnòstic.

A partir d'aquestes s'obtenen màscares de segmentació codificades per color: vermell (infiltració), blau (displàsia) i verd clar (combinada).




Fig. 1: Exemple de WSI i la seva corresponent màscara de segmentació.

4.3 Extracció de Patches i Embeddings CLS

S'aplica una finestra lliscant (*sliding window*) sense solapament per dividir cada làmina en *patches* de 2048×2048 píxels a resolució completa (nivell 0). El model de fundació **UNI2** [12] processa cada *patch* individualment i extreu el token *CLS* de la seva sortida, obtenint un vector de **1.536 dimensions** que condensa la informació morfològica i textural del patch. No s'aplica cap filtratge de qualitat previ (ni per borrositat ni per proporció de blanc): tots els *patches* d'una secció generen un node del graf.

5 CONSTRUCCIÓ DEL GRAF

5.1 Nodes i característiques

Cada *patch* de 2048×2048 px del WSI constitueix un **node** del graf. El vector de característiques de cada node és l'embedding CLS de **1.536 dimensions** obtingut per UNI2. La posició del node al pla WSI és el centre del patch (coordenades en píxels a nivell 0). A la subfigura 2a es pot observar la distribució esparsa dels *patches* extrets sobre una làmina real.

5.2 Model de dades: dimensions i estructures

Formalment, cada secció histològica es representa com un graf $\mathcal{G} = (\mathbf{X}, \mathbf{A})$ on:

- $\mathbf{X} \in \mathbb{R}^{N \times 1536}$ és la matriu de característiques dels N nodes (*patches*).
- $\mathbf{A} \in \{0, 1\}^{N \times N}$ és la matriu d'adjacència construïda per triangulació de Delaunay i posterior poda d'arestes llargues.

Dues estratègies de *pooling* transformen la seqüència de grafs en un vector global que alimenta el capçal MLP per produir $P(N1)$:

- **Pla (readout).** *Mean* o *max* aplicats sobre les sortides de la darrera capa GAT, reduint directament de N nodes a d_h dimensions.
- **Jeràrquic (DiffPool intercalat).** Dues capes DiffPool s'insereixen entre les capes GAT: la primera colapsa el graf de N nodes a K_1 super-nodes, i la segona de K_1 a K_2 . Cada nivell aprèn una matriu d'assignació suau i produeix un nou graf de menor grandària sobre el qual opera la capa GAT següent.

Model 1 — Múltiples grafs + agregació MIL. Cada secció genera un graf independent; les S seccions d'un pacient es processen per separat i les probabilitats $\{P(N1_i)\}_{i=1}^S$ s'agreguen a posteriori (Secció 7.1).

Model 2 — Un sol graf per pacient. Com a alternativa, es pot construir un únic graf per pacient concatenant verticalment les matrius de característiques i col·locant les matrius d'adjacència en la diagonal d'una mega-matriu per blocs:

$$\mathbf{X}_{\text{pac}} = \begin{pmatrix} \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_S \end{pmatrix} \in \mathbb{R}^{(\sum_i N_i) \times 1536} \quad (1)$$

$$\mathbf{A}_{\text{pac}} = \begin{pmatrix} \mathbf{A}_1 & \mathbf{0} & \cdots \\ \mathbf{0} & \ddots & \mathbf{0} \\ \cdots & \mathbf{0} & \mathbf{A}_S \end{pmatrix} \quad (2)$$

Els triangles fora de la diagonal queden a zero, és a dir, no hi ha arestes entre seccions diferents. D'aquesta manera el mecanisme d'atenció del GAT opera sobre totes les seccions simultàniament, i un únic *pooling* global produeix directament el diagnòstic del pacient sense necessitat d'una etapa d'agregació de probabilitats. Tots dos models estan implementats: el Model 1 és el mode per defecte del *pipeline*, i el Model 2 s'activa amb l'argument `--mega` de `scripts/build_dataset.py`, que genera un fitxer `.pt` per pacient en lloc d'un per secció.

5.3 Connectivitat per triangulació de Delaunay


Una connectivitat fixa de reixeta no és adequada perquè la màscara exclou regions de fons i trenca la simetria de la quadrícula. Per aquest motiu, s'aplica una **triangulació de**

Delaunay sobre els nodes restants, que s'adapta a distribucions irregulars de forma natural. A continuació, s'eliminen les arestes que travessen píxels de valor zero a la màscara, evitant connexions entre regions separades per espai buit. Finalment, s'aplica un criteri de distància màxima: s'eliminen les arestes que superen el doble de la longitud mitjana del conjunt ($\text{DISTANCE_FACTOR} = 2,0$). La subfigura 2b mostra el resultat sobre la mateixa làmina: les arestes eliminades pel filtre de màscara apareixen en vermell.

6 ARQUITECTURA DEL MODEL

6.1 GATClassifier

El model implementat, **GATClassifier**, és un classificador de grafs que alterna capes **Graph Attention Network** (GATConv [4, 15]) amb capes de *pooling* jeràrquic per a la classificació binària N0/N1. L'arquitectura proposa intercalar operacions de reducció del graf *entre* les capes de propagació de missatges, de manera que cada estadi treballa sobre una representació progressivament més compacta del teixit:



on $K_1 \ll N$ i $K_2 \ll K_1$ són el nombre de *super-nodes* de cada nivell jeràrquic.

Mecanisme d'atenció. A diferència de les xarxes convolucionals clàssiques sobre grafs que tracten tots els veïns d'un node de forma uniforme, GAT aprèn a assignar pesos d'importància diferenciats a cada veí. Donada la representació $\mathbf{h}_i \in \mathbb{R}^F$ del node i , per a cada parella de nodes veïns (i, j) es calcula un coeficient d'atenció no normalitzat:

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j])$$

on $\mathbf{W}$ és una transformació lineal aprenible, $\parallel$ la concatenació i $\mathbf{a}$ un vector d'atenció aprenible. Els coeficients es normalitzen amb *softmax* sobre tots els veïns del node i :

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$

i la nova representació del node s'obté com la suma ponderada dels veïns:

$$\mathbf{h}'_i = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W}\mathbf{h}_j \right)$$

Multi-cap. Per incrementar la capacitat expressiva, cada capa usa H caps d'atenció independents les sortides dels quals es concatenen (a les dues primeres capes) o es promitgen (tercera capa). D'aquesta manera el model pot capturar múltiples tipus de relació de veïnatge simultàniament. Cada capa va seguida de normalització per *batch*, activació ELU i *dropout*.

El capçal MLP ($\text{Linear} \rightarrow \text{ReLU} \rightarrow \text{Dropout} \rightarrow \text{Linear}$) transforma la representació global del graf en els logits N0/N1.

6.2 Estratègies de Pooling Pla (Readout)

Quan no s'utilitza pooling jeràrquic, les representacions dels nodes de la darrera capa GAT s'agreguen directament amb operacions de *readout*: *mean*, *max* o la seva concatenació (*mean_max*). Tot i la seva eficiència computacional, aquestes estratègies ignoren la topologia del graf i col·lapsen tota la informació espacial en un sol pas.

6.3 Pooling Jeràrquic: DiffPool entre Capes GAT

Per superar les limitacions del *readout* pla, s'implementa **DiffPool** [11] com a operació intermèdia entre les capes de propagació. A diferència d'aplicar el *pooling* únicament al final, la proposta intercala dues capes DiffPool al llarg de la xarxa: una entre la primera i la segona capa GAT, i una altra entre la segona i la tercera. Cada capa DiffPool aprèn una matriu d'assignació suau (*soft assignment*) $\mathbf{S} \in \mathbb{R}^{N \times K}$ que agrupa els N nodes actuals en $K \ll N$ *super-nodes*:

$$\mathbf{X}^{(\ell+1)} = \mathbf{S}^\top \mathbf{X}^{(\ell)}, \quad \mathbf{A}^{(\ell+1)} = \mathbf{S}^\top \mathbf{A}^{(\ell)} \mathbf{S}$$

Amb aquesta arquitectura, la primera capa GAT opera sobre el graf original de nodes de teixit (N patches), la segona ho fa sobre un graf reduït de K_1 super-nodes que representen regions de teixit de nivell intermedi, i la tercera opera sobre un graf molt compacte de K_2 super-nodes que codifiquen l'organització arquitectònica global de la secció. Finalment, un *readout* global (*mean* o *max*) sobre els K_2 nodes produeix l'embedding que entra al capçal MLP.


L'entrenament incorpora una pèrdua auxiliar (*link prediction* + entropia mínima) per regularitzar l'assignació i evitar degeneracions trivials.

Com a alternativa, **SAGPool** [16] proposa un enfocament esparç que selecciona els K nodes més rellevants via puntuacions d'auto-atenció, descartant la resta i preservant l'estructura topològica original. A diferència de DiffPool, SAGPool no aprèn assignacions suaus sinó seleccions discretes, amb un cost computacional menor però sense la capacitat de capturar representacions jeràrquiques contínues. En aquest projecte s'utilitza DiffPool per la seva major expressivitat i la possibilitat d'integrar la pèrdua auxiliar de regularització.


7 METODOLOGIA

7.1 Agregació per Pacient (MIL)

El diagnòstic és per **pacient**, no per làmina. Una mateixa secció histològica pot no presentar senyals visibles de metàstasi si s'analitza aïlladament, mentre que en una altra



(a) Posicions dels *patches* dels quals se n'extreuen les característiques, superposades sobre la imatge original.



(b) Graf de Delaunay sobre la imatge anotada. Les zones verdes indiquen àrees afectades anotades per la patòloga; les arestes en vermell han estat eliminades pel filtratge de màscara.

Fig. 2: Visualització del procés de construcció del graf sobre una làmina real. Les dues imatges corresponen a la mateixa secció histològica i il·lustren com la topologia del graf s'adapta a la distribució irregular del teixit.




Fig. 3: Il·lustració del mecanisme d'atenció en una capa GAT amb tres caps independents (verd, blau, lila). El node central $\vec{h}_1$ agrega les representacions dels seus veïns i la seva pròpia (α_{11} , *self-loop*) mitjançant coeficients d'atenció α_{1j} apresos per cada cap. Les sortides dels caps es combinen per concatenació o promig per obtenir la nova representació $\vec{h}'_1$.

secció del mateix pacient sí que és apreciable. Si s'entrena a nivell de làmina, les seccions N1 de pacients N1 que no mostren metàstasi visible reben un senyal de supervisió incorrecte (N0), contaminant l'entrenament.

Per evitar aquest problema, s'utilitza el paradigma d'**aprenentatge per múltiples instàncies** (*Multiple Instance Learning*, MIL): cada pacient es tracta com un *bag* i totes les seves làmines comparteixen la mateixa etiqueta. El model aprèn a classificar el pacient a partir de les seves seccions, sense necessitat d'etiquetes individuals per làmina.

Donades les probabilitats $\{p_i = P(N1_i)\}_{i=1}^S$ de les S làmines d'un pacient, s'implementen les estratègies d'agregació següents:

- **Noisy-OR** (per defecte): $P(N1_p) = 1 - \prod_{i=1}^S (1 - p_i)$. Modela la hipòtesi que n'hi ha prou que una làmina

presenti metàstasi per classificar el pacient com N1.

- **Max**: $P(N1_p) = \max_i p_i$. Predicció conservadora basada en l'evidència màxima.
- **Mean / LSE**: mitjana aritmètica o *log-sum-exp* per als casos intermedis.
- **Attention MIL**: *PatientAggregator* basat en l'atenció *gated* de Ilse et al. [5]. Aprèn un pes d'atenció per a cada làmina a partir del seu embedding (produït per l'encoder del GAT sense el capçal MLP), i la representació del pacient s'obté com la suma ponderada dels embeddings de les seves làmines.

Formalment, per a l'agregació per atenció, donat l'embedding $\mathbf{h}_i \in \mathbb{R}^d$ de la làmina i produït per l'encoder GAT, els pesos d'atenció i la representació del pacient s'obtenen com:

$$a_i = \frac{\exp(\mathbf{w}^\top (\tanh(\mathbf{V}\mathbf{h}_i) \odot \sigma(\mathbf{U}\mathbf{h}_i)))}{\sum_{j=1}^S \exp(\mathbf{w}^\top (\tanh(\mathbf{V}\mathbf{h}_j) \odot \sigma(\mathbf{U}\mathbf{h}_j)))}$$

$$\mathbf{z}_p = \sum_{i=1}^S a_i \mathbf{h}_i$$

on $\mathbf{w}$, $\mathbf{V}$, $\mathbf{U}$ són paràmetres aprenibles, $\odot$ és la multiplicació element a element i $\mathbf{z}_p$ és l'embedding del pacient que entra al capçal MLP per a la predicció final N0/N1.

7.2 Desbalanceig de Classes

El conjunt de dades presenta un fort desbalanceig: els casos N0 superen àmpliament els N1 (proporció aproximada 80/20). Per combatre-ho s'apliquen tres mesures complementàries.




Fig. 4: Agrupació jeràrquica de nodes per *DiffPool*: l'assignació suau colapsa progressivament el graf en super-nodes de major abstracció. En el model proposat, dos nivells *DiffPool* s'intercalen entre les capes GAT. Font: [11].

(1) **Validació creuada estratificada.** S'utilitza una validació creuada de $k = 5$ particions estratificades a nivell de pacient, assegurant que la proporció N0/N1 sigui representativa en cada partició. Sense estratificació, amb un conjunt petit i desequilibrat, algunes particions podrien contenir per atzar una proporció de N1 molt diferent a la real, invalidant les mètriques.

(2) **Pesos de classe.** S'apliquen pesos balancejats $w_c = N/(C \cdot n_c)$, on n_c és el nombre de pacients de la classe c , incorporats directament a la funció de pèrdua BCE. Així, cada error sobre un cas N1 té més pes en el gradient que un error sobre N0, penalitzant més els falsos negatius.

(3) **Mostratge ponderat per batch.** Durant l'entrenament s'utilitza un *WeightedRandomSampler* que assigna a cada pacient una probabilitat de mostratge inversament proporcional a la freqüència de la seva classe. Això garanteix que cada *mini-batch* contingui una proporció equilibrada de casos N0 i N1, evitant que el model vegi gairebé exclusivament N0 durant molts *batches* consecutius.

7.3 Grid Search i Configuració d'Entrenament

S'ha dut a terme un *grid search* amb múltiples hiperparàmetres variables: *hidden units*, nombre de caps d'atenció, tipus de *pooling*, mètode d'agregació MIL, nombre de clústers *DiffPool*, *dropout* i *weight decay*. Cada combinació d'hiperparàmetres genera una *run* independent amb mètriques registrades a *Weights & Biases*. El millor model per AUC de validació es desa com a *checkpoint*. L'entrenament inclou *early stopping* amb 15 epochs de *warm-up* i *patience* de 10, basant el criteri d'aturada en la pèrdua de validació.

La partició del conjunt de dades es realitza **una sola vegada** en el moment de construir els grafs, amb estratificació a nivell de pacient (llavor fixa `random_state=42`): 70% entrenament, 15% validació i 15% test. Els grafs s'emmagatzemen físicament en tres subdirectoris independents (`train/`, `val/`, `test/`), i la partició es registra en un fitxer `split.json` per garantir la reproductibilitat i evitar la filtració de dades entre conjunts. El conjunt de test no s'utilitza durant l'entrenament ni la selecció d'hiperparàmetres: únicament s'empra per a l'avaluació final de les mètriques clíniques (sensibilitat, especificitat, AUC-ROC).

8 RESULTATS PRELIMINARS

S'han avaluat **48 configuracions** que creuen: arquitectura (GAT Baseline / GAT+*DiffPool*), tipus de graf (per sec-

ció / per pacient), *pooling* (attention / mean_max / diff), agregació MIL (mean / attention / noisy-OR) i *learning rate* $\{10^{-3}, 10^{-4}, 10^{-5}, 10^{-6}\}$. La taula completa es troba a l'Apèndix A. La Taula 2 resumeix les millors configuracions de cada família sobre el conjunt de test.

El millor model és el **GAT Baseline amb attention pooling i agregació mean**, que assoleix un AUC de test de **0,917** ($lr = 10^{-5}$, grafs per secció, 56 pacients). El GAT Baseline supera consistentment el GAT+*DiffPool* a totes les comparatives, cosa que suggereix que el *pooling* jeràrquic no aporta avantatge amb el conjunt de dades actual.

Destaquen dues observacions rellevants. Primera, l'*attention pooling* amb agregació *mean* és la millor combinació, mentre que l'agregació *attention* (PatientAggregator) no generalitza bé malgrat tenir un AUC de validació elevat ($val = 0,918$, $test = 0,700$), cosa que indica un cert sobreajustament al conjunt de validació. Segona, el graf per pacient aconsegueix un AUC de test raonable (0,811) però inferior al millor model per-secció, i *DiffPool* sobre el graf per pacient fracassa per a totes les configuracions (AUC test $\leq 0,56$).

8.1 Anàlisi d'influència dels hiperparàmetres

Per identificar quins factors determinen els resultats, s'han calculat els **efectes principals** de cada hiperparàmetre: per a cada nivell d'un factor s'obté la mitjana de l'AUC de test en tots els experiments que inclouen aquell nivell, independentment dels altres factors. El **rang d'influència** (diferència entre el millor i el pitjor nivell) mesura la rellevància relativa de cada factor.

El factor amb més influència és el **pooling** (rang 0,200): l'*attention pooling* supera clarament *mean_max* i tots dos superen *diff* (l'únic disponible per a *DiffPool*). Atès que el pooling i l'arquitectura estan parcialment correlacionats (*diff* implica GAT+*DiffPool*), la caiguda del rang d'arquitectura (0,153) reflecteix en part la mateixa diferència.

Respecte de la **agregació MIL**, l'agregació *mean* és la millor opció, mentre que *attention* (PatientAggregator) té un rendiment pitjor malgrat la seva complexitat, cosa que suggereix que amb 367 pacients el mòdul d'atenció tendeix al sobreajustament. El *learning rate* òptim és 10^{-5} (rang 0,115), i 10^{-6} és perjudicial.

La Taula 4 mostra la interacció entre *pooling* i agregació MIL per al subconjunt de GAT Baseline amb grafs per secció (les 24 configuracions no condicionades per l'arquitectura *DiffPool*).

La combinació *attention pooling* + agregació *mean* és la




Fig. 5: Comparació de les dues arquitectures GATClassifier. **Esquerra:** model de referència amb readout pla (mean || max global); **Dreta:** model jeràrquic on DiffPool redueix progressivament $N \rightarrow K_1 \rightarrow K_2$ super-nodes. Les dimensions del tensor de sortida s'indiquen a la dreta de cada bloc ($h = 128$, $H = 4$, per tant $h \cdot H = 512$).

millor en totes les configuracions i apunta clarament la direcció de treball futur: l'*attention pooling* aprèn a ponderar els nodes del graf, i l'agregació *mean* de les slides evita el sobreajustament del PatientAggregator.

9 IMPLEMENTACIÓ I FRONTEND

La implementació segueix un disseny modular: la construcció de grafs, el model, el codi d'entrenament i els *data loaders* estan desacoblats per facilitar l'experimentació independent. La configuració d'hiperparàmetres es gestiona via fitxer YAML, on qualsevol paràmetre pot ser una llista per activar el *grid search* automàtic. El repositori és accessible a [17] i el desplegament al servidor CVC es gestiona via GitHub Actions amb un *runner self-hosted*.

9.1 Frontend Web Interactiu

S'ha desenvolupat un *frontend* web (FastAPI + JavaScript pur, sense *build step*) per facilitar l'exploració dels models entrenats. Les funcionalitats principals inclouen:

- **Inferència en temps real:** selecció de pacient o làmina, *forward pass* al model actiu i visualització del resultat N0/N1 amb la descomposició per làmina.

- **Visualització de l'atenció:** representació del graf de Delaunay sobre la làmina, amb nodes colorejats per pes d'atenció (capes GATConv) i visualització dels *patches* RGB originals.

- **Estadístiques:** corbes ROC i PR, matriu de confusió i mètriques per classe sobre el conjunt de validació.

- **Selecció de checkpoint:** comparació entre múltiples models entrenats.

La figura 6 mostra el diagrama de flux complet del sistema.

10 CONCLUSIONS I TREBALL FUTUR

10.1 Conclusions Parcial

En aquest TFG s'ha construït un sistema complet de classificació N0/N1 per a càncer colorrectal pT1 a partir de WSI, que inclou la generació de grafs espacials, l'entrenament del model GAT amb diverses configuracions i l'avaluació amb validació creuada de 5 particions. L'AUC obtinguda ($0,817 \pm 0,073$) és un bon punt de partida per a un sistema que encara no ha estat optimitzat en profunditat. Se'n destaquen tres observacions:

TAULA 2: MILLORS CONFIGURACIONS DEL *grid search* SOBRE EL CONJUNT DE TEST (NIVELL DE PACIENT, 56 PACIENTS). **NEGRETA**: MILLOR VALOR PER COLUMNA.

Model	Graf	Pooling	MIL	LR	AUC val	AUC test
GAT Baseline	per secció	<i>attention</i>	<i>mean</i>	10^{-5}	0,878	0,917
GAT Baseline	per secció	<i>mean_max</i>	<i>mean</i>	10^{-5}	0,902	0,895
GAT Baseline	per secció	<i>attention</i>	<i>mean</i>	10^{-4}	0,882	0,878
GAT Baseline	per pacient	<i>attention</i>	<i>mean</i>	10^{-4}	0,788	0,811
GAT+DiffPool	per secció	<i>diff</i>	<i>mean</i>	10^{-5}	0,868	0,795
GAT+DiffPool	per secció	<i>diff</i>	<i>mean</i>	10^{-4}	0,745	0,784
GAT+DiffPool	per secció	<i>diff</i>	<i>attention</i>	10^{-5}	0,870	0,616

TAULA 3: EFECTES PRINCIPALS DE CADA HIPERPARÀMETRE SOBRE L'AUC DE TEST (48 EXPERIMENTS, 56 PACIENTS). RANGS D'INFLUÈNCIA EN NEGRETA PER ORDRE DECREIXENT.

Factor	Nivell	<i>n</i>	AUC test (mitjana $\pm$ std)	Rang
Pooling	<i>attention</i>	16	$0,719 \pm 0,128$	0,200
	<i>mean_max</i>	16	$0,624 \pm 0,189$	
	<i>diff</i>	16	$0,519 \pm 0,151$	
Arquitectura	GAT Baseline	32	$0,672 \pm 0,168$	0,153
	GAT+DiffPool	16	$0,519 \pm 0,151$	
Tipus de graf	Per secció	36	$0,652 \pm 0,164$	0,126
	Per pacient	12	$0,526 \pm 0,184$	
<i>Learning rate</i>	10^{-5}	12	$0,681 \pm 0,153$	0,115
	10^{-3}	12	$0,624 \pm 0,180$	
	10^{-4}	12	$0,611 \pm 0,186$	
	10^{-6}	12	$0,566 \pm 0,173$	
Agregació MIL	<i>mean</i>	24	$0,662 \pm 0,210$	0,099
	<i>noisy-OR</i>	12	$0,597 \pm 0,120$	
	<i>attention</i>	12	$0,562 \pm 0,129$	

- El mètode d'agregació MIL té un impacte molt gran: el GAT Baseline passa d'AUC 0,581 amb *noisy-OR* a 0,817 amb *attention*. Triar bé com s'agreguen les seccions d'un pacient és tan important com l'arquitectura del model.
- GAT+DiffPool amb *attention* obté menys variabilitat entre *folds* ($\sigma = 0,042$) i el millor F1-N1 ($0,679 \pm 0,058$), però no supera clarament el model de referència en AUC. Caldrà fer experiments més amplis per saber si el *pooling* jeràrquic aporta avantatge real.
- El nombre de pacients és petit (230) i l'espai de cerca d'hiperparàmetres és molt limitat; no és possible treure conclusions definitives en aquesta fase.

10.2 Treball Futur

Ampliar la cerca d'hiperparàmetres. Fins ara s'han provat 4 combinacions sobre un *grid* molt reduït. En les pròximes fases s'ampliarà la cerca incloent valors de h_{hidden} , K_1/K_2 per a DiffPool, *dropout* i *learning rate*, entre d'altres, per trobar una configuració millor.

Supervisió amb màscares d' anotació. Les màscares de displàsia i infiltració anotades per la Dra. Musulén podrien fer-se servir per guiar els pesos d'atenció del GAT: les regions anotades haurien de rebre més atenció que les zones sanes. Tourniaire et al. [18] mostren que fins i tot amb un nombre limitat d'anotacions parcials es pot millorar la localització i la classificació del model.

Comparació de connectivitats. En el marc del mateix projecte, un altre estudiant treballa en paral·lel en un model on la matriu d'adjacència es construeix a partir de la **distància entre les característiques** dels *patches*, sense triangulació de Delaunay ni relacions espacials. Comparar els dos models sobre el mateix conjunt de dades permetrà valorar si la topologia espacial aporta avantatge real respecte d'una connectivitat basada en similitud de *features*.

REFERÈNCIES

- [1] Sociedad Española de Oncología Médica (SEOM). *Las Cifras del Cáncer en España 2026*. Consultat el 6 de febrer de 2026. 2026. URL: <https://seom.org/prensa/el-cancer-en-cifras>.
- [2] Unitat Funcional Càncer Colorectal. *Protocol de Pràctica Clínica del Càncer de Còlon i Recte*. Actualització de la 3^a edició. Parc de Salut MAR Barcelona - Hospital del Mar. Barcelona, juny de 2013. URL: https://www.hospitaldelmar.cat/media/upload/arxius/unitats/cancer_colorectal/protocols/practica_clinica.pdf.
- [3] Fernando Martínez de Juan, Samuel Navarro i Isidro Machado. "Refining Risk Criteria May Substantially Reduce Unnecessary Additional Surgeries after Local Resection of T1 Colorectal Cancer". A:

TAULA 4: AUC DE TEST MITJANA: INTERACCIÓ *pooling* × AGREGACIÓ MIL (GAT BASELINE, GRAFS PER SECCIÓ, $n = 4$ PER CEL·LA).

Pooling \ MIL	mean	attention	noisy-OR
attention	0,882	0,663	0,616
mean_max	0,836	0,587	0,638




Fig. 6: Diagrama de flux del *pipeline* complet. *Blocs grisos*: etapes realitzades pels companys de l'equip i dades de referència. *Blocs blaus*: contribucions d'aquest TFG. La fletxa $\times S$ indica que les S seccions d'un pacient es processen com a grafs independents i les $P(N1)$ s'agreguen via MIL per obtenir el diagnòstic a nivell de pacient, que es compara amb el diagnòstic real de l'Excel.

- Cancers* 16.13 (2024), pàg. 2321. DOI: 10.3390/cancers16132321.
- [4] Petar Veličković et al. *Graph Attention Networks*. 2018. arXiv: 1710.10903 [stat.ML]. URL: <https://arxiv.org/abs/1710.10903>.
- [5] Maximilian Ilse, Jakub M. Tomczak i Max Welling. *Attention-based Deep Multiple Instance Learning*. 2018. arXiv: 1802.04712 [cs.LG]. URL: <https://arxiv.org/abs/1802.04712>.
- [6] Ming Y. Lu et al. *Data Efficient and Weakly Supervised Computational Pathology on Whole Slide Images*. 2020. arXiv: 2004.09666 [eess.IV]. URL: <https://arxiv.org/abs/2004.09666>.
- [7] Bin Li, Yin Li i Kevin W. Eliceiri. *Dual-stream Multiple Instance Learning Network for Whole Slide Image Classification with Self-supervised Contrastive Learning*. 2021. arXiv: 2011.08939 [cs.CV]. URL: <https://arxiv.org/abs/2011.08939>.
- [8] Holger S. Muti, Christoph Röcken, Hans-Michael Behrens et al. "Deep learning trained on lymph node status predicts outcome from gastric cancer histopathology: a retrospective multicentric study". A: *European Journal of Cancer* 194 (2023), pàg. 113335. DOI: 10.1016/j.ejca.2023.113335.
- [9] Guillaume Jaume et al. *HistoCartography: A Toolkit for Graph Analytics in Digital Pathology*. 2021. arXiv: 2107.10073 [eess.IV]. URL: <https://arxiv.org/abs/2107.10073>.
- [10] Daniele Grattarola et al. "Understanding Pooling in Graph Neural Networks". A: *IEEE Transactions on Neural Networks and Learning Systems* 35.2 (febr. de 2024), pàg. 2708-2718. ISSN: 2162-2388. DOI: 10.1109/tnnls.2022.3190922.
- [11] Rex Ying et al. *Hierarchical Graph Representation Learning with Differentiable Pooling*. 2019. arXiv: 1806.08804 [cs.LG]. URL: <https://arxiv.org/abs/1806.08804>.
- [12] Richard J. Chen et al. "Towards a general-purpose foundation model for computational pathology". A: *Nature Medicine* 30.3 (març de 2024), pàg. 850-862. DOI: 10.1038/s41591-024-02857-3.
- [13] Ming Y. Lu et al. "A visual-language foundation model for computational pathology". A: *Nature Medicine* 30.3 (març de 2024), pàg. 863-874. DOI: 10.1038/s41591-024-02856-4.
- [14] Pau Martí Escolà. "Anàlisi d'espais de representació profunds pel diagnòstic del carcinoma colorectal en histopatologia digital". Treb. fin. de màst. Universitat Autònoma de Barcelona, 2025. URL: <https://ddd.uab.cat/record/317556>.
- [15] Matthias Fey i Jan Eric Lenssen. *Fast Graph Representation Learning with PyTorch Geometric*. 2019. arXiv: 1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.
- [16] Junhyun Lee, Inyeop Lee i Jaewoo Kang. *Self-Attention Graph Pooling*. 2019. arXiv: 1904.

08082 [cs.LG]. URL: <https://arxiv.org/abs/1904.08082>.

- [17] David M. et al. *Implementació de Graph Attention Networks per a la detecció de metàstasi en pT1*. 2026. URL: <https://github.com/IAM-CVC/PT1Diagnosis> (cons. 03-05-2026).
- [18] Paul Tourniaire et al. “MS-CLAM: Mixed supervision for the classification and localization of tumors in Whole Slide Images”. A: *Medical Image Analysis* 85 (2023), pàg. 102763. DOI: 10.1016/j.media.2023.102763.

A RESULTATS COMPLETS DEL *grid search*

La Taula 5 mostra les 48 configuracions avaluades, ordenades per AUC de test descendent. Les mètriques s’han calculat sobre el conjunt de test (56 pacients, 255 seccions) usant l’agregació MIL indicada a cada fila.

TAULA 5: RESULTATS COMPLETS DEL *grid search* (48 EXPERIMENTS). ORDENATS PER AUC TEST ↓. **NEGRETA:** TOP-3 PER AUC TEST.

Model	Graf	Pooling	MIL	LR	Epoch	AUC val	AUC test
GAT Baseline	per secció	att.	mean	10^{-5}	23	0,878	0,917
GAT Baseline	per secció	mean_max	mean	10^{-5}	60	0,902	0,895
GAT Baseline	per secció	att.	mean	10^{-4}	7	0,882	0,878
GAT Baseline	per secció	mean_max	mean	10^{-3}	8	0,840	0,870
GAT Baseline	per secció	att.	mean	10^{-6}	97	0,780	0,869
GAT Baseline	per secció	att.	mean	10^{-3}	36	0,902	0,866
GAT Baseline	per pacient	att.	mean	10^{-4}	9	0,788	0,811
GAT Baseline	per secció	mean_max	mean	10^{-6}	88	0,745	0,798
GAT+DiffPool	per secció	diff	mean	10^{-5}	26	0,868	0,795
GAT+DiffPool	per secció	diff	mean	10^{-4}	7	0,745	0,784
GAT Baseline	per secció	mean_max	mean	10^{-4}	30	0,878	0,778
GAT Baseline	per pacient	att.	mean	10^{-5}	10	0,832	0,772
GAT Baseline	per secció	att.	noisy-OR	10^{-3}	11	0,755	0,769
GAT Baseline	per pacient	att.	mean	10^{-6}	91	0,827	0,764
GAT Baseline	per secció	mean_max	noisy-OR	10^{-3}	25	0,772	0,763
GAT Baseline	per pacient	mean_max	mean	10^{-3}	42	0,798	0,727
GAT Baseline	per secció	mean_max	noisy-OR	10^{-5}	88	0,763	0,717
GAT+DiffPool	per secció	diff	mean	10^{-6}	29	0,703	0,716
GAT Baseline	per secció	att.	attention	10^{-5}	34	0,918	0,700
GAT Baseline	per secció	att.	attention	10^{-4}	9	0,873	0,694
GAT Baseline	per secció	att.	attention	10^{-3}	15	0,850	0,677
GAT Baseline	per secció	mean_max	noisy-OR	10^{-4}	13	0,753	0,672
GAT Baseline	per secció	mean_max	attention	10^{-5}	61	0,848	0,661
GAT Baseline	per secció	mean_max	attention	10^{-4}	25	0,890	0,656
GAT Baseline	per secció	mean_max	attention	10^{-3}	16	0,887	0,617
GAT+DiffPool	per secció	diff	attention	10^{-5}	28	0,870	0,616
GAT+DiffPool	per secció	diff	noisy-OR	10^{-5}	13	0,698	0,614
GAT Baseline	per secció	att.	noisy-OR	10^{-5}	10	0,543	0,598
GAT+DiffPool	per secció	diff	noisy-OR	10^{-3}	40	0,727	0,594
GAT Baseline	per secció	att.	attention	10^{-6}	98	0,768	0,581
GAT Baseline	per secció	att.	noisy-OR	10^{-4}	10	0,617	0,566
GAT+DiffPool	per secció	diff	noisy-OR	10^{-6}	100	0,600	0,561
GAT+DiffPool	per pacient	diff	mean	10^{-5}	36	0,506	0,556
GAT Baseline	per secció	att.	noisy-OR	10^{-6}	84	0,487	0,533
GAT Baseline	per pacient	att.	mean	10^{-3}	12	0,677	0,508
GAT+DiffPool	per pacient	diff	mean	10^{-4}	14	0,500	0,423
GAT Baseline	per secció	mean_max	attention	10^{-6}	88	0,730	0,413
GAT+DiffPool	per secció	diff	attention	10^{-6}	31	0,803	0,408
GAT+DiffPool	per secció	diff	mean	10^{-3}	6	0,421	0,406
GAT Baseline	per secció	mean_max	noisy-OR	10^{-6}	52	0,330	0,400
GAT+DiffPool	per pacient	diff	mean	10^{-6}	45	0,412	0,394
GAT+DiffPool	per secció	diff	noisy-OR	10^{-4}	14	0,492	0,372
GAT+DiffPool	per secció	diff	attention	10^{-4}	2	0,813	0,368
GAT+DiffPool	per secció	diff	attention	10^{-3}	9	0,753	0,359
GAT Baseline	per pacient	mean_max	mean	10^{-6}	13	0,572	0,358
GAT+DiffPool	per pacient	diff	mean	10^{-3}	19	0,522	0,338
GAT Baseline	per pacient	mean_max	mean	10^{-4}	7	0,365	0,333
GAT Baseline	per pacient	mean_max	mean	10^{-5}	3	0,515	0,330