

Predicció de Metàstasis en Histopatologia en Càncer Colorrectal usant Graph Attention Networks

David Morillo Massagué

Resum— Aquest treball aborda la predicció de metàstasis en ganglis limfàtics en pacients amb càncer colorrectal en estadi pT1 a partir d'imatges de gran format (*Whole Slide Images*). S'utilitzen *Graph Attention Networks* (GAT) sobre grafs on cada node representa un *bag* de 256 *patches* de 256×256 px ($\approx 4096 \times 4096$ px al WSI), caracteritzat per l'embedding CLS de 1.536 dimensions del model de fundació *UNI2*. S'exploren dues estratègies de *pooling*: jeràrquic (DiffPool intercalat entre capes GAT, $N \rightarrow K_1 \rightarrow K_2$ nodes) o pla (*mean/max* al final). El conjunt de dades comprèn 963 grafs provinents de 230 pacients, dividits estratificadament en entrenament i validació. Per afrontar el desbalanceig de classes ($N_0 \gg N_1$), s'apliquen pesos per classe. Donat que el diagnòstic és per pacient, s'implementen diverses estratègies d'agregació (*Multiple Instance Learning*, MIL) que integren les prediccions de totes les làmines d'un pacient. Un *grid search* inicial ha identificat un model candidat amb AUC de 0,846. A més, s'ha desenvolupat un *frontend* web per a la inferència en temps real i la visualització de l'atenció del model.

Paraules clau— Càncer colorectal, Histopatologia digital, Graph Attention Networks (GAT), DiffPool, Metàstasi, Estadi pT1, Aprenentatge per múltiples instàncies (MIL), Desbalanceig de classes.

Abstract— This work addresses lymph node metastasis prediction in pT1 colorectal cancer patients from Whole Slide Images. We propose a methodology based on Graph Attention Networks (GAT) where each node represents a bag of 256 patches of 256×256 px ($\approx 4096 \times 4096$ px at WSI level 0), characterised by a 1,536-dimensional CLS embedding from the UNI2 foundation model. Two pooling strategies are explored: hierarchical DiffPool layers *interleaved between* GAT layers ($N \rightarrow K_1 \rightarrow K_2$ nodes), enabling multi-scale tissue representations, or flat readout (mean/max) applied after the final GAT layer. The dataset comprises 963 graphs from 230 patients, stratified into training and validation splits. To handle class imbalance ($N_0 \gg N_1$), class weighting is applied. Since the diagnosis is patient-level rather than slide-level, Multiple Instance Learning (MIL) aggregation strategies are implemented to integrate predictions across all slides of a patient. An initial grid search has identified a candidate model achieving an AUC of 0.846. An interactive web frontend has also been developed for real-time inference and attention visualization.

Keywords— Colorectal cancer, Digital histopathology, Graph Attention Networks (GAT), Diff-Pool, Metastasis, pT1 stage, Multiple Instance Learning (MIL), Class imbalance.

1 INTRODUCCIÓ

EL càncer colorrectal (CCR) representa un dels reptes de salut pública més greus del nostre entorn. A Es-

- E-mail de contacte: David.MorilloMa@autonoma.cat
- Treball tutoritzat per: Debora Gil Resina (DCC)
- Curs 2025/26

panya, la SEOM preveu per al 2026 més de **44.132** nous casos anuals, convertint-lo en el tumor més freqüentment diagnosticat i en la segona causa de mort per càncer amb 14.629 defuncions [1].

El carcinoma pT1 és especialment complex: el tumor ha envaït la submucosa però no la muscular pròpia, i el risc de metàstasi als ganglis limfàtics oscil·la entre el **2%** i el **23%** depenent de la profunditat d'invasió [2]. Quan hi ha criteris de mal pronòstic, el risc s'estima al voltant del 10%, la qual

cosa obliga a considerar una cirurgia radical. Tanmateix, s'estima que **entre el 80% i el 90%** d'aquestes cirurgies resulten innecessàries [3].

La histopatologia digital, a través de les *Whole Slide Images* (WSI), obre la porta a tècniques avançades de visió per computador. En concret, les *Graph Attention Networks* (GAT) [4] permeten modelar l'arquitectura espacial del teixit de forma relacional. Aquest projecte, desenvolupat al grup IAM del CVC (iam.cvc.uab.es) sota la supervisió de la Dra. Debora Gil, proposa un *pipeline* complet per a la classificació N0/N1 que integra construcció de grafs, *pooling* jeràrquic diferenciable i agregació MIL per pacient.

2 MOTIVACIÓ

Dues raons complementàries justifiquen la tria d'aquest projecte. Des del punt de vista clínic, els sistemes d'IA demostren una capacitat creixent per identificar patrons morfològics subtils de manera consistent, amb el potencial real de reduir cirurgies innecessàries. Des del punt de vista tècnic, la combinació de xarxes d'atenció sobre grafs i aprenentatge profund sobre imatges histopatològiques d'alta resolució és exactament la intersecció entre la teoria de grafs i les xarxes neuronals profundes que vull explorar dins de l'Enginyeria de Dades.

3 OBJECTIUS

- Construir un *pipeline* complet de classificació N0/N1 sobre WSI reals a partir d'embeddings CLS.
- Avaluar estratègies de *pooling* jeràrquic per a la representació global de grafs histopatològics.
- Implementar i comparar mètodes d'agregació MIL a nivell de pacient.
- Explorar l'ús de les màscares d'anotació expert per supervisar l'atenció del model.
- Proporcionar una eina interactiva de visualització i inferència en temps real.

4 DADES I PREPROCESSAMENT

Aquest projecte es realitza en col·laboració amb un equip de la UAB que cobreix des de la recollida de dades fins a la creació d'autoencoders per a l'extracció de característiques.

4.1 Imatges de Gran Format (WSI)

Les dades originals consisteixen en imatges de làmines senceres (WSI) obtingudes amb escàners d'alta resolució i tintades amb hematoxilina-eosina, emmagatzemades en format MIRAX (.mrxs). Les dimensions oscil·len entre els 30.000 i els 150.000 píxels per costat, amb una quantitat significativa d'espai buit o artefactes que requereixen tractament previ.

El conjunt de dades comprèn **963 grafs**, un per secció histològica (cadascun amb una o diverses components connexes), provinents de **230 pacients** en total. S'aplica una divisió estratificada 80/20 a nivell de pacient per evitar la filtració d'informació entre entrenament i validació.

4.2 Anotacions i Màscares de Segmentació

La Dra. Eva Musulén, patòloga especialitzada, ha realitzat les anotacions manualment amb el programari *Labelme*. Aquestes identifiquen tres categories d'afectació:

- **Infiltració:** teixit anormal que envaeix zones no corresponents.
- **Displàsia:** cèl·lules anormals que poden esdevenir canceroses.
- **Infiltració + Displàsia:** emprat en casos de dubte diagnòstic.

A partir d'aquestes s'obtenen màscares de segmentació codificades per color: vermell (infiltració), blau (displàsia) i verd clar (combinada).




Fig. 1: Exemple de WSI i la seva corresponent màscara de segmentació.

4.3 Extracció de Patches i Embeddings CLS

S'aplica una finestra lliscant (*sliding window*) sense solapament per dividir cada làmina en *patches* de 256×256 píxels. Aquests s'agrupen en **bags** de 16×16 *patches* (256 *patches* per *bag*), cadascun cobrint una regió de $\approx 4096 \times 4096$ píxels del WSI a resolució completa (nivell 0). El model de fundació **UNI2** [5] processa cada *bag* i extreu el token **CLS** de la seva sortida, obtenint un vector de **1.536 dimensions** que condensa la informació morfològica i textural de la regió. No s'aplica cap filtratge de qualitat previ (ni per borrositat ni per proporció de blanc): tots els *bags* d'una secció generen un node del graf.

5 CONSTRUCCIÓ DEL GRAF

5.1 Nodes i característiques

Cada *bag* (conjunt de 256 *patches* de 256×256 px que cobreix $\approx 4096 \times 4096$ px al WSI) constitueix un **node** del graf. El vector de característiques de cada node és l'embedding CLS de **1.536 dimensions** obtingut per UNI2. La posició del node al pla WSI és el centroid de les coordenades dels seus 256 *patches*. A la subfigura 2a es pot observar la distribució esparsa dels *bags* extrets sobre una làmina real.

5.2 Model de dades: dimensions i estructures

Formalment, cada secció histològica es representa com un graf $\mathcal{G} = (\mathbf{X}, \mathbf{A})$ on:

- $\mathbf{X} \in \mathbb{R}^{N \times 1536}$ és la matriu de característiques dels N nodes (*bags*).

- $\mathbf{A} \in \{0, 1\}^{N \times N}$ és la matriu d'adjacència construïda per triangulació de Delaunay i posterior poda d'arestes llargues.

Dues estratègies de *pooling* transformen la seqüència de grafs en un vector global que alimenta el capçal MLP per produir $P(N1)$:

- **Pla (readout).** *Mean* o *max* aplicats sobre les sortides de la darrera capa GAT, reduint directament de N nodes a d_h dimensions.
- **Jeràrquic (DiffPool intercalat).** Dues capes DiffPool s'insereixen entre les capes GAT: la primera colapsa el graf de N nodes a K_1 super-nodes, i la segona de K_1 a K_2 . Cada nivell aprèn una matriu d'assignació suau i produeix un nou graf de menor grandària sobre el qual opera la capa GAT següent.

Model 1 — Múltiples grafs + agregació MIL. Cada secció genera un graf independent; les S seccions d'un pacient es processen per separat i les probabilitats $\{P(N1_i)\}_{i=1}^S$ s'agreguen a posteriori (Secció 7.1).

Model 2 — Mega-graf pacient (un sol graf). Com a alternativa, es pot construir un únic graf per pacient concatenant verticalment les matrius de característiques i col·locant les matrius d'adjacència en la diagonal d'una mega-matriu per blocs:

$$\mathbf{X}_{\text{pac}} = \begin{pmatrix} \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_S \end{pmatrix} \in \mathbb{R}^{(\sum_i N_i) \times 1536} \quad (1)$$

$$\mathbf{A}_{\text{pac}} = \begin{pmatrix} \mathbf{A}_1 & \mathbf{0} & \cdots \\ \mathbf{0} & \ddots & \mathbf{0} \\ \cdots & \mathbf{0} & \mathbf{A}_S \end{pmatrix} \quad (2)$$

Els triangles fora de la diagonal queden a zero, és a dir, no hi ha arestes entre seccions diferents. D'aquesta manera el mecanisme d'atenció del GAT opera sobre totes les seccions simultàniament, i un únic *pooling* global produeix directament el diagnòstic del pacient sense necessitat d'una etapa d'agregació de probabilitats. La implementació actual correspon al Model 1; el Model 2 és una línia de treball futura.


5.3 Connectivitat per triangulació de Delaunay

Una connectivitat fixa de reixeta no és adequada perquè la màscara exclou regions de fons, trencant la simetria de la quadrícula inicial. Per aquest motiu, s'aplica una **triangulació de Delaunay** sobre els nodes restants, que s'adapta orgànicament a distribucions irregulars. A continuació, s'eliminen les arestes que creuen píxels de valor zero en la màscara, evitant connexions entre regions separades per espai buit. Finalment, s'aplica un criteri de distància màxima: s'eliminen les arestes que superen el doble de la longitud mitjana del conjunt ($\text{DISTANCE_FACTOR} = 2,0$). La subfigura 2b mostra el resultat sobre la mateixa làmina: les arestes eliminades pel filtre de màscara apareixen en vermell.

6 ARQUITECTURA DEL MODEL

6.1 GATClassifier

El model implementat, **GATClassifier**, és un classificador de grafs que alterna capes **Graph Attention Network** (GATConv [4, 6]) amb capes de *pooling* jeràrquic per a la classificació binària N0/N1. L'arquitectura proposa intercalar operacions de reducció del graf *entre* les capes de propagació de missatges, de manera que cada estadi treballa sobre una representació progressivament més compacta del teixit:



on $K_1 \ll N$ i $K_2 \ll K_1$ són el nombre de *super-nodes* de cada nivell jeràrquic.

Mecanisme d'atenció. A diferència de les xarxes convolucionals clàssiques sobre grafs que tracten tots els veïns d'un node de forma uniforme, GAT aprèn a assignar pesos d'importància diferenciats a cada veí. Donada la representació $\mathbf{h}_i \in \mathbb{R}^F$ del node i , per a cada parella de nodes veïns (i, j) es calcula un coeficient d'atenció no normalitzat:

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j])$$

on $\mathbf{W}$ és una transformació lineal aprenible, $\parallel$ la concatenació i $\mathbf{a}$ un vector d'atenció aprenible. Els coeficients es normalitzen amb *softmax* sobre tots els veïns del node i :


$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$

i la nova representació del node s'obté com la suma ponderada dels veïns:


$$\mathbf{h}'_i = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W}\mathbf{h}_j \right)$$

Multi-cap. Per incrementar la capacitat expressiva, cada capa usa H caps d'atenció independents les sortides dels quals es concatenen (a les dues primeres capes) o es promitgen (tercera capa). D'aquesta manera el model pot capturar múltiples tipus de relació de veïnatge simultàniament. Cada capa va seguida de normalització per *batch*, activació ELU i *dropout*.

El capçal MLP (*Linear* $\rightarrow$ *ReLU* $\rightarrow$ *Dropout* $\rightarrow$ *Linear*) transforma la representació global del graf en els logits N0/N1.



(a) *Patches* extrets (nodes del graf) superposats sobre la imatge original.



(b) Graf de Delaunay sobre la imatge anotada. Les zones verdes indiquen àrees afectades anotades per la patòloga; les arestes en vermell han estat eliminades pel filtratge de màscara.

Fig. 2: Visualització del procés de construcció del graf sobre una làmina real. Les dues imatges corresponen a la mateixa secció histològica i il·lustren com la topologia del graf s'adapta a la distribució irregular del teixit.




Fig. 3: Il·lustració del mecanisme d'atenció en una capa GAT amb tres caps independents (verd, blau, lila). El node central $\vec{h}_1$ agrega les representacions dels seus veïns i la seva pròpia (α_{11} , *self-loop*) mitjançant coeficients d'atenció α_{1j} apresos per cada cap. Les sortides dels caps es combinen per concatenació o promig per obtenir la nova representació $\vec{h}'_1$.

6.2 Estratègies de Pooling Pla (*Readout*)

Quan no s'utilitza pooling jeràrquic, les representacions dels nodes de la darrera capa GAT s'agreguen directament amb operacions de *readout*: *mean*, *max* o la seva concatenació (*mean_max*). Tot i la seva eficiència computacional, aquestes estratègies ignoren la topologia del graf i col·lapsen tota la informació espacial en un sol pas.

6.3 Pooling Jeràrquic: DiffPool entre Capes GAT

Per superar les limitacions del *readout* pla, s'implementa **DiffPool** [7] com a operació intermèdia entre les capes de propagació. A diferència d'aplicar el *pooling* únicament al final, la proposta intercala dues capes DiffPool al llarg de la

xarxa: una entre la primera i la segona capa GAT, i una altra entre la segona i la tercera. Cada capa DiffPool aprèn una matriu d'assignació suau (*soft assignment*) $\mathbf{S} \in \mathbb{R}^{N \times K}$ que agrupa els N nodes actuals en $K \ll N$ *super-nodes*:

$$\mathbf{X}^{(\ell+1)} = \mathbf{S}^\top \mathbf{X}^{(\ell)}, \quad \mathbf{A}^{(\ell+1)} = \mathbf{S}^\top \mathbf{A}^{(\ell)} \mathbf{S}$$

Amb aquesta arquitectura, la primera capa GAT opera sobre el graf original de nodes de teixit (N bags), la segona ho fa sobre un graf reduït de K_1 super-nodes que representen regions de teixit de nivell intermedi, i la tercera opera sobre un graf molt compacte de K_2 super-nodes que codifiquen l'organització arquitectònica global de la secció. Finalment, un *readout* global (*mean* o *max*) sobre els K_2 nodes produeix l'embedding que entra al capçal MLP.

L'entrenament incorpora una pèrdua auxiliar (*link prediction* + entropia mínima) per regularitzar l'assignació i evitar degeneracions trivials.

Com a alternativa, **SAGPool** [8] proposa un enfocament esparç que selecciona els K nodes més rellevants via puntuacions d'auto-atenció, descartant la resta i preservant l'estructura topològica original. A diferència de DiffPool, SAGPool no aprèn assignacions suaus sinó seleccions discretes, amb un cost computacional menor però sense la capacitat de capturar representacions jeràrquiques contínues. En aquest projecte s'utilitza DiffPool per la seva major expressivitat i la possibilitat d'integrar la pèrdua auxiliar de regularització.

7 METODOLOGIA

7.1 Agregació per Pacient (MIL)

El diagnòstic és per **pacient**, no per làmina. Una mateixa secció histològica pot no presentar senyals visibles de metàstasi si s'analitza aïlladament, mentre que en una altra




Fig. 4: Agrupació jeràrquica de nodes per *DiffPool*: l'assignació suau colapsa progressivament el graf en super-nodes de major abstracció. En el model proposat, dos nivells *DiffPool* s'intercalen entre les capes GAT. Font: [7].

secció del mateix pacient sí que és apreciable. Si s'entrena a nivell de làmina, les seccions N1 de pacients N1 que no mostren metàstasi visible reben un senyal de supervisió incorrecte (N0), contaminant l'entrenament.

Per solucionar-ho, s'adopta un paradigma d'**aprenentatge per múltiples instàncies** (*Multiple Instance Learning*, MIL) [9]: cada pacient és un *bag* i les seves làmines (instàncies) comparteixen l'etiqueta del *bag*. El model aprèn a classificar el *bag* a partir de les instàncies.

Donades les probabilitats $\{p_i = P(N1_i)\}_{i=1}^S$ de les S làmines d'un pacient, s'implementen les estratègies d'agregació següents:

- **Noisy-OR** (per defecte): $P(N1_p) = 1 - \prod_{i=1}^S (1 - p_i)$. Modela la hipòtesi que n'hi ha prou que una làmina presenti metàstasi per classificar el pacient com N1.
- **Max**: $P(N1_p) = \max_i p_i$. Predicció conservadora basada en l'evidència màxima.
- **Mean / LSE**: mitjana aritmètica o *log-sum-exp* per als casos intermedis.
- **Attention MIL**: *PatientAggregator* basat en l'atenció *gated* de Ilse et al. [9]. Aprèn un pes d'atenció per a cada làmina a partir del seu embedding (produït per l'encoder del GAT sense el capçal MLP), i la representació del pacient s'obté com la suma ponderada dels embeddings de les seves làmines.

7.2 Desbalanceig de Classes

El conjunt de dades presenta un fort desbalanceig: els casos N0 superen àmpliament els N1 (proporció aproximada 80/20). Per combatre-ho s'apliquen tres mesures complementàries.

(1) **Divisió estratificada**. La partició entrenament/validació (80/20) es realitza de forma estratificada a nivell de pacient: s'assegura que la proporció N0/N1 sigui equivalent en ambdós subconjunts. Sense estratificació, amb un conjunt petit i desbalancejat, el conjunt de validació podria contenir per atzar una proporció de N1 molt diferent a la real, invalidant les mètriques.

(2) **Pesos de classe**. S'apliquen pesos balancejats $w_c = N/(C \cdot n_c)$, on n_c és el nombre de pacients de la classe c , incorporats directament a la funció de pèrdua BCE. Així, cada error sobre un cas N1 té més pes en el gradient que un error sobre N0, penalitzant més els falsos negatius.

(3) **Mostratge ponderat per batch**. Durant l'entrenament s'utilitza un *WeightedRandomSampler* que assigna a

cada pacient una probabilitat de mostrar-se inversament proporcional a la freqüència de la seva classe. Això garanteix que cada *mini-batch* contingui una proporció equilibrada de casos N0 i N1, evitant que el model vegi gairebé exclusivament N0 durant molts *batches* consecutius.

7.3 Grid Search i Configuració d'Entrenament

S'ha dut a terme un *grid search* amb múltiples hiperparàmetres variables: *hidden units*, nombre de caps d'atenció, tipus de *pooling*, mètode d'agregació MIL, nombre de clústers *DiffPool*, *dropout* i *weight decay*. Cada combinació d'hiperparàmetres genera una *run* independent amb mètriques registrades a *Weights & Biases*. El millor model per AUC de validació es desa com a *checkpoint*. L'entrenament inclou *early stopping* amb 15 epochs de *warm-up* i *patience* de 10, basant el criteri d'aturada en la pèrdua de validació.

7.4 Atenció Supervisada amb Màscares

Una línia d'investigació planificada és l'ús de les màscares binàries d'anotació expert (displàsia, infiltració) per supervisar els pesos d'atenció del model GAT. L'objectiu és que les regions anotades amb patologia actuïn com a guia de supervisió feble, forçant el model a focalitzar l'atenció sobre les àrees d'interès clínic independentment de l'etiqueta N0/N1 final. Això permetria aprofitar les anotacions disponibles més enllà del diagnòstic binari, afegint un senyal de regularització espacialment informat.

8 RESULTATS PRELIMINARS

El *grid search* inicial ha identificat un model candidat amb els hiperparàmetres de la Taula 1. Les mètriques de validació a nivell de pacient es presenten a la Taula 2 i la Taula 3.

TAULA 1: HIPERPARÀMETRES DEL MODEL CANDIDAT.

Paràmetre	Valor
<i>Hidden</i> (d_h)	128
Caps d'atenció (H)	2
<i>Pooling</i>	<i>diff</i>
Clústers <i>DiffPool</i> (K)	5
<i>Dropout</i>	0,5
Agregació pacient	<i>mean</i>
Millor epoch	34




Fig. 5: Arquitectura detallada del GATClassifier amb pooling jeràrquic. Les etiquetes a la dreta indiquen la forma del tensor de sortida de cada bloc ($h = 128$, $H = 4$, per tant $h \cdot H = 512$). Les capes DiffPool aprenen una matriu d'assignació suau S i emeten una pèrdua auxiliar $\mathcal{L}_{aux}$ que es suma a la BCE principal. $K_1 \ll N$ i $K_2 \ll K_1$ són els super-nodes dels dos nivells de reducció (p. ex. $N \approx 250$, $K_1 = 25$, $K_2 = 5$ amb la configuració per defecte).

L'AUC de 0,846 sobre 44 pacients de validació (30 N0, 14 N1) és un resultat prometedor tenint en compte el desbalanceig de classes i la dificultat intrínseca del problema. El model mostra una millor capacitat de discriminació per a N0 (recall 0,813) que per a N1 (recall 0,714), fet esperable per la menor representació dels casos positius. Cal destacar que tan sols 4 falsos positius i 4 falsos negatius sobre 44 pacients indiquen un bon potencial clínic.

9 IMPLEMENTACIÓ I FRONTEND

La implementació segueix un disseny modular: la construcció de grafs, el model, el codi d'entrenament i els *data loaders* estan desacoblats per facilitar l'experimentació independent. La configuració d'hiperparàmetres es gestiona via fitxer YAML, on qualsevol paràmetre pot ser una llista per activar el *grid search* automàtic. El repositori és accessible a [10] i el desplegament al servidor CVC es gestiona via GitHub Actions amb un *runner self-hosted*.

TAULA 2: MÈTRIQUES DE VALIDACIÓ DEL MODEL CANDIDAT. AUC: **0,846**.

	N0	N1	Mitjana
Precisió	0,867	0,625	0,746
Recall	0,813	0,714	0,763
F1-Score	0,839	0,667	0,753

TAULA 3: MATRIU DE CONFUSIÓ (VALIDACIÓ, NIVELL DE PACIENT).

		Predicció	
		N0	N1
Real	N0	26	4
	N1	4	10

9.1 Frontend Web Interactiu

S'ha desenvolupat un *frontend* web (FastAPI + JavaScript pur, sense *build step*) per facilitar l'exploració dels models entrenats. Les funcionalitats principals inclouen:

- **Inferència en temps real:** selecció de pacient o làmina, *forward pass* al model actiu i visualització del resultat N0/N1 amb la descomposició per làmina.
- **Visualització de l'atenció:** representació del graf de Delaunay sobre la làmina, amb nodes colorejats per pes d'atenció (capes GATConv) i visualització dels *patches* RGB originals.
- **Estadístiques:** corbes ROC i PR, matriu de confusió i mètriques per classe sobre el conjunt de validació.
- **Selecció de checkpoint:** comparació entre múltiples models entrenats.

La figura 6 mostra el diagrama de flux complet del sistema.

REFERÈNCIES

- [1] Sociedad Española de Oncología Médica (SEOM). *Las Cifras del Cáncer en España 2026*. Consultat el 6 de febrer de 2026. URL: <https://seom.org/prensa/el-cancer-en-cifras>.
- [2] Unitat Funcional Càncer Colorectal. *Protocol de Pràctica Clínica del Càncer de Colón i Recte*. Actualització de la 3^a edició. Parc de Salut MAR Barcelona - Hospital del Mar. Barcelona, juny de 2013. URL: https://www.hospitaldelmar.cat/media/upload/arxius/unitats/cancer_colorectal/protocols/practica_clinica.pdf.
- [3] Fernando Martínez de Juan, Samuel Navarro i Isidro Machado. "Refining Risk Criteria May Substantially Reduce Unnecessary Additional Surgeries after Local Resection of T1 Colorectal Cancer". A: *Cancers* 16.13 (2024), pàg. 2321. DOI: 10.3390/cancers16132321. URL: <https://doi.org/10.3390/cancers16132321>.




Fig. 6: Diagrama de flux del *pipeline* complet. *Blocs grisos*: etapes realitzades pels companys de l'equip (extracció de *patches* 256×256 px agrupats en *bags* de $16 \times 16 = 4096 \times 4096$ px, sense filtratge, i obtenció de l'embedding CLS via UNI2). *Blocs blaus (vora gruixuda)*: contribucions d'aquest TFG. El model alterna capes GAT amb capes DiffPool intercalades: la primera DiffPool redueix el graf de N nodes a K_1 super-nodes i la segona a $K_2 \ll K_1$; un *readout* final agrega els K_2 nodes en un vector global. Com a alternativa sense pooling jeràrquic, s'aplica directament *mean* o *max* sobre la darrera capa GAT. La fletxa $\times S$ indica que les S seccions d'un pacient es processen com a grafs independents i les probabilitats $P(N1)$ s'agreguen via MIL per obtenir el diagnòstic final (Model 1); el Model 2 (mega-graf, Secció 5.2) és una alternativa sense etapa d'agregació.

- [4] Petar Veličković et al. *Graph Attention Networks*. 2018. arXiv: 1710.10903 [stat.ML]. URL: <https://arxiv.org/abs/1710.10903>.
- [5] Richard J. Chen et al. "Towards a general-purpose foundation model for computational pathology". A: *Nature Medicine* 30.3 (març de 2024), pàg. 850-862. DOI: 10.1038/s41591-024-02857-3.
- [6] Matthias Fey i Jan Eric Lenssen. *Fast Graph Representation Learning with PyTorch Geometric*. 2019. arXiv: 1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.
- [7] Rex Ying et al. *Hierarchical Graph Representation Learning with Differentiable Pooling*. 2019. arXiv: 1806.08804 [cs.LG]. URL: <https://arxiv.org/abs/1806.08804>.
- [8] Junhyun Lee, Inyeop Lee i Jaewoo Kang. *Self-Attention Graph Pooling*. 2019. arXiv: 1904.08082 [cs.LG]. URL: <https://arxiv.org/abs/1904.08082>.
- [9] Maximilian Ilse, Jakub M. Tomczak i Max Welling. *Attention-based Deep Multiple Instance Learning*. 2018. arXiv: 1802.04712 [cs.LG]. URL: <https://arxiv.org/abs/1802.04712>.
- [10] David M. et al. *Implementació de Graph Attention Networks per a la detecció de metàstasi en pT1*. 2026. URL: <https://github.com/IAM-CVC/PT1Diagnosis> (cons. 03-05-2026).