

Predicció de Metàstasi en Histopatologia en Càncer Colorrectal usant Graph Attention Networks

David Morillo Massagué

Resum— Es presenta un sistema de classificació N0/N1 per a la detecció de metàstasi en ganglis limfàtics en càncer colorrectal pT1 a partir de *Whole Slide Images*. El teixit es representa com un **graf espacial** construït per triangulació de Delaunay sobre les coordenades dels *bags*, de manera que es preserva la topologia real del teixit —a diferència d'enfocaments basats en similitud de característiques. Cada node és un *bag* de 256 *patches* representat per l'embedding CLS (1.536 dim.) del model UNI2. Es comparen dues arquitectures: un GAT de referència amb *readout* pla i un GAT amb **DiffPool jeràrquic** intercalat ($N \rightarrow K_1 \rightarrow K_2$ super-nodes) per obtenir representacions a múltiples escales. El diagnòstic per pacient s'obté per agregació MIL sobre les seccions. El millor model obté un AUC de $0,817 \pm 0,073$ (5-fold CV, 230 pacients).

Paraules clau— Càncer colorrectal pT1, Histopatologia digital, Graph Attention Networks, Diff-Pool jeràrquic, Graf espacial de Delaunay, MIL, Desbalanceig de classes.

Abstract— We present an N0/N1 classification system for lymph node metastasis prediction in pT1 colorectal cancer from Whole Slide Images. Tissue is represented as a **spatial graph** built by Delaunay triangulation over bag coordinates, preserving the real spatial topology of the tissue —unlike feature-similarity graph approaches. Each node is a bag of 256 patches represented by a 1,536-dimensional CLS embedding from the UNI2 model. Two architectures are compared: a **GAT baseline** with flat readout (mean/max) and a **GAT+DiffPool** model with pooling layers interleaved between GAT layers ($N \rightarrow K_1 \rightarrow K_2$ super-nodes) for multi-scale representations. Patient-level diagnosis is obtained via MIL aggregation over histological sections. The best model achieves an AUC of 0.817 ± 0.073 (5-fold CV, 230 patients).

Keywords— pT1 colorectal cancer, Digital histopathology, Graph Attention Networks, Hierarchical DiffPool, Spatial Delaunay graph, Multiple Instance Learning, Class imbalance.

1 INTRODUCCIÓ

EL càncer colorrectal (CCR) representa un dels reptes de salut pública més greus del nostre entorn. A Espanya, la SEOM preveu per al 2026 més de **44.132** nous casos anuals, convertint-lo en el tumor més freqüentment diagnosticat i en la segona causa de mort per càncer amb 14.629 defuncions [1].

El carcinoma pT1 és especialment complex: el tumor ha envaït la submucosa però no la muscular pròpia, i el risc de

metàstasi als ganglis limfàtics oscil·la entre el **2%** i el **23%** depenent de la profunditat d'invasió [2]. Quan hi ha criteris de mal pronòstic, el risc s'estima al voltant del 10%, la qual cosa obliga a considerar una cirurgia radical. Tanmateix, s'estima que **entre el 80% i el 90%** d'aquestes cirurgies resulten innecessàries [3].

La histopatologia digital, a través de les *Whole Slide Images* (WSI), obre la porta a tècniques avançades de visió per computador. En concret, les *Graph Attention Networks* (GAT) [4] permeten modelar l'arquitectura espacial del teixit de forma relacional. Una decisió clau en la construcció del graf és la definició de les arestes: mentre que alguns treballs les basen en la *similitud de característiques* entre *bags*, aquest projecte opta per la **proximitat espacial** (triangulació de Delaunay sobre coordenades WSI), preservant la topologia real del teixit. Aquest projecte, desenvolupat al

- E-mail de contacte: David.MorilloMa@autonoma.cat
- Treball tutoritzat per: Debora Gil Resina (DCC)
- Curs 2025/26

grup IAM del CVC (iam.cvc.uab.es) sota la supervisió de la Dra. Debora Gil, compara un GAT de referència amb *readout* pla contra un model amb *pooling* jeràrquic (DiffPool) intercalat, i proposa estratègies d'agregació MIL per al diagnòstic a nivell de pacient.

Dues raons complementàries justifiquen la tria d'aquest projecte. Des del punt de vista clínic, els sistemes d'IA demostren una capacitat creixent per identificar patrons morfològics subtils de manera consistent, amb el potencial real de reduir cirurgies innecessàries. Des del punt de vista tècnic, la combinació de xarxes d'atenció sobre grafs i aprenentatge profund sobre imatges histopatològiques d'alta resolució és exactament la intersecció entre la teoria de grafs i les xarxes neuronals profundes que vull explorar dins de l'Enginyeria de Dades.

2 OBJECTIUS

- Construir un *pipeline* complet de classificació N0/N1 sobre WSI reals a partir d'embeddings CLS del model UNI2, basat en **grafs espacials** (triangulació de Delaunay sobre coordenades del teixit).
- **Comparar un GAT de referència** amb *readout* pla contra un model amb **DiffPool jeràrquic** intercalat entre les capes GAT, avaluant si la reducció progressiva del graf aporta millor representació multi-escala.
- Implementar i comparar estratègies d'agregació MIL a nivell de pacient per integrar les prediccions de múltiples seccions histològiques.
- Avaluar la robustesa dels models mitjançant validació creuada estratificada (*k*-fold).
- Proporcionar una eina interactiva de visualització i inferència en temps real.

3 ESTAT DE L'ART

3.1 Classificació de WSI amb MIL

Les *Whole Slide Images* tenen resolucions de fins a $150\,000 \times 150\,000$ píxels i no es poden processar directament amb xarxes convencionals. L'enfocament habitual és dividir la làmina en *patches* petits i treballar amb *Multiple Instance Learning* (MIL), on el model ha d'inferir l'etiqueta global a partir de fragments sense etiqueta individual. Ilse et al. [5] van proposar l'agregació per atenció (*attention-based MIL*), que aprèn quins *patches* són més rellevants per al diagnòstic. Lu et al. [6] van aplicar aquest mètode a conjunts de dades clínics reals (CLAM), i Li et al. [7] van proposar DSMIL, que combina dues branques —a nivell de *patch* i de làmina— amb aprenentatge contrastiu. La predicció de metàstasi ganglionar a partir d'histopatologia s'ha estudiat en altres càncers: Muti et al. [8] mostren que és possible predir l'estat N0/N1 a partir de làmines de càncer gàstric, amb resultats prometedors.

3.2 Grafs i GNN en Patologia Digital

Les *Graph Neural Networks* permeten tractar el teixit com una estructura on les regions estan connectades segons la

seua proximitat, capturant relacions espacials que les CNN no modelen directament. Jaume et al. [9] van presentar HistoCartography, un entorn de treball per a l'anàlisi de grafs en patologia digital, amb resultats que mostren millores respecte de les CNN en classificació de biòpsies. Les GAT [4] afegeixen un mecanisme d'atenció que permet al model ponderar cada veí de manera diferent, cosa especialment útil en histopatologia on no totes les regions del teixit aporten la mateixa informació. Pel que fa al *pooling* en grafs, Grattarola et al. [10] revisen els principals mètodes existents, entre ells DiffPool [11], que agrupa nodes en super-nodes de manera progressiva.

3.3 Models de Fundació per a Histopatologia

En els darrers anys han aparegut *foundation models* preentrenats específicament sobre dades de patologia, que generen embeddings molt més informatius que les CNNs genèriques. UNI2 [12] és un *vision transformer* entrenat sobre més de 100 milions de *patches* de 20 tipus de teixit, amb bons resultats en nombroses tasques de classificació histopatològica. CONCH [13] és un model similar que incorpora a més alineament entre imatge i text. En aquest projecte s'utilitzen els embeddings de UNI2 com a vector de característiques de cada node, ja que estan preentrenats en el mateix domini i capturen informació morfològica rellevant.

3.4 Treball Previ al CVC sobre pT1 CRC

Aquest treball s'integra dins una línia de recerca del grup IAM del CVC. Martí et al. [14] van treballar sobre el mateix conjunt de dades pT1 CRC comparant CNNs, ViTs i GNNs per a la classificació de *patches* individuals, obtenint la millor AUC ($0,954 \pm 0,077$) amb una arquitectura híbrida ViT+NN. Aquell treball, però, opera a nivell de *patch* i no considera la topologia espacial del teixit ni el diagnòstic a nivell de pacient. El present TFG parteix dels embeddings CLS del model UNI2 per construir grafs espacials de les seccions i aborda el problema des d'una perspectiva de MIL a nivell de pacient.

4 DADES I PREPROCESSAMENT

Aquest projecte es realitza en col·laboració amb un equip de la UAB que cobreix des de la recollida de dades fins a la creació d'autoencoders per a l'extracció de característiques.

4.1 Imatges de Gran Format (WSI)

Les dades originals consisteixen en imatges de làmines senceres (WSI) obtingudes amb escàners d'alta resolució i tintades amb hematoxilina-eosina, emmagatzemades en format MIRAX (.mrxs). Les dimensions oscil·len entre els 30.000 i els 150.000 píxels per costat, amb una quantitat significativa d'espai buit o artefactes que requereixen tractament previ.

El conjunt de dades efectiu comprèn **963 grafs** (un per secció histològica), provinents de **230 pacients** distribuïts de forma desequilibrada entre les dues classes (Taula 1). D'un total de 606 pacients a la base de dades clínica, 236 es

descarten per diagnòstic indeterminat (NX), i dels 370 restants amb diagnòstic vàlid, 140 no disposen encara d'embeddings UNI2 generats, deixant 230 pacients usables. L'avaluació es realitza amb validació creuada estratificada de 5 particions a nivell de pacient.

TAULA 1: COMPOSICIÓ DEL DATASET EFECTIU (26 HOSPITALS).

	N0	N1	Total
Pacients	160	70	230
Slides úniques	—	—	448
Seccions (grafs)	—	—	963
Bags (nodes)	—	—	89 637

Bags per secció: mín. 3 / mitjana 93 / màx. 619

4.2 Anotacions i Màscares de Segmentació

La Dra. Eva Musulén, patòloga especialitzada, ha realitzat les anotacions manualment amb el programari *Labelme*. Aquestes identifiquen tres categories d'afectació:

- **Infiltració:** teixit anormal que envaeix zones no corresponents.
- **Displàsia:** cèl·lules anormals que poden esdevenir canceroses.
- **Infiltració + Displàsia:** emprat en casos de dubte diagnòstic.

A partir d'aquestes s'obtenen màscares de segmentació codificades per color: vermell (infiltració), blau (displàsia) i verd clar (combinada).




Fig. 1: Exemple de WSI i la seva corresponent màscara de segmentació.

4.3 Extracció de Patches i Embeddings CLS

S'aplica una finestra lliscant (*sliding window*) sense solapament per dividir cada làmina en *patches* de 256×256 píxels. Aquests s'agrupen en **bags** de 16×16 *patches* (256 *patches* per *bag*), cadascun cobrint una regió de $\approx 4096 \times 4096$ píxels del WSI a resolució completa (nivell 0). El model de fundació UNI2 [12] processa cada *bag* i extreu el token CLS de la seva sortida, obtenint un vector de **1.536 dimensions** que condensa la informació morfològica i textural de la regió. No s'aplica cap filtratge de qualitat previ (ni per borrositat ni per proporció de blanc): tots els *bags* d'una secció generen un node del graf.

5 CONSTRUCCIÓ DEL GRAF

5.1 Nodes i característiques

Cada *bag* (conjunt de 256 *patches* de 256×256 px que cobreix $\approx 4096 \times 4096$ px al WSI) constitueix un **node** del graf. El vector de característiques de cada node és l'embedding CLS de **1.536 dimensions** obtingut per UNI2. La posició del node al pla WSI és el centroid de les coordenades dels seus 256 *patches*. A la subfigura 2a es pot observar la distribució esparsa dels *bags* extrets sobre una làmina real.

5.2 Model de dades: dimensions i estructures

Formalment, cada secció histològica es representa com un graf $\mathcal{G} = (\mathbf{X}, \mathbf{A})$ on:

- $\mathbf{X} \in \mathbb{R}^{N \times 1536}$ és la matriu de característiques dels N nodes (*bags*).
- $\mathbf{A} \in \{0, 1\}^{N \times N}$ és la matriu d'adjacència construïda per triangulació de Delaunay i posterior poda d'arestes llargues.

Dues estratègies de *pooling* transformen la seqüència de grafs en un vector global que alimenta el capçal MLP per produir $P(N1)$:

- **Pla (readout).** *Mean* o *max* aplicats sobre les sortides de la darrera capa GAT, reduint directament de N nodes a d_h dimensions.
- **Jeràrquic (DiffPool intercalat).** Dues capes DiffPool s'insereixen entre les capes GAT: la primera colapsa el graf de N nodes a K_1 super-nodes, i la segona de K_1 a K_2 . Cada nivell aprèn una matriu d'assignació suau i produeix un nou graf de menor grandària sobre el qual opera la capa GAT següent.

Model 1 — Múltiples grafs + agregació MIL. Cada secció genera un graf independent; les S seccions d'un pacient es processen per separat i les probabilitats $\{P(N1_i)\}_{i=1}^S$ s'agreguen a posteriori (Secció 7.1).

Model 2 — Mega-graf pacient (un sol graf). Com a alternativa, es pot construir un únic graf per pacient concatenant verticalment les matrius de característiques i col·locant les matrius d'adjacència en la diagonal d'una mega-matriu per blocs:

$$\mathbf{X}_{\text{pac}} = \begin{pmatrix} \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_S \end{pmatrix} \in \mathbb{R}^{(\sum_i N_i) \times 1536} \quad (1)$$

$$\mathbf{A}_{\text{pac}} = \begin{pmatrix} \mathbf{A}_1 & \mathbf{0} & \cdots \\ \mathbf{0} & \ddots & \mathbf{0} \\ \cdots & \mathbf{0} & \mathbf{A}_S \end{pmatrix} \quad (2)$$

Els triangles fora de la diagonal queden a zero, és a dir, no hi ha arestes entre seccions diferents. D'aquesta manera el mecanisme d'atenció del GAT opera sobre totes les seccions simultàniament, i un únic *pooling* global produeix directament el diagnòstic del pacient sense necessitat d'una etapa d'agregació de probabilitats. Tots dos models estan implementats: el Model 1 és el mode per defecte del

pipeline, i el Model 2 s'activa amb l'argument `--mega` de `scripts/build_dataset.py`, que genera un fitxer `.pt` per pacient en lloc d'un per secció.


5.3 Connectivitat per triangulació de Delaunay

Una connectivitat fixa de reixeta no és adequada perquè la màscara exclou regions de fons i trenca la simetria de la quadrícula. Per aquest motiu, s'aplica una **triangulació de Delaunay** sobre els nodes restants, que s'adapta a distribucions irregulars de forma natural. A continuació, s'eliminen les arestes que travessen píxels de valor zero a la màscara, evitant connexions entre regions separades per espai buit. Finalment, s'aplica un criteri de distància màxima: s'eliminen les arestes que superen el doble de la longitud mitjana del conjunt (`DISTANCE_FACTOR = 2,0`). La subfigura 2b mostra el resultat sobre la mateixa làmina: les arestes eliminades pel filtre de màscara apareixen en vermell.

6 ARQUITECTURA DEL MODEL

6.1 GATClassifier

El model implementat, `GATClassifier`, és un classificador de grafs que alterna capes **Graph Attention Network** (GATConv [4, 15]) amb capes de *pooling* jeràrquic per a la classificació binària N0/N1. L'arquitectura proposa intercalar operacions de reducció del graf *entre* les capes de propagació de missatges, de manera que cada estadi treballa sobre una representació progressivament més compacta del teixit:



on $K_1 \ll N$ i $K_2 \ll K_1$ són el nombre de *super-nodes* de cada nivell jeràrquic.

Mecanisme d'atenció. A diferència de les xarxes convolucionals clàssiques sobre grafs que tracten tots els veïns d'un node de forma uniforme, GAT aprèn a assignar pesos d'importància diferenciats a cada veí. Donada la representació $\mathbf{h}_i \in \mathbb{R}^F$ del node i , per a cada parella de nodes veïns (i, j) es calcula un coeficient d'atenció no normalitzat:

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j])$$

on $\mathbf{W}$ és una transformació lineal aprenible, $\parallel$ la concatenació i $\mathbf{a}$ un vector d'atenció aprenible. Els coeficients es

normalitzen amb *softmax* sobre tots els veïns del node i :

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$

i la nova representació del node s'obté com la suma ponderada dels veïns:

$$\mathbf{h}'_i = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W}\mathbf{h}_j \right)$$

Multi-cap. Per incrementar la capacitat expressiva, cada capa usa H caps d'atenció independents les sortides dels quals es concatenen (a les dues primeres capes) o es promitgen (tercera capa). D'aquesta manera el model pot capturar múltiples tipus de relació de veïnatge simultàniament. Cada capa va seguida de normalització per *batch*, activació ELU i *dropout*.

El capçal MLP (*Linear* $\rightarrow$ ReLU $\rightarrow$ Dropout $\rightarrow$ Linear) transforma la representació global del graf en els logits N0/N1.

6.2 Estratègies de Pooling Pla (Readout)

Quan no s'utilitza pooling jeràrquic, les representacions dels nodes de la darrera capa GAT s'agreguen directament amb operacions de *readout*: *mean*, *max* o la seva concatenació (*mean_max*). Tot i la seva eficiència computacional, aquestes estratègies ignoren la topologia del graf i col·lapsen tota la informació espacial en un sol pas.

6.3 Pooling Jeràrquic: DiffPool entre Capes GAT


Per superar les limitacions del *readout* pla, s'implementa **DiffPool** [11] com a operació intermèdia entre les capes de propagació. A diferència d'aplicar el *pooling* únicament al final, la proposta intercala dues capes DiffPool al llarg de la xarxa: una entre la primera i la segona capa GAT, i una altra entre la segona i la tercera. Cada capa DiffPool aprèn una matriu d'assignació suau (*soft assignment*) $\mathbf{S} \in \mathbb{R}^{N \times K}$ que agrupa els N nodes actuals en $K \ll N$ *super-nodes*:

$$\mathbf{X}^{(\ell+1)} = \mathbf{S}^\top \mathbf{X}^{(\ell)}, \quad \mathbf{A}^{(\ell+1)} = \mathbf{S}^\top \mathbf{A}^{(\ell)} \mathbf{S}$$


Amb aquesta arquitectura, la primera capa GAT opera sobre el graf original de nodes de teixit (N bags), la segona ho fa sobre un graf reduït de K_1 super-nodes que representen regions de teixit de nivell intermedi, i la tercera opera sobre un graf molt compacte de K_2 super-nodes que codifiquen l'organització arquitectònica global de la secció. Finalment, un *readout* global (*mean* o *max*) sobre els K_2 nodes produeix l'embedding que entra al capçal MLP.

L'entrenament incorpora una pèrdua auxiliar (*link prediction* + entropia mínima) per regularitzar l'assignació i evitar degeneracions trivials.

Com a alternativa, **SAGPool** [16] proposa un enfocament esparç que selecciona els K nodes més rellevants via puntuacions d'auto-atenció, descartant la resta i preservant l'estructura topològica original. A diferència de DiffPool, SAGPool no aprèn assignacions suaus sinó seleccions discretes, amb un cost computacional menor però sense la



(a) Posicions dels *patches* dels quals se n'extreuen les característiques, superposades sobre la imatge original.



(b) Graf de Delaunay sobre la imatge anotada. Les zones verdes indiquen àrees afectades anotades per la patòlogia; les arestes en vermell han estat eliminades pel filtratge de màscara.

Fig. 2: Visualització del procés de construcció del graf sobre una làmina real. Les dues imatges corresponen a la mateixa secció histològica i il·lustren com la topologia del graf s'adapta a la distribució irregular del teixit.




Fig. 3: Il·lustració del mecanisme d'atenció en una capa GAT amb tres caps independents (verd, blau, lila). El node central $\vec{h}_1$ agrega les representacions dels seus veïns i la seva pròpia (α_{11} , *self-loop*) mitjançant coeficients d'atenció α_{1j} apresos per cada cap. Les sortides dels caps es combinen per concatenació o promig per obtenir la nova representació $\vec{h}'_1$.

capacitat de capturar representacions jeràrquiques contínues. En aquest projecte s'utilitza DiffPool per la seva major expressivitat i la possibilitat d'integrar la pèrdua auxiliar de regularització.

7 METODOLOGIA

7.1 Agregació per Pacient (MIL)

El diagnòstic és per **pacient**, no per làmina. Una mateixa secció histològica pot no presentar senyals visibles de metàstasi si s'analitza aïlladament, mentre que en una altra secció del mateix pacient sí que és apreciable. Si s'entrena a nivell de làmina, les seccions N1 de pacients N1 que no mostren metàstasi visible reben un senyal de supervisió

incorrecte (N0), contaminant l'entrenament.

Per evitar aquest problema, s'utilitza el paradigma d'**aprenentatge per múltiples instàncies** (*Multiple Instance Learning*, MIL): cada pacient es tracta com un *bag* i totes les seves làmines comparteixen la mateixa etiqueta. El model aprèn a classificar el pacient a partir de les seves seccions, sense necessitat d'etiquetes individuals per làmina.

Donades les probabilitats $\{p_i = P(N1_i)\}_{i=1}^S$ de les S làmines d'un pacient, s'implementen les estratègies d'agregació següents:

- **Noisy-OR** (per defecte): $P(N1_p) = 1 - \prod_{i=1}^S (1 - p_i)$. Modela la hipòtesi que n'hi ha prou que una làmina presenti metàstasi per classificar el pacient com N1.
- **Max**: $P(N1_p) = \max_i p_i$. Predicció conservadora basada en l'evidència màxima.
- **Mean / LSE**: mitjana aritmètica o *log-sum-exp* per als casos intermedis.
- **Attention MIL**: *PatientAggregator* basat en l'atenció *gated* de Ilse et al. [5]. Aprèn un pes d'atenció per a cada làmina a partir del seu embedding (produït per l'encoder del GAT sense el capçal MLP), i la representació del pacient s'obté com la suma ponderada dels embeddings de les seves làmines.

Formalment, per a l'agregació per atenció, donat l'embedding $\mathbf{h}_i \in \mathbb{R}^d$ de la làmina i produït per l'encoder GAT, els pesos d'atenció i la representació del pacient s'obtenen




Fig. 4: Agrupació jeràrquica de nodes per *DiffPool*: l'assignació suau colapsa progressivament el graf en super-nodes de major abstracció. En el model proposat, dos nivells *DiffPool* s'intercalen entre les capes GAT. Font: [11].

com:

$$a_i = \frac{\exp(\mathbf{w}^\top (\tanh(\mathbf{V}\mathbf{h}_i) \odot \sigma(\mathbf{U}\mathbf{h}_i)))}{\sum_{j=1}^S \exp(\mathbf{w}^\top (\tanh(\mathbf{V}\mathbf{h}_j) \odot \sigma(\mathbf{U}\mathbf{h}_j)))}$$

$$\mathbf{z}_p = \sum_{i=1}^S a_i \mathbf{h}_i$$

on $\mathbf{w}$, $\mathbf{V}$, $\mathbf{U}$ són paràmetres aprenibles, $\odot$ és la multiplicació element a element i $\mathbf{z}_p$ és l'embedding del pacient que entra al capçal MLP per a la predicció final N0/N1.

7.2 Desbalanceig de Classes

El conjunt de dades presenta un fort desbalanceig: els casos N0 superen àmpliament els N1 (proporció aproximada 80/20). Per combatre-ho s'apliquen tres mesures complementàries.

(1) Validació creuada estratificada. S'utilitza una validació creuada de $k = 5$ particions estratificades a nivell de pacient, assegurant que la proporció N0/N1 sigui representativa en cada partició. Sense estratificació, amb un conjunt petit i desequilibrat, algunes particions podrien contenir per atzar una proporció de N1 molt diferent a la real, invalidant les mètriques.

(2) Pesos de classe. S'apliquen pesos balancejats $w_c = N/(C \cdot n_c)$, on n_c és el nombre de pacients de la classe c , incorporats directament a la funció de pèrdua BCE. Així, cada error sobre un cas N1 té més pes en el gradient que un error sobre N0, penalitzant més els falsos negatius.

(3) Mostratge ponderat per batch. Durant l'entrenament s'utilitza un *WeightedRandomSampler* que assigna a cada pacient una probabilitat de mostratge inversament proporcional a la freqüència de la seva classe. Això garanteix que cada *mini-batch* contingui una proporció equilibrada de casos N0 i N1, evitant que el model vegi gairebé exclusivament N0 durant molts *batches* consecutius.

7.3 Grid Search, K-Fold i Configuració d'Entrenament

S'ha dut a terme un *grid search* amb múltiples hiperparàmetres variables: *hidden units*, nombre de caps d'atenció, tipus de *pooling*, mètode d'agregació MIL, nombre de clústers *DiffPool*, *dropout* i *weight decay*. Cada combinació d'hiperparàmetres genera una *run* independent amb mètriques registrades a *Weights & Biases*. El millor model per

AUC de validació es desa com a *checkpoint*. L'entrenament inclou *early stopping* amb 15 epochs de *warm-up* i *patience* de 10, basant el criteri d'aturada en la pèrdua de validació.

Per obtenir una avaluació més fiable, s'utilitza una validació creuada de k particions ($k = 5$) estratificada a nivell de pacient, activable amb l'argument `--kfold 5` de `train.py`. Cada *fold* entrena un model independent i al final es reporta la mitjana $\pm$ desviació estàndard de les mètriques principals (AUC, F1-macro, F1-N1). Això és especialment important amb un conjunt de dades petit com el d'aquest projecte, on un únic split podria donar resultats poc representatius. El mode *k-fold* és compatible amb el *grid search*: si es combinen, s'executen $n_{\text{combos}} \times k$ entrenaments en total.

8 RESULTATS PRELIMINARS

El *grid search* amb validació creuada de 5 *folds* estratificada per pacient ha avaluat 4 configuracions: els dos tipus de *pooling* (GAT Baseline *mean_max* i GAT+*DiffPool diff*) creuats amb els dos mètodes d'agregació MIL (*noisy-OR* i *attention*). Per a cada combinació es va seleccionar el millor *learning rate* entre $\{10^{-4}, 10^{-5}\}$. Les mètriques de validació a nivell de pacient (mitjana $\pm$ desviació estàndard dels 5 *folds*) es presenten a la Taula 2.

El GAT Baseline amb agregació *attention* obté el millor AUC ($0,817 \pm 0,073$). El GAT+*DiffPool* amb *attention* té un AUC semblant ($0,801 \pm 0,042$) però menys variabilitat entre *folds* i el millor F1-N1 ($0,679 \pm 0,058$), cosa que indica que detecta els casos positius de manera més consistent. En canvi, les configuracions amb *noisy-OR* donen resultats notablement pitjors, sobretot el GAT Baseline ($0,581 \pm 0,142$), cosa que suggereix que el mètode d'agregació és molt rellevant per a aquest problema.

Cal remarcar que aquests resultats són **preliminars**: corresponen a la segona entrega del TFG, en un moment en què l'arquitectura del model i les estratègies d'entrenament encara s'estan definint. No és possible extreure conclusions definitives sobre la superioritat d'un model respecte de l'altre; les diferències observades entre configuracions podrien variar significativament amb un espai de cerca d'hiperparàmetres més ampli, més dades o ajustaments al preprocés. En fases posteriors del projecte es duran a terme experiments més exhaustius i una avaluació final consolidada.




Fig. 5: Comparació de les dues arquitectures GATClassifier. **Esquerra:** model de referència amb readout pla (mean || max global); **Dreta:** model jeràrquic on DiffPool redueix progressivament $N \rightarrow K_1 \rightarrow K_2$ super-nodes. Les dimensions del tensor de sortida s'indiquen a la dreta de cada bloc ($h = 128$, $H = 4$, per tant $h \cdot H = 512$).

9 IMPLEMENTACIÓ I FRONTEND

La implementació segueix un disseny modular: la construcció de grafs, el model, el codi d'entrenament i els *data loaders* estan desacoblats per facilitar l'experimentació independent. La configuració d'hiperparàmetres es gestiona via fitxer YAML, on qualsevol paràmetre pot ser una llista per activar el *grid search* automàtic. El repositori és accessible a [17] i el desplegament al servidor CVC es gestiona via GitHub Actions amb un *runner self-hosted*.

9.1 Frontend Web Interactiu

S'ha desenvolupat un *frontend* web (FastAPI + JavaScript pur, sense *build step*) per facilitar l'exploració dels models entrenats. Les funcionalitats principals inclouen:

- **Inferència en temps real:** selecció de pacient o làmina, *forward pass* al model actiu i visualització del resultat N0/N1 amb la descomposició per làmina.
- **Visualització de l'atenció:** representació del graf de Delaunay sobre la làmina, amb nodes colorejats per pes d'atenció (capes GATConv) i visualització dels *patches* RGB originals.
- **Estadístiques:** corbes ROC i PR, matriu de confusió i mètriques per classe sobre el conjunt de validació.

- **Selecció de checkpoint:** comparació entre múltiples models entrenats.

La figura 6 mostra el diagrama de flux complet del sistema.

10 CONCLUSIONS I TREBALL FUTUR

10.1 Conclusions Parcial

En aquest TFG s'ha construït un sistema complet de classificació N0/N1 per a càncer colorectal pT1 a partir de WSI, que inclou la generació de grafs espacials, l'entrenament del model GAT amb diverses configuracions i l'avaluació amb validació creuada de 5 particions. L'AUC obtinguda ($0,817 \pm 0,073$) és un bon punt de partida per a un sistema que encara no ha estat optimitzat en profunditat. Se'n destaquen tres observacions:

- El mètode d'agregació MIL té un impacte molt gran: el GAT Baseline passa d'AUC 0,581 amb *noisy-OR* a 0,817 amb *attention*. Triar bé com s'agreguen les seccions d'un pacient és tan important com l'arquitectura del model.
- GAT+DiffPool amb *attention* obté menys variabilitat entre *folds* ($\sigma = 0,042$) i el millor F1-N1 ($0,679 \pm$

TAULA 2: RESULTATS DEL *grid search* (5-fold CV, NIVELL DE PACIENT). PER A CADA COMBINACIÓ ES MOSTRA EL *learning rate* ÒPTIM. **NEGRETA**: MILLOR VALOR PER COLUMNA. MÈTRIQUES REPORTADES COM A MITJANA $\pm$ DESVIACIÓ ESTÀNDAR.

Model	Pooling	Agregació MIL	AUC	F1-macro	F1-N1
GAT Baseline	<i>mean_max</i>	<i>noisy-OR</i>	$0,581 \pm 0,142$	$0,498 \pm 0,123$	$0,499 \pm 0,070$
GAT Baseline	<i>mean_max</i>	<i>attention</i>	$0,817 \pm 0,073$	$0,751 \pm 0,083$	$0,641 \pm 0,126$
GAT+DiffPool	<i>diff</i>	<i>noisy-OR</i>	$0,754 \pm 0,059$	$0,653 \pm 0,046$	$0,568 \pm 0,052$
GAT+DiffPool	<i>diff</i>	<i>attention</i>	$0,801 \pm 0,042$	$0,749 \pm 0,061$	$0,679 \pm 0,058$

0,058), però no supera clarament el model de referència en AUC. Caldrà fer experiments més amplis per saber si el *pooling* jeràrquic aporta avantatge real.

- El nombre de pacients és petit (230) i l'espai de cerca d'hiperparàmetres és molt limitat; no és possible treure conclusions definitives en aquesta fase.

10.2 Treball Futur

Ampliar la cerca d'hiperparàmetres. Fins ara s'han provat 4 combinacions sobre un *grid* molt reduït. En les pròximes fases s'ampliarà la cerca incloent valors de h_{hidden} , K_1/K_2 per a DiffPool, *dropout* i *learning rate*, entre d'altres, per trobar una configuració millor.

Supervisió amb màscares d' anotació. Les màscares de displàsia i infiltració anotades per la Dra. Musulén podrien fer-se servir per guiar els pesos d'atenció del GAT: les regions anotades haurien de rebre més atenció que les zones sanes. Tourniaire et al. [18] mostren que fins i tot amb un nombre limitat d'anotacions parcials es pot millorar la localització i la classificació del model.

Ampliar el dataset. De moment, 140 dels 370 pacients amb diagnòstic vàlid no tenen embeddings UNI2 generats perquè el *pipeline* d'extracció no s'ha executat sobre les seves làmines (per exemple, tot l'H. 12 de Octubre, amb 48 pacients). Generar aquests embeddings pràcticament duplicaria el dataset i hauria de millorar els resultats.

Comparació de connectivitats. En el marc del mateix projecte, un altre estudiant treballa en paral·lel en un model on la matriu d'adjacència es construeix a partir de la **distància entre les característiques** dels *bags*, sense triangulació de Delaunay ni relacions espacials. Comparar els dos models sobre el mateix conjunt de dades permetrà valorar si la topologia espacial aporta avantatge real respecte d'una connectivitat basada en similitud de *features*.

REFERÈNCIES

- [1] Sociedad Española de Oncología Médica (SEOM). *Las Cifras del Cáncer en España 2026*. Consultat el 6 de febrer de 2026. 2026. URL: <https://seom.org/prensa/el-cancer-en-cifras>.
- [2] Unitat Funcional Càncer Colorectal. *Protocol de Pràctica Clínica del Càncer de Còlon i Recte*. Actualització de la 3^a edició. Parc de Salut MAR Barcelona - Hospital del Mar. Barcelona, juny de 2013. URL: https://www.hospitaldelmar.cat/media/upload/arxius/unitats/cancer_colorectal/protocols/practica_clinica.pdf.
- [3] Fernando Martínez de Juan, Samuel Navarro i Isidro Machado. "Refining Risk Criteria May Substantially Reduce Unnecessary Additional Surgeries after Local Resection of T1 Colorectal Cancer". A: *Cancers* 16.13 (2024), pàg. 2321. DOI: 10.3390/cancers16132321.
- [4] Petar Veličković et al. *Graph Attention Networks*. 2018. arXiv: 1710.10903 [stat.ML]. URL: <https://arxiv.org/abs/1710.10903>.
- [5] Maximilian Ilse, Jakub M. Tomczak i Max Welling. *Attention-based Deep Multiple Instance Learning*. 2018. arXiv: 1802.04712 [cs.LG]. URL: <https://arxiv.org/abs/1802.04712>.
- [6] Ming Y. Lu et al. *Data Efficient and Weakly Supervised Computational Pathology on Whole Slide Images*. 2020. arXiv: 2004.09666 [eess.IV]. URL: <https://arxiv.org/abs/2004.09666>.
- [7] Bin Li, Yin Li i Kevin W. Eliceiri. *Dual-stream Multiple Instance Learning Network for Whole Slide Image Classification with Self-supervised Contrastive Learning*. 2021. arXiv: 2011.08939 [cs.CV]. URL: <https://arxiv.org/abs/2011.08939>.
- [8] Holger S. Muti, Christoph Röcken, Hans-Michael Behrens et al. "Deep learning trained on lymph node status predicts outcome from gastric cancer histopathology: a retrospective multicentric study". A: *European Journal of Cancer* 194 (2023), pàg. 113335. DOI: 10.1016/j.ejca.2023.113335.
- [9] Guillaume Jaume et al. *HistoCartography: A Toolkit for Graph Analytics in Digital Pathology*. 2021. arXiv: 2107.10073 [eess.IV]. URL: <https://arxiv.org/abs/2107.10073>.
- [10] Daniele Grattarola et al. "Understanding Pooling in Graph Neural Networks". A: *IEEE Transactions on Neural Networks and Learning Systems* 35.2 (febr. de 2024), pàg. 2708-2718. ISSN: 2162-2388. DOI: 10.1109/tnnls.2022.3190922.
- [11] Rex Ying et al. *Hierarchical Graph Representation Learning with Differentiable Pooling*. 2019. arXiv: 1806.08804 [cs.LG]. URL: <https://arxiv.org/abs/1806.08804>.
- [12] Richard J. Chen et al. "Towards a general-purpose foundation model for computational pathology". A: *Nature Medicine* 30.3 (març de 2024), pàg. 850-862. DOI: 10.1038/s41591-024-02857-3.




Fig. 6: Diagrama de flux del *pipeline* complet. *Blocs grisos*: etapes realitzades pels companys de l'equip i dades de referència. *Blocs blaus*: contribucions d'aquest TFG. La fletxa $\times S$ indica que les S seccions d'un pacient es processen com a grafs independents i les $P(N1)$ s'agreguen via MIL per obtenir el diagnòstic a nivell de pacient, que es compara amb el diagnòstic real de l'Excel.

- [13] Ming Y. Lu et al. "A visual-language foundation model for computational pathology". A: *Nature Medicine* 30.3 (març de 2024), pàg. 863 - 874. DOI: 10 . 1038/s41591-024-02856-4.
- [14] Pau Martí Escolà. "Anàlisi d'espais de representació profunds pel diagnòstic del carcinoma colorectal en histopatologia digital". Treb. fin. de màst. Universitat Autònoma de Barcelona, 2025. URL: <https://ddd.uab.cat/record/317556>.
- [15] Matthias Fey i Jan Eric Lenssen. *Fast Graph Representation Learning with PyTorch Geometric*. 2019. arXiv:1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.
- [16] Junhyun Lee, Inyeop Lee i Jaewoo Kang. *Self-Attention Graph Pooling*. 2019. arXiv: 1904 . 08082 [cs.LG]. URL: <https://arxiv.org/abs/1904.08082>.
- [17] David M. et al. *Implementació de Graph Attention Networks per a la detecció de metàstasi en pT1*. 2026. URL: <https://github.com/IAM-CVC/PT1Diagnosis> (cons. 03-05-2026).
- [18] Paul Tourniaire et al. "MS-CLAM: Mixed supervision for the classification and localization of tumors in Whole Slide Images". A: *Medical Image Analysis* 85 (2023), pàg. 102763. DOI: 10 . 1016/j.media . 2023.102763.