

Predicció de Metàstasis en Histopatologia en Càncer Colorrectal usant Graph Attention Networks

David Morillo Massagué

Resum– Es presenta un sistema de classificació N0/N1 per a la detecció de metàstasi en ganglis limfàtics en càncer colorrectal pT1 a partir de *Whole Slide Images*. El teixit es representa com un **graf espacial** construït per triangulació de Delaunay sobre les coordenades dels *patches*, de manera que es preserva la topologia real del teixit, a diferència d'enfocaments basats en similitud de característiques. Cada node és un *patch* de 2048×2048 px representat per l'embedding CLS (1.536 dim.) del model UNI2. Es comparen dues arquitectures: un GAT de referència amb *readout* pla i un GAT amb **DiffPool jeràrquic** intercalat ($N \rightarrow K_1 \rightarrow K_2$ super-nodes) per obtenir representacions a múltiples escales. El diagnòstic per pacient s'obté per agregació MIL sobre les seccions. El millor model obté un AUC de test de 0,925 amb sensibilitat i especificitat de 0,875 (validació creuada 5-fold; AUC CV = $0,860 \pm 0,061$; 367 pacients).

Paraules clau– Càncer colorrectal pT1, Histopatologia digital, Graph Attention Networks, DiffPool jeràrquic, Graf espacial de Delaunay, MIL, Desbalanceig de classes.

Abstract– We present an N0/N1 classification system for lymph node metastasis prediction in pT1 colorectal cancer from Whole Slide Images. Tissue is represented as a **spatial graph** built by Delaunay triangulation over patch coordinates, preserving the real spatial topology of the tissue, unlike feature-similarity graph approaches. Each node is a 2048×2048 px patch represented by a 1,536-dimensional CLS embedding from the UNI2 model. Two architectures are compared: a **GAT baseline** with flat readout (mean/max) and a **GAT+DiffPool** model with pooling layers interleaved between GAT layers ($N \rightarrow K_1 \rightarrow K_2$ super-nodes) for multi-scale representations. Patient-level diagnosis is obtained via MIL aggregation over histological sections. The best model achieves a test AUC of 0.925 with 0.875 sensitivity/specificity (5-fold cross-validation; CV AUC = 0.860 ± 0.061 ; 367 patients).

Keywords– pT1 colorectal cancer, Digital histopathology, Graph Attention Networks, Hierarchical DiffPool, Spatial Delaunay graph, Multiple Instance Learning, Class imbalance.



1 INTRODUCCIÓ

EL càncer colorrectal (CCR) representa un dels reptes de salut pública més greus del nostre entorn. A Espanya, la SEOM preveu per al 2026 més de **44.132** nous casos anuals, convertint-lo en el tumor més freqüentment diagnosticat i en la segona causa de mort per càncer amb 14.629 defuncions [1].

El carcinoma pT1 és especialment complex: el tumor ha envaït la submucosa però no la muscular pròpia, i el risc de metàstasi als ganglis limfàtics oscil·la entre el **2%** i el **23%** depenent de la profunditat d'invasió [2]. Quan hi ha criteris de mal pronòstic (**invasió submucosa $\geq 1000 \mu\text{m}$, invasió vascular o limfàtica, histologia indiferenciada, tumor budding de grau ≥ 2 o marge vertical positiu** [3, 4]), el risc s'estima al voltant del 10%, la qual cosa obliga les guies clíniques (JSCCR [3], NCCN i ESMO [5]) a recomanar cirurgia radical addicional. Tanmateix, com que la majoria de tumors pT1 no desenvolupa LNM real, s'estima que **més del 80%** d'aquestes cirurgies resulten innecessàries [6, 7].

La histopatologia digital, a través de les *Whole Slide Images* (WSI), obre la porta a tècniques avançades de visió

• E-mail de contacte: David.MorilloMa@autonoma.cat
• Treball tutoritzat per: Debora Gil Resina (DCC)
• Curs 2025/26

per computador. En concret, les *Graph Attention Networks* (GAT) [8] permeten modelar l'arquitectura espacial del teixit de forma relacional. Una decisió clau en la construcció del graf és la definició de les arestes: mentre que alguns treballs les basen en la *similitud de característiques* entre *patches*, aquest projecte opta per la **proximitat espacial** (triangulació de Delaunay sobre coordenades WSI), preservant la topologia real del teixit. Aquest projecte, desenvolupat al grup IAM del CVC (iam.cvc.uab.es) sota la supervisió de la Dra. Debora Gil, compara un GAT de referència amb *readout* pla contra un model amb *pooling* jeràrquic (Diff-Pool) intercalat, i proposa estratègies d'agregació MIL per al diagnòstic a nivell de pacient.

Dues raons complementàries justifiquen la tria d'aquest projecte. Des del punt de vista clínic, els sistemes d'IA demostren una capacitat creixent per identificar patrons morfològics subtils de manera consistent, amb el potencial real de reduir cirurgies innecessàries. Des del punt de vista tècnic, la combinació de xarxes d'atenció sobre grafs i aprenentatge profund sobre imatges histopatològiques d'alta resolució és exactament la intersecció entre la teoria de grafs i les xarxes neuronals profundes que vull explorar dins de l'Enginyeria de Dades.

2 OBJECTIUS

- Construir un *pipeline* complet de classificació N0/N1 sobre WSI reals a partir d'embeddings CLS del model UNI2, basat en **grafs espacials** (triangulació de Delaunay sobre coordenades del teixit).
- Comparar un GAT de referència amb *readout* pla contra un model amb **DiffPool jeràrquic** intercalat entre capes GAT, avaluant si la reducció progressiva del graf aporta millor representació multi-escala.
- Implementar i comparar estratègies d'agregació MIL a nivell de pacient per integrar les prediccions de múltiples seccions histològiques.

3 ESTAT DE L'ART

3.1 Classificació de WSI amb MIL

Les *Whole Slide Images* tenen resolucions de fins a $150\,000 \times 150\,000$ píxels i no es poden processar directament amb xarxes convencionals. L'enfocament habitual és dividir la làmina en *patches* petits i treballar amb *Multiple Instance Learning* (MIL), on el model ha d'inferir l'etiqueta global a partir de fragments sense etiqueta individual. Ilse et al. [9] van proposar l'agregació per atenció (*attention-based MIL*), que aprèn quins *patches* són més rellevants per al diagnòstic. Lu et al. [10] van aplicar aquest mètode a conjunts de dades clínics reals (CLAM), i Li et al. [11] van proposar DSMIL, que combina dues branques, a nivell de *patch* i de làmina, amb aprenentatge contrastiu. La predicció de metàstasi ganglionar a partir d'histopatologia s'ha estudiat en altres càncers: Muti et al. [12] mostren que és possible predir l'estat N0/N1 a partir de làmines de càncer gàstric, amb resultats prometedors.

3.2 Grafs i GNN en Patologia Digital

Les *Graph Neural Networks* permeten tractar el teixit com una estructura on les regions estan connectades segons la seva proximitat, capturant relacions espacials que les CNN no modelen directament. Jaume et al. [13] van presentar HistoCartography, un entorn de treball per a l'anàlisi de grafs en patologia digital, amb resultats que mostren millores respecte de les CNN en classificació de biòpsies. Les GAT [8] afegeixen un mecanisme d'atenció que permet al model ponderar cada veí de manera diferent, cosa especialment útil en histopatologia on no totes les regions del teixit aporten la mateixa informació. Pel que fa al *pooling* en grafs, Grattarola et al. [14] revisen els principals mètodes existents, entre ells DiffPool [15], que agrupa nodes en super-nodes de manera progressiva.

3.3 Models de Fundació per a Histopatologia

En els darrers anys han aparegut *foundation models* preentrenats específicament sobre dades de patologia, que generen embeddings molt més informatius que les CNNs genèriques. UNI2 [16] és un *vision transformer* entrenat sobre més de 100 milions de *patches* de 20 tipus de teixit, amb bons resultats en nombroses tasques de classificació histopatològica. CONCH [17] és un model similar que incorpora a més alineament entre imatge i text. En aquest projecte s'utilitzen els embeddings de UNI2 com a vector de característiques de cada node, ja que estan preentrenats en el mateix domini i capturen informació morfològica rellevant.

3.4 Guies Clíniques i Models Predictius per a pT1 CRC

Les guies clíniques de referència (JSCCR [3], NCCN i ESMO [5]) recomanen cirurgia addicional quan el pacient presenta un o més dels criteris de risc histopatològics esmentats a la Introducció. Malgrat la seva sensibilitat elevada, la seva especificitat és baixa: en un estudi comparatiu sobre 560 pacients [18], les AUC reportades són 0,596 (JSCCR), 0,749 (NCCN) i 0,743 (ESMO), amb especificitats del 19%, 52% i 50% respectivament, la qual cosa implica que més del 80% dels pacients operats no tenien LNM real [18, 6].

Paral·lelament, Piao et al. [19] van proposar un model d'IA sobre variables clinicopatològiques ($n = 783$ entrenament, $n = 105$ test) basat en regressió logística regularitzada (LASSO), obtenint sensibilitat del 100%, especificitat del 85,8%, AUC de 0,960 i *balanced accuracy* del 92,9%; la taxa de pacients classificats com a alt risc es va reduir del 83,8% (JSCCR) al 20,9%. Dawson et al. [4] van proposar l'IBC Score, una puntuació ponderada sobre invasió limfovascular, grau de *tumor budding*, profunditat d'invasió i grau tumoral, que obté AUC de 0,68 sobre 565 pacients. A diferència d'aquests treballs, el present TFG aborda la predicció exclusivament a partir de la **imatge histopatològica** (WSI), sense variables clíniques estructurades ni puntuació manual d'un patòleg.

3.5 Treball Previ al CVC sobre pT1 CRC

Aquest treball s'integra dins una línia de recerca del grup IAM del CVC. Martí et al. [20] van treballar sobre el mateix conjunt de dades pT1 CRC comparant CNNs, ViTs i

GNNs per a la classificació de *patches* individuals, obtenint la millor AUC ($0,954 \pm 0,077$) amb una arquitectura híbrida ViT+NN. Aquell treball, però, opera a nivell de *patch* i no considera la topologia espacial del teixit ni el diagnòstic a nivell de pacient. El present TFG parteix dels embeddings CLS del model UNI2 per construir grafs espacials de les seccions i aborda el problema des d'una perspectiva de MIL a nivell de pacient.

4 DADES I PREPROCESSAMENT

Aquest projecte es realitza en col·laboració amb un equip de la UAB que cobreix des de la recollida de dades fins a la creació d'autoencoders per a l'extracció de característiques.

4.1 Imatges de Gran Format (WSI)

Les dades originals consisteixen en imatges de làmines senceres (WSI) obtingudes amb escàners d'alta resolució i tintades amb hematoxilina-eosina, emmagatzemades en format MIRAX (.mrxs). Les dimensions oscil·len entre els 30.000 i els 150.000 píxels per costat, amb una quantitat significativa d'espai buit o artefactes que requereixen tractament previ.

El conjunt de dades efectiu comprèn **1.607 grafs** (un per secció histològica), provinents de **367 pacients** distribuïts de forma desequilibrada entre les dues classes (Taula 1). D'un total de 606 pacients a la base de dades clínica, 236 es descarten per diagnòstic indeterminat (NX), i dels 370 restants amb diagnòstic vàlid, 3 no disposen d'embeddings UNI2 generats, deixant 367 pacients usables. Les mostres es divideixen en conjunts d'entrenament (70%), validació (15%) i test (15%) estratificats a nivell de pacient.

4.2 Anotacions i Màscares de Segmentació

La Dra. Eva Musulén, patòloga especialitzada, ha realitzat les anotacions manualment amb el programari *Labelme*. Aquestes identifiquen tres categories d'afectació:

- **Infiltració:** teixit anormal que envaeix zones no corresponents.
- **Displàsia:** cèl·lules anormals que poden esdevenir canceroses.
- **Infiltració + Displàsia:** emprat en casos de dubte diagnòstic.

A partir d'aquestes s'obtenen màscares de segmentació codificades per color: vermell (infiltració), blau (displàsia) i verd clar (combinada).

4.3 Extracció de Patches i Embeddings CLS

S'aplica una finestra lliscant (*sliding window*) sense solapament per dividir cada làmina en *patches* de 2048×2048 píxels a resolució completa (nivell 0). El model de fundació UNI2 [16] processa cada *patch* individualment i extreu el token CLS de la seva sortida, obtenint un vector de **1.536 dimensions** que condensa la informació morfològica i textural del patch. No s'aplica cap filtratge de qualitat previ (ni per borrositat ni per proporció de blanc): tots els *patches* d'una secció generen un node del graf.




Fig. 1: Exemple de WSI i la seva corresponent màscara de segmentació.

5 CONSTRUCCIÓ DEL GRAF

5.1 Model de dades: dimensions i estructures

Formalment, cada secció histològica es representa com un graf $\mathcal{G} = (\mathbf{X}, \mathbf{A})$ on:

- $\mathbf{X} \in \mathbb{R}^{N \times 1536}$ és la matriu de característiques dels N nodes (*patches*).
- $\mathbf{A} \in \{0, 1\}^{N \times N}$ és la matriu d'adjacència construïda per triangulació de Delaunay i posterior poda d'arestes llargues.

Dues estratègies de *pooling* transformen la seqüència de grafs en un vector global que alimenta el capçal MLP per produir $P(N1)$:

- **Pla (readout).** *Mean* o *max* aplicats sobre les sortides de la darrera capa GAT, reduint directament de N nodes a d_h dimensions.
- **Jeràrquic (DiffPool intercalat).** Dues capes DiffPool s'insereixen entre les capes GAT: la primera colapsa el graf de N nodes a K_1 super-nodes, i la segona de K_1 a K_2 . Cada nivell aprèn una matriu d'assignació suau i produeix un nou graf de menor grandària sobre el qual opera la capa GAT següent.

Model 1 — Múltiples grafs + agregació MIL. Cada secció genera un graf independent; les S seccions d'un pacient es processen per separat i les probabilitats $\{P(N1_i)\}_{i=1}^S$ s'agreguen a posteriori (Secció 7.1).

Model 2 — Un sol graf per pacient. Com a alternativa, totes les seccions d'un pacient es concatenen en un únic mega-graf bloc-diagonal: les matrius de característiques s'apilen i les d'adjacència s'organitzen a la diagonal (sense arestes entre seccions). El GAT opera llavors sobre totes les seccions simultàniament i un únic *pooling* global produeix el diagnòstic sense etapa MIL separada. Empíricament, aquest enfocament és inferior al Model 1.

5.2 Connectivitat per triangulació de Delaunay

Una connectivitat fixa de reixeta no és adequada perquè la màscara exclou regions de fons i trenca la simetria de la quadrícula. Per aquest motiu, s'aplica una **triangulació de Delaunay** sobre els nodes restants, que s'adapta a distribucions irregulars de forma natural. A continuació, s'eliminen

TAULA 1: COMPOSICIÓ DEL DATASET EFECTIU PER PARTICIÓ (26 HOSPITALS). ELS GRAFS CORRESPONEN A SECCIONS HISTOLÒGIQUES INDIVIDUALS (UN PER SECCIÓ).

Partició	Pacients			Grafs (seccions)		
	N0	N1	Total	N0	N1	Total
Train	184	72	256	897	185	1 082
Val	40	15	55	236	34	270
Test	40	16	56	212	43	255
Total	264	103	367	1 345	262	1 607


les arestes que travessen píxels de valor zero a la màscara, evitant connexions entre regions separades per espai buit. Finalment, s'aplica un criteri de distància màxima: s'eliminen les arestes que superen el doble de la longitud mitjana del conjunt. La figura 2 mostra el resultat del procés: les arestes eliminades pel filtre de màscara apareixen en vermell.

Cal notar que una secció histològica pot contenir múltiples regions de teixit físicament separades (per exemple, diverses illes de teixit sobre el porta). En aquest cas, la triangulació de Delaunay produeix un graf amb múltiples **components connexes**, sense arestes entre illes. El pipeline genera **un graf per secció** (no per component): tot el teixit de la secció s'inclou en un únic objecte `Data`, i el *pooling* global opera sobre tots els nodes conjuntament.

6 ARQUITECTURA DEL MODEL

6.1 GATClassifier

El model implementat, `GATClassifier`, és un classificador de grafs que alterna capes **Graph Attention Network** (GATConv [8, 21]) amb capes de *pooling* jeràrquic per a la classificació binària N0/N1. L'arquitectura proposa intercalar operacions de reducció del graf *entre* les capes de propagació de missatges, de manera que cada estadi treballa sobre una representació progressivament més compacta del teixit:



on $K_1 \ll N$ i $K_2 \ll K_1$ són el nombre de *super-nodes* de cada nivell jeràrquic.

Mecanisme d'atenció. A diferència de les xarxes convolucionals clàssiques sobre grafs que tracten tots els veïns d'un node de forma uniforme, GAT aprèn a assignar pesos

d'importància diferenciats a cada veí. Donada la representació $\mathbf{h}_i \in \mathbb{R}^F$ del node i , per a cada parella de nodes veïns (i, j) es calcula un coeficient d'atenció no normalitzat:

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j])$$

on $\mathbf{W}$ és una transformació lineal aprenible, $\parallel$ la concatenació i $\mathbf{a}$ un vector d'atenció aprenible. Els coeficients es normalitzen amb *softmax* sobre tots els veïns del node i :

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$

i la nova representació del node s'obté com la suma ponderada dels veïns:

$$\mathbf{h}'_i = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{W}\mathbf{h}_j \right)$$

Multi-cap. Per incrementar la capacitat expressiva, cada capa usa H caps d'atenció independents les sortides dels quals es concatenen (a les dues primeres capes) o es promitgen (tercera capa). D'aquesta manera el model pot capturar múltiples tipus de relació de veïnatge simultàniament. Cada capa va seguida de normalització per *batch*, activació ELU i *dropout*.

El capçal MLP (*Linear* $\rightarrow$ ReLU $\rightarrow$ Dropout $\rightarrow$ *Linear*) transforma la representació global del graf en els logits N0/N1.

6.2 Estratègies de Pooling Pla (Readout)

Quan no s'utilitza pooling jeràrquic, les representacions dels nodes de la darrera capa GAT s'agreguen directament amb operacions de *readout*: *mean*, *max* o la seva concatenació (*mean_max*). Tot i la seva eficiència computacional, aquestes estratègies ignoren la topologia del graf i col·lapsen tota la informació espacial en un sol pas.

6.3 Pooling Jeràrquic: DiffPool entre Capes GAT

Per superar les limitacions del *readout* pla, s'implementa **DiffPool** [15] com a operació intermèdia entre les capes de propagació. A diferència d'aplicar el *pooling* únicament al final, la proposta intercala dues capes DiffPool al llarg de la xarxa: una entre la primera i la segona capa GAT, i una altra entre la segona i la tercera. Cada capa DiffPool aprèn una matriu d'assignació suau (*soft assignment*) $\mathbf{S} \in \mathbb{R}^{N \times K}$ que agrupa els N nodes actuals en $K \ll N$ *super-nodes*:

$$\mathbf{X}^{(\ell+1)} = \mathbf{S}^\top \mathbf{X}^{(\ell)}, \quad \mathbf{A}^{(\ell+1)} = \mathbf{S}^\top \mathbf{A}^{(\ell)} \mathbf{S}$$




Fig. 2: Etapes del preprocessament per a la construcció del graf. D'esquerra a dreta: WSI original → extracció de *patches* de 2048×2048 px per finestra lliscant + filtratge → extracció de l'embedding CLS de 1.536 dimensions per UNI2 (un vector per *patch*) → construcció del graf de Delaunay sobre la màscara anotada, on les arestes en vermell han estat eliminades pel filtre de màscara




Fig. 3: Il·lustració del mecanisme d'atenció en una capa GAT amb tres caps independents (verd, blau, lila). El node central $\vec{h}_1$ agrega les representacions dels seus veïns i la seva pròpia (α_{11} , *self-loop*) mitjançant coeficients d'atenció α_{1j} apresos per cada cap. Les sortides dels caps es combinen per concatenació o promig per obtenir la nova representació $\vec{h}'_1$.

Amb aquesta arquitectura, la primera capa GAT opera sobre el graf original de nodes de teixit (N patches), la segona ho fa sobre un graf reduït de K_1 super-nodes que representen regions de teixit de nivell intermedi, i la tercera opera sobre un graf molt compacte de K_2 super-nodes que codifiquen l'organització arquitectònica global de la secció. Finalment, un *readout* global (*mean* o *max*) sobre els K_2 nodes produeix l'embedding que entra al capçal MLP.

L'entrenament incorpora una pèrdua auxiliar (*link prediction* + entropia mínima) per regularitzar l'assignació i evitar degeneracions trivials.

Els algorismes clàssics de particionat de grafs, com el *min-cut* o la clusterització espectral, podrien en principi reduir la mida del graf entre capes de propagació i proporcionar representacions jeràrquiques. El problema fonamental és que aquestes operacions **no són diferenciables**: el mínim tall és un problema combinatori que no admet gradients res-

pecte dels paràmetres de la xarxa, de manera que la partició no pot ajustar-se en funció de la pèrdua de classificació final i no és possible integrar-la en un *pipeline* entrenable per retropropagació. DiffPool resol exactament aquest problema: la matriu d'assignació S s'obté com la sortida d'una GNN auxiliar amb *softmax*, de manera que cada entrada S_{ij} expressa de forma **suau** la probabilitat que el node i pertanyi al super-node j . Com que tots els passos (GNN auxiliar, multiplicació matricial i pèrdua de classificació) són operacions diferenciables, el gradient flueix de cap a cap i el *pooling* s'ajusta conjuntament amb la resta del model.

Com a alternativa, SAGPool [22] selecciona els K nodes més rellevants via puntuacions d'auto-atenció (selecció discreta, no assignació suau); s'ha preferit DiffPool per la seva expressivitat contínua i la pèrdua auxiliar de regularització.

7 METODOLOGIA

7.1 Agregació per Pacient (MIL)

El diagnòstic és per **pacient**, no per làmina. Una mateixa secció histològica pot no presentar senyals visibles de metàstasi si s'analiza aïlladament, mentre que en una altra secció del mateix pacient sí que és apreciable. Si s'entrena a nivell de làmina, les seccions N1 de pacients N1 que no mostren metàstasi visible reben un senyal de supervisió incorrecte (N0), contaminant l'entrenament.

Per evitar aquest problema, s'utilitza el paradigma d'**aprenentatge per múltiples instàncies** (*Multiple Instance Learning*, MIL): cada pacient es tracta com un *bag* i totes les seves làmines comparteixen la mateixa etiqueta. El model aprèn a classificar el pacient a partir de les seves seccions, sense necessitat d'etiquetes individuals per làmina.

Donades les probabilitats $\{p_i = P(N1_i)\}_{i=1}^S$ de les S làmines d'un pacient, s'implementen les estratègies d'agregació següents:

- **Noisy-OR** (per defecte): $P(N1_p) = 1 - \prod_{i=1}^S (1 - p_i)$. Modela la hipòtesi que n'hi ha prou que una làmina




Fig. 4: Comparació visual de les dues arquitectures. **Dalt:** GAT Baseline, on les capes d'atenció operen sobre els N nodes originals al llarg de tota la xarxa i un *readout* global (mean, max) produeix l'embedding final de dimensió $1 \times F_2$. **Baix:** GAT+DiffPool, on cada capa d'atenció va seguida d'un DiffPool que col·lapsa progressivament el graf de N nodes a K_1 macro-nodes i finalment a un únic macro-node, capturant representacions multi-escala del teixit.

presenti metàstasi per classificar el pacient com N1.

- **Max:** $P(N1_p) = \max_i p_i$. Predicció conservadora basada en l'evidència màxima.
- **Mean / LSE:** mitjana aritmètica o *log-sum-exp* per als casos intermedis.
- **Attention MIL:** *PatientAggregator* basat en l'atenció *gated* de Ilse et al. [9]. Aprèn un pes d'atenció per a cada làmina a partir del seu embedding (produït per l'encoder del GAT sense el capçal MLP), i la representació del pacient s'obté com la suma ponderada dels embeddings de les seves làmines.

Formalment, per a l'agregació per atenció, donat l'embedding $\mathbf{h}_i \in \mathbb{R}^d$ de la làmina i produït per l'encoder GAT, els pesos d'atenció i la representació del pacient s'obtenen com:

$$a_i = \frac{\exp(\mathbf{w}^\top (\tanh(\mathbf{V}\mathbf{h}_i) \odot \sigma(\mathbf{U}\mathbf{h}_i)))}{\sum_{j=1}^S \exp(\mathbf{w}^\top (\tanh(\mathbf{V}\mathbf{h}_j) \odot \sigma(\mathbf{U}\mathbf{h}_j)))}$$

$$\mathbf{z}_p = \sum_{i=1}^S a_i \mathbf{h}_i$$

on $\mathbf{w}$, $\mathbf{V}$, $\mathbf{U}$ són paràmetres aprenibles, $\odot$ és la multiplicació element a element i $\mathbf{z}_p$ és l'embedding del pacient que entra al capçal MLP per a la predicció final N0/N1.

7.2 Desbalanceig de Classes

El conjunt de dades presenta un fort desbalanceig: els casos N0 superen àmpliament els N1 (proporció aproximada 80/20). Per combatre-ho s'apliquen tres mesures complementàries.

(1) **Partició estratificada.** La divisió train/val/test es realitza amb estratificació a nivell de pacient, assegurant que la proporció N0/N1 sigui representativa en cada subconjunt (Taula 1). Sense estratificació, amb un conjunt petit i desequilibrat, alguns subconjunts podrien contenir per atzar una proporció de N1 molt diferent a la real, invalidant les mètriques.

(2) **Pesos de classe.** S'apliquen pesos balancejats $w_c = N/(C \cdot n_c)$, on n_c és el nombre de pacients de la classe c , incorporats directament a la funció de pèrdua BCE. Així, cada error sobre un cas N1 té més pes en el gradient que un error sobre N0, penalitzant més els falsos negatius.

(3) **Mostratge ponderat per batch.** Durant l'entrenament s'utilitza un *WeightedRandomSampler* que assigna a cada pacient una probabilitat de mostratge inversament proporcional a la freqüència de la seva classe. Això garanteix que cada *mini-batch* contingui una proporció equilibrada de casos N0 i N1, evitant que el model vegi gairebé exclusivament N0 durant molts *batches* consecutius.

7.3 Grid Search i Validació Creuada

L'avaluació de cada configuració d'hiperparàmetres s'efectua mitjançant **Stratified K-Fold Cross-Validation** ($K =$




Fig. 5: Comparació de les dues arquitectures GATClassifier. **Esquerra:** model de referència amb readout pla (mean || max global); **Dreta:** model jeràrquic on DiffPool redueix progressivament $N \rightarrow K_1 \rightarrow K_2$ super-nodes. Les dimensions del tensor de sortida s'indiquen a la dreta de cada bloc ($h = 128$, $H = 4$, per tant $h \cdot H = 512$).

5) sobre el pool d'entrenament/validació, mantenint el conjunt de test completament aïllat des de la construcció dels grafs. Aquest esquema substitueix el *hold-out* simple emprat inicialment per dues raons:

- **Estabilitat estadística.** Reportar mitjana i desviació típica ($\mu \pm \sigma$) sobre $K = 5$ folds proporciona una mesura més robusta del rendiment esperat. Amb un conjunt relativament petit (367 pacients), un únic *hold-out* és sensible a la composició concreta del split i pot sobreestimar o subestimar la capacitat de generalització del model.
- **Representativitat de classes.** L'estratificació per etiqueta N0/N1 manté la proporció original de classes a cada fold. En histopatologia això és especialment crític: amb una classe minoritària com N1 (28% del dataset), un split aleatori podria infrarepresentar-la i distorsionar les mètriques de sensibilitat, mètrica clínicament més important que l'especificitat.

Per a cada combinació del *grid* s'entrenen $K = 5$ models independents (un per fold). Cada model usa *early stopping* (patience= 20) i reducció adaptativa de la taxa d'aprenentatge en *plateau* sobre la pèrdua de validació del fold corresponent. Les mètriques reportades són $\mu \pm \sigma$ d'AUC-ROC, sensibilitat, F1-macro i *accuracy*. Un cop identificat el millor model per AUC mitjana de validació creuada, s'avalua

sobre el conjunt de test (56 pacients) per obtenir l'estimació final de generalització. Aquest valor s'incorpora al report únicament del millor model, no de totes les configuracions, per preservar la independència del test set.

L'espai de cerca cobreix de manera conjunta els hiperparàmetres del model i de l'optimitzador: arquitectura (GAT Baseline / GAT+DiffPool), tipus de graf (per secció / per pacient), estratègia de *pooling*, agregació MIL, *learning rate*, dimensió oculta h , nombre de caps d'atenció H , taxa de *dropout* i regularització L2 (λ_{wd}). Les configuracions amb h i H elevats poden saturar la memòria GPU; en aquest cas el sistema redueix automàticament la mida del *batch* de pacients i reinventa el fold, garantint que totes les combinacions s'avaluen.

Els grafs es preparen físicament a nivell de pacient en tres particions disjunts (entrenament, validació i test); les dues primeres formen el *pool* sobre el qual s'executa la validació creuada, mentre que la partició de test resta intacta i fora de qualsevol procés d'ajust. Pesos de classe, paràmetres del model i tota selecció d'hiperparàmetres s'ajusten exclusivament sobre el fold d'entrenament per evitar filtracions de dades (*data leakage*).

8 RESULTATS

Les mètriques principals usades en aquest treball són l'**AUC-ROC** (àrea sota la corba receptor-operador, mesura d'ordenació global independent del llindar de decisió) i les **mètriques clíniques**: la **sensibilitat** ($VP/(VP + FN)$, proporció de casos N1 detectats correctament) i l'**especificitat** ($VN/(VN + FP)$, proporció de casos N0 identificats correctament). En un context clínic com la detecció de metàstasi, la sensibilitat és especialment rellevant perquè un fals negatiu (deixar un pacient N1 sense tractar) és més greu que un fals positiu.

La cerca d'hiperparàmetres es realitza mitjançant validació creuada 5-fold sobre el *pool* d'entrenament/validació (vegeu Secció 7.3), explorant conjuntament: arquitectura (GAT Baseline / GAT+DiffPool), tipus de graf (per secció / per pacient), *pooling* (*attention* / *mean_max* / *diff*), agregació MIL (*mean* / *attention* / *noisy-OR*), *learning rate* $\in \{3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}\}$, dimensió oculta $h \in \{128, 256\}$, nombre de caps d'atenció $H \in \{2, 4, 8\}$, *dropout* $\in \{0, 1; 0, 2; 0, 3\}$ i regularització L2 $\lambda_{wd} \in \{0, 10^{-4}, 10^{-3}\}$. En total s'han avaluat **255 configuracions** amb validació creuada 5-fold sobre el *pool* d'entrenament, millorant substancialment els resultats de la primera tanda exploratòria sobre *hold-out* simple (48 configuracions, AUC test màxim 0,917, sensibilitat 0,56). La Taula 2 mostra les 5 millors configuracions per AUC CV mitjana, i el text que segueix justifica la selecció del model final.

Les 5 millors configuracions per CV mostren un AUC molt similar (rang 0,860–0,881), cosa que suggereix que diverses combinacions properes a l'òptim donen un rendiment comparable. Per al *reporting* final s'ha seleccionat el model #5 (GAT Baseline amb *attention pooling*, $H = 2$, $h = 256$, *dropout* 0,1 i $\lambda_{wd} = 10^{-4}$): tot i ser el 5è per CV mitjana, és el que assoleix l'**AUC de test més alt** (0,925) i, especialment, el millor **punt operatiu clínic** (Sens.= 100% amb Espec.= 85%, Secció 10.3). El model #1, més estable en CV ($\sigma = 0,034$), té un AUC de test inferior (0,850) i una especificitat substancialment pitjor al punt Sens.= 100% (47,5% vs 85%), cosa que el fa menys útil per a la comparació amb les guies clíniques.

Respecte a la primera tanda exploratòria sobre *hold-out* simple, la incorporació de la regularització L2 i un *dropout* més suau (0,1 enfront de 0,3), combinats amb un *learning rate* més agressiu ($3 \cdot 10^{-4}$), milloren especialment la sensibilitat del model seleccionat: dels 16 casos N1 del conjunt de test, el model en detecta correctament 14 al llindar 0,5 (només 2 falsos negatius), i la totalitat al llindar 0,388.

8.1 Anàlisi d'influència dels hiperparàmetres

Per identificar quins factors determinen el rendiment, s'han calculat els **efectes principals** sobre l'AUC mitjà de validació creuada (5-fold): per a cada nivell d'un factor s'obté la mitjana de l'AUC CV sobre totes les configuracions que inclouen aquell nivell, independentment dels altres factors. El **rang d'influència** (diferència entre el millor i el pitjor nivell) mesura la rellevància relativa de cada factor. L'anàlisi es restringeix al subgrup de configuracions amb el millor *backbone* (GAT Baseline, *grafs per secció*, agregació MIL *mean*; $n = 248$), de manera que els efectes són directament comparables i no estan barrejats amb pèrdues

conegudes (DiffPool, mega-graf, MIL alternatives).

El factor amb diferència més influent és el **nombre de caps d'atenció** (rang 0,253): $H = 8$ provoca un col·lapse del rendiment a CV AUC $\sim 0,58$ (proper a l'atzar), mentre que $H = 2$ i $H = 4$ donen resultats pràcticament idèntics (0,833 i 0,830). La causa probable és la combinació de més paràmetres a entrenar amb un conjunt d'entrenament limitat (~ 250 pacients): el model amb 8 caps no convergeix amb estabilitat dins les 50 èpoques permeses i les 5 folds.

La **dimensió oculta** (h , rang 0,062) i la **regularització L2** (λ_{wd} , rang 0,052) tenen efectes similars. La interpretació, però, és diferent: $h = 128$ té un rendiment mitjà superior a $h = 256$ principalment perquè les configuracions amb $h = 256$ inclouen també les de $H = 8$ (totes elles fallides); filtrant aquestes, els dos valors són comparables. La regularització L2 amb $\lambda_{wd} = 10^{-3}$, en canvi, produeix una desviació substancialment més baixa ($\sigma = 0,018$ vs 0,127): un nivell de regularització alt estabilitza l'entrenament i evita configuracions problemàtiques.

El tipus de *pooling* (rang 0,033), el *learning rate* (rang 0,016) i el *dropout* (rang 0,007) tenen efectes molt menors quan la resta dels factors s'han escollit correctament. L'*attention pooling* segueix sent lleugerament millor que *mean_max*, i el *learning rate* òptim s'ha desplaçat de 10^{-5} (cerca preliminar amb *hold-out*) a $3 \cdot 10^{-4}$ (validació creuada), reflectint que l'*early stopping* estabilitza l'entrenament a taxes més agressives.

La Taula 4 mostra la matriu de confusió del millor model sobre el conjunt de test (56 pacients), que permet quantificar errors per classe.

8.2 Comparació amb guies clíniques i SOTA

La Taula 5 situa el model en context amb les guies clíniques de referència (Secció 3.4) i el model de IA de referència. Les mètriques de les guies provenen de [18] ($n = 560$); les del model GAT s'han obtingut sobre el conjunt de test d'aquest treball ($n = 56$ pacients, prevalença N1 28,6%, superior a la prevalença clínica real estimada ~ 8 –15% [6]). Sensibilitat i especificitat són independents de la prevalença i constitueixen les mètriques comparatives més robustes; el VPP s'ha d'interpretar amb cautela (vegeu Secció 10.3).

9 IMPLEMENTACIÓ

La implementació segueix un disseny modular: la construcció de grafs, el model, el codi d'entrenament i els *data loaders* estan desacoblats per facilitar l'experimentació independent. La configuració d'hiperparàmetres es gestiona via fitxer YAML, on qualsevol paràmetre pot ser una llista per activar el *grid search* automàtic. El repositori és accessible a [23] i el desplegament al servidor CVC es gestiona via GitHub Actions amb un *runner self-hosted*.

S'ha implementat un *frontend* web per explorar els models entrenats, visualitzar els grafs de Delaunay amb pesos d'atenció per node i consultar corbes ROC/PR i matrius de confusió sobre el conjunt de test.

La figura 6 mostra el diagrama de flux de la implementació completa, d'aquest treball.

TAULA 2: TOP-5 CONFIGURACIONS PER AUC CV MITJANA (COMBINACIÓ DE 255 CONFIGS AVALUADES EN VALIDACIÓ CREUADA 5-FOLD; TEST DE 56 PACIENTS). **NEGRETA**: MODEL SELECCIONAT PER AL *reporting* FINAL, ESCOLLIT PER LA COMBINACIÓ DE RENDIMENT ALT AL TEST (0,925) I UN PUNT OPERATIU CLÍNIC FAVORABLE (SENS.= 100% AMB ESPEC.= 85%, VEGEU SECCIÓ 10.3). TOTS ELS MODELS SÓN *GAT Baseline* AMB AGREGACIÓ MIL *mean*.

#	Pooling	LR	H	hidden	drop	λ_{wd}	AUC CV	AUC test
1	<i>attention</i>	$3 \cdot 10^{-4}$	4	256	0,3	10^{-4}	0,881 $\pm$ 0,034	0,850
2	<i>attention</i>	$3 \cdot 10^{-4}$	2	256	0,1	0	0,865 $\pm$ 0,072	0,884
3	<i>mean_max</i>	$1 \cdot 10^{-4}$	2	128	0,2	0	0,862 $\pm$ 0,038	0,891
4	<i>attention</i>	$3 \cdot 10^{-4}$	4	128	0,3	10^{-3}	0,861 $\pm$ 0,058	0,866
5	<i>attention</i>	$3 \cdot 10^{-4}$	2	256	0,1	10^{-4}	0,860 $\pm$ 0,061	0,925

TAULA 3: EFECTES PRINCIPALS DE CADA HIPERPARÀMETRE SOBRE L'AUC CV MITJANA (248 CONFIGURACIONS, *GAT Baseline* + GRAFS PER SECCIÓ + AGREGACIÓ *mean*). ELS VALORS MOSTREN $\mu \pm \sigma$ DE L'AUC MITJANA DE 5-FOLD DINS DE CADA NIVELL. RANGS D'INFLUÈNCIA ORDENATS PER MAGNITUD DECREIXENT.

Factor	Nivell	n	AUC CV (mitjana $\pm$ std)	Rang
Heads (<i>H</i>)	2	108	0,833 $\pm$ 0,015	0,253
	4	104	0,830 $\pm$ 0,019	
	8	36	0,580 $\pm$ 0,167	
Hidden (<i>h</i>)	128	106	0,830 $\pm$ 0,017	0,062
	256	142	0,768 $\pm$ 0,139	
λ_{wd}	10^{-3}	72	0,831 $\pm$ 0,018	0,052
	10^{-4}	90	0,781 $\pm$ 0,128	
	0	86	0,779 $\pm$ 0,127	
Pooling	<i>attention</i>	124	0,811 $\pm$ 0,035	0,033
	<i>mean_max</i>	124	0,779 $\pm$ 0,150	
<i>Learning rate</i>	$3 \cdot 10^{-4}$	84	0,801 $\pm$ 0,107	0,016
	10^{-4}	80	0,798 $\pm$ 0,108	
	$3 \cdot 10^{-5}$	84	0,785 $\pm$ 0,115	
Dropout	0,1	84	0,799 $\pm$ 0,101	0,007
	0,2	84	0,794 $\pm$ 0,106	
	0,3	80	0,791 $\pm$ 0,124	

TAULA 4: MATRIU DE CONFUSIÓ DEL MILLOR MODEL (*GAT Baseline*, *attention pooling*, AGREGACIÓ *mean*, $LR = 3 \cdot 10^{-4}$, $H = 2$, *dropout* = 0,1, $\lambda_{wd} = 10^{-4}$; CONJUNT DE TEST, 56 PACIENTS). MÈTRIQUES CLÍNiques: SENSIBILITAT = 0,875, ESPECIFICITAT = 0,875, VPP = 0,737, VPN = 0,946.

	Diagnòstic real	
	N0	N1
Predicció	N0	35
	N1	5
		2
		14

10 CONCLUSIONS I TREBALL FUTUR

10.1 Conclusions

En aquest TFG s'ha construït un sistema complet de classificació N0/N1 per a càncer colorrectal pT1 a partir de WSI, que inclou la generació de grafs espacials de Delaunay, l'entrenament del model GAT amb una cerca d'hiperparàmetres avaluada per validació creuada 5-fold i l'avaluació final sobre un conjunt de test fix (56 pacients). El millor model assoleix un AUC de **0,925** (CV: $0,860 \pm 0,061$) amb una sensibilitat i una especificitat de 0,875, detectant correcta-

ment 14 dels 16 casos N1 reals del conjunt de test. Se'n destaquen tres observacions:

- El mètode d'agregació MIL i el tipus de *pooling* del graf són factors amb influència de primer ordre sobre el resultat. La combinació *attention pooling* + agregació *mean* (mitjana de probabilitats per pacient) és consistentment la millor.
- El GAT Baseline supera el GAT+DiffPool, cosa que suggereix que el *pooling* jeràrquic no aporta avantatge real amb el conjunt de dades actual: la dimensió de cada secció (N del centenar de *patches*) probablement és massa petita perquè la reducció a super-nodes preservi informació útil.
- La incorporació de regularització L2 i un *dropout* suau, combinats amb un *learning rate* relativament alt, milloren significativament la sensibilitat respecte de la cerca preliminar (de 0,56 a 0,875), mantenint l'especificitat. Aquest és el guany clínicament més rellevant: cada N1 detectat addicional és un pacient identificat per a tractament correcte.

TAULA 5: COMPARACIÓ DE RENDIMENT ENTRE EL MODEL PROPOSAT, LES GUIES CLÍNiques I L'ESTAT DE L'ART. **GUIES:** TANINO ET AL. [18] ($n=560$, HIROSHIMA). **IBC SCORE:** DAWSON ET AL. [4] ($n=565$, MULTICÈNTRIC). **LASSO:** PIAO ET AL. [19] ($n=105$ TEST, VARIABLES CLINICOPAT.). **GAT:** AQUEST TREBALL ($n=56$ TEST). ESTUDIS I POBLACIONS INDEPENDENTS; EL PPV NO ÉS DIRECTAMENT COMPARABLE (PREVALENÇA N1 DIFERENT ENTRE ESTUDIS). $BAL.ACC. = (S+E)/2$; CALCULADA PER A LES GUIES I L'IBC SCORE A PARTIR DE SENS./ESPEC. REPORTADES.

Sistema	Tipus d'entrada	Sens.	Espec.	AUC	Bal.Acc.
<i>Guies i puntuació clínica</i>					
JSCCR [3]	Guia clínica	100%	19%	0,596	59,5%
NCCN	Guia clínica	98%	52%	0,749	75,0%
ESMO [5]	Guia clínica	98%	50%	0,743	74,0%
IBC Score [4]	Puntuació histopat.	90%	26%	0,68	58,0%
<i>Models d'IA</i>					
LASSO [19]	Var. clinicopatol.	100%	85,8%	0,960	92,9%
GAT (aquest TFG)	Imatge WSI	87,5%	87,5%	0,925	87,5%




Fig. 6: Diagrama de flux del *pipeline* complet. *Blocs grisos*: etapes realitzades pels companys de l'equip i dades de referència. *Blocs blaus*: contribucions d'aquest TFG. La fletxa $\times S$ indica que les S seccions d'un pacient es processen com a grafs independents i les $P(N1)$ s'agreguen via MIL per obtenir el diagnòstic a nivell de pacient, que es compara amb el diagnòstic real de l'Excel.

10.2 Discussió Comparativa

Respecte de les guies clíniques (Taula 5), el model obté una AUC de test de 0,925, per damunt de JSCCR (0,596), NCCN (0,749) i ESMO (0,743) [18]. L'especificitat de 87,5% és substancialment superior a la de les tres guies, cosa que reduiria el sobretractament si el model s'apliqués com a filtre previ a la decisió quirúrgica.

VPP i ajust per prevalença. El VPP de 73,7% s'ha calculat sobre el conjunt de test amb prevalença N1 de 28,6%, molt superior a la prevalença clínica real estimada ($\sim 8-15\%$) [6]. Per la fórmula de Bayes, a una prevalença del 10% el VPP baixa fins al 43,8%:

$$VPP_{10\%} = \frac{0,875 \times 0,10}{0,875 \times 0,10 + 0,125 \times 0,90} \approx 0,438$$

El VPN a la mateixa prevalença s'eleva fins al 98,4%, cosa que suggereix que el model és especialment útil com a **filtre de descartament**: un resultat negatiu (N0) té una probabilitat molt alta de ser correcte i podria evitar la cirurgia amb seguretat. Sensibilitat i especificitat, independents de la pre-

valença, continuen sent les mètriques comparatives més robustes.

Sensibilitat respecte de les guies. La sensibilitat de 87,5% és inferior a la de JSCCR/NCCN/ESMO (98–100%). Cal tenir en compte que les guies assoleixen la sensibilitat màxima a costa d'una especificitat del 19% (JSCCR), classificant com a alt risc fins a quatre pacients N0 per cada N1 detectat. La corba ROC del model GAT (AUC = 0,925) permet operar a sensibilitat del 100% mantenint una especificitat al voltant del 85%, equivalent a la de les guies clíniques en especificitat però amb sensibilitat total. Respecte de JSCCR, aquest punt operatiu suposa una millora de 66 **punts d'especificitat** per al mateix nivell de sensibilitat.

Comparació amb IA SOTA. El model LASSO de Piao et al. [19], entrenat sobre un conjunt $\sim 14\times$ més gran i amb accés a variables clinicopatològiques estructurades, assoleix sensibilitat del 100% amb especificitat del 85,8% i AUC de 0,960. La corba ROC del model GAT indica que, al punt operatiu de sensibilitat del 100%, l'especificitat és

del 85,0%, pràcticament equivalent a la del LASSO, a partir exclusivament de la imatge histopatològica, sense necessitat d'anotacions clinicopatològiques manuals. La petita diferència d'AUC (0,925 vs 0,960) és coherent amb la diferència de grandària del conjunt d'entrenament i de l'accés a variables explícites. Els dos models són metodològicament complementaris: el GAT pot operar sobre la WSI immediatament després de l'escanejat (sense esperar el report patològic complet), aportant una primera estimació basada en morfologia, mentre que el LASSO requereix disposar de variables clinicopatològiques estructurades.

10.3 Limitacions

(1) Mida del test. El conjunt de test de 56 pacients implica intervals de confiança al 95% amplis per a l'AUC; el valor CV AUC $0,860 \pm 0,061$ sobre cinc *folds* és la xifra estadísticament més honesta del rendiment esperat.

(2) Absència de validació externa. El *dataset* prové d'un consorci de 26 hospitals catalans, però no s'ha realitzat cap validació sobre dades d'un centre independent. Campanella et al. [24] observen, en models MIL de patologia computacional entrenats sobre grans consorcis, caigudes de 3–6 punts d'AUC en avaluar sobre escàners externs i de fins a 7 punts en canvis de domini institucional; models amb supervisió completa presenten caigudes superiors al 20%. L'aplicabilitat clínica del model proposat requereix, per tant, validació sobre dades d'hospitals externs al consorci PEARSON.

(3) Desbalanceig de prevalença. La prevalença N1 al test (28,6%) supera la prevalença clínica real (~ 8 –15%) [6]; el VPP s'ha d'interpretar amb cautela en context clínic (vegeu Discussió Comparativa).

(4) Sensibilitat subòptima al lllindar per defecte. Al lllindar 0,5, dos casos N1 (de 16) queden sense detectar; en context clínic, un fals negatiu suposa privar un pacient de cirurgia necessària. La corba ROC (AUC = 0,925) mostra que és possible operar a sensibilitat del 100% a costa d'una especificitat propera al 85%, però el lllindar de decisió hauria de fixar-se sobre un conjunt de validació independent, en col·laboració amb els patòlegs, en funció del cost relatiu entre falsos negatius i falsos positius. Futures versions del model poden integrar tècniques de *cost-sensitive learning* per optimitzar directament aquest *trade-off* durant l'entrenament.

10.4 Treball Futur

Optimització dirigida d'hiperparàmetres. La cerca actual ha cobert els eixos estructurals (arquitectura, *pooling*, MIL, *h*, *H*, *dropout*, λ_{wd} , *learning rate*) amb 255 configuracions de validació creuada 5-fold. Un pas natural seria una cerca bayesiana o quasi-aleatòria centrada al voltant de la regió òptima identificada (*attention* o *mean_max*, $H \in \{2, 4\}$, $\lambda_{wd} = 10^{-3}$, $lr \in [10^{-4}, 3 \cdot 10^{-4}]$), per explorar més finament els valors continus i estimar millor la incertesa del millor punt operatiu.

Supervisió amb màscares d'anotació. Les màscares de displàsia i infiltració anotades per la Dra. Musulén podrien fer-se servir per guiar els pesos d'atenció del GAT: les regions anotades haurien de rebre més atenció que les zones sanes. Tourniaire et al. [25] mostren que fins i tot amb

un nombre limitat d'anotacions parcials es pot millorar la localització i la classificació del model.

Comparació de connectivitats. En el marc del mateix projecte, un altre estudiant treballa en paral·lel en un model on la matriu d'adjacència es construeix a partir de la **distància entre les característiques** dels *patches*, sense triangulació de Delaunay ni relacions espacials. Comparar els dos models sobre el mateix conjunt de dades permetrà valorar si la topologia espacial aporta avantatge real respecte d'una connectivitat basada en similitud de *features*.

REFERÈNCIES

- [1] Sociedad Española de Oncología Médica (SEOM). *Las Cifras del Cáncer en España 2026*. Consultat el 6 de febrer de 2026. URL: <https://seom.org/prensa/el-cancer-en-cifras>.
- [2] Unitat Funcional Càncer Colorectal. *Protocol de Pràctica Clínica del Càncer de Còlon i Recte*. Actualització de la 3^a edició. Parc de Salut MAR Barcelona - Hospital del Mar. Barcelona, juny de 2013. URL: https://www.hospitaldelmar.cat/media/upload/arxius/unitats/cancer_colorectal/protocols/practica_clinica.pdf.
- [3] Yojiro Hashiguchi et al. "Japanese Society for Cancer of the Colon and Rectum (JSCCR) guidelines 2019 for the treatment of colorectal cancer". A: *International Journal of Clinical Oncology* 25.1 (2020), pàg. 1-42. DOI: 10.1007/s10147-019-01485-z. URL: <https://doi.org/10.1007/s10147-019-01485-z>.
- [4] Heather Dawson et al. "Lymph node metastases and recurrence in pT1 colorectal cancer: Prediction with the International Budding Consortium Score — a retrospective, multi-centric study". A: *United European Gastroenterology Journal* 12.3 (2024), pàg. 299-308. DOI: 10.1002/ueg2.12521. URL: <https://doi.org/10.1002/ueg2.12521>.
- [5] Pedro Pimentel-Nunes et al. "Endoscopic submucosal dissection for superficial gastrointestinal lesions: European Society of Gastrointestinal Endoscopy (ESGE) Guideline – Update 2022". A: *Endoscopy* 54.6 (2022), pàg. 591-622. DOI: 10.1055/a-1811-7025. URL: <https://doi.org/10.1055/a-1811-7025>.
- [6] Dario Zaffalon et al. "Dilemmas in the Clinical Management of pT1 Colorectal Cancer". A: *Cancers* 15.13 (2023), pàg. 3511. DOI: 10.3390/cancers15133511. URL: <https://doi.org/10.3390/cancers15133511>.
- [7] Fernando Martínez de Juan, Samuel Navarro i Isidro Machado. "Refining Risk Criteria May Substantially Reduce Unnecessary Additional Surgeries after Local Resection of T1 Colorectal Cancer". A: *Cancers* 16.13 (2024), pàg. 2321. DOI: 10.3390/cancers16132321.

- [8] Petar Veličković et al. *Graph Attention Networks*. 2018. arXiv: 1710.10903 [stat.ML]. URL: <https://arxiv.org/abs/1710.10903>.
- [9] Maximilian Ilse, Jakub M. Tomczak i Max Welling. *Attention-based Deep Multiple Instance Learning*. 2018. arXiv: 1802.04712 [cs.LG]. URL: <https://arxiv.org/abs/1802.04712>.
- [10] Ming Y. Lu et al. *Data Efficient and Weakly Supervised Computational Pathology on Whole Slide Images*. 2020. arXiv: 2004.09666 [eess.IV]. URL: <https://arxiv.org/abs/2004.09666>.
- [11] Bin Li, Yin Li i Kevin W. Eliceiri. *Dual-stream Multiple Instance Learning Network for Whole Slide Image Classification with Self-supervised Contrastive Learning*. 2021. arXiv: 2011.08939 [cs.CV]. URL: <https://arxiv.org/abs/2011.08939>.
- [12] Holger S. Muti, Christoph Röcken, Hans-Michael Behrens et al. "Deep learning trained on lymph node status predicts outcome from gastric cancer histopathology: a retrospective multicentric study". A: *European Journal of Cancer* 194 (2023), pàg. 113335. DOI: 10.1016/j.ejca.2023.113335.
- [13] Guillaume Jaume et al. *HistoCartography: A Toolkit for Graph Analytics in Digital Pathology*. 2021. arXiv: 2107.10073 [eess.IV]. URL: <https://arxiv.org/abs/2107.10073>.
- [14] Daniele Grattarola et al. "Understanding Pooling in Graph Neural Networks". A: *IEEE Transactions on Neural Networks and Learning Systems* 35.2 (febr. de 2024), pàg. 2708-2718. ISSN: 2162-2388. DOI: 10.1109/tnnls.2022.3190922.
- [15] Rex Ying et al. *Hierarchical Graph Representation Learning with Differentiable Pooling*. 2019. arXiv: 1806.08804 [cs.LG]. URL: <https://arxiv.org/abs/1806.08804>.
- [16] Richard J. Chen et al. "Towards a general-purpose foundation model for computational pathology". A: *Nature Medicine* 30.3 (març de 2024), pàg. 850-862. DOI: 10.1038/s41591-024-02857-3.
- [17] Ming Y. Lu et al. "A visual-language foundation model for computational pathology". A: *Nature Medicine* 30.3 (març de 2024), pàg. 863-874. DOI: 10.1038/s41591-024-02856-4.
- [18] Fumiaki Tanino et al. "Comparative prediction of lymph node metastasis in pT1 colorectal cancer among Western and Japanese guidelines". A: *Frontiers in Oncology* 14 (2024), pàg. 1475270. DOI: 10.3389/fonc.2024.1475270. URL: <https://www.frontiersin.org/journals/oncology/articles/10.3389/fonc.2024.1475270>.
- [19] Zhenghu Piao, Ruiquan Ge i Ling Lu. "An artificial intelligence prediction model outperforms conventional guidelines in predicting lymph node metastasis of T1 colorectal cancer". A: *Frontiers in Oncology* 13 (2023), pàg. 1229998. DOI: 10.3389/fonc.2023.1229998. URL: <https://doi.org/10.3389/fonc.2023.1229998>.
- [20] Pau Martí Escolà. "Anàlisi d'espais de representació profunds pel diagnòstic del carcinoma colorectal en histopatologia digital". Treb. fin. de màst. Universitat Autònoma de Barcelona, 2025. URL: <https://ddd.uab.cat/record/317556>.
- [21] Matthias Fey i Jan Eric Lenssen. *Fast Graph Representation Learning with PyTorch Geometric*. 2019. arXiv: 1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.
- [22] Junhyun Lee, Inyeop Lee i Jaewoo Kang. *Self-Attention Graph Pooling*. 2019. arXiv: 1904.08082 [cs.LG]. URL: <https://arxiv.org/abs/1904.08082>.
- [23] David M. et al. *Implementació de Graph Attention Networks per a la detecció de metàstasi en pT1*. 2026. URL: <https://github.com/IAM-CVC/PT1Diagnosis> (cons. 03-05-2026).
- [24] Gabriele Campanella et al. "Clinical-grade computational pathology using weakly supervised deep learning on whole slide images". A: *Nature Medicine* 25.8 (2019), pàg. 1301-1309. DOI: 10.1038/s41591-019-0508-1. URL: <https://doi.org/10.1038/s41591-019-0508-1>.
- [25] Paul Tourniaire et al. "MS-CLAM: Mixed supervision for the classification and localization of tumors in Whole Slide Images". A: *Medical Image Analysis* 85 (2023), pàg. 102763. DOI: 10.1016/j.media.2023.102763.